

Análise de sobrevivência

teoria e aplicações em saúde

Marília Sá Carvalho
Valeska Lima Androzzi
Claudia Torres Codeço
Dayse Pereira Campos
Maria Teresa Serrano Barbosa
Silvia Emiko Shimakura

ANÁLISE DE SOBREVIVÊNCIA

Teoria e aplicações em saúde

FUNDAÇÃO OSWALDO CRUZ

Presidente

Paulo Gadelha

Vice-Presidente de Ensino, Informação e Comunicação

Nísia Trindade Lima

EDITORA FIOCRUZ

Diretora

Nísia Trindade Lima

Editor Executivo

João Carlos Canossa Mendes

Editores Científicos

Gilberto Hochman

Ricardo Ventura Santos

Conselho Editorial

Ana Lucia Teles Rabello

Armando de Oliveira Schubach

Carlos E.A. Coimbra Jr.

Gerson Oliveira Penna

Joseli Lannes Vieira

Ligia Vieira da Silva

Maria Cecília de Souza Minayo

ANÁLISE DE SOBREVIVÊNCIA

Teoria e aplicações em saúde

Marilia Sá Carvalho

Valeska Lima Andreozzi

Claudia Torres Codeço

Dayse Pereira Campos

Maria Tereza Serrano Barbosa

Silvia Emiko Shimakura

2ª edição revista e ampliada



Copyright © 2011 das autoras

Todos os direitos desta edição reservados à FUNDAÇÃO OSWALDO CRUZ/EDITORIA

2ª edição revista e ampliada

(A 1ª edição deste livro foi publicada pela Editora Fiocruz em 2005, sob o título *Análise de sobrevida: teoria e aplicações em saúde.*)

CAPA

Bruno Fiuza e Bruno Correia

REVISÃO E PROJETO GRÁFICO DE MIOLO

Vivian Andreozzi

EDITORACÃO ELETRÔNICA

pelas autoras no **L^AT_EX**, coordenadas por Valeska Andreozzi, utilizando a classe fiocruz.cls, disponível na página eletrônica do livro: <http://sobrevida.fiocruz.br>.

REVISÃO DE PROVAS

Marcionílio Cavalcanti de Paiva

Catálogo na fonte

Instituto de Comunicação e Informação Científica e Tecnológica

Biblioteca de Saúde Pública

C331a Carvalho, Marília Sá

Análise de Sobrevida: teoria e aplicações em saúde. 2. ed. rev. ampl. / Marília Sá Carvalho... [et al.]. – Rio de Janeiro : Editora Fiocruz, 2011.

432 p.: il.; tab.; graf.

ISBN: 978-85-7541-216-9

1. Análise de Sobrevida. 2. Estimativa de Kaplan-Meier. 3. Modelos de Riscos Proporcionais. 4. Análise de Regressão. I. Andreozzi, Valeska Lima. II. Codeço, Cláudia Torres. III. Campos, Dayse Pereira. IV. Barbosa, Maria Tereza Serrano. V. Shimakura, Silvia Emiko. VI. Título.

CDD - 22.ed. – 519.5

2011

Editora Fiocruz

Av. Brasil, 4036 - térreo - sala 112 - Manguinhos

21040-361 - Rio de Janeiro, RJ

Tels.: (21) 3882-9039 | 3882-9041

Fax: +55 (21) 3882-9006

editora@fiocruz.br

www.fiocruz.br/editora

Autoras

Marília Sá Carvalho

Médica pela Universidade Federal do Rio de Janeiro; doutora em Engenharia Biomédica pela Universidade Federal do Rio de Janeiro; com pós-doutorado pela University of Lancaster, Inglaterra; pesquisadora titular no Centro de Métodos Quantitativos da Fiocruz.

Valeska Lima Andreozzi

Matemática pela Universidade do Estado do Rio de Janeiro; doutora em Engenharia Biomédica pela Universidade Federal do Rio de Janeiro; pesquisadora adjunta (licenciada) da Fiocruz; com pós-doutorado pela Faculdade de Ciências da Universidade de Lisboa; investigadora no Centro de Estatística e Aplicações da Universidade de Lisboa.

Cláudia Torres Codeço

Bióloga pela Universidade Federal do Rio de Janeiro; doutora em Quantitative Biology pela University of Texas, Estados Unidos; com pós-doutorado pelo Instituto Gulbenkian de Ciências; pesquisadora adjunta no Centro de Métodos Quantitativos da Fiocruz.

Dayse Pereira Campos

Estatística pela Escola Nacional de Ciências Estatísticas; doutora em Saúde Saúde Pública pela Fiocruz; tecnologista no Instituto de Pesquisa Clínica Evandro Chagas da Fiocruz.

Maria Tereza Serrano Barbosa

Matemática pela Universidade Federal de Pernambuco; doutora em Saúde Coletiva pela Universidade do Estado do Rio de Janeiro; professora adjunta do Centro de Ciências Exatas e Tecnologia da Universidade Federal do Estado do Rio de Janeiro.

Silvia Emiko Shimakura

Estatística pela Universidade Estadual Paulista Júlio de Mesquita Filho; doutora em Estatística pela University of Lancaster, Inglaterra; professora adjunta do Departamento de Estatística da Universidade Federal do Paraná.

Colaboradores

Ângela Jourdan Gadelha

Médica pela Universidade Estadual do Rio de Janeiro; doutora em Saúde Pública pela Universidade de São Paulo; pesquisadora titular (aposentada) da Fiocruz.

Antonio Guilherme Pacheco

Médico pela Universidade Federal do Rio de Janeiro; doutor em Epidemiologia pela University of Pittsburgh, Estados Unidos; pesquisador adjunto do Centro de Métodos Quantitativos da Fiocruz.

Cláudio José Struchiner

Médico pela Universidade Federal do Rio de Janeiro; doutor em Dinâmica Populacional de Doenças Infecciosas pela Universidade de Harvard, Estados Unidos; pesquisador titular do Centro de Métodos Quantitativos da Fiocruz.

Dario Hart Pontes Signorini

Médico pela Universidade Federal do Estado do Rio de Janeiro; doutor em Saúde Pública pela Escola Nacional de Saúde Pública Sergio Arouca; professor adjunto do Centro de Ciências Biológicas e da Saúde da Universidade Federal do Estado do Rio de Janeiro.

Geraldo Marcelo da Cunha

Matemático pela Universidade Federal de Minas Gerais; doutor em Estatística pela Universidade Federal do Rio de Janeiro; pesquisador adjunto da Escola Nacional de Saúde Pública Sergio Arouca da Fiocruz.

Jorge Francisco da Cunha Pinto

Médico pela Universidade Federal do Estado do Rio de Janeiro; mestre em Saúde Pública pela Escola Nacional de Saúde Pública Sergio Arouca; professor adjunto do Centro de Ciências Biológicas e da Saúde da Universidade Federal do Estado do Rio de Janeiro.

Maria Rita Lustosa Byington

Médica pela Faculdade de Medicina e Cirurgia da Universidade do Rio de Janeiro; mestre em Saúde Coletiva pela Universidade do Estado do Rio de Janeiro; médica do Instituto Nacional de Câncer.

Uma pequena homenagem a quem viveu seu tempo com coragem.

*Senhoras e senhores
Trago boas novas
Eu vi a cara da morte
E ela estava viva
Eu vi a cara da morte
E ela estava viva – viva!*

*Porque o tempo, o tempo não pára
Dias sim, dias não
Eu vou sobrevivendo sem um arranhão*

(Cazuza)

Este livro contém exercícios de modelagem de dados de sobrevivência, utilizando o pacote estatístico R.

O R é um software livre, com código fonte aberto. A versão mais recente encontra-se sempre na página da internet

www.r-project.org. Procedimentos para instalação e diversos tutoriais estão disponíveis na internet.



Os exercícios do livro baseiam-se em problemas e pesquisas reais. Os dados podem ser obtidos na página do livro:
sobrevida.fiocruz.br



Sumário

Apresentação à 2ª edição	17
Apresentação à 1ª edição	21
1 Modelos de sobrevivência e a epidemiologia	27
1.1 Introdução	28
1.2 Modelagem estatística	31
1.3 O tempo	33
1.4 O modelo estatístico de sobrevivência	37
1.5 Fontes de incerteza e imprecisão	38
1.6 Desenhos de estudo	40
1.7 Comentários finais	44
2 O tempo na análise de sobrevivência	47
2.1 Introdução	47
2.2 Mecanismos de censura e truncamento	50
2.3 Coortes abertas	57
2.4 Processo de contagem	59
2.5 Organização dos dados	65
Resumo	69
Exercícios	70

3	Funções básicas de sobrevivência	77
3.1	Introdução	77
3.2	Função densidade de probabilidade	78
3.3	Função de sobrevivência	80
3.4	Função de risco (<i>hazard</i>)	83
3.5	Comportamento da função de risco	85
3.6	Função de risco acumulado	88
3.7	Relação entre as funções	91
3.8	Função de verossimilhança	92
	Resumo	94
	Exercícios	95
4	Estimação não paramétrica	99
4.1	Introdução	99
4.2	Estimador produto de Kaplan-Meier	100
4.3	Estimador de Nelson-Aalen	109
4.4	Intervalos de confiança	110
4.5	Tempo de sobrevivência mediano	114
4.6	Kaplan-Meier com estratificação	116
4.7	Teste log-rank	121
4.8	Teste Peto	123
	Resumo	127
	Exercícios	128
5	Modelo paramétrico de sobrevivência	133
5.1	Introdução	133
5.2	Distribuições do tempo de sobrevivência	135
5.3	Estimação	146

5.4	Modelo de regressão paramétrico	148
5.5	Seleção de modelos	161
5.6	Qualidade do ajuste do modelo	162
5.7	Análise de resíduos	166
	Resumo	170
	Exercícios	172
6	Modelo semiparamétrico de sobrevivência	183
6.1	Introdução	183
6.2	Modelo de riscos proporcionais	185
6.3	Modelo de Cox	186
6.4	Modelo de Cox estratificado	192
6.5	Seleção de modelos	195
6.6	Qualidade do ajuste do modelo	198
6.7	Tempos de vida empatados	206
	Resumo	207
	Exercícios	208
7	Análise de resíduos	213
7.1	Introdução	213
7.2	Resíduos de Schoenfeld	215
7.3	Resíduos martingale	225
7.4	Resíduos <i>deviance</i>	230
7.5	Resíduos <i>escore</i>	233
	Resumo	237
	Exercícios	237
8	Covariáveis mudando no tempo	241
8.1	Introdução	241

8.2	Modelo de Cox estendido	242
8.3	Estrutura dos dados mudando no tempo	244
8.4	Diagnóstico do ajuste	251
8.5	Dados prevalentes	260
8.6	Intervalos de tempo descontínuos	265
	Resumo	267
	Exercícios	267
9	Funções de suavização em modelos de sobrevivência	273
9.1	Introdução	274
9.2	Modelo de Cox estendido	275
9.3	<i>Lowess</i>	276
9.4	<i>Spline</i>	279
9.5	Validação cruzada	283
	Resumo	292
	Exercícios	292
10	Eventos múltiplos	295
10.1	Introdução	295
10.2	Classificação de eventos múltiplos	298
10.3	Modelos marginais	302
10.4	Eventos paralelos	305
10.5	Eventos ordenados independentes	312
10.6	Eventos ordenados estruturados	317
10.7	Como escolher o modelo marginal	319
	Resumo	321
	Exercícios	324
11	Eventos competitivos	329

11.1	Introdução	329
11.2	Conceitos básicos	331
11.3	Sobrevivência livre de eventos	338
11.4	Risco específico por causa	341
11.5	Subdistribuições dos riscos	345
11.6	Verificação dos pressupostos do modelo	354
11.7	Desenvolvimentos recentes	356
	Resumo	358
	Exercícios	358
12	Fragilidade	363
12.1	Introdução	363
12.2	Modelo de fragilidade	367
12.3	Inferência	370
12.4	Desdobramentos dos modelos de fragilidade	388
	Resumo	389
	Exercícios	390
	Bibliografia	395
	Apêndice – Descrição dos dados	403
	Aids adesão à Haart – suavização	403
	Aids – clássico	405
	Aids doenças oportunistas – eventos múltiplos	407
	Aids – eventos competitivos	408
	Aids terapia – mudança no tempo	409
	Aleitamento	411
	Diálise – clássico e fragilidade	411
	Diálise – eventos competitivos	413

Diarreia – eventos múltiplos 414

Infarto – suavização e fragilidade (SUS) 416

Reinternação – eventos múltiplos 417

Transplante de medula óssea – clássico e mudança no tempo 419

UTI – suavização 421

Índices 423

Apresentação à 2^a edição

É com muito orgulho que trazemos à luz a segunda edição do livro, que agora se chama *Análise de Sobrevivência: teoria e aplicações em saúde*. A mudança de nome é decorrente da mudança de uma das autoras (Valeska) para além-mar. Como lá só se utiliza o termo “sobrevivência”, adotamos cá também. Afinal, o livro tem sido utilizado também em Portugal.

Não pretendíamos fazer uma segunda edição. Terminar a primeira já tinha demandado um esforço imenso, que pouco conta para os processos de avaliação a que estamos submetidos como pesquisadores brasileiros. Entretanto, um e-mail recebido em março de 2010 resumiu algo que tínhamos escutado várias vezes, e nos impulsionou:

Escrevo para agradecer-lhe pelo seu livro
Análise de Sobrevida: Teoria e Aplicações em Saúde.
Esta semana defendi minha tese de doutorado [...] e seu livro tornou-se minha leitura de cabeceira todas as noites. Ele ajudou-me a esclarecer muitas dúvidas e, sem sombra de dúvidas, foi minha bússola e o meu porto seguro.

Tínhamos planos de escrever outro livro, voltado para modelos de regressão, mas decidimos antes fazer a revisão e segunda edição deste. Afinal, pensávamos, seria relativamente rápido, pois muitos dos erros já estavam registrados graças ao apoio de nossos alunos e leitores. Doce ilusão. Já que vamos mexer mesmo, então porque não melhorar o parágrafo tal que não está assim tão claro, que tal incluir

novos temas que aprendemos recentemente... A síndrome do “já que” tomou conta, nesse caso justificadamente.

Podemos dizer que nesta segunda edição todos os capítulos foram reescritos. Alguns foram pouco modificados. Outros, muito. E, principalmente, novos temas foram acrescentados, desdobrando-se alguns capítulos em dois. As principais mudanças foram:

- Capítulo 1 – Modelos de sobrevivência e a epidemiologia: Cláudio Struchiner traz um debate instigante sobre o que é modelagem;
- Capítulo 2 e 3 – O tempo na análise de sobrevivência e funções básicas de sobrevivência: definições e exemplos substancialmente alterados;
- Capítulo 5 – Modelo paramétrico de sobrevivência: reúne dois capítulos da versão anterior, dedicados à estimação e modelos paramétricos, com modificações substanciais na análise de resíduos;
- Capítulo 6 – Modelo semiparamétrico: inclusão de mais uma medida de ajuste;
- Capítulo 7 – Análise de resíduos: bem melhorado;
- Capítulo 9 – Funções de suavização em modelos de sobrevivência: capítulo novo, com coautoria de Geraldo Marcelo da Cunha, cujo embrião estava na análise de resíduo martingale;
- Capítulo 10 – Eventos múltiplos: um tipo de modelo foi eliminado, pois nunca conseguimos aplicá-lo no contexto dos estudos com os quais trabalhamos;
- Capítulo 11 – Eventos competitivos: capítulo novo, com coautoria de Antonio Guilherme Pacheco, ampliado a partir do Capítulo 10 da versão anterior;
- Capítulo 12 – Fragilidade: alguma matemática retirada e ajuste com fragilidade individual incluído.

O grupo se ampliou: além do Antonio e do Marcelo, a Dayse Pereira Campos se incorporou ao trabalho, com muita vontade e dedicação. Ela passou o pente fino em todo o livro e refez todos os exercícios. Bem-vindos ao grupo! E, repetindo a apresentação anterior: foram dezenas de cursos, no Rio, em Recife, em Lisboa, no Porto; e incontáveis e-mails e acessos ao site do livro. Outros temas que gostaríamos de ter trabalhado, por exemplo, censura intervalar, ficarão para depois, talvez mesmo como um capítulo extra a ser colocado na internet, na página do livro.

Acreditamos que o livro ajudou a disseminar o pacote estatístico R. Continuamos firmes na opção ideológica de acreditar no software livre: liberdade para executar, copiar, distribuir, estudar, modificar e aperfeiçoar. E, principalmente, usar o melhor pacote estatístico que existe. Nesse intervalo, tivemos o prazer de interagir com o Professor John Fox, da Universidade McMaster, no Canadá, que é o responsável pela biblioteca *Rcmdr*, cujo objetivo é desenvolver uma interface amigável, em janelas, para o usuário iniciante do R. A partir desse contato, um *plugin* da biblioteca *survival* foi escrito, e eu tive o prazer de testar, ajudar com exemplos e traduzir as mensagens para o português. Experimentem: *RcmdrPlugin.survival*.

Muitos leitores nos procuram com dúvidas sobre o R. Em geral procuramos responder, mas lembrem-se: o R é uma obra em constante mudança. Assim, coisas que funcionam hoje talvez não funcionem quando o livro for lançado. Não há como saber, exceto experimentando. Aliás, sugerimos frequentes visitas à página que concentra todas as novidades na área da sobrevivência: *CRAN Task View: Survival Analysis* – <http://cran.r-project.org/web/views/Survival.html>.

Esta segunda edição reflete a experiência acumulada ao longo dos cinco anos (e mais dois bebês) que separam as duas edições. Eram 396 páginas com três apêndices. Agora são 434, com uma fonte menor, e somente um apêndice. Dados e exercícios da nova edição, bem como os apêndices sobre o R e organização dos dados que saíram do livro, estão disponíveis em <http://sobrevida.fiocruz.br>. Visitem-nos.

Marília Sá Carvalho

Agradecimentos

À Fiocruz, que viabilizou o projeto por intermédio do Programa de Apoio à Pesquisa Estratégica em Saúde (Papes).

Ao CNPq e à Faperj, pelas bolsas e financiamentos dos autores.

Aos alunos de todos os cursos que muito contribuíram para amadurecermos ideias, textos e exercícios.

Aos nossos orientandos de graduação, mestrado, doutorado e pós-doutorado, pelos vários exemplos e por tudo que nos ensinaram.

Aos nossos vários professores de estatística, epidemiologia e análise de sobrevivência.

Aos parceiros das diversas pesquisas, com os quais aprendemos não só análise de sobrevivência, mas muita coisa da enorme tarefa que é a construção de bancos de dados de boa qualidade.

Aos colegas que leram e criticaram as várias versões do livro.

Aos pareceristas da Editora Fiocruz, pelas preciosas sugestões.

Às instituições e seus pesquisadores que cederam, mais do que seus dados, seus problemas, ideias e perguntas:

- Departamento de Informação e Informática do SUS – Datasus;
- Escola Nacional de Saúde Pública – Fundação Oswaldo Cruz;
- Hospital Geral de Betim;
- Hospital Universitário Clementino Fraga Filho – Universidade Federal do Rio de Janeiro;
- Hospital Universitário Gaffrée e Guinle – Universidade Federal do Estado do Rio de Janeiro;
- Instituto de Pesquisa Clínica Evandro Chagas – Fundação Oswaldo Cruz;
- Instituto de Saúde Coletiva – Universidade Federal da Bahia;
- Instituto Nacional do Câncer.

Apresentação à 1^a edição

Este livro aconteceu por uma convergência de interesses, em um certo momento, dos vários autores, que submeteram um projeto ao Programa de Apoio à Pesquisa Estratégica em Saúde (Papes III) da Fundação Oswaldo Cruz (Fiocruz). Esse projeto tinha como objetivo apoiar o desenvolvimento metodológico em análise de dados longitudinais, através da aplicação, teste e disseminação de métodos estatísticos inovadores no contexto da saúde, particularmente os voltados para a análise de sobrevivência. Nosso principal produto vem finalmente à luz.

Foram quase três anos de trabalho intenso. Nove cursos oferecidos em vários níveis – na pós-graduação em Saúde Pública da Escola Nacional de Saúde Pública Sergio Arouca (Ensp/Fiocruz), na pós-graduação em Medicina Tropical da Universidade Federal de Pernambuco, no VI Congresso Brasileiro de Epidemiologia, no mestrado em Estudos Populacionais e Pesquisas Sociais da Escola Nacional de Ciência Estatística/IBGE – permitiram testar as ideias, exercícios, linguagem. Dezenas de problemas em que o tempo é o objeto de análise foram incorporados ao trabalho, seja nos exemplos, nos exercícios ou mesmo para nosso aprendizado.

Este livro foi de fato escrito por cinco cabeças. Cada uma de nós entrou com sua experiência: Cláudia, excelente professora, montava exemplos, exercícios, redigia claramente textos às vezes limitados a iniciados; Tereza, matemática rigorosa que exigia uma precisão absoluta, foi quem mais deu cursos; Valeska, também matemática, além de ter transposto o livro para o $\text{\LaTeX}$, trouxe sua paixão pelo R no desenvolvimento de novas funções e, como professora de modelos

lineares generalizados e de análise de dados longitudinais na pós-graduação da Ensp, foi fundamental na incorporação das bases da modelagem; Silvia, estatística com doutorado em modelos de sobrevivência, foi nossa guru, entre os nascimentos de dois filhos. Eu tive o privilégio de coordenar o trabalho deste grupo.

Mas nós cinco não trabalhamos sozinhas. Ângela Jourdan Gadelha, que infelizmente precisou se afastar, teve papel fundamental em conduzir o livro para o concreto, para a epidemiologia, para uma linguagem acessível desde o início. Além disso, trouxe a colaboração de duas pesquisadoras do Instituto de Pesquisa Evandro Chagas (Ipec/Fiocruz): Dayse Pereira Campos, com sua experiência na montagem do banco de dados de acompanhamento dos pacientes HIV positivos atendidos nesse hospital e na modelagem da sobrevivência dos pacientes, e Valéria Rolla, infectologista e pesquisadora, também com experiência em modelagem utilizando métodos descritos neste livro. Alguns dos nossos exemplos e exercícios são provenientes do Ipec.

Ao mesmo tempo, dois então alunos do mestrado da Ensp foram fundamentais na crítica das várias versões, na resposta dos exercícios e na padronização da linguagem, quando possível. Dario Hart Signorini é o responsável pela montagem do banco de dados do serviço de imunologia do Hospital Universitário Gaffrée Guinle, que servirá para vários estudos e pesquisas em sobrevivência. Jorge Francisco da Cunha Pinto aceitou o desafio e foi o professor de fato da disciplina Análise de Sobrevivência no ano de 2003.

O primeiro capítulo teve a inestimável contribuição de Cláudio Struchiner, orientador em alguma etapa da vida acadêmica de todas as autoras, exceto a Silvia. O modelo de Cox (Capítulo 7) e a inclusão de variáveis tempo-dependentes (Capítulo 9) contou com a participação da Rita Byington, atual diretora do Hospital do Câncer, com sua experiência na análise deste tipo de evento. Os vários exemplos foram trabalhados ou retrabalhados por nós. Agradecemos a todos que cederam sua experiência e seus dados colaborando nesta construção.

Optamos por utilizar somente o pacote estatístico R. Opção ideológica, por acreditarmos nos princípios que regem o *software* livre: liberdade dos usuários executarem, copiarem, distribuírem, estudarem, modificarem e aperfeiçoarem o *software*. Mas foi, principalmente, uma escolha pelo melhor: no R estão disponíveis as mais recentes técnicas desenvolvidas pelos estatísticos de todo o mundo. Aprender a usá-lo exige um pouco de dedicação. Mas a recompensa é enorme: acesso ao que de mais novo é desenvolvido na modelagem estatística, sem maior esforço ou gasto. O R é o pacote estatístico da ciência, e recupera um dos princípios básicos: a partilha de código, descobertas, formas de fazer, sempre permitindo a crítica e a reprodução do que foi feito. A ciência cresce coletivamente.

Além disso, todos os exemplos e exercícios são baseados em dados reais, tratados de forma a incluir algum ruído, garantindo dessa forma aspectos éticos e evitando problemas de quebra de sigilo. Eventualmente os dados foram um pouco modificados para mostrar ou enfatizar algum aspecto didático. Quais? Segredo. Procuramos sempre que possível preservar a realidade, de forma a acostumar o aluno com os resultados estranhos, os bancos de dados confusos, buscando um amadurecimento no processo da modelagem estatística, tão necessário e importante, não só em análise de sobrevida. Os dados e a solução dos exercícios estarão disponíveis na página da Editora Fiocruz (www.fiocruz.br/editora). Aos poucos pretendemos atualizar exercícios e incluir material de ensino baseado no livro. Visitem-nos.

O objetivo principal deste livro é apresentar para pesquisadores da área da saúde – da clínica à epidemiologia e à avaliação de serviços –, de forma simples e acessível, as várias formas de modelar o tempo de sobrevida. Entretanto, não é um livro simples, introdutório somente. Incluímos alguns desenvolvimentos bastante recentes, tais como os modelos para tratamento de eventos múltiplos e modelos de efeitos aleatórios, acreditando que trabalhar com eventos tempo-dependentes em saúde não pode ser minimamente realizado somente com ferramentas simples. A complexidade da área é tal que precisamos de modelos mais flexíveis, cabendo, a quem se propõe a escrever um livro, buscar formas que facilitem sua compreensão. Mas nunca abrindo mão do conhecimento do método, pois aquilo

que sabemos como investigar condiciona inclusive nossas perguntas. Assim, organizamos o livro buscando sempre integrar conhecimento teórico em estatística e epidemiologia, com muitos exemplos e exercícios totalmente reais.

O livro evolui lentamente no início: Capítulos 2 e 3 apresentam o tempo e as funções básicas de sobrevida. Capítulos 4 e 5, as formas de estimação, não paramétrica e paramétrica respectivamente. No Capítulo 6 apresentamos os modelos paramétricos quando a resposta é o tempo de sobrevida, utilizando a formulação de modelos de regressão. O Capítulo 7 apresenta o Modelo de Riscos Proporcionais de Cox. O artigo em que o modelo foi apresentado (Cox D.R, Regression models and life-tables. *JRSS B*, 34:187-201, 1972) é um dos mais citados na literatura médica até hoje. Uma busca na internet utilizando as palavras “proportional hazards” e “cox” gerou 45.100 páginas. É de fato o modelo mais utilizado em análise de sobrevida, ainda que nem sempre sejam respeitados os pressupostos.

Até esse capítulo, o livro acompanha os cursos mais tradicionais da área. A análise de resíduos apresentada traz novas abordagens (Capítulo 8), com as quais procuramos facilitar e estimular o leitor a realmente testar os pressupostos do modelo, particularmente a proporcionalidade dos riscos. A partir desse capítulo, a velocidade aumenta, com um conjunto de técnicas que estendem o modelo. São as análises de covariáveis mudando no tempo (Capítulo 9) e eventos múltiplos por indivíduo (Capítulo 10), sejam eventos do mesmo tipo, que se sucedem ou se sobrepõem, eventos competitivos, modelos condicionais ou marginais. O importante é que aqui se torna claro por que buscamos incorporar desde os primeiros capítulos a abordagem da sobrevida sob a forma de um processo de contagem. É dessa forma que se pode incluir no contexto da análise de sobrevida a complexidade necessária aos estudos epidemiológicos. O Capítulo 11 traz a inclusão dos efeitos aleatórios, ou modelos multinível, no contexto de modelos de sobrevida também denominados modelos com fragilidade.

Fizemos uma opção por apresentar a bibliografia consultada somente ao final do livro, sem referências ao longo do texto, visando dar maior fluidez à leitura. Todos os conceitos abordados no livro estão, com certeza, nos livros listados ao final, bem como os trabal-

hos que originaram os exemplos e exercícios. Incluímos ainda dois apêndices para facilitar a instalação e uso do R, e para organizar os bancos de dados com estrutura de tempo mais complexa.

Gostaríamos de ter feito ainda mais. Incluir modelos para análise de dados longitudinais, comparando-os com a abordagem de sobrevida. Apresentar a inferência Bayesiana, além dos métodos de verossimilhança – clássica, parcial, restrita – utilizados no livro. Mas isso fica para os próximos trabalhos. Este livro já é suficientemente ousado para nossa clientela de eleição: pesquisadores da área da saúde, com curiosidade e interesse além do clique-mouse dos pacotes prontos e rotinas limitantes.

Leiam, instalem o R, baixem os dados, façam os exercícios! Temos certeza que será proveitoso.

Marília Sá Carvalho

1

Modelos de sobrevivência e a epidemiologia

Coautor: *Cláudio Struchiner*

O objetivo deste capítulo é capacitar o leitor para:

Relacionar o modelo explicativo da epidemiologia e os modelos de análise de sobrevivência.

Identificar os cuidados necessários à construção de modelos adequados.

Reconhecer os modelos de análise de sobrevivência e sua aplicabilidade nos estudos na área da saúde.

Relacionar os desenhos de estudo epidemiológico com as diversas abordagens no campo dos modelos de sobrevivência.

1.1 Introdução

Para entendermos melhor os objetivos, as condições de utilização dos modelos de sobrevivência e os componentes que entram na sua concepção é importante situar esses modelos em um contexto mais amplo. Na Tabela 1.1, adaptada do livro de Ben Bolker (2008), procuramos listar, por contraste, as várias dimensões utilizadas para a classificação dos mais diversos tipos de modelos usados na pesquisa biomédica. Modelos de sobrevivência podem ser definidos como uma classe de modelos quantitativos estocásticos utilizados para analisar características e fatores associados ao tempo até a ocorrência do desfecho de interesse.

Na Tabela 1.1 são apresentadas diversas dimensões para caracterização de um modelo científico. Sem pretender discutir exaustivamente as ideias listadas, vamos nos deter nos conceitos associados à dicotomia **mecanístico** *versus* **fenomenológico**, essenciais para a compreensão dos modelos em epidemiologia. Modelos mecanísticos traduzem os processos causais subjacentes que têm papel determinante no desfecho em estudo e constituem um dos focos principais de um estudo epidemiológico. Esta rede de causalidade tem, forçosamente, caráter teórico e é construída anteriormente à observação empírica. Modelos fenomenológicos, por outro lado, procuram identificar padrões observáveis empiricamente e que serão objeto de exercícios analíticos futuros. Os primeiros procuram capturar os **processos** subjacentes que irão determinar o surgimento de **padrões** de ocorrência das observações empíricas no espaço e no tempo. A recíproca não é verdadeira, ou seja, modelos fenomenológicos capturam o padrão, mas não trazem novas percepções quanto aos processos causais. Os primeiros são usualmente descritos no campo da epidemiologia como modelos **explicativos**, em contraste com os modelos **preditivos**. Essas diferentes abordagens implicarão em construções distintas, desde o processo de seleção das variáveis independentes até a escolha das formas funcionais que as ligam ao desfecho.

Os aspectos técnicos e a estrutura dos modelos de sobrevivência são o objeto deste livro. Entretanto, ainda neste capítulo, abordaremos algumas questões relacionados ao componente

Tabela 1.1: Caracterização de modelos por meio de dicotomias

Estratégia	
mecanístico	fenomenológico
padrão	processo
explicativo	preditivo
teórica	aplicada
qualitativo	quantitativo
Definições de estrutura	
determinístico	estocástico
analítico	computacional
dinâmico	estático
contínuo	discreto
populacional	individual
paramétrico	não(semi) paramétrico
linear	não linear
Elaboração	
simples	complexo
específico	geral
aproximado	preciso
caricato	realístico
Inferência estatística	
frequentista	bayesiano

probabilístico que caracteriza a classe de modelos **estocásticos**. Este componente é decorrente de diferentes fontes de incertezas, que têm sua origem em mecanismos distintos tais como: o erro amostral; o erro de mensuração das variáveis imposto pela observação imperfeita da realidade; a estocasticidade demográfica, imposta pela variabilidade inata observada em diferentes realizações de um evento entre unidades idênticas; e a estocasticidade ambiental, que tem sua origem em fontes externas não previsíveis. A distinção entre as diferentes fontes de incerteza pode ser feita de forma explícita na estrutura de um modelo probabilístico. Os modelos **determinísticos** não permitem a representação de fontes de incerteza e suas predições podem ser entendidas como uma descrição do comportamento médio do processo observado.

As vantagens e desvantagens dos diferentes tipos de modelos têm sido objeto de ampla discussão na literatura no campo da filosofia da ciência aplicada a problemas biomédicos. Listamos ao final do livro alguns texto essenciais nesse debate (Levins, 1966; Orzack & Sober, 1993; Levins, 1993). Escolher uma abordagem específica de modelagem decorre de interpretações subjetivas individuais e nem sempre podem ser arbitradas de forma independente. Por exemplo, modelos que preservam as qualidades sempre desejáveis de generalidade, realismo e precisão são difíceis de serem formulados (e mensurados) na prática. Esta dificuldade nos obriga a abrir mão de algumas dessas dimensões em função daquelas consideradas mais relevantes em um dado momento. Por exemplo, modelos gerais comumente incorrem em imprecisão ao omitirem covariáveis que respondem por pequenos efeitos ou ainda covaráveis com efeitos intensos mas restritos a pequenos subgrupos populacionais.

Modelos matemáticos, incluindo os estatísticos, não devem ser considerados como substitutos de hipóteses nem de teorias. Modelos são simultaneamente verdadeiros e falsos. Falsos porque sempre deixam de fora algum aspecto do problema. Verdadeiros porque, por outro lado, é possível restringir o universo analisado a situações bem específicas ou particulares, onde uma determinada relação plausível representada por um modelo seja verdade. Não raro, diferentes modelos (nenhum deles perfeito) são formulados para um mesmo problema,

de tal forma que a “verdade” que sintetiza as diferentes abordagens é uma interseção de inverdades e verdades parciais ou aproximadas.

Nosso foco neste livro são modelos **estocásticos**, aplicados a um problema particular – tempo até um desfecho de saúde – estimados de forma **frequentista**. Como toda escolha, deixamos de fora muita coisa interessante e útil. Mas acreditamos que nossa escolha seja igualmente interessante e, principalmente, útil.

1.2 Modelagem estatística

Um dos mais importantes instrumentos analíticos em estudos epidemiológicos é a modelagem estatística. No modelo estatístico, as estruturas de causalidade, que são concebidas através do raciocínio epidemiológico e motivadas pelas evidências empíricas disponíveis no momento, são representadas pelos efeitos principais e pelos parâmetros de interação, associados a cada covariável escolhida para compor o modelo. As fontes de incerteza são representadas pela estrutura de erro do modelo estatístico.

Uma das grandes vantagens da utilização de modelos estatísticos para a descrição e representação do conhecimento científico em geral, e, em particular, do conhecimento epidemiológico, está na possibilidade de afirmações probabilísticas. No contexto de construção de intervalos de confiança, essa fonte de variabilidade é geralmente interpretada como o grau de incerteza associado a previsões produzidas pelo modelo. No contexto de testes de hipóteses, a variabilidade está relacionada à estimativa do erro de rejeição da hipótese nula.

Na literatura epidemiológica, dois mecanismos de geração de incertezas foram propostos para justificar o uso de modelos probabilísticos. O primeiro mecanismo pressupõe a existência de uma população de tamanho infinito cujos parâmetros populacionais se deseja conhecer e da qual dispomos de uma amostra, objeto do nosso estudo. Eventuais discrepâncias entre os valores desses parâmetros na população e as estimativas proporcionadas pelos dados de nossa amostra são causados por variações amostrais. Sob esse mecanismo, características associadas a cada indivíduo são fixas, podendo variar entre

os indivíduos que formam a população-alvo, dando origem a uma distribuição populacional desconhecida, cujos parâmetros se deseja estimar.

O segundo mecanismo pressupõe que a mensuração das características individuais obedece a uma lei estocástica comum a todos os indivíduos. Sob esse mecanismo, valores de uma mesma característica, mensurados repetidas vezes para um mesmo indivíduo, exibem uma distribuição a ser determinada, não sendo, portanto, assumidos como fixos, como no mecanismo anterior. Mais comumente, apenas um conjunto de observações por indivíduo encontra-se disponível para estudo, o que impede a descrição dessa distribuição individual. Entretanto, pressupostos adicionais de que os indivíduos são homogêneos e independentes entre si vão permitir o exercício de inferência.

Os dois mecanismos descritos acima permitem generalizações. Assim, a população infinita que serve de fonte para a amostra em estudo pode ser formada de misturas de populações com diferentes distribuições. De forma análoga, as leis estocásticas que regem a distribuição de mensurações realizadas em um único indivíduo não precisam ser necessariamente iguais, implicando numa amostra com indivíduos heterogêneos entre si. Estas ideias darão origem aos modelos conhecidos como de efeitos aleatórios ou de fragilidade, que serão explorados no Capítulo 12.

Um dos mais conhecidos e bem-sucedidos frutos da aplicação do raciocínio estatístico na epidemiologia é a utilização de modelos de regressão logística na análise de dados provenientes de estudos de coorte, caso-controle ou seccionais. Sob essa representação, os **conceitos epidemiológicos** são traduzidos por **termos do modelo**, ou seja, o efeito de cada **variável de interesse** é quantificado por uma **razão de chances** (*odds ratio* – OR), obtida pela exponenciação do parâmetro estimado pelo modelo. Neste capítulo frequentemente utilizaremos esse modelo para comparações com os modelos de sobrevivência, partindo do que supomos ser de conhecimento prévio do leitor.

No modelo logístico, o efeito de um fator de exposição sobre o risco de ocorrência de um desfecho é estimado como uma probabili-

dade condicional de experiência do desfecho, conhecidas as condições de exposição ($Pr(D|E)$). Outras medidas de risco, entretanto, podem ser mais interessantes, por exemplo, a noção de taxa de incidência – $\lambda(t)$ –, também denominada força de morbididade ou risco instantâneo. Esta grandeza epidemiológica, que é uma das variáveis resposta do modelo de sobrevivência, permite o cálculo do risco entre expostos e não expostos, como a razão entre suas taxas, **a cada momento do tempo**.

Quando o risco é constante ao longo do tempo, as duas formas de estimar o efeito do fator de exposição são equivalentes. Entretanto, a estimação da taxa de incidência permite discriminar situações de mesmo risco médio, caso este varie no tempo, sendo portanto mais informativa do que a razão de chances. Por exemplo, o registro de 150 casos incidentes de gripe numa população de 1.000.000 habitantes num período de um ano, por si só, não permite a identificação de qualquer padrão temporal. Quer os casos tenham ocorrido uniformemente no tempo ou de acordo com algum padrão sazonal, a estimativa de risco seria uma só, $150/1.000.000$. As duas situações poderiam ser facilmente distinguíveis se, ao invés, tivéssemos acesso à estimativa da taxa de incidência.

1.3 O tempo

A análise de sobrevivência, eventualmente chamada de análise de sobrevida, será utilizada quando o tempo for o objeto de interesse, seja esse interpretado como **o tempo até a ocorrência de um evento** ou o **risco de ocorrência de um evento por unidade de tempo**. As perguntas passíveis de resposta nesse tipo de abordagem são:

- Qual o efeito de um dado anticancerígeno sobre o tempo de sobrevivência?
- Quais os fatores associados ao tempo de duração da amamentação?

- Quais os fatores preditivos para reinternação hospitalar, considerando o tempo entre internações?
- Qual o efeito da unidade assistencial na sobrevivência após um infarto agudo do miocárdio?

Três dimensões de tempo distintas surgem com frequência num contexto epidemiológico. A primeira dimensão de tempo é a que se cristaliza na idade do indivíduo. Predições realizadas em bases individuais sobre a evolução da grande maioria das condições de morbidade geralmente têm na idade uma variável importante para o risco de ocorrência do desfecho. Um exemplo seria a mortalidade, fenômeno biológico claramente dependente da idade. Cabe lembrar que a idade também indica a coorte de nascimento, e todo um conjunto de condições de vida comuns que pode ter efeito importante no desfecho.

A segunda dimensão contabiliza a duração em uma determinada condição. Esta é a dimensão natural a ser utilizada em ensaios clínicos. São bons exemplos: o tempo desde um evento cirúrgico até a recidiva, em um estudo clínico em pacientes com melanoma maligno; a duração do tempo desde o diagnóstico de Aids até o óbito em pacientes tratados com terapia antirretroviral; o tempo de observação entre a entrada e a saída dos pacientes, seja por cura ou pelo final do estudo, em um ensaio clínico aleatorizado.

A terceira dimensão seria o tempo calendário propriamente dito. O acesso à descrição da taxa de incidência como uma função do tempo calendário permite o estudo da evolução temporal de padrões de morbidade e a descrição de seus determinantes, fornecendo as bases empíricas das ações em saúde pública. Além disso, o tempo calendário relaciona-se ao denominado efeito de período. Por exemplo, na estimativa do efeito protetor da vitamina A sobre a incidência de diarreias em um ensaio clínico comunitário, a ocorrência de um surto de diarreias, típico efeito de período, pode ser fator de confusão na análise. Na Figura 1.1 observa-se o efeito protetor da idade das crianças sobre a ocorrência de diarreia. Entretanto, na ocorrência de um surto, o risco, medido como taxa de incidência mensal, volta a aumentar. No gráfico seguinte, o mesmo dado é apresentado considerando cada coorte de nascimento. Nesse caso, o efeito do surto afeta

o efeito protetor da idade: dependendo da época do ano (tempo calendário), a incidência de diarreia em crianças da mesma idade pode variar substancialmente.




Figura 1.1: Interação entre idade, coorte e período em estudo de diarreias infantis

O foco de interesse da discussão epidemiológica situa-se, em geral, em combinações dessas três dimensões. A Figura 1.2 representa essas três dimensões utilizando-se um diagrama de Lexis. Esse diagrama é formado a partir da representação do tempo calendário e da idade de cada indivíduo, respectivamente nos eixos horizontais e verticais de um gráfico cartesiano, dando origem a linhas individuais de evolução em ângulos de 45 graus.

O gráfico indica também decomposições adicionais:

- momento e idade do início da observação, que também pode ser a ocorrência de um evento que marca o início da contagem do tempo, por exemplo, aleatorização;
- momento e idade da ocorrência de um evento;
- período não observado dentro do período de acompanhamento e mesmo antes;

- eventos não observados, antes do período de acompanhamento;
- eventos não observados após o fim do período de acompanhamento (censura).




Figura 1.2: Diagrama de Lexis: idade, tempo, coorte

A decomposição do tempo em coorte, idade e período é essencial para a correta implementação e interpretação dos modelos de sobrevivência. Nesses, a dimensão **duração** é a mais tradicionalmente utilizada para estimar o risco associado a fatores em estudo. Entretanto, é cada vez mais frequente a utilização do tempo calendário, possibilitando o controle do efeito período e de outros fatores relacionados ao desenho do estudo, tais como a modelagem de dados prevalentes ou incidentes, tempo real de prospecção, entrada no estudo em múltiplos tempos, entre outros. Neste livro, dedicaremos parte substancial aos modelos que utilizam o tempo calendário, pela maior flexibilidade no tratamento dos diferentes desenhos. No Capítulo 2 serão introduzidos os fundamentos conceituais que permitem esse tipo de abordagem.

1.4 O modelo estatístico de sobrevivência

O exercício de construção do modelo causal consiste em descrever a força de incidência como função de variáveis explicativas no qual se procura conhecer o efeito de cada uma delas e suas interações, livres da presença de confusão. Os mecanismos envolvidos são análogos ao de uma análise que utiliza a regressão logística, com a qual o leitor já deve estar familiarizado, porém agora o foco de interesse é a incidência, e não mais o risco.

O modelo de sobrevivência, como qualquer modelo de regressão, é composto dos seguintes elementos: uma variável resposta, co-variáveis explicativas, a função de ligação e a estrutura de erro.

A variável resposta nos modelos de sobrevivência pode ser expressa de três formas interconvertíveis: probabilidade de sobrevivência, taxa de incidência e taxa de incidência acumulada. A probabilidade de sobrevivência é definida como a probabilidade de não ocorrer o evento de interesse dentro do intervalo de tempo $[t_0, t]$. Em outras palavras, a probabilidade de sobrevivência é a probabilidade de “sobreviver” por mais que t unidades de tempo. Por definição, essa probabilidade é 1, no início da observação (em t_0). Em um estudo de coorte, costuma-se utilizar uma transformação em escala tal que a probabilidade de sobrevivência seja interpretada como a frequência de sobreviventes no tempo t , de uma coorte de tamanho N , ao invés de uma probabilidade.

A taxa de incidência (ou de *hazard*) é definida como a taxa instantânea de ocorrência do evento de interesse no tempo t condicionada à sua não ocorrência anterior a t , correspondendo à definição usual de incidência encontrada em livros-texto de epidemiologia.

A incidência acumulada (*cumulative incidence*) também é frequentemente encontrada em textos epidemiológicos. É importante observar que a incidência acumulada difere do conceito de risco, embora sejam aproximadamente iguais numericamente, quando a incidência é baixa. Entretanto, diferentes funções de incidência podem levar ao mesmo risco, e por isso a análise de sobrevivência é mais informativa que a análise de risco extraída de modelos como a regres-

são logística. Havendo escolha, ou seja, sendo possível incorporar a informação do tempo na análise, a preferência deve recair sobre os modelos de sobrevivência. Essas três funções são apresentadas com mais detalhes no Capítulo 3.

Os modelos de análise de dados de sobrevivência podem ser estimados de forma não paramétrica (Capítulo 4), paramétrica (Capítulo 5) ou semiparamétrica (Capítulo 6).

1.5 Fontes de incerteza e imprecisão

O objetivo de uma análise que incorpora a incerteza é determinar qual é a incerteza na resposta que resulta da incerteza associada aos elementos que compõem o modelo utilizado. As fontes de incerteza resultam da aplicação da **lei estocástica** que se supõe reger o fenômeno de interesse, e dos **erros amostrais** a que estamos sujeitos pelo processo de estimação dos parâmetros envolvidos.

No caso da regressão logística, a lei estocástica a que nos referimos é a binomial, na qual a probabilidade de ocorrência do fenômeno de interesse para um indivíduo é uma função do valor das covariáveis que se relacionam ao desfecho através de parâmetros que quantificam essa relação. Ao substituírmos os valores desses parâmetros por seus estimadores, obtidos com os dados da amostra, estamos nos debruçando com uma primeira fonte de incerteza, o **erro amostral**. Entretanto, mesmo se tivéssemos acesso a todos os indivíduos da população-alvo, e dessa forma conhecêssemos todos os parâmetros sem a interferência do erro amostral, ainda assim estaríamos incertos sobre a ocorrência ou não do fenômeno de interesse no indivíduo, dado os valores observados. Tudo que é possível saber é a **probabilidade** de ocorrência desse desfecho, que pode ou não ocorrer.

A imensa maioria dos procedimentos que tentam representar a incerteza, quer através de testes de hipóteses, quer através da construção de intervalos de confiança, restringe-se a essas duas fontes de incerteza: o erro amostral e o processo estocástico. Entretanto, o que dizer sobre a escolha da função de ligação, a forma funcional em si

(linear, logística, exponencial etc.), assim como sobre a escolha do conjunto de variáveis identificadas como alvo da análise?

Essas últimas fontes adicionais de incerteza são dificilmente mensuráveis e geralmente não são levadas em consideração na construção de intervalos de confiança e realização de testes de hipótese. Para diferenciá-las das fontes de incerteza mais frequentemente descritas, as denominaremos de **fontes de imprecisão**.

Resumindo, podemos nos defrontar com a situação em que o modelo estatístico encontra-se corretamente especificado, mas mesmo assim estamos incertos quanto à realização de um experimento regido por tal modelo probabilístico. Ou podemos nos defrontar com a situação em que o modelo encontra-se especificado de forma imprecisa e essa especificação incorreta descreve, por sua vez, uma lei estocástica que traz implicitamente incertezas associadas a afirmações de natureza probabilística. Dificilmente conseguiremos distinguir entre as duas situações com base apenas nas observações amostrais. A contabilização parcial das fontes de incerteza e imprecisão leva à estimativas otimistas da capacidade preditiva do modelo utilizado. Ou seja, as predições feitas com base nos modelos são, em geral, muito melhores que a realidade.

Entre as fontes mais comuns de imprecisão na especificação de modelos estatísticos estão a utilização de pressupostos de linearidade nas covariáveis, funções de ligação incompatíveis com o fenômeno biológico em estudo, e a especificação de leis estocásticas (estrutura de erro) que não traduzem com correção a estrutura de dependência entre indivíduos ou de medidas repetidas de um mesmo indivíduo.

Um pressuposto adicional utilizado na análise epidemiológica de dados é o de que covariáveis explicativas seriam fixas por desenho. Isto é, essas variáveis não estariam sujeitas a erros sistemáticos ou aleatórios de observação. O relaxamento desse pressuposto pode ser obtido com a utilização de modelos que permitem a especificação de erros de mensuração para essas variáveis explicativas. A incorporação das outras fontes de imprecisão acarreta uma diminuição da capacidade preditiva do modelo ajustado, ou seja, modelos menos otimistas e mais compatíveis com as condições reais de predições futuras.

Na análise de sobrevivência, todas essas fontes de incerteza e de imprecisão precisam ser consideradas. Assim, ao especificar um modelo paramétrico (Capítulo 5), as características particulares das várias distribuições para a descrição do tempo até a ocorrência do fenômeno de interesse devem ser adequadas ao fenômeno em estudo. No modelo semiparamétrico de Cox (Capítulo 6), a distribuição estatística associada ao tempo não é importante, mas a proporcionalidade do risco ao longo do tempo é pressuposto básico (Capítulo 7). Além disso, a escolha da escala de tempo deve ser adequada ao fenômeno. Observações com tempos muito longos em relação à maioria das observações podem introduzir distorções na modelagem.

1.6 Desenhos de estudo

O paradigma de desenho de estudo que gera esse tipo de informação é o estudo de coorte, observacional ou de intervenção (ensaios clínicos), uma vez que esse desenho pressupõe o acompanhamento dos indivíduos de uma coorte ao longo do tempo e, conseqüentemente, o acesso à variável resposta de excelência – o tempo até o desfecho (categórico). Ou seja, se for do interesse estudar o efeito de um medicamento sobre o tempo para a redução de peso, os modelos de sobrevivência somente poderão ser utilizados se o desfecho for, por exemplo, atingir determinado patamar do índice de massa corporal. Os modelos para análise de medidas repetidas, ainda que apresentem alguns pontos de interseção com os modelos de sobrevivência, têm outra lógica. Nesses, a resposta não é o tempo até a ocorrência de um desfecho, mas a medida deste – contínuo ou categórico –, dado o tempo entre as observações de um mesmo indivíduo.

1.6.1 Coortes observacionais

Os diferentes tipos de coortes, e particularmente a forma como o tempo se faz presente no estudo, devem ser criteriosamente analisados. Vejamos um exemplo com razoável complexidade, buscando identificar aspectos do desenho que afetam a forma de modelar. Imaginemos um estudo sobre os fatores de risco associados ao tempo de

sobrevivência após uma crise hipertensiva grave, clinicamente bem definida.

Uma coorte fechada partiria de todos os indivíduos que apresentaram um episódio de hipertensão em um período determinado e os acompanharia por um tempo considerado relevante. Nesse caso, o **tempo relevante** pode ser relativamente longo, digamos dez anos. Um primeiro problema já está presente: o envelhecimento da coorte. Este pode ser tratado de várias formas: no desenho do estudo, na forma de entrar o dado **idade** e na forma de modelar o tempo. No desenho do estudo, uma coorte aberta, que equilibre entradas e saídas, resolve o problema do envelhecimento. Mas cria-se um novo problema: considerando que o acompanhamento levará dez anos, nesse intervalo, diversas mudanças podem ocorrer na população estudada, inclusive nos fatores incluídos no estudo, entre os quais podem estar os medicamentos. E mesmo a idade individual deve ser considerada uma variável que muda no tempo, pois ainda que a idade média da população seja mantida, cada indivíduo acompanhado envelhece, e o efeito da idade pode ser subestimado se for incluída somente a idade no início do estudo. Ou seja, de alguma forma é necessário incorporar a mudança de situação ao longo do tempo (Capítulo 8).

Suponhamos que esses dois problemas – envelhecimento da coorte e mudança de covariáveis no tempo – estejam resolvidos. Outro aspecto a se considerar é a definição do início do acompanhamento. Pode ser necessário utilizar dados prevalentes, ou seja, de indivíduos que já haviam tido algum episódio grave de hipertensão. Novamente: pode-se restringir o estudo apenas a dados incidentes, evitando o problema por meio do desenho, ou incorporar os dados prevalentes de forma adequada no modelo, ou seja, corrigindo o problema no processo de modelagem. Evidentemente, se for fácil incluir no estudo a população desejada, a solução via desenho é mais simples. Entretanto, frequentemente a captação dos indivíduos não é tão simples, e incluir dados prevalentes pode ser uma boa opção. A discussão sobre a forma de tratamento de dados prevalentes ou dados truncados é apresentada nos Capítulos 2 e 8.

Ainda no tópico da seleção dos indivíduos, cabe lembrar que se diversos serviços de saúde forem utilizados, de alguma forma deve-se

controlar a eventual heterogeneidade da clientela e mesmo da assistência prestada aos pacientes. Por exemplo, hospitais universitários costumam ter uma clientela bem diferente daquela dos postos de saúde e emergências municipais. Essa variabilidade entre grupos de observações permite supor a presença de uma estrutura de dependência entre os indivíduos atendidos no mesmo local. Claro, selecionar apenas um local permite restringir essa fonte adicional de erro, mas limita as conclusões apenas aos indivíduos submetidos ao tipo de assistência selecionada. De modo alternativo, modelos multiníveis podem permitir a estimação do efeito das unidades incluídas na amostra, além de permitirem controlar por variáveis desse nível (Capítulo 12).

Na definição do desfecho do hipotético estudo de hipertensão, deve-se considerar a possibilidade de diferentes causas de óbito. Pode-se definir que somente óbitos diretamente relacionados à hipertensão – por acidente vascular cerebral, por exemplo – serão considerados no estudo. Entretanto, a hipertensão está relacionada a diversas causas de óbito, que competem pelo mesmo indivíduo. Além disso, o tempo pode ser medido desde o primeiro episódio grave de hipertensão, ou a contagem do tempo pode recomeçar a cada novo episódio. A modelagem de eventos múltiplos é recente no campo da análise de sobrevivência, e permite o tratamento de uma enorme gama de problemas, incluindo eventos competitivos, eventos recorrentes e paralelos (Capítulo 10).

1.6.2 Ensaios clínicos

Na avaliação da eficácia de tratamentos, área de grande interesse na epidemiologia, outros problemas são enfrentados pelo epidemiologista na definição do desenho de estudo. Suponhamos um ensaio clínico aleatorizado e duplo-cego, considerado o desenho de escolha. Consideremos inicialmente tratamentos que são administrados de forma pontual. Nesse caso, a alocação aleatória do tratamento se dá no início do estudo e a inferência sobre a eficácia do tratamento deve acomodar as respostas individuais heterogêneas, bem como a adesão ao tratamento alocado. A não adesão pode sofrer influências de es-

colhas individuais assim como de opções de ordem médica, como, por exemplo, devido à ocorrência de efeitos adversos.

Em um segundo caso, o tratamento se dá ao longo de um período de tempo. Nesse caso, a adesão ao tratamento pode variar ao longo do período, e a homogeneidade na distribuição de covariáveis objeto do processo de aleatorização não é mais garantida ao longo do período de observação. Em ambos os casos descritos anteriormente, o padrão de censura pode também ser variável ao longo do período de observação. A incorporação desses aspectos do desenho do estudo na análise tornam os modelos estatísticos bem mais complexos.

Também como consequência do tratamento explícito da dimensão tempo na análise de dados, o conceito de confusão merece atenção especial do epidemiologista. Podemos generalizar o conceito de confusão deixando também explícita a dimensão tempo, que passaremos a denominar confusão dependente do tempo. Um exemplo pode tornar o conceito mais claro. Suponha que estejamos interessados em estudar o efeito de drogas altamente potentes – Haart – no tempo até o aparecimento da Aids. Sabemos ser esse efeito dependente da carga viral e da contagem de células do tipo CD4 no momento de início do tratamento. Estes níveis, por sua vez, são expressões de esquemas terapêuticos anteriores e a situação configura, então, a necessidade de estimar o efeito de Haart controlado por carga viral e número de linfócitos do tipo CD4. Entretanto, o controle apenas pelos níveis iniciais não é suficiente, já que eles irão variar no decorrer do estudo. Esse exemplo ilustra as dificuldades presentes para generalizar os conceitos epidemiológicos descritos de forma estática no tempo para o caso de dependência explícita nessa dimensão.

1.6.3 Estudos transversais ou seccionais

Além de todas essas questões, ainda que a análise de dados de sobrevivência esteja tradicionalmente ligada aos estudos de coorte, as mesmas ferramentas de análise podem ser utilizadas também em estudos seccionais, desde que certas premissas sejam satisfeitas, ou em estudos seccionais repetidos, também conhecidos como estudos de painéis (*panel study*). À primeira vista, o uso de informações obtidas por

meio de um desenho de estudo que permite a estimativa de prevalência em modelos que descrevem incidência pode parecer estranho. Entretanto, como estudos de coorte podem ser caros e demorados, uma abordagem alternativa é o uso de dados prevalentes para vários grupos etários, como é frequentemente descrito em inquéritos sorológicos. A reconstituição de taxas de incidência a partir da distribuição marginal do evento de interesse por faixa etária pode também ser objeto de análise com as ferramentas de processos de contagem descritas no Capítulo 2.

A repetição em momentos sucessivos dos estudos seccionais permite a estimação da prevalência do evento de interesse, específica por faixa etária, para sucessivos momentos no tempo. Também nesse caso, as ferramentas de processos contáveis irão permitir a descrição da dependência da função de incidência na idade e no tempo, além de covariáveis de interesse. A utilização desses procedimentos requer, na maioria das vezes, a irreversibilidade do marcador da presença do evento de interesse. No caso de inquéritos sorológicos, isso se traduz na manutenção, por toda a vida, da cicatriz imunológica que descreve o contato com o agente infeccioso.

1.7 Comentários finais

Este conjunto de questões nos remete à discussão que contrapõe as ideias de controlar confundimento por meio do desenho do estudo com o controle utilizando-se técnicas de modelagem. Essa questão é muito mais ampla, ultrapassando o escopo desse capítulo, até porque estudos bem desenhados, com o pleno domínio das técnicas possíveis de modelagem, trazem o melhor dos dois mundos. Vale lembrar que modelos que até recentemente não tinham viabilidade prática, por falta de implementação em software são agora de utilização relativamente simples.

Uma recomendação importante para melhor viabilizar os estudos de sobrevivência é buscar detalhar o máximo possível a informação relacionada ao **tempo**, incluindo sempre datas para cada mudança verificada em covariáveis. A montagem cuidadosa do banco de

dados, de forma a refletir a variação temporal, evita erros e desperdício de recursos. Além disso, é sempre necessário avaliar comparativamente os custos, tanto na coleta da informação como na análise.

Esse último aspecto merece mais atenção: em geral, o custo da coleta de dados é muito maior do que o custo da análise, e os desenhos mais elaborados eventualmente tornam a seleção dos indivíduos proibitiva. Por outro lado, o custo envolvido no ferramental metodológico, incluindo o computacional, vem diminuindo com o aumento do poder de processamento dos microcomputadores. Além disso, a velocidade no desenvolvimento de técnicas no campo da modelagem, em conjunto com sua disponibilização relativamente rápida em ambientes de software livre, como o pacote R, utilizado nos exemplos e exercícios desse livro, permitem a incorporação aos modelos de estruturas de crescente complexidade, cada vez melhor especificados.

Como usar o R

Ao longo de todo o livro, colocamos caixas como esta para apresentar como se executa cada análise no R. No índice remissivo estão listadas as principais funções utilizadas. Como muitas vezes o que não se sabe é o nome da função, também organizamos, sob o título R, um índice de palavras-chaves a partir do qual é possível encontrar o comando desejado.

Além disso, o *help* do R é bastante útil: leia-o com atenção e tente fazer os exemplos apresentados ao final. Uma visita aos arquivos do R, onde estão os manuais, tutoriais e mensagens, pode ser feita digitando:

```
> RSiteSearch("palavra de busca")
```

Uma janela do seu navegador da internet abrirá na página do R.

Novatos no R

Para o leitor novato em R, sugerimos fortemente que estude algum tutorial. Na página do projeto R (www.r-project.org) existem dezenas de tutoriais, alguns em português. Procure também nas páginas do Cemeq/Fiocruz (www.procc.fiocruz.br) e do LEG/UFPR (www.leg.ufpr.br/doku.php). Além da lista de discussão principal do R, a lista brasileira (www.leg.ufpr.br/doku.php/software:rbr) é ótima para tirar dúvidas sobre o uso do programa, em português, claro.

Se você é totalmente novato, experimente a biblioteca *Rcmdr*, que cria uma interface gráfica para o R, facilitando o primeiro contato com o software. Ao mesmo tempo, como todos os comandos ficam visíveis, sendo possível editá-los, gradativamente os usuários se familiarizam com a linguagem. Para a análise de sobrevivência utiliza-se o *plugin Rcmdr-Plugin.survival*, que ajudamos a construir.

- Instale as duas bibliotecas – *Rcmdr* e *RcmdrPlugin.survival* – a partir da janela do R, no menu *pacote*.
- Coloque em uso a biblioteca *Rcmdr*:

```
> library(Rcmdr)
```

- O *plugin* é chamado a partir da janela que se abre ao iniciar o *Rcmdr*, no menu *ferramentas*. Uma pequena apostila do *Rcmdr* está disponível na página do livro em sobrevida.fiocruz.br.

2

O tempo na análise de sobrevivência

Ao término do Capítulo 2, espera-se que o leitor seja capaz de:

Identificar os mecanismos de censura e truncamento.

Representar graficamente o tempo até o evento de duas formas: clássica e por processo de contagem.

Identificar em que períodos de tempo cada indivíduo observado contribui para o grupo de risco.

2.1 Introdução

No Sistema de Informações Ambulatoriais (SIA) são registrados mensalmente as sessões de hemodiálise realizadas nos pacientes com insuficiência renal usuários do Sistema Único de Saúde (SUS) brasileiro. Os dados gerados por esse sistema, por meio da Autorização de Procedimentos de Alta Complexidade (Apac), permitem estudar a sobrevivência desses pacientes entre o início da terapia e o óbito.

A Tabela 2.1 apresenta o tempo de sobrevivência de 10 pacientes em diálise medido em meses. Esses dados podem ser descritos graficamente como linhas (veja Figura 2.1): no eixo das abscissas está

o tempo de acompanhamento e no eixo das ordenadas está o identificador do paciente. O momento do óbito está assinalado, na trajetória do paciente, por um X. Nessa figura, vê-se uma coorte composta por 10 pacientes onde o paciente 1 foi acompanhado até a ocorrência do evento no 22º mês, o paciente 4 até o 43º mês, quando ocorreu o evento, e assim por diante. Nessa coorte, toda a informação referente a cada indivíduo i se restringe apenas ao tempo decorrido entre a entrada do indivíduo i na coorte e a ocorrência do evento de interesse, que denotamos por T_i . Assim, $T_1 = 22$ e $T_4 = 43$.

Tabela 2.1: Tempo de sobrevivência (em meses) de 10 pacientes em diálise

Paciente (i)	Tempo (T_i)
1	22
2	6
3	12
4	43
5	23
6	10
7	35
8	18
9	36
10	29

É importante notar que na análise de sobrevivência, o tempo a ser analisado não está restrito ao tempo até o óbito, mas até a ocorrência de qualquer evento de interesse: diagnóstico de uma doença, nascimento, cura, aparecimento de efeito colateral de um medicamento, aparecimento de um tumor, etc. No exemplo acima, o evento é o óbito e o tempo de sobrevivência, T_i , é o intervalo entre o início da diálise e o óbito. O evento que marca o término do tempo de observação também é chamado de **falha** ou **desfecho**. O termo falha surgiu no contexto de análise de confiabilidade, na qual se busca modelar o tempo até a falha de algum equipamento ou componente.




Figura 2.1: Tempo de sobrevivência de 10 pacientes em diálise (Tabela 2.1). Cada linha representa a trajetória de um paciente e o símbolo $\times$ indica a ocorrência do evento ou falha

No exemplo da Figura 2.1, as informações estão completas para todos os pacientes, ou seja, o momento de início da diálise e o momento do óbito são conhecidos para **todos** os indivíduos. Entretanto, esse exemplo não é muito realista: dificilmente todos os indivíduos de uma coorte são acompanhados até a ocorrência do evento de interesse e muitas vezes não se conhece a data de início do acompanhamento da coorte. As causas de perda da informação temporal completa são várias:

- óbito por causas não relacionadas ao estudo – por exemplo, por causas externas;
- término do estudo;
- perda de contato – por exemplo, mudança de residência;
- recusa em continuar participando, o que é relativamente comum em estudos de coorte;

- mudança de procedimento, quando, por exemplo, um paciente recebe um transplante renal e sai da coorte de acompanhamento de hemodiálise;
- abandono devido a efeitos adversos de tratamento;
- desconhecimento da data de início do tempo que se deseja modelar – por exemplo, no estudo do tempo entre a infecção pelo HIV e o diagnóstico de Aids, raramente se conhece a data de infecção pelo vírus;
- utilização de dados prevalentes – por exemplo, no estudo de sobrevivência dos pacientes em diálise, os pacientes que morreram antes da implementação do sistema de acompanhamento estão excluídos.

Nesses casos diz-se que houve **censura** ou **truncamento**. Censura refere-se à perda de informação decorrente de não se ter observado a **data de ocorrência** do desfecho. Os itens listados anteriormente (exceto o último) são causas possíveis de dados censurados. Truncamento ocorre quando alguns indivíduos, que naturalmente pertenceriam à população estudada, são inteiramente excluídos do estudo. Isso é comum quando se analisa dados prevalentes.

2.2 Mecanismos de censura e truncamento

2.2.1 Censura

Para estudar o tempo entre o diagnóstico de Aids e o óbito, 193 pacientes foram acompanhados em um ambulatório especializado de 1986 a 2000. Durante esse período, foram observados 92 óbitos. Sabemos que até a data de término do estudo, em dezembro de 2000, ainda permaneciam vivos 101 pacientes. Dizemos, então, que ocorreram 92 eventos e 101 censuras. Esse tipo de censura, denominada **censura à direita**, é a mais comum. Nesse caso aproveita-se a informação do tempo durante o qual a pessoa esteve sob observação sem que ocorresse o evento. Na censura à direita sabe-se que o tempo entre o

início da observação e o evento é maior do que o tempo de fato observado ($T > t^-$), como representado no primeiro quadro da Figura 2.3. Desprezar essa informação faria com que o risco fosse superestimado, pois o tempo até a morte é desconhecido, mas o paciente estava vivo pelo menos até dezembro de 2000, data do último contato registrado.

A Figura 2.2 mostra como fica a representação gráfica dos tempos de observação de 10 pacientes em diálise (Tabela 2.2), incluindo a informação sobre a ocorrência de censura à direita. Observe que, para cada indivíduo da coorte, temos a informação do seu tempo de observação e se o desfecho ocorreu ou não.

A notação clássica para dados sujeitos à censura à direita, geralmente utilizada para descrever a experiência de cada indivíduo, é (T_i, δ_i) , em que T_i é o tempo de observação do indivíduo i e δ_i é uma variável indicadora do status, que assume valor 1 se o desfecho ocorreu e 0 se o indivíduo foi censurado. Então, $\delta_i = 1$ significa que o desfecho ocorreu antes do final do estudo e $\delta_i = 0$, que o indivíduo deixou de ser acompanhado (censura à direita). Assim, o registro do paciente 3 é $(T_3, \delta_3) = (12, 1)$, o do paciente 8 é $(T_8, \delta_8) = (18, 0)$, e assim por diante. No primeiro caso, o tempo de sobrevivência do paciente equivale ao tempo de acompanhamento (do início ao desfecho). No segundo caso, a informação parcial que temos é que o tempo de sobrevivência é maior do que o tempo observado.

Outros tipos de censura são a **censura à esquerda** e a **censura intervalar**. A censura à esquerda ocorre quando não conhecemos o momento da ocorrência do desfecho, mas sabemos que ele ocorreu antes do tempo observado. Considere por exemplo um estudo para investigar os fatores associados à infecção por leptospirose em uma comunidade de baixa renda, recém-criada. Os participantes são incluídos assim que mudam para a área. Uma vez por ano, os pesquisadores coletam sangue dos participantes para verificar se houve soroconversão. Alguns participantes logo na primeira coleta já estavam soropositivos. Ou seja, a soroconversão pode ter acontecido em qualquer momento entre o dia da mudança para a comunidade e alguns dias antes do primeiro exame. Só podemos afirmar que o tempo para a soroconversão, que define o tempo de sobrevivência, é menor que o tempo para o primeiro exame ($T < t^+$), como indica

Tabela 2.2: Tempo de observação (em meses) de 10 pacientes em diálise e a ocorrência de censura à direita

Paciente (i)	Tempo (T_i)	Status (δ_i)
1	22	1
2	6	0
3	12	1
4	43	0
5	23	1
6	10	1
7	35	1
8	18	0
9	36	1
10	29	1




Figura 2.2: Trajetórias individuais dos 10 pacientes em diálise (Tabela 2.2). A marca $\times$ indica ocorrência do evento, e o símbolo $\circ$ corresponde à presença de censura

o segundo quadro da Figura 2.3. É importante observar que, para haver censura à esquerda, o marcador de tempo de início não pode estar relacionado ao marcador de evento.

O último quadro da Figura 2.3 ilustra outro participante no qual a soroconversão aconteceu no segundo exame. Ou seja, temos certeza que o tempo exato de sobrevivência é maior que o tempo até o primeiro exame e menor do que o tempo até o segundo exame, isto é, o momento em que a soroconversão ocorreu certamente se situa entre o primeiro e o segundo exames ($t^- < T < t^+$). Neste caso, dizemos que ocorreu censura intervalar, sendo t^- o tempo observado entre início do estudo e o primeiro exame, e t^+ o tempo entre o primeiro e o segundo exames.

A censura pode ainda ser classificada em **informativa** e **não informativa**. Diz-se que a censura é não informativa quando não há razão para suspeitar que o motivo dessa perda de informação esteja relacionado ao desfecho. Nos exemplos anteriores, as censuras são consideradas não informativas porque ocorrem por acaso. Ou seja, a data da consulta de acompanhamento ou a data do final do estudo não foram definidas em função do desfecho. Entretanto, se o indivíduo se afastasse do estudo por motivo associado ao evento estudado, por exemplo, se o abandono do tratamento fosse em decorrência da piora do paciente ou se o óbito não fosse conhecido por falha no acompanhamento dos pacientes, esta seria uma censura informativa. Esse tipo de problema introduz um viés de seleção, interferindo na validade das estimativas e deve ser evitado ao máximo. Os métodos para evitar esse tipo de viés são os mesmos utilizados para contornar o problema das perdas em qualquer estudo epidemiológico: predefinir todos os passos na busca dos pacientes e no encerramento desta, analisar as causas de censura, comparar os perfis dos pacientes com tempos censurados e não censurados utilizando medidas descritivas, entre outros.

2.2.2 Truncamento

O segundo tipo de dado incompleto, denominado **dado truncado**, ocorre quando indivíduos são excluídos do estudo por motivo relacionado à ocorrência do evento. Em outras palavras, acontece quando o




Figura 2.3: Representação gráfica de censura à direita do tempo até o óbito por Aids e de censuras à esquerda e intervalar no exemplo do tempo até a soroconversão para leptospirose. A linha pontilhada é o tempo de sobrevivência exato (não observado). A linha tracejada representa a janela temporal onde o evento poderia ocorrer

estudo inclui somente indivíduos em que o evento ocorreu dentro de uma janela temporal pré-estabelecida denominada (T_E, T_D) . **Dado truncado à esquerda** inclui somente observações em que o desfecho ocorreu após o limite inferior da janela temporal de observação (o tempo $T \geq T_E$). Também podemos dizer que só ocorre quando a perda da informação está relacionada a indivíduos que foram excluídos do estudo porque já tinham experimentado o evento antes do início do estudo e não podiam ser observados. Por exemplo, no estudo de sobrevivência de pacientes em hemodiálise, os dados referem-se somente àqueles pacientes em tratamento em janeiro de 1998 ou aos que iniciaram o tratamento numa data posterior. Nesse caso, os pacientes diagnosticados antes de janeiro de 1998 e que morreram antes daquela data não são incluídos no estudo, caracterizando o que se denomina truncamento à esquerda, causado pelo uso de **dados prevalentes**, como ilustra a Figura 2.4. Nesse estudo, parte do tempo considerado na análise é observado prospectivamente, e parte retrospectivamente. As informações dos indivíduos que já tinham sofrido o desfecho antes do início do estudo nunca poderiam ser incluídas no estudo, embora se esteja considerando os sobreviventes. Nesse caso teremos um viés de seleção, pois os indivíduos com sobrevivência mais longa têm maior probabilidade de entrar no estudo, fazendo com que o risco de ocorrência do evento seja subestimado. Para corrigir esse viés, os pacientes que iniciaram a diálise antes do início do estudo só terão computados os tempos após a data de início do estudo. Observe que esses pacientes na Figura 2.4 possuem linha pontilhada antes do início do estudo e linha contínua dentro da janela temporal de análise. Para interpretar adequadamente a modelagem com dados prevalentes é necessário ter sempre em mente que os resultados encontrados estão condicionados ao fato do paciente estar vivo em janeiro de 1998.

O truncamento à direita ocorre quando o critério de seleção dos indivíduos inclui somente os que sofreram o evento, isto é, a data de ocorrência do evento é sempre menor que o limite superior da janela temporal ($T \leq T_D$). Este tipo de truncamento é comum em estudos de sobrevivência que partem do dado do óbito para selecionar as observações. É o caso de análises para estimar fatores associados à sobrevivência de pacientes com Aids que partem do registro de óbito.




Figura 2.4: Representação gráfica do truncamento à esquerda. Trajetórias em pontilhado à esquerda do início do estudo não são incluídas na análise e as linhas contínuas são os dados prevalentes a analisar

Isso significa, por um lado, que não haverá censura à direita, mas por outro lado, que indivíduos que não sofrem o evento, mesmo tendo todos os fatores de risco presentes, não serão incluídos no estudo. Em doenças de curta duração e muito bem caracterizadas, este viés de seleção será pouco importante, pois é esperado que não haja tempos longos não observáveis na janela definida. Caso contrário, o truncamento à direita faz com que o risco de ocorrência do evento seja superestimado (Figura 2.5).

A presença de truncamento e censura são limitações mais frequentes em estudos observacionais do que em ensaios clínicos, exceto pela censura à direita, comum em praticamente todos os estudos. Limitações devem sempre ser reconhecidas, mas não devem impedir o uso adequado da informação. Cabe identificar corretamente o problema e selecionar o modelo que permitirá o ajuste dos dados, extraindo toda a informação possível. As bases teóricas para a modelagem de dados serão apresentadas nas próximas seções.




Figura 2.5: Representação gráfica do truncamento à direita. Os eventos na janela temporal de seleção definem a amostra. Trajetórias em pontilhado não são observadas, mesmo que cruzem a janela temporal, pois o evento não ocorreu no intervalo definido. Nunca há censura à direita

2.3 Coortes abertas

Frequentemente os desenhos dos estudos são coortes abertas, em que o momento de entrada dos pacientes na coorte varia. No caso dos pacientes em hemodiálise, a cada momento novos pacientes entram em insuficiência renal, sendo então registrados na Apac. A Figura 2.6 ilustra como o tempo de sobrevivência dos pacientes pode ser representado.

Note que, em contraste com a Figura 2.2, o tempo de sobrevivência na Figura 2.6 não pode ser lido diretamente no eixo das abscissas, como anteriormente. Este eixo tem agora um novo significado, indicando o tempo calendário, isto é, o tempo decorrido desde um ponto arbitrário de tempo, definido como 0. Este ponto inicial em geral é definido como a data do primeiro registro, ou a data de início de um estudo prospectivo. Neste gráfico, para se obter o tempo T_i de observação do paciente i , temos que subtrair o tempo calendário final de observação do tempo calendário inicial, como mostra

a Tabela 2.3. Por exemplo, considere o paciente 5 da Figura 2.6. Ele entrou na coorte no mês calendário 10 e foi acompanhado até o mês 33, quando ocorreu o evento. Assim, o registro do paciente 5 será $(T_5, \delta_5) = (23, 1)$, isto é, ele foi acompanhado por 23 meses ($33 - 10 = 23$). Já para o paciente 8, o registro será $(T_8, \delta_8) = (18, 0)$, indicando que ele ficou 18 meses em observação (do mês 12 ao mês 30) e que foi censurado.




Figura 2.6: Representação gráfica dos tempos de observação ou trajetórias de pacientes em uma coorte aberta. Pacientes 2, 4 e 8 apresentam censuras à direita, marcadas pelo símbolo $\circ$

Uma forma alternativa de se registrar o tempo de sobrevivência, algo importante quando lidamos com coortes abertas, é explicitar o tempo calendário inicial e o tempo calendário final de acompanhamento do paciente. Isto é, em vez do registro (T_i, δ_i) , (tempo, evento), utiliza-se o registro (I_i, F_i, δ_i) , em que I_i é o tempo calendário inicial de acompanhamento do paciente i , F_i é o tempo, novamente denominado calendário, final de seu acompanhamento e δ_i indica a ocorrência ou não do desfecho. Por exemplo, em vez de registrar o tempo de sobrevivência do paciente 5 acima como $(T_5, \delta_5) = (23, 1)$, podemos escrever: $(I_5, F_5, \delta_5) = (10, 33, 1)$.

Tabela 2.3: Tempo de observação de pacientes participantes da coorte aberta

Paciente	Tempo* inicial (I)	Tempo* final (F)	Tempo** T (F - I)	Status (δ)
1	0	22	22	1
2	15	21	6	0
3	0	12	12	1
4	5	48	43	0
5	10	33	23	1
6	0	10	10	1
7	0	35	35	1
8	12	30	18	0
9	3	39	36	1
10	15	44	29	1

*Tempo calendário (em meses)

**Tempo decorrido (em meses)

2.4 Processo de contagem

A forma clássica de análise de sobrevivência, disponível na maior parte dos pacotes estatísticos, permite analisar o tempo de sobrevivência assumindo que todos os pacientes começaram a ser observados juntos, no tempo zero. Esse modelo mais simples é bastante razoável em diversas circunstâncias, mas limitado em análises de dados mais complexos. Uma situação comum na qual a forma clássica não se adequa ocorre quando há mudança no valor da covariável de um paciente no decorrer do estudo. Por exemplo, na investigação do impacto de uma certa combinação de medicamentos na sobrevivência de pacientes com Aids, a mudança de medicamentos implicaria na saída do indivíduo do estudo. Utilizando os modelos de sobrevivência formalizados na forma de processo de contagem, é possível reformular o problema considerando os tempos nos quais o paciente tomou cada um dos medicamentos. Esse tipo de modelo, no qual as covariáveis mudam ao longo do tempo, será abordado no Capítulo 8.

Outra situação em que a forma clássica de modelar não é a mais adequada ocorre em estudos com dados prevalentes (dados truncados à esquerda). Nestes casos, a análise clássica pode acarretar viés a favor de tempos mais longos. Retornando ao problema da diálise, deve-se lembrar que, ao ser iniciado, o sistema da Apac incluiu todos os pacientes vivos naquele momento. Se considerarmos o tempo total de diálise de cada paciente (que, para alguns, ultrapassava 10 anos), estaremos introduzindo um viés a favor de tempos mais longos, pois os pacientes que morreram em tempos curtos (antes que o sistema fosse montado) não entraram no sistema.

Uma terceira situação na qual a abordagem clássica também é limitada ocorre em estudos com múltiplos eventos ou desfechos, como sucessivos infartes agudos do miocárdio ou a ocorrência de efeitos colaterais de medicamentos. Nestas circunstâncias, a abordagem que utiliza o processo de contagem permite estimar de forma mais natural os parâmetros envolvidos. Esses problemas serão aprofundados nos capítulos de eventos múltiplos e de eventos competitivos.

A teoria de análise de sobrevivência formulada sob a ótica de processos de contagem permite acomodar com relativa facilidade tanto censuras quanto situações mais complexas, como covariáveis que mudam no tempo, eventos recorrentes e eventos múltiplos. A teoria completa subjacente ao processo de contagem foge do escopo deste livro. Optamos por descrevê-la, ainda que de forma simplificada, por considerarmos que sua formulação, junto com sua representação gráfica, tornaria natural a explicação, para um leitor da área da saúde, sobre como os grupos de risco são formados a cada momento do tempo. Esse entendimento é essencial no momento da criação dos bancos de dados que incluam eventos múltiplos, eventos competitivos ou a possibilidade de covariáveis que mudam ao longo do tempo.

Na abordagem clássica, descrita no início deste capítulo, o tempo de sobrevivência de um indivíduo i é codificado por um par de variáveis (T_i, δ_i) , no qual T_i é o tempo de observação e δ_i é a variável indicadora de censura ou evento. Sob a ótica do processo de contagem, o tempo de sobrevivência passa a ser descrito por um par de variáveis que se modificam com o tempo, através das funções $(N_i(t), Y_i(t))$, em que $N_i(t)$ é o número de eventos sofridos pelo in-

divíduo i no intervalo de tempo $[0, t]$ e $Y_i(t)$ é uma variável binária indicadora de presença na população em risco:


$Y_i(t) = 1$, se o indivíduo i está sob observação e em risco de sofrer o evento no instante t ;

$Y_i(t) = 0$, caso contrário, isto é, se o indivíduo não está em observação e não deve ser computado na população em risco.


Note que $Y_i(t)$ assume valor zero quando o indivíduo i não estiver em risco em t , seja porque ainda não havia entrado no estudo, seja porque já tinha desenvolvido o evento (caso não haja possibilidade de recorrência), seja porque havia sido censurado. Neste último caso, o paciente pode até vir a experimentar o evento no futuro, mas como ele não está sendo acompanhado, o evento não será observável pelo pesquisador. Em outras palavras, $Y_i(t)$ será 1 apenas quando o participante do estudo estiver em risco de sofrer um evento que seja observável pelo pesquisador.

Vamos ilustrar como esta notação é utilizada para representar as trajetórias de dois pacientes diagnosticados com Aids acompanhados até a ocorrência do óbito. Observe o gráfico da Figura 2.7 referente ao paciente 1 da Tabela 2.3. Até o tempo 22, o indivíduo estava sob risco e, portanto, o valor de $Y_1(t) = 1$ foi mantido até $t = 22$. Durante esse período, nenhum evento foi observado, logo $N_1(t) = 0$ até $t = 22$. Exatamente no tempo 22, o indivíduo sofreu o evento e, assim, $N_1(t) = 1$ para $t \geq 22$. Uma vez tendo ocorrido o evento, o paciente deixou de estar em risco e $Y_1(t) = 0$ para $t > 22$. Note que no momento exato do evento ($t = 22$), os valores de $Y(t)$ e $N(t)$ são iguais a 1, e para tempos maiores que 22 meses, assumem valores zero e 1, respectivamente.

Neste exemplo, o número máximo de eventos que um paciente pode sofrer é 1, logo a variável $N(t)$ somente pode assumir valores 0 ou 1. Em outros casos, por exemplo, quando o interesse é o aparecimento de doenças oportunistas em pacientes com Aids, é possível observar a ocorrência de mais de um evento no mesmo paciente, e a variável $N_i(t)$ terá valor 2 a partir do momento da segunda ocorrência, e assim



Paciente 1: diagnosticado no mês zero, acompanhado até o mês 22. A ocorrência do evento é assinalada pelo sinal ●



Paciente 3: diagnosticado no mês zero, acompanhado até o mês 12, quando ocorreu o evento.

Figura 2.7: Representação gráfica, na forma de processo de contagem, das trajetórias individuais de dois pacientes apresentados na Tabela 2.3

por diante. Nota-se aqui a capacidade dessa formulação de acomodar estudos em que eventos recorrentes são de interesse. Outros exemplos que envolvem eventos múltiplos são: o tempo até episódios agudos de isquemia cardíaca, em que um mesmo paciente pode ter diversos episódios; recidivas de câncer; múltiplas internações de um mesmo paciente; cáries dentárias, entre outros. A modelagem desse tipo de problema será estudada detalhadamente nos capítulos de eventos múltiplos e competitivos.

Como representar dados de indivíduos com tempo censurados, sob a forma de processo de contagem? Na Figura 2.8 encontram-se representadas as trajetórias de dois indivíduos fictícios com tempo censurados. Os indivíduos A e B nunca desenvolveram o evento e, conseqüentemente, os valores de $N(t)$ permaneceram em zero por todo o período de observação. Entretanto, o indivíduo A foi observado somente do mês 0 ao 6, sem ocorrência do evento. Nesse período, ele esteve em risco ($Y_A(t) = 1$ para $t \leq 6$). A censura observada em $t = 6$ ocasionou a saída desse indivíduo do grupo de risco, resultando em $Y_A(t) = 0$ para $t > 6$. É importante notar que dizer que o indivíduo está fora do grupo de risco não significa dizer que ele não sofrerá o evento de interesse. O que está sendo dito é que ele não está mais em risco de sofrer o evento sob a observação do pesquisador.

O indivíduo B, por outro lado, permaneceu no estudo durante todo o tempo de acompanhamento, mas nenhum evento foi registrado. O fato dele ter estado todo o tempo sob risco de ocorrência do fenômeno fica registrado no valor da variável Y , $Y_B(t) = 1$ para todo $t \geq 0$.

Percebe-se que, sob a ótica de um processo de contagem, o registro da experiência do paciente é contínuo ao longo do tempo, e independe do tempo de observação ou do tempo calendário, e da censura à esquerda ou à direita. O processo registrado indica se o indivíduo está ou não sob risco e o número de eventos observados até cada tempo. Esta generalização é demonstrada na Figura 2.9, quando são apresentadas as trajetórias e os registros sob o processo de contagem de dois pacientes já descritos na Figura 2.6 com a notação clássica.




Figura 2.8: Trajetória de dois pacientes censurados. No primeiro gráfico ocorre censura aos 6 meses; no segundo, ocorre censura ao término do estudo

De acordo com a Figura 2.6, o paciente 5 ficou sob observação durante 23 meses, entre os meses 10 e 33, quando sofreu o evento, e assim $Y_5(t) = 1$ apenas entre os meses 10 e 33, e $Y_5(t) = 0$ nos outros tempos. Enquanto isso, $N_5(t) = 1$ a partir da ocorrência do evento no tempo 33, ou seja, $N_5(t) = 1$ se $t \geq 33$. O paciente 8 entrou no estudo no mês 12 e foi censurado no mês 30. Assim, $Y_8(t) = 0$ se $t < 12$ ou $t > 30$, ou seja, é zero antes de entrar no estudo e depois de censurado, quando também não estará mais em risco, e o $N_8(t) = 0$ durante todo o tempo de observação.

O processo de contagem também acomoda naturalmente dados prevalentes, o que era um problema para a abordagem clássica. Na abordagem de processo de contagem, o que acontece com o indivíduo durante o período não observado não é considerado na modelagem. Assim, mesmo que a data de início do tempo de sobrevivência preceda a data de início do estudo, esse tempo anterior não será considerado na modelagem, pois foi um período em que o indivíduo não estava em risco (observável). Logo, o registro do paciente prevalente não diferirá de outro que tenha entrado no início do estudo. E desta forma é possível corrigir o viés de seleção de sobreviventes com tempos longos.




Figura 2.9: Trajetória dos pacientes 5 e 8 que entraram na coorte ao longo do estudo

A teoria dos processos de contagem é um campo amplo da estatística. Formalmente, um processo de contagem é definido como um processo estocástico $N(t)$ com $t > 0$, de tal forma que $N(0) = 0$ e $N(t) < \infty$. A trajetória de $N(t)$ é contínua à direita a partir de uma função segmentada com saltos de tamanho igual a um. Assim, devido a essas propriedades, a análise de sobrevivência pode ser pensada como um processo de contagem onde $N(t)$ é o número de eventos observados até o tempo t e $\Delta N(t)$ é a diferença entre a contagem de eventos até o instante t e a contagem no momento imediatamente anterior a t .

2.5 Organização dos dados

Ao longo do livro veremos que a organização adequada do banco de dados é crucial para que sua análise seja feita de forma correta. Mais do que isso, a utilização de alguns métodos de análise mais avançados demanda formas distintas de organização dos dados para que as funções implementadas no R façam as estimativas corretamente.

Nesta seção, serão apresentadas as duas formas de construção do banco de dados – clássica e processo de contagem.

Na forma clássica de análise de sobrevivência, é necessário registrar o tempo de acompanhamento e uma variável indicadora que represente o status (ou a ocorrência do evento) junto a este tempo. Essa variável denominada δ assume valor 1 se o evento ocorreu, e 0 se houve censura no momento indicado por T .

Um exemplo de banco de dados no formato clássico seria:

id	tempo (T)	status (δ)	sexo	idade
1	30	0	F	54
2	14	1	F	34
3	23	1	M	65
4	11	1	F	45
5	12	0	M	44

Na notação de processo de contagem, ao invés de se indicar o tempo de acompanhamento, informa-se as datas de entrada e de saída da coorte para cada paciente, como no exemplo a seguir.

id	início (I)	fim (F)	status (δ)	sexo	idade
1	0	30	0	F	54
2	5	19	1	F	34
3	3	26	1	M	65
4	0	11	1	F	45
5	4	16	0	M	44

Note que a forma de processo de contagem é mais informativa, já que a partir das variáveis *início* e *fim*, é possível obter a informação de tempo de acompanhamento. Já o resgate da informação das datas de entrada e saída da coorte, a partir do tempo de acompanhamento, somente é possível se todos entraram juntos na coorte, no tempo zero.

De forma geral, recomenda-se organizar os dados de forma a combinar as duas abordagens, isto é, incluindo tanto as variáveis de *início* e *fim* como a variável *tempo*, indicando o tempo decorrido.

Exemplo

Neste capítulo, foram introduzidos dois temas que serão revistos várias vezes ao longo do livro: a sobrevivência de pacientes com Aids e a sobrevivência de pacientes em hemodiálise. Em ambos os casos, o desfecho de interesse é o óbito.

No banco de dados *ipec.csv* está armazenada amostra de 193 indivíduos diagnosticados como Aids (critério CDC 1993) provenientes de uma população de 1.591 pacientes HIV positivos atendidos entre 1986 e 2000 no Ipec – Instituto de Pesquisa Clínica Evandro Chagas/Fiocruz (a descrição detalhada está no Apêndice, seção Aids, adesão à Haart). O tempo de sobrevivência é definido como o tempo entre o diagnóstico de Aids e o óbito ou censura.

Para abrir o banco de dados de Aids do Ipec no R, procedemos da seguinte forma:

```
> ipec <- read.table("ipec.csv",header=T,sep=";")
```

Uma parte ds dados referentes aos primeiros 8 indivíduos do banco de Aids estão listados abaixo:

id	ini	fim	tempo	status	sexo	escola	idade
1	1243	2095	852	1	M	3	34
2	2800	2923	123	1	M	2	38
3	1250	2395	1145	1	M	9	32
4	1915	4670	2755	0	M	9	43
5	2653	4770	2117	0	M	9	40
6	3	332	329	0	M	9	34
7	36	96	60	1	M	9	27
8	1	152	151	1	M	0	22

Este é um exemplo de coorte aberta, cujos dados foram registrados no formato (I, F, δ) . O primeiro dia do estudo (20 de outubro de 1987) foi chamado de dia 1, e o tempo de entrada e saída de cada indivíduo foi contado como o número de dias a partir dessa data. Assim, o paciente 1 entrou na coorte no dia 1.243 (quando foi diagnosticado com Aids) e saiu no dia 2.095, quando faleceu, perfazendo um tempo de sobrevivência de 852 dias. Já o indivíduo 6 entrou na

coorte no terceiro dia do estudo e foi censurado ($\text{status} = 0$) no dia 332, com tempo total de observação de 329 dias.

Esta coorte, de 193 pacientes, é composta de 49 mulheres e 144 homens, com idades entre 20 e 68 anos. Durante os quatro anos do estudo, foram registradas 103 censuras e 90 eventos (óbitos). Todas as censuras são classificadas como censuras à direita, já que resultaram de perda de acompanhamento, seja por abandono ou término do tempo de observação. Não há censura à esquerda.

A organização deste banco de dados permite utilizar as duas notações de tempo de sobrevivência. Na notação clássica, a forma de mostrar a ocorrência de censura é o sinal + colocado ao lado do tempo de observação, indicando que o indivíduo estava em risco pelo menos até o momento assinalado. Compare a saída do R abaixo com os dados dos 8 pacientes listados anteriormente no texto:

```
> require(survival)
> Surv(ipecc$tempo,ipecc$status)
```

```
[1] 852    123   1145  2755+ 2117+  329+   60     151    1563
```

Na notação de processo de contagem, o sinal + ao lado da data de saída da coorte, da mesma forma, indica censura. O parêntese no início do intervalo de tempo significa que o intervalo é aberto à esquerda, isto é, o tempo registrado para o início do intervalo não está incluído no intervalo. O colchete à direita indica que o último tempo é parte do intervalo. Isso é importante quando temos tempos sucessivos para um mesmo indivíduo (Capítulos 8 e 10).

```
> Surv(ipecc$ini,ipecc$fim,ipecc$status)
```

```
[1] (1243,2095 ] (2800,2923 ] (1250,2395 ] (1915,4670+]
[5] (2653,4770+] (   3, 332+] (   36,   96 ] (    1, 152 ]
```

Tempo de Sobrevivência no R

O R aceita os dois formatos de registro do tempo de sobrevivência. O formato *(tempo,status)* permite análise de sobrevivência utilizando os métodos clássicos (Capítulos 4 a 7). Já o formato *(inicio,fim,status)* permite o uso dos métodos baseados em processo de contagem.

O comando *Surv* tem como função combinar, em um único objeto, a informação referente ao tempo de sobrevivência de cada indivíduo e a informação a respeito do status do paciente, definido como 1 (um), se ocorreu o evento, e como 0 (zero), se o tempo foi censurado. Este comando faz parte da biblioteca *survival*, que precisa ser carregada antes:

```
> require(survival)
```

A sintaxe do comando *Surv()* para definir o objeto do tipo tempo de sobrevivência, nas duas notações (clássica e contagem), é, respectivamente:

```
> Surv(tempo,status)
> Surv(inicio,fim,status)
```

Resumo

Neste capítulo, foram apresentadas as diferentes abordagens – clássica e processo de contagem – para se estudar o tempo até a ocorrência de um evento, identificando-se:

- o tempo quando ocorre o evento;
- a população em risco em cada tempo;
- a censura não informativa e informativa;
- a censura à esquerda, à direita e intervalar;
- o truncamento à esquerda e à direita.

Exercícios

2.1 O tempo de aleitamento, isto é, o tempo decorrido desde o nascimento até o desmame, pode ser considerado como uma variável tempo de sobrevivência. Suponha que o tempo até o desmame, em meses, tenha sido registrado para 15 crianças que nasceram no mesmo dia:

6 12 10 3 5 1 6 8 1 5 2 2 5 8 1

Considerando que não houve censura:

- Represente graficamente os tempos de observação das 15 crianças.
- Represente as trajetórias dos primeiros cinco indivíduos utilizando as variáveis $N(t)$ e $Y(t)$ do processo de contagem.
- Como você construiria um banco de dados para analisar esses dados pelo processo clássico?
- E pelo processo de contagem?

2.2 Considere agora o tempo de sobrevivência de 15 pacientes submetidos à hemodiálise. Neste caso, a variável de interesse é o tempo desde a primeira diálise até o óbito (em meses).

2 4 29+ 6+ 3 1 1 2 3 9+ 10 11 5+ 5 1


Os tempos censurados (censura à direita) estão indicados pelo sinal de +. Considere que todos os pacientes entraram juntos no início do estudo.

- Represente graficamente os tempos de observação dos pacientes, utilizando a notação clássica.
- Represente as trajetórias dos primeiros cinco indivíduos utilizando as variáveis $N(t)$ e $Y(t)$ do processo de contagem.


- (c) Construa um banco de dados para analisar esses dados pelo processo clássico.
- (d) Reconstrua o banco de dados, na forma de processo de contagem, considerando que essa é uma coorte aberta e as datas de início do tempo de observação de cada paciente são dadas pela tabela abaixo.

Paciente	Início	Tempo	Censura
1	0	2	n
2	1	4	n
3	12	29	s
4	3	6	s
5	1	3	n
6	7	1	n
7	0	1	n
8	1	2	n
9	1	3	n
10	3	9	s
11	12	10	n
12	4	11	n
13	4	5	s
14	1	5	n
15	22	1	n

2.3 Em um hospital, seis pacientes HIV positivos são acompanhados ao longo de um ano. No gráfico a seguir, as linhas horizontais representam o tempo de acompanhamento de cada paciente: linhas terminadas em $\times$ indicam a ocorrência do desfecho (óbito), linhas terminadas com $\circ$ indicam censuras. Represente, utilizando as variáveis $N(t)$ e $Y(t)$, as trajetórias de cada um dos seis pacientes.




2.4 Considerando a trajetória observada de um paciente apresentada na figura abaixo, responda:



- (a) Qual foi o mês de entrada do paciente no estudo?
- (b) Em que mês ocorreu o desfecho?
- (c) Em que meses o paciente esteve sob risco de óbito?

2.5 Outro paciente tem a seguinte trajetória de observação:



Com base neste gráfico, responda:

- Qual foi a data de entrada do paciente no estudo?
- Em que data ocorreu o desfecho?

2.6 Considere seis indivíduos em uma coorte para avaliação de fatores de risco para infecção por HIV. O estudo iniciou-se em 01/06/2008, quando dois dos indivíduos entraram no estudo, com resultados negativos para a infecção. Um deles, ao realizar o segundo exame, um mês depois, apresentou resultado positivo, e o outro positivou dois meses depois. Os outros quatro indivíduos entraram no estudo em 01/07/2008, 01/09/2008, 01/08/2008, e 01/08/2008 e suas respectivas datas de soroconversão foram 2, 3, 2, e 5 meses após a entrada.

- Construa o banco de dados no formato clássico.
- Construa o banco de dados em formato de processo de contagem.
- Represente graficamente os tempos observados desses indivíduos.

- (d) Represente as trajetórias dos 6 indivíduos utilizando $N(t)$ e $Y(t)$.
- (e) Quais são os indivíduos em risco no quinto mês do estudo?
- (f) Que tipo de censura ocorreu nesse estudo?
- (g) Em que situação haveria truncamento?

Dicas para ler o banco

- Os dados estão disponíveis em <http://sobrevida.fiocruz.br>. Copie o banco `ipec.csv` para o sua pasta de trabalho.
- Lembre-se de indicar ao R em que diretório está o arquivo com o banco de dados usando o menu *File > Change Dir*. Ou, na linha de comando, digite `getwd()` para ver em que diretório se está trabalhando, e `setwd("caminho/completo")`.
- Esse banco está em formato `.csv`; para ler use o comando:

```
> ipec <- read.table("ipec.csv",header=T,sep=";")
```
- Uma forma alternativa de ler o banco de dados é usando a biblioteca *foreign*, que importa de diversos formatos. Caso o arquivo seja no padrão inglês (ponto como separador decimal e vírgula como separador de variáveis), a função é `read.csv`. Caso seja o modelo em português, com vírgula no lugar do ponto e ponto e vírgula como separador, deve-se utilizar `read.csv2`. Na dúvida, procure ver o banco em qualquer editor de texto puro.
- Arquivos de dados em puro texto, em geral denominados `.dat` ou `.txt`, têm como separador de variáveis marcas de tabulação ou espaços. Nesse caso, a função `read.table` não necessita que seja indicado o separador `sep=`.
- Procure nunca usar acentuação gráfica, por exemplo ç, ú, ã, espaços, e outros sinais nos nomes de variáveis ou das categorias, pois pode dificultar a importação dos dados. Os espaços, em geral, são transformados em pontos, mas é melhor evitar esse tipo de grafia.
- Nomes de variáveis não podem iniciar por números.
- Lembre-se que no R letras maiúsculas e minúsculas **não** são a mesma coisa. Por exemplo, `sexo`, `Sexo` e `SEXO` são três variáveis distintas.

2.7 Para se familiarizar com o R e com o banco de dados do Ipec (*ippec.csv*, veja o Apêndice, seção Aids – clássico) que será utilizado nos próximos capítulos, inicie a análise de sobrevivência observando os dados dos pacientes:

- (a) No formato clássico.
- (b) No formato de processo de contagem.
- (c) Observe a saída nos dois formatos. Quais os tempos e status do 1º e 79º pacientes em cada um dos formatos?

2.8 Ainda com os dados do Ipec, organize o banco de dados e faça uma análise exploratória das variáveis de interesse.

- (a) Verifique as dimensões dos dados.
- (b) Veja quais são as variáveis que constam nos dados.
- (c) Substitua os dados faltantes (codificados com 9, 99 ou I) por *NA* (padrão do R).
- (d) Indique ao R quais são as variáveis categóricas que estão erroneamente classificadas como numéricas pelo R (isso acontece quando números são utilizados para codificar as categorias).
- (e) Calcule as medidas resumo das variáveis presentes no banco.
- (f) Construa tabelas de frequência para as variáveis de maior interesse.
- (g) Construa gráficos para o tempo de sobrevivência e para outras variáveis de interesse.

Dicas

- Para abrir e verificar as dimensões dos dados, use a função `dim()`:

```
> ipec <- read.table("ipec.csv",header=T,sep=";")
> dim(ipec)
```

- Para listar os nomes das variáveis, use: `names(ipec)`
- Para inspecionar algumas linhas do banco de dados, use: `head(ipec)` ou `tail(ipec)`
- Para substituir por *NA* o código 99 utilizado no banco para dado faltante, use:

```
> ipec$nomedavariavel[ipec$nomedavariavel==99]<-NA
```

- Para indicar ao R quais são as variáveis que representam variáveis categóricas, use o comando `factor`:

```
> ipec$nomedavariavel <- factor(ipec$nomedavariavel)
```

- Para renomear as categorias (*labels*) dos fatores, acrescente ao comando `factor` o argumento `labels`, acompanhado de uma listagem das novas categorias que segue a ordenação numérica das categorias originais. Por exemplo, a variável *escola* (escolaridade) está codificada como: 0: Sem nenhuma escolaridade, 1: Ensino Fundamental, 2: Ensino Médio, 3: Ensino Superior. Para substituir os números por nomes, o comando deve ser:

```
> ipec$escola <- factor(ipec$escola, labels =
  c("sem", "fundam", "médio", "sup"))
```

- Para obter as medidas resumo de todas as variáveis, utilize: `> summary(ipec)`
- Para as variáveis categóricas pode-se também utilizar a função `table()` para obter as tabelas de frequência.
- Para fazer um box-plot, use o comando:

```
> boxplot(y ~ x, data=dados, main="Título",
  ylab="Y", xlab="X")
```

- Para fazer um histograma:

```
> hist(dados$y, breaks=12, main="Título",
  ylab="Frequência", xlab="Y")
```

- Importação de dados e transformação de variáveis são facilmente realizáveis no ambiente do *Rcmdr*, no menu *Dados*.

3

Funções básicas de sobrevivência

Ao término do Capítulo 3, espera-se que o leitor seja capaz de:

Definir e interpretar as funções que descrevem a sobrevivência: função de sobrevivência, de risco e de risco acumulado

Indicar as relações matemáticas entre as funções de sobrevivência.

Estimar e representar graficamente as funções de sobrevivência a partir de um conjunto de dados.

3.1 Introdução

Uma coorte de 50 pacientes é acompanhada por quatro anos (1.460 dias) para estudar a sobrevivência após o diagnóstico de Aids. Ao longo desse período 32 óbitos foram observados. Uma forma de descrever esse processo seria calcular a taxa de mortalidade média do grupo, dividindo-se o total de óbitos pelo total de pessoas-tempo de observação. A taxa de mortalidade média nos 4 anos de acompanhamento foi de $32/50 = 0,64$. A cada ano essa taxa de mortalidade média foi de $(0,64 \times 100)/4 \text{ anos} = 16 \text{ óbitos por } 100 \text{ pessoas-ano}$.

Entretanto, se essa taxa não é a mesma ao longo do tempo, a simples média de eventos por unidade de pessoa-tempo não descreve adequadamente o fenômeno: a probabilidade de um paciente vir a morrer de Aids é uma função que depende do tempo desde o diagnóstico. A análise de sobrevivência permite tratar de problemas nos quais a ocorrência do evento não é constante ao longo do tempo.

Empregando as técnicas de análise de sobrevivência podemos responder questões do tipo:

- Qual o **risco** de um paciente diagnosticado com Aids vir a falecer **em até** três anos após o diagnóstico?
- Qual a **probabilidade** de um paciente sobreviver por **mais de** dois anos após o diagnóstico de Aids?
- Qual seria o **número esperado** de óbitos em uma coorte de pacientes acompanhada por cinco anos?
- Qual o **tempo mediano** de sobrevivência?

Neste capítulo serão definidas as funções básicas da análise de sobrevivência. Por meio dessas funções será possível responder às questões acima, nas quais o processo de ocorrência dos eventos ao longo do tempo é o foco de interesse.

3.2 Função densidade de probabilidade

No capítulo anterior, definimos a variável T como o tempo de sobrevivência, isto é, o tempo até a ocorrência de um evento. T é considerada uma variável aleatória contínua e positiva com função de densidade de probabilidade denominada $f(t)$. No contexto da análise de sobrevivência, a função $f(t)$ pode ser interpretada como a probabilidade de um indivíduo sofrer um evento em um intervalo instantâneo de tempo:

$$f(t) = \lim_{\epsilon \rightarrow 0^+} \frac{Pr(t \leq T < t + \epsilon)}{\epsilon}, \quad (3.1)$$

em que ϵ é o incremento de tempo infinitamente pequeno.

Se não houver censura, isso é, se todos os pacientes apresentarem o evento antes do fim do estudo, a função $f(t)$ pode ser estimada a partir dos tempos em que ocorrem os eventos. Suponha que 32 pacientes diagnosticados com Aids foram acompanhados ao longo do tempo, e que todos faleceram antes do fim do estudo. Vejamos os dados na Tabela 3.1:

Tabela 3.1: Tempos de sobrevivência de 32 pacientes com Aids que morreram antes do fim do estudo

3	18	29	54	60	84	110	112	116	123	134
145	151	151	158	173	194	214	329	331	371	408
490	514	541	555	688	780	801	858	887	998	

Nesse caso, o valor observado de T – o momento de um (ou mais) eventos – está relacionado à amplitude do intervalo x entre o evento anterior e o atual, calculando-se $f_x(t)$:

$$\hat{f}_x(t) = \frac{N_x(t)}{(\text{n}^\circ \text{ total de ocorrências}) \times \Delta_x}, \quad (3.2)$$

em que x é o índice do intervalo (1, 2, ...), $N_x(t)$ é o número de ocorrências no intervalo de tempo x e Δ_x é a amplitude do intervalo de tempo x . Observe que com esta definição a probabilidade de ocorrência do evento permanece constante dentro do intervalo de tempo entre o evento anterior e o atual.

A Tabela 3.2 mostra a função de densidade de probabilidade estimada para os dados não censurados da coorte de pacientes com Aids. Observe que a função de densidade do tempo de sobrevivência não é constante ao longo do tempo. Para os 32 pacientes com tempos não censurados o cálculo é simples. Por exemplo, para o intervalo (18, 29], teremos $\hat{f}_{(18,29]}(t) = \frac{1}{32 \times 11} = 0,00284$.

Tabela 3.2: Função de densidade do tempo até o óbito após o diagnóstico de Aids dos primeiros pacientes da Tabela 3.1

Intervalo	$R_x(t)$ risco	$N_x(t)$ eventos	Δ_x amplitude do intervalo	$\hat{f}_x(t)$ função de densidade
(0,3]	32	1	3	0,01042
(3,18]	31	1	15	0,00208
(18,29]	30	1	11	0,00284
(29,54]	29	1	25	0,00125
(54,60]	28	1	6	0,00521
(60,84]	27	1	24	0,00130
(84,110]	26	1	26	0,00120
(110,112]	25	1	2	0,01563
(112,116]	24	1	4	0,00781
(116,123]	23	1	7	0,00446
(123,134]	22	1	11	0,00284
(134,145]	21	1	11	0,00284
(145,151]	20	2	6	0,01042
(151,158]	18	1	7	0,00446
(158,173]	17	1	15	0,00208
⋮				

3.3 Função de sobrevivência

Qual é a probabilidade de um paciente com Aids sobreviver por mais de 365 dias? Isto é, qual a probabilidade de T ser maior do que um determinado valor $t = 365$? Ou, mais formalmente, qual é $Pr(T > 365)$?

Define-se função de sobrevivência, $S(t)$, como a probabilidade de um indivíduo sobreviver por mais do que um determinado tempo t , ou por no mínimo um tempo igual a t :

$$S(t) = Pr(T > t). \quad (3.3)$$

Relembrando, de algum curso básico de estatística, que a função de distribuição acumulada $F(t)$ de uma variável aleatória, no caso o tempo de sobrevivência T , é definida como a probabilidade de um evento ocorrer até o tempo t :

$$F(t) = Pr(T \leq t). \quad (3.4)$$

Fica claro que, a partir dessa definição, $S(t)$ é simplesmente o complemento da função de distribuição acumulada $F(t)$:

$$S(t) = Pr(T > t) = 1 - Pr(T \leq t) = 1 - F(t). \quad (3.5)$$

A Figura 3.1 ilustra uma curva teórica da função de sobrevivência. Esta se caracteriza por começar sempre com $S(0) = 1$, ou seja, a probabilidade de um indivíduo sobreviver por mais de 0 dias é 1. À medida que o tempo passa, $S(t)$ decresce ou permanece constante e no limite, quando $t \rightarrow \infty$, $S(\infty) = 0$.

A partir da função de sobrevivência, é possível calcular os percentis de T . Observando a Figura 3.1 vemos que o tempo de sobrevivência mediano foi de 35 unidades de tempo, pois este é o tempo no qual espera-se que 50% dos pacientes não tenham sofrido o evento ($S(35) = 0,5$).

Considerando os 32 pacientes com Aids temos que a probabilidade de sobreviver mais que 18 dias ($S(18)$) é dada por:

$$\begin{aligned} \hat{F}(18) &= \widehat{Pr}(T \leq 18) = \frac{2}{32} = 0,06250 \\ \hat{S}(18) &= \widehat{Pr}(T > 18) = 1 - \hat{F}(18) = 0,93750. \end{aligned}$$

Assim como $f(t)$, a função de sobrevivência também pode ser estimada diretamente a partir dos dados quando não há censura.




Figura 3.1: Curva teórica da função de sobrevivência indicando o tempo mediano (35 unidades de tempo)

Voltando ao problema da coorte de Aids, vamos acrescentar uma coluna à Tabela 3.2 para calcular $S(t)$, da seguinte forma:

$$\hat{S}_x(t) = \frac{R_x(t)}{\text{n}^\circ \text{ total de pacientes}}. \quad (3.6)$$

em que $R_x(t)$ é o número de pessoas sob risco no início do intervalo de tempo x . Substituindo pelos valores da Tabela 3.2, teremos:

$$\hat{S}_{(18,29]}(t) = \frac{R_{(18,29]}(t)}{32} = \frac{30}{32} = 0,93750.$$

Assim, a probabilidade de um paciente sobreviver por mais de 116 dias é 0,71875, mais de 145 dias é 0,62500. O tempo de sobrevivência mediano não pode ser visto nesta tabela, que só vai até a probabilidade de sobrevivência de 0,53125. A Figura 3.2 (A) mostra a curva estimada de sobrevivência para esta coorte, e nesta podemos ver o tempo de sobrevivência mediano: 173 dias.

Tabela 3.3: Cálculo da função de sobrevivência dos 32 pacientes da coorte de Aids (Tabela 3.1)

Intervalo	$R_x(t)$ (risco)	$N_x(t)$ (eventos)	$\hat{f}_x(t)$ (densidade)	$\hat{S}_x(t)$ (sobrevivência)
(0,3]	32	1	0,01042	1,00000
(3,18]	31	1	0,00208	0,96875
(18,29]	30	1	0,00284	0,93750
(29,54]	29	1	0,00125	0,90625
(54,60]	28	1	0,00521	0,87500
(60,84]	27	1	0,00130	0,84375
(84,110]	26	1	0,00120	0,81250
(110,112]	25	1	0,01563	0,78125
(112,116]	24	1	0,00781	0,75000
(116,123]	23	1	0,00446	0,71875
(123,134]	22	1	0,00284	0,68750
(134,145]	21	1	0,00284	0,65625
(145,151]	20	2	0,01042	0,62500
⋮				

3.4 Função de risco (*hazard*)

Qual é o risco de um paciente com Aids vir a óbito após sobreviver 365 dias? Esse risco de morrer aumenta ou diminui com o tempo? A função de risco, $\lambda(t)$, é definida como o risco instantâneo de um indivíduo sofrer o evento entre o tempo t e $t + \epsilon$, dado que ele sobreviveu até o tempo t . Como ϵ , o incremento de tempo considerado, pode ser infinitamente pequeno, a função de risco expressa o risco instantâneo de ocorrência de um evento, dado que até então o evento não tenha ocorrido.




Figura 3.2: (A) Função de sobrevivência indicando o tempo de sobrevivência mediano e (B) Função de risco acumulado, estimadas para os dados de Aids (Tabela 3.1)

Matematicamente, a definição de risco pode ser expressa pela fórmula:

$$\lambda(t) = \lim_{\epsilon \rightarrow 0} \frac{Pr[(t \leq T < t + \epsilon) | T \geq t]}{\epsilon}.$$

A função de risco, $\lambda(t)$, também é chamada de função ou taxa de incidência, força de infecção, taxa de falha, força de mortalidade ou força de mortalidade condicional. É importante ressaltar que apesar de se utilizar o nome risco, $\lambda(t)$ é uma taxa, e não uma probabilidade. Sua unidade é tempo^{-1} e pode assumir qualquer valor real maior do que zero, não estando restrita ao intervalo $[0, 1]$.

A função de risco está relacionada com a função de sobrevivência através das expressões:

$$\lambda(t) = \frac{f(t)}{S(t)} \quad (3.7)$$

$$\lambda(t) = -\frac{d \ln(S(t))}{dt}, \quad (3.8)$$

onde $\ln$ é o logaritmo neperiano e d representa o operador derivada. Através das expressões acima, pode-se observar que as funções de

sobrevivência e de risco são inversamente proporcionais: quando o risco aumenta, a probabilidade de sobrevivência diminui e vice-versa.

A função de risco pode ser estimada a partir dos dados na ausência de censura, dividindo-se o número de eventos observados em cada intervalo de tempo ($N_x(t)$) pelo número de pessoas sob risco no início do intervalo ($R_x(t)$). Esta fração é, então, dividida pela amplitude do intervalo Δ_x para se obter uma medida instantânea:

$$\hat{\lambda}_x(t) = \frac{N_x(t)}{R_x(t) \times \Delta_x}. \quad (3.9)$$

Uma alternativa para estimar $\lambda(t)$ é utilizar as relações entre $S(t)$, $f(t)$ e $\lambda(t)$ descritas pelas equações (3.7) e (3.8).

A Tabela 3.4 mostra a estimativa da função de risco para os dados de Aids da Tabela 3.1. Apresentamos a forma direta de calcular, sem recorrer às funções $S(t)$ e $f(t)$. Mas o resultado é exatamente o mesmo. Veja, por exemplo, o risco no intervalo (18, 29]: estimando por meio da relação $f(t)/S(t)$, obteríamos $0,00284/0,93750 = 0,00303$.

A função de risco instantâneo, quando estimada para dados esparsos como os da Tabela 3.4, não permite identificar padrões, pois flutua muito. Entretanto, a mesma estimativa aplicada a dados agregados em classes de tempo, por exemplo, a cada 6 meses, pode indicar uma tendência do risco instantâneo ao longo do tempo. Todas as funções apresentadas até aqui – densidade, sobrevivência, risco instantâneo – podem ser aplicadas a dados tabulares, o que é feito nas tábuas de vida comuns em demografia.

3.5 Comportamento da função de risco

A função de risco permite analisar o risco de um indivíduo sofrer um evento em um determinado tempo t , dado que ele já sobreviveu até aquele momento. Por exemplo, qual é o risco de um paciente falecer logo após uma cirurgia? Será que o risco de vir a óbito no primeiro dia pós-cirúrgico é o mesmo de vir a óbito no trigésimo dia?

Tabela 3.4: Estimativa da função de risco para os dados de Aids (veja também Tabelas 3.2 e 3.3)

Intervalo	$R_x(t)$	$N_x(t)$	Δ_x	$\hat{f}_x(t)$	$\hat{S}_x(t)$	$\hat{\lambda}_x(t)$
(0,3]	32	1	3	0,01042	1,00000	$\frac{1}{32 \times 3} = 0,01042$
(3,18]	31	1	15	0,00208	0,96875	$\frac{1}{31 \times 15} = 0,00215$
(18,29]	30	1	11	0,00284	0,93750	$\frac{1}{30 \times 11} = 0,00303$
(29,54]	29	1	25	0,00125	0,90625	$\frac{1}{29 \times 25} = 0,00138$
(54,60]	28	1	6	0,00521	0,87500	$\frac{1}{28 \times 6} = 0,00595$
(60,84]	27	1	24	0,00130	0,84375	$\frac{1}{27 \times 24} = 0,00154$
(84,110]	26	1	26	0,00120	0,81250	$\frac{1}{26 \times 26} = 0,00148$
(110,112]	25	1	2	0,01563	0,78125	$\frac{1}{25 \times 2} = 0,02000$
(112,116]	24	1	4	0,00781	0,75000	$\frac{1}{24 \times 4} = 0,01042$
(116,123]	23	1	7	0,00446	0,71875	$\frac{1}{23 \times 7} = 0,00621$
(123,134]	22	1	11	0,00284	0,68750	$\frac{1}{22 \times 11} = 0,00413$
(134,145]	21	1	11	0,00284	0,65625	$\frac{1}{21 \times 11} = 0,00433$
(145,151]	20	2	6	0,01042	0,62500	$\frac{2}{20 \times 6} = 0,01667$
(151,158]	18	1	7	0,00446	0,56250	$\frac{1}{18 \times 7} = 0,00794$
(158,173]	17	1	15	0,00208	0,53125	$\frac{1}{17 \times 15} = 0,00392$
:						

É provável que não. O risco de óbito devido a uma cirurgia diminui com o tempo.

Voltando ao exemplo da Aids. Como a Aids é uma doença que vai comprometendo o sistema imunológico, supor risco constante não parece razoável. Antes da existência do tratamento antirretroviral, a hipótese de um risco de óbito sempre crescente a partir da data do diagnóstico parecia razoável. Porém, após a introdução da terapia antirretroviral de alta potência, será que essa hipótese continua válida? Podemos supor, por exemplo, uma alternativa mais complexa, em que o risco de um paciente seria alto logo depois do diagnóstico, devido à presença de doenças oportunistas. Nos primeiros anos, graças ao

tratamento, o risco de óbito decresceria, voltando a aumentar tardiamente devido à diminuição do efeito do tratamento. Na Figura 3.3 estão apresentados graficamente vários comportamentos teóricos possíveis para a função de risco. Vamos examinar em detalhes cada uma dessas funções.

A Figura 3.3A mostra uma situação em que o risco é constante ao longo do tempo. Este padrão é esperado, por exemplo, para o risco de acontecer uma fratura numa população de escolares no decorrer de 12 meses. Algumas crianças eventualmente terão fraturas, e a ocorrência deste evento, no limite de tempo de observação de 12 meses, pode ser considerada um evento com probabilidade aproximadamente constante se as atividades que expõem as crianças à ocorrência de fraturas forem as mesmas durante todo o período. Quando o risco é constante no tempo, pode-se dizer que a ocorrência do evento é **sem memória**, ou seja, a chance de ocorrer uma fratura nesses 12 meses é independente do tempo decorrido.

A Figura 3.3B mostra uma curva decrescente de risco. Este padrão pode ser encontrado, por exemplo, para o óbito pós-cirúrgico, onde o risco é maior nos primeiros dias, caindo rapidamente a zero com o passar do tempo.

A Figura 3.3C mostra uma curva de risco crescente que poderia ser encontrada, por exemplo, em um estudo sobre o tempo até a solidificação de uma fratura óssea. O “risco” de solidificação, que nos primeiros dias é praticamente nulo, vai aumentando com o passar do tempo, até que praticamente todas as fraturas estejam solidificadas. Vale ressaltar que o evento neste caso é a cura!

As Figuras 3.3D, E e F mostram padrões mais complexos de risco. A curva D mostra um risco que é constante e igual a zero no início do período, cresce entre o quinto e o 25^o mês e se estabiliza depois. Este gráfico poderia descrever a ocorrência de metástases de câncer: no período inicial, durante a quimioterapia, o risco de surgimento é baixo e não varia, aumenta em seguida, e após um tempo (25 meses, neste caso) fica aproximadamente constante até decair novamente. Já na Figura 3.3E, o risco começa alto, decai após um certo tempo e volta a subir, reproduzindo o possível comportamento

da mortalidade por Aids após a introdução das terapias antirretrovirais. Na Figura 3.3F, o risco sobe rapidamente no início do período de observação, e cai rapidamente depois. Um exemplo deste último comportamento é apresentado pela tuberculose, em que o risco de óbito cai rapidamente após a introdução dos tuberculostáticos.

3.6 Função de risco acumulado

Qual o risco de um paciente com Aids vir a óbito no primeiro ano após o diagnóstico? E nos primeiros dois anos? A função de risco acumulado $\Lambda(t)$ mede o risco de ocorrência do evento até um determinado tempo t . Matematicamente, isso significa a soma de todos os riscos em todos os tempos até o tempo t . Como T é uma variável aleatória contínua, esta é uma soma infinitesimal e pode ser calculada a partir de uma integral da função de risco:

$$\Lambda(t) = \int_0^t \lambda(u) d(u). \quad (3.10)$$

Note que, assim como o risco, o risco acumulado também é uma taxa e não está restrito ao intervalo $[0, 1]$. A expressão (3.10) pode ser reescrita utilizando-se as relações entre função de risco e função de sobrevivência, o que resulta em:

$$\Lambda(t) = -\ln(S(t)). \quad (3.11)$$

A função de risco acumulado pode ser estimada, na ausência de censura, a partir da função risco. Considere que o risco acumulado do primeiro intervalo $\hat{\Lambda}_1(t)$ é zero. Para cada intervalo posterior, o risco acumulado é soma dos riscos anteriores multiplicados pelos respectivos intervalos de tempo, como mostra a expressão a seguir:

$$\hat{\Lambda}_x(t) = \sum_{k=1}^{x-1} \hat{\lambda}_k(t) \times \Delta_k. \quad (3.12)$$

Retornando ao exemplo da Aids, a Tabela 3.5 mostra a estimativa de $\hat{\Lambda}(t)$ para esses dados sem censura e a Figura 3.2 (B) a curva resultante.




Figura 3.3: Função de risco com diversos formatos

Tabela 3.5: Estimativa da função de risco acumulado para os dados de Aids utilizando estimativas calculadas nas Tabelas 3.3 e 3.4

Intervalo	Δ_x	$f_x(t)$	$S_x(t)$	$\lambda_x(t)$	$\hat{\Lambda}_x(t)$
(0,3]	3	0,01042	1,00000	0,01042	$\hat{\Lambda}(0) = 0$
(3,18]	15	0,00208	0,96875	0,00215	$\hat{\Lambda}(3) = 0, 01042 \times 3 = 0, 031250$
(18,29]	11	0,00284	0,93750	0,00303	$\hat{\Lambda}(29) = 0, 00215 \times 15 + 0, 031250 = 0, 063508$
(29,54]	25	0,00125	0,90625	0,00138	$\hat{\Lambda}(54) = 0, 00303 \times 11 + 0, 063508 = 0, 096841$
(54,60]	6	0,00521	0,87500	0,00595	$\hat{\Lambda}(60) = 0, 00138 \times 25 + 0, 096841 = 0, 131324$
(60,84]	24	0,00130	0,84375	0,00154	$\hat{\Lambda}(84) = 0, 00595 \times 6 + 0, 131324 = 0, 167038$
(84,110]	26	0,00120	0,81250	0,00148	$\hat{\Lambda}(110) = 0, 00154 \times 24 + 0, 167038 = 0, 204075$
(110,112]	2	0,01563	0,78125	0,02000	$\hat{\Lambda}(112) = 0, 00148 \times 26 + 0, 204075 = 0, 242537$
(112,116]	4	0,00781	0,75000	0,01042	$\hat{\Lambda}(116) = 0, 02000 \times 2 + 0, 242537 = 0, 282537$
(116,123]	7	0,00446	0,71875	0,00621	$\hat{\Lambda}(123) = 0, 01042 \times 4 + 0, 282537 = 0, 324204$
(123,134]	11	0,00284	0,68750	0,00413	$\hat{\Lambda}(134) = 0, 00621 \times 7 + 0, 324204 = 0, 367682$
(134,145]	11	0,00284	0,65625	0,00433	$\hat{\Lambda}(145) = 0, 00413 \times 11 + 0, 367682 = 0, 413136$
(145,151]	6	0,01042	0,62500	0,01667	$\hat{\Lambda}(151) = 0, 00433 \times 11 + 0, 413136 = 0, 460756$
(151,158]	7	0,00446	0,56250	0,00794	$\hat{\Lambda}(158) = 0, 01667 \times 6 + 0, 460756 = 0, 560756$
(158,173]	15	0,00208	0,53125	0,00392	$\hat{\Lambda}(173) = 0, 00794 \times 7 + 0, 560756 = 0, 616311$
...					

3.7 Relação entre as funções

As funções básicas descritas neste capítulo, $f(t)$, $S(t)$, $\lambda(t)$ e $\Lambda(t)$ são relacionadas entre si. Assim, ao estimar a função de sobrevivência $S(t)$, obtém-se também as funções de risco e de risco acumulado a partir do logaritmo de $S(t)$. Se a função de risco $\lambda(t)$ é estimada, pode-se obter a função de risco acumulado $\Lambda(t)$, e a partir dela, a função de sobrevivência $S(t)$. Essas funções são matematicamente equivalentes e representam diferentes formas de descrever o mesmo fenômeno (Tabela 3.6). Elas respondem às três perguntas básicas da análise de sobrevivência:

- Qual a probabilidade de sobreviver por mais de t unidades de tempo? Função de sobrevivência.
- Qual o risco de sofrer o evento no tempo t se sabemos que o paciente sobreviveu até aquele momento? Função de risco.
- Qual o risco de sofrer o evento até um determinado tempo t ? Função de risco acumulado.

Tabela 3.6: Relação entre as funções básicas de sobrevivência

$S(t) = 1 - F(t)$ $\lambda(t) = -\frac{d \ln(S(t))}{dt}$ $\lambda(t) = \frac{f(t)}{S(t)}$ $\lambda(t) = \frac{f(t)}{1 - F(t)}$ $\Lambda(t) = -\ln(S(t))$ $S(t) = \exp(-\Lambda(t))$

3.8 Função de verossimilhança

A função de verossimilhança está na base da modelagem estatística. Através dessa função se avalia o quanto os dados apoiam, concordam ou suportam cada valor possível do parâmetro a ser estimado. Ou seja, é uma medida de concordância entre os dados e os possíveis valores do parâmetro, daí decorrendo o nome função de **verossimilhança**. É uma função: a cada valor na escala do parâmetro – por exemplo entre 0 e 1 para o parâmetro da distribuição Bernouli (p) – corresponde um valor de verossimilhança. Suponhamos por exemplo uma amostra de uma população para avaliar hipertensão. Nessa amostra, 10% dos participantes são hipertensos. É evidente que a verossimilhança da proporção de hipertensos na população ser 90% é baixíssima. Por outro lado, à medida que nos aproximamos de 10%, a verossimilhança aumenta, tornando a baixar quando os valores possíveis dessa proporção se aproximam de zero. Ou seja, temos uma função contínua, que cobre todo o espaço possível do parâmetro. O método de estimação denominado método da máxima verossimilhança (MMV) é exatamente o que o nome diz: considera que a melhor estimativa possível para o parâmetro populacional é o valor que maximiza a função de verossimilhança obtida dos dados amostrais.

São pressupostos básicos: observações independentes e tempos de sobrevivência e de censura também independentes. Dessa forma, a contribuição conjunta de todas as observações para a função de verossimilhança é dada pelo produto da probabilidade de ocorrência do evento para cada observação.

No contexto de análise de sobrevivência, entretanto, só conhecemos o tempo exato de sobrevivência para os que sofreram o evento, e por isso somente para esses é possível calcular a probabilidade exata do evento ocorrer através da função de densidade $f(t)$. Assim, no caso de dados sem censura, a função de verossimilhança $\mathcal{L}$, para i indivíduos na amostra, toma a seguinte forma:

$$\mathcal{L} \propto \prod_i f(t_i). \quad (3.13)$$

Quando há censura à direita, sabemos apenas que o tempo de sobrevivência exato é maior que o observado. Logo, a contribuição da observação censurada à direita é dada pela função de sobrevivência e a função de verossimilhança é proporcional à:

$$\mathcal{L} \propto \prod_{i \in O} f(t_i) \prod_{i \in D} S(t_i), \quad (3.14)$$

em que O é o conjunto de observações que sofreram o evento e D é o conjunto de observações que foram censuradas à direita.

Quando existe censura à esquerda sabemos somente que o tempo de sobrevivência exato é menor que o observado e consequentemente a contribuição dessas observações é dada pela função de distribuição acumulada $F(t) = 1 - S(t)$. Nesse caso, a função de verossimilhança fica assim definida:

$$\mathcal{L} \propto \prod_{i \in O} f(t_i) \prod_{i \in D} S(t_i) \prod_{i \in E} [1 - S(t_i)], \quad (3.15)$$

em que E é o conjunto de observações que foram censuradas à esquerda.

Para as censuras intervalares sabemos a probabilidade de ocorrência do evento dentro de um intervalo de tempo t^- e t^+ . A inclusão dessas observações faz com que a função de verossimilhança tenha a seguinte forma:

$$\mathcal{L} \propto \prod_{i \in O} f(t_i) \prod_{i \in D} S(t_i) \prod_{i \in E} [1 - S(t_i)] \prod_{i \in I} [S(t_i^-) - S(t_i^+)], \quad (3.16)$$

sendo I é o conjunto de observações que sofreram censuras intervalares.

Quando as observações são truncadas, as probabilidades acima descritas são substituídas por probabilidades condicionais na construção da verossimilhança. Ou seja, a probabilidade de observarmos um evento está condicionada à probabilidade do indivíduo ser incluído no estudo. Claro, a probabilidade de indivíduos com tempo de sobrevivência muito pequeno serem incluídos no estudo é menor do que a de indivíduos com tempo de sobrevivência grande.

Assim, para observações truncadas à esquerda, quando a janela temporal do estudo é definida em (T_E, T_D) , a probabilidade do evento ocorrer, dada por $f(t_i)$, passa a ser condicionada ao fato de o indivíduo ter sobrevivido até o início da janela temporal do estudo. Ou seja, matematicamente, a contribuição de um indivíduo para a função de verossimilhança deverá ser ponderada pela função de sobrevivência no início do estudo ($f(t)/S(t_E)$). No caso do truncamento à direita, a contribuição individual para a função de verossimilhança é dada por $f(t_i)/[1 - S(t_i)]$, ou seja, a função de densidade é ponderada pela probabilidade acumulada de ocorrência do evento $F(t_i) = 1 - S(t_i)$.

Resumo

Neste capítulo vimos as funções básicas da análise de sobrevivência, a forma de estimá-las e a relação entre elas (Tabela 3.6):


- Função de sobrevivência: $S(t) = Pr(T > t)$;
- Função de risco: $\lambda(t) = \lim_{\epsilon \rightarrow 0} \frac{Pr[(t \leq T < t + \epsilon) | T \geq t]}{\epsilon}$;
- Função de risco acumulado: $\Lambda(t) = \int_0^t \lambda(u) du$.

A contribuição para a função de verossimilhança de cada indivíduo de acordo com o tipo de censura é:

- Tempo exato ($T_i = t_i$): $f(t_i)$;
- Censura à direita ($T_i > t_i^-$): $S(t_i^-)$;
- Censura à esquerda ($T_i < t_i^+$): $1 - S(t_i^+) = F(t_i^+)$;
- Censura intervalar ($t^- < T < t^+$): $S(t_i^-) - S(t_i^+)$.

Exercícios

3.1 A figura a seguir mostra uma curva de sobrevivência. Com base nesta curva, identifique:



- (a) A probabilidade de sobreviver por mais de 10 dias.
- (b) A sobrevivência mediana e o tempo mediano de sobrevivência.
- (c) O tempo em que 80% dos pacientes ainda estavam vivos.

3.2 Sabendo-se que a probabilidade de sobreviver por mais de 100 dias após o transplante de coração é igual a 0,7, calcule:

- (a) A probabilidade de sobreviver por, no máximo, 100 dias (inclusive).
- (b) O risco acumulado do óbito ocorrer em até 100 dias (ou seja, no máximo em 100 dias).
- (c) O risco acumulado do óbito ocorrer após 100 dias (ou seja, no mínimo em 100 dias).

3.3 A tabela a seguir mostra o tempo até o óbito de todos pacientes de uma coorte de 32 indivíduos vivendo com Aids, não havendo tempos censurados. Complete as lacunas em branco na tabela usando as definições e as relações entre as funções básicas de sobrevivência, onde T é o tempo até o óbito, $R(t)$ é o número de pessoas sob risco no início do intervalo de tempo e $N(t)$ é o número de óbitos ocorridos no intervalo de tempo.

3.4 Lembrando que o evento é óbito em pacientes vivendo com Aids, e interpretando a tabela do exercício anterior, responda:

- (a) Qual o tempo mediano de sobrevivência desta coorte ?
- (b) O que significa o valor atribuído a $\hat{S}(214)$?
- (c) O que significa o valor atribuído a $\hat{F}(214)$?
- (d) O que significa o valor atribuído a $\hat{\lambda}(214)$?
- (e) O que significa o valor atribuído a $\hat{\Lambda}(214)$?

t	Intervalo	$\Delta_x(t)$	$R(t)$	$N(t)$	Eventos acumulados	$\hat{f}(t)$	$\hat{F}(t)$	$\hat{S}(t)$	$\hat{\lambda}(t)$	$\hat{\Lambda}(t)$
0	0	0	32	0	0					
0	(0,3]	3	32	1	1	0,0104	0,000	1,000	0,0104	0
3	(3,18]	15	31	1	2	0,0021	0,031	0,968	0,0022	0,031
18	(18,29]	11	30	1	3	0,0028	0,062	0,937	0,0030	0,063
29	(29,54]	25	29	1	4	0,0013	0,093	0,906	0,0014	0,096
54				1						
60				1						
84	(84,110]	26	26	1		0,0012	0,187	0,812	0,0015	0,204
110	(110,112]	2	25	1		0,0156	0,218	0,781	0,0200	0,242
112				1						
116				1						
123				1						
134				1						
145	(145,151]			1						
151	(151,158]			2						
158	(158,173]			1						
173	(173,194]			1						
194				1						
214	(214,329]			1						
329	(329,331]	2	14	1		0,003	0,562	0,437	0,0006	0,804
331	(331,371]	40	13	1		0,0156	0,593	0,406	0,0385	0,875

4

Estimação não paramétrica

Ao término do Capítulo 4, espera-se que o leitor seja capaz de:

Estimar a função de sobrevivência através do estimador produto de Kaplan-Meier.

Estimar a função de risco acumulado através do estimador de Nelson-Aalen.

Construir e interpretar os intervalos de confiança dessas estimativas.

Interpretar o tempo de sobrevivência mediano.

Estimar a função de sobrevivência de Kaplan-Meier estratificando por covariáveis.

Aplicar e interpretar os testes de log-rank e Peto.

4.1 Introdução

Nos Capítulos 2 e 3, foram definidos os conceitos e os dados necessários para analisar o tempo de sobrevivência. Foram apresentadas as quatro funções básicas, $f(t)$, $S(t)$, $\lambda(t)$ e $\Lambda(t)$, e um método simples

de estimação destas funções que pode ser utilizado quando não há censura. O método que foi apresentado, porém, é de uso limitado, uma vez que a ocorrência de censura é mais regra do que exceção. Por exemplo, a coorte de pacientes com Aids acompanhada no Ipec, apresentada no Capítulo 2, possui registro de 193 pacientes. Destes, apenas 90 foram acompanhados até a ocorrência do óbito. Os 103 restantes foram censurados à direita, por perda de seguimento ou por estarem vivos no fim do estudo. A Tabela 4.1 apresenta os tempos de sobrevivência de 21 pacientes desta coorte com tempos de sobrevivência menor que 90 dias.

Tabela 4.1: Tempo de sobrevivência (em dias) de alguns pacientes da coorte de Aids do Ipec

60	84	25+	54	80+	37	18	29	50+	83	80
81+	35	52	21	40	22	85+	39	16	21+	

Neste capítulo, veremos duas formas não paramétricas de estimação das funções básicas de sobrevivência, bem como a variabilidade dessas estimativas, quando os tempos de sobrevivência incluem observações censuradas. O estimador Kaplan-Meier, também conhecido como estimador produto-limite, será utilizado para estimar a função de sobrevivência, $S(t)$, e o estimador de Nelson-Aalen para estimar a função de risco acumulado, $\Lambda(t)$. Na abordagem não paramétrica não é feita qualquer suposição sobre a distribuição probabilística do tempo de sobrevivência T , e assim não são estimados parâmetros estatísticos.

4.2 Estimador produto de Kaplan-Meier

Vimos no Capítulo 3 que, se todos os indivíduos fossem acompanhados até a ocorrência do evento, a função de sobrevivência, em cada

tempo t , $S(t) = Pr(T > t)$, poderia ser estimada a partir dos dados observados como a proporção dos indivíduos que sobreviveram além do tempo t (Equação (3.6)).

Como estimar $S(t)$ quando há indivíduos censurados? Por exemplo, considere o terceiro indivíduo listado na Tabela 4.1, censurado no 25º dia de acompanhamento. Até a data de sua saída, sabia-se que estava vivo; logo, para calcular $S(t)$ para $t < 25$, poderíamos incluí-lo tanto no numerador (ele era um sobrevivente, neste período), como no denominador (ele fazia parte do grupo de risco). E a partir do dia 25? Não podemos mais garantir se ele é um sobrevivente ou não, pois não estava mais sendo acompanhado e também não se pode incluí-lo no grupo sob risco, pelo mesmo motivo.

O estimador de Kaplan-Meier traz uma solução para esse problema. Ele utiliza os conceitos de independência de eventos e de probabilidade condicional para desdobrar a condição de sobreviver até o tempo t em uma sequência de elementos independentes que caracterizam a sobrevivência em cada intervalo de tempo anterior a t , cuja probabilidade é condicional aos que estão em risco em cada período.

A expressão **estimador produto** refere-se ao fato de que a ocorrência dos eventos são independentes e conseqüentemente a função de sobrevivência é estimada utilizando o produto das probabilidades de sobrevivência até o tempo t .

Sejam $t_1 < t_2 < \dots < t_m$ os m diferentes tempos onde ocorreram os eventos em uma amostra com n indivíduos. Denota-se $R(t_j)$ o número de pessoas no grupo de risco no tempo t_j e $\Delta N(t_j)$ o número total de eventos ocorridos precisamente em t_j . Assim, para os m tempos t_j em que ocorre um evento, a probabilidade de sobrevivência será estimada pelo número de sobreviventes no tempo t_j ($R(t_j) - \Delta N(t_j)$) sobre os que estavam em risco naquele tempo ($R(t_j)$). Como os eventos são independentes, a função de sobrevivência $S(t)$ é estimada empiricamente pelo produto das probabilidade de sobrevivência a cada tempo $t_j \leq t$:

$$\begin{aligned}
 \hat{S}_{\text{km}}(t) &= \frac{R(t_1) - \Delta N(t_1)}{R(t_1)} \times \frac{R(t_2) - \Delta N(t_2)}{R(t_2)} \times \dots \\
 &\times \frac{R(t_m) - \Delta N(t_m)}{R(t_m)} = \\
 &= \prod_{j:t_j \leq t} \frac{R(t_j) - \Delta N(t_j)}{R(t_j)} = \\
 &= \prod_{j:t_j \leq t} 1 - \frac{\Delta N(t_j)}{R(t_j)}.
 \end{aligned} \tag{4.1}$$

A mesma equação pode ser apresentada na forma recursiva como:

$$\hat{S}_{\text{km}}(t_j) = \hat{S}_{\text{km}}(t_{j-1}) \times \frac{R(t_j) - \Delta N(t_j)}{R(t_j)}.$$

Exemplo

Vamos retornar ao exemplo dos pacientes com Aids cujos tempos de sobrevivência estão listados na Tabela 4.1. Observe que, dos 21 indivíduos acompanhados, 15 morreram e 6 foram censurados. Existem apenas 15 diferentes tempos de sobrevivência sem censura ($m = 15$), que correspondem aos tempos $t_j : j = 1, 2, \dots, 15$:

$$\begin{aligned}
 16 &< 18 < 21 < 22 < 29 < 35 < 37 < \\
 39 &< 40 < 52 < 54 < 60 < 80 < 83 < 84
 \end{aligned}$$

Esses tempos estão listados na primeira coluna da Tabela 4.2. Para cada um dos tempos, o grupo sob risco $R(t_j)$ é definido como o conjunto de indivíduos que sobreviveram até pelo menos o tempo t_j . No tempo $t_j = 0$ (o momento de entrada do indivíduo na coorte) o conjunto sob risco é o total de pacientes, ou seja, $R(0) = 21$ indivíduos, todos vivos. Nesse tempo $t_j = 0$, a probabilidade dos pacientes sobreviverem mais que 0 dia é igual a 1, $S(0) = 1$. Essa situação permanece até o dia 16, quando a primeira morte ocorre. Nesse ponto, o

grupo sob risco se altera para 20 indivíduos e $S(t)$ é calculado como a razão entre o número de sobreviventes e o tamanho do grupo que estava sob risco antes do evento:

$$S(16) = \frac{20}{21} = 0,952.$$

No dia 18, a segunda morte ocorre e o grupo sob risco se reduz de 20 para 19 pessoas. A função de sobrevivência em $t = 18$ é calculada como o produto:

$$S(18) = 0,952 \times \left(\frac{19}{20}\right) = 0,904,$$

no qual o primeiro termo do produto é a probabilidade de sobreviver por mais do que o tempo anterior, $S(16)$, e o segundo termo do produto é a probabilidade de sobreviver 18 dias, dado que já tinha sobrevivido pelo menos até $t = 16$. Este último termo é calculado como o número de sobreviventes em $t = 18$ (19 sobreviventes) dividido pelo número de pacientes em risco antes do evento (20 indivíduos).

No tempo $t = 21$, das 19 pessoas no grupo de risco, uma foi a óbito e uma foi censurada. Assim, nesse momento, o grupo de risco cai de 19 para 17 pessoas. A função de sobrevivência em $t = 21$, $S(21)$, é definida como a probabilidade de ter sobrevivido até o tempo anterior, $S(18)$, vezes a probabilidade de sobreviver 21 dias, dado que já tinha sobrevivido pelo menos até $t = 18$. Novamente, este último termo é calculado como o quociente entre o número de sobreviventes em $t = 18$ (18 sobreviventes) e o número de pacientes em risco antes do evento (19 sobreviventes):

$$S(21) = 0,904 \times \left(\frac{19 - 1}{19}\right) = 0,857.$$

Na Tabela 4.2 estão os cálculos de $S(t)$ para todos os valores de t_j .

A Figura 4.1 mostra a curva de sobrevivência estimada pelo método Kaplan-Meier para os dados da Tabela 4.1. Esse método gera uma função escada que salta em cada tempo onde ocorreu um evento. O tamanho desse salto depende do número de eventos observados

Tabela 4.2: Função de sobrevivência estimada pelo método Kaplan-Meier para os 21 pacientes com Aids (Tabela 4.1)

t_j	$R(t)$	$\Delta N(t)$	$\hat{S}_{\text{km}}(t) = \prod_{t_j \leq t} \frac{R(t_j) - \Delta N(t_j)}{R(t_j)}$
16	21	1	$\left(\frac{21-1}{21}\right) = 0,9524$
18	20	1	$0,9524 \times \left(\frac{20-1}{20}\right) = 0,9048$
21	19	1	$0,9048 \times \left(\frac{19-1}{19}\right) = 0,8571$
22	17	1	$0,8571 \times \left(\frac{17-1}{17}\right) = 0,8067$
29	15	1	$0,8067 \times \left(\frac{15-1}{15}\right) = 0,7529$
35	14	1	$0,7529 \times \left(\frac{14-1}{14}\right) = 0,6992$
37	13	1	$0,6992 \times \left(\frac{13-1}{13}\right) = 0,6454$
39	12	1	$0,6454 \times \left(\frac{12-1}{12}\right) = 0,5916$
40	11	1	$0,5916 \times \left(\frac{11-1}{11}\right) = 0,5378$
52	9	1	$0,5378 \times \left(\frac{9-1}{9}\right) = 0,4781$
54	8	1	$0,4781 \times \left(\frac{8-1}{8}\right) = 0,4183$
60	7	1	$0,4183 \times \left(\frac{7-1}{7}\right) = 0,3585$
80	6	1	$0,3585 \times \left(\frac{6-1}{6}\right) = 0,2988$
83	3	1	$0,2988 \times \left(\frac{3-1}{3}\right) = 0,1992$
84	2	1	$0,1992 \times \left(\frac{2-1}{2}\right) = 0,0996$

nesse tempo e também do número de observações censuradas antes dele. Essa função é em escada porque o risco se mantém constante até a ocorrência do próximo evento.




Figura 4.1: Função de sobrevivência dos pacientes com Aids (Tabela 4.1) estimada utilizando o estimador produto Kaplan-Meier. Os símbolos “+” localizam as censuras

A Tabela 4.2 e a Figura 4.1 foram geradas a partir do registro de pacientes do banco de dados *ipeccsv*, que possuíam tempo de sobrevivência menor que 90 dias.

A partir da função de sobrevivência estimada pelo método Kaplan-Meier, é possível obter as outras funções básicas da análise de sobrevivência, usando as relações existentes entre estas funções. Por exemplo, no Capítulo 3, a função de risco acumulado, $\Lambda(t)$, foi definida a partir da função de sobrevivência $S(t)$ como $\Lambda(t) = -\ln(S(t))$. A partir desta relação, pode-se criar um estimador Kaplan-Meier (KM) para $\Lambda(t)$:

$$\hat{\Lambda}_{km}(t) = -\ln(\hat{S}_{km}(t)) \quad (4.2)$$

Kaplan-Meier no R

No R, a tabela e a curva de sobrevivência estimada pelo método Kaplan-Meier são geradas com o comando `survfit()`. A sintaxe do comando é:

```
> survfit(formula =, data = )
```

O primeiro argumento é uma fórmula que possui o seguinte formato:

$$formula = Surv(tempo, status) \sim 1$$

A variável tempo de sobrevivência é construída utilizando o comando `Surv()` (ver Capítulo 2). O segundo argumento do comando `survfit()` é o nome do objeto no R (banco de dados) que contém as variáveis `tempo` e `status`. O comando `survfit()` estima também o intervalo de confiança de 95%.

Por exemplo, na Tabela 4.2, a função de sobrevivência no tempo $t = 21$ foi estimada em 0,8571. Logo, a função de risco acumulado em $t = 21$ é:

$$\hat{\Lambda}_{km}(21) = -\ln(\hat{S}_{km}(21)) = -\ln(0,8571) = 0,1542$$

Na Tabela 4.3, a função de risco acumulado estimada pelo método Kaplan-Meier é calculada para os outros valores de t . Sugereimos que o leitor refaça os cálculos para fixar os conceitos apresentados.

A Figura 4.2 mostra esses valores graficamente e permite observar que o risco de óbito nessa coorte vem aumentando como uma função escada até o dia 80. A partir do dia 80 o risco dá um salto maior, passando de 1 para um valor maior que 2.

Tabela 4.3: Função de risco acumulado por Kaplan-Meier (km) e Nelson-Aalen (na) para os 21 pacientes com Aids listados na Tabela 4.1

t_j	$R(t)$	$\Delta N(t)$	$\hat{\Lambda}_{\text{km}}(t)$	$\hat{\Lambda}_{\text{na}}(t)$
16	21	1	0,0488	$(\frac{1}{21}) = 0,0476$
18	20	1	0,1001	$(0,0476 + \frac{1}{20}) = 0,0976$
21	19	1	0,1542	$(0,0976 + \frac{1}{19}) = 0,1503$
22	17	1	0,2148	$(0,1502 + \frac{1}{17}) = 0,2091$
29	15	1	0,2838	$(0,2091 + \frac{1}{15}) = 0,2757$
35	14	1	0,3578	$(0,2757 + \frac{1}{14}) = 0,3472$
37	13	1	0,4379	$(0,3472 + \frac{1}{13}) = 0,4241$
39	12	1	0,5249	$(0,4241 + \frac{1}{12}) = 0,5074$
40	11	1	0,6203	$(0,5074 + \frac{1}{11}) = 0,5983$
52	9	1	0,7379	$(0,5983 + \frac{1}{9}) = 0,7094$
54	8	1	0,8716	$(0,7094 + \frac{1}{8}) = 0,8344$
60	7	1	1,0258	$(0,8344 + \frac{1}{7}) = 0,9773$
80	6	1	1,2080	$(0,9773 + \frac{1}{6}) = 1,1440$
83	3	1	1,6134	$(1,1439 + \frac{1}{3}) = 1,4773$
84	2	1	2,3066	$(1,4773 + \frac{1}{2}) = 1,9773$




Figura 4.2: Estimativa Kaplan-Meier da função de risco acumulado dos pacientes com Aids (Tabela 4.1)

Gráfico Kaplan-Meier no R

Para construir um gráfico da função de sobrevivência estimada pelo método Kaplan-Meier (Figura 4.1) basta usar a função `plot()` do objeto que recebeu a função `survfit()`:

```
> plot(KM)
```

O gráfico coloca as linhas do intervalo de confiança por *default*. Se quiser retirar essas linhas do gráfico, acrescente o argumento `conf.int = F`:

```
> plot(KM, conf.int = F)
```

Para construir o gráfico da função de risco acumulado (Figura 4.2) acrescente o argumento `fun = "cumhaz"`:

```
> plot(KM, conf.int = F, fun = "cumhaz")
```

4.3 Estimador de Nelson-Aalen

Uma alternativa para estimar a função risco acumulado é utilizar o estimador de Nelson-Aalen, dado por:

$$\hat{\Lambda}_{\text{na}}(t) = \sum_{j:t_j \leq t} \frac{\Delta N(t_j)}{R(t_j)}. \quad (4.3)$$

Note que, por meio da relação $\Lambda(t) = -\ln(S(t))$, podemos, a partir do estimador de Nelson-Aalen para $\Lambda(t)$, obter outra estimativa não paramétrica para sobrevivência dada por $\hat{S}_{\text{na}}(t) = \exp(-\hat{\Lambda}_{\text{na}}(t))$. Para amostras suficientemente grandes, a estimativa de Kaplan-Meier e Nelson-Aalen para a função de sobrevivência são bem próximas. Mas quando a amostra é pequena, o estimador Nelson-Aalen possui propriedades estatísticas que o tornam preferível. No exemplo da Tabela 4.3 os dois estimadores são diferentes, e a diferença aumenta em direção ao final do período, sendo o estimador de Nelson-Aalen mais conservador.

Nelson-Aalen no R

Para obter as estimativas de sobrevivência de Nelson-Aalen, a função `survfit()` tem como argumento o objeto que a função `coxph()` retorna. Isso significa uma função dentro da outra, como abaixo. Observe que a função `coxph()` também recebe como argumento o que outra função – `Surv()` – retorna.

Utilizando os dados dos 21 pacientes com tempo de sobrevivência menor que 90 dias do Ipec, tem-se:

```
> ipec90 <- ipec[ipec$tempo<90,]
> sobrev.na <- survfit(coxph(Surv(tempo,status)~1,
  data = ipec90))
> sobrev.na
> summary(sobrev.na)
```

4.4 Intervalos de confiança

Conhecer a variância de qualquer estimador é essencial para a construção de um intervalo de confiança em torno da estimativa pontual. Aqui serão apresentados estimadores da variância para a função de sobrevivência estimada por Kaplan-Meier ($Var(\hat{S}_{km}(t))$). O estimador de variância mais utilizado para $S(t)$ é o de Greenwood, cuja fórmula é:

$$Var(\hat{S}_{km}(t)) = (\hat{S}_{km}(t))^2 \sum_{j:t_j \leq t} \frac{\Delta N(t_j)}{R(t_j)(R(t_j) - \Delta N(t_j))}. \quad (4.4)$$

A partir da Equação (4.4), é possível definir o intervalo de confiança de $100(1 - \alpha)\%$ para $S(t)$, assumindo-se que $\hat{S}(t)$ segue distribuição normal cujo desvio padrão estimado é a raiz quadrada do estimador de Greenwood. Dessa forma, os limites do intervalo são definidos por:

$$\text{Limite inferior: } \hat{S}_{km}(t) - z_{\alpha/2} \sqrt{Var(\hat{S}_{km}(t))};$$

$$\text{Limite superior: } \hat{S}_{km}(t) + z_{\alpha/2} \sqrt{Var(\hat{S}_{km}(t))}.$$

Este método calcula intervalos de confiança simétricos para cada tempo t . Como consequência, é possível obter estimativas de $\hat{S}_{km}(t)$ maiores do que 1 ou menores do que 0 nos tempos em que $\hat{S}_{km}(t)$ está próximo destes limites. Por exemplo, voltando aos dados da Tabela 4.2, vê-se que o intervalo de confiança de 95% para a sobrevivência depois de 84 dias, $S(84)$, usando-se a fórmula de Greenwood e o pressuposto de normalidade, é dado por:

$$\text{Limite inferior: } 0,096 - 1,96 \times 0,089 = -0,075;$$

$$\text{Limite superior: } 0,096 + 1,96 \times 0,089 = 0,274.$$

Esse fato é incoerente com a definição de probabilidade. Uma forma de contornar essa incompatibilidade é a construção de um intervalo de confiança assimétrico para $S(t)$ a partir de um intervalo

simétrico para $\ln(\Lambda(t)) = \ln(-\ln S(t))$. Esse método, além de assegurar que os limites de confiança sejam positivos e menores ou iguais a 1, é considerado mais preciso porque $\ln(\hat{\Lambda}_{km}(t))$ tem uma distribuição mais próxima da normal do que $\hat{S}_{km}(t)$. Assim, o intervalo de confiança de $100(1 - \alpha)\%$ para $\ln(\Lambda(t))$ será:

$$\begin{aligned} \text{Limite inferior: } & \ln(\hat{\Lambda}_{km}(t)) - z_{\alpha/2} \sqrt{\text{Var}(\ln(\hat{\Lambda}_{km}(t)))}; \\ \text{Limite superior: } & \ln(\hat{\Lambda}_{km}(t)) + z_{\alpha/2} \sqrt{\text{Var}(\ln(\hat{\Lambda}_{km}(t)))}. \end{aligned} \quad (4.5)$$

A $\text{Var}(\ln(\hat{\Lambda}_{km}(t)))$ é dada por:

$$\text{Var}(\ln(\hat{\Lambda}_{km}(t))) = \frac{1}{\ln(\hat{S}_{km}(t))^2} \sum_{j:t_j \leq t} \frac{\Delta N(t_j)}{R(t_j)(R(t_j) - \Delta N(t_j))}. \quad (4.6)$$

Como $S(t) = \exp(-\Lambda(t))$, o intervalo assimétrico para $\hat{S}_{km}(t)$, denominado intervalo de confiança exponencial de Greenwood, é dado pelos limites:

$$\begin{aligned} \text{Limite inferior: } & \exp(-\exp(l_{sup})); \\ \text{Limite superior: } & \exp(-\exp(l_{inf})). \end{aligned} \quad (4.7)$$

Exemplo

A Tabela 4.2 mostrou como estimar a função de sobrevivência para o conjunto de pacientes com Aids listados no início do capítulo. A Tabela 4.4 calcula o estimador exponencial de Greenwood para variância do Kaplan-Meier (Equação (4.6)), visando a construção do intervalo de confiança. Vamos ilustrar o cálculo passo a passo para $t = 18$. A variância (Equação 4.6) para o logaritmo do risco acumulado no tempo $t = 18$ é igual a:

$$\begin{aligned} \text{Var}(\ln(\hat{\Lambda}_{km}(t))) &= \frac{1}{\ln(0,9048)^2} \left[\frac{1}{21(21-1)} + \frac{1}{20(20-1)} \right] \\ &= 0,50042. \end{aligned}$$

Logo, o intervalo de 95% para o logaritmo do risco acumulado (Equação (4.5)) é:

$$\begin{aligned} \text{Limite inferior: } \ln(0,1001) & -1,96 \times \sqrt{0,50042}; \\ \text{Limite superior: } \ln(0,1001) & +1,96 \times \sqrt{0,50042}; \\ \text{Intervalo: } & [-3,6883; -0,9152]. \end{aligned}$$

Para calcular o intervalo de 95% para a sobrevivência $S(18) = 0,9048$, basta exponenciar:

$$\begin{aligned} & [\exp(-\exp(-3,6883)) ; \exp(-\exp(-0,9152))] , \\ & [0,6700 ; 0,9753] . \end{aligned}$$

Observe na Tabela 4.4 o cálculo da variância para os outros tempos.

A Figura 4.3 apresenta novamente a função de sobrevivência estimada pelo método Kaplan-Meier, agora com intervalos de confiança de 95%.




Figura 4.3: Curva de sobrevivência estimada pelo Kaplan-Meier dos pacientes com Aids (Tabela 4.1) com intervalo de confiança de 95%

Tabela 4.4: Estimativa do intervalo de confiança exponencial de Greenwood para $\hat{S}_{km}(t)$

t_j	$\hat{S}_{km}(t)$	$ln(\hat{\Lambda}_{km}(t))$	Variância*	Limites $ln(\hat{\Lambda}_{km}(t))$		Limites $\hat{S}_{km}(t)$	
				Inferior	Superior	Inferior	Superior
16	0,9524	-3,0202	1,00020	-4,9804	-1,0600	0,7072	0,9932
18	0,9048	-2,3018	0,50042	-3,6883	-0,9152	0,6700	0,9753
21	0,8571	-1,8698	0,33399	-3,0026	-0,7371	0,6197	0,9516
22	0,8067	-1,5382	0,25175	-2,5216	-0,5547	0,5631	0,9228
29	0,7529	-1,2596	0,20335	-2,1435	-0,3757	0,5032	0,8894
35	0,6992	-1,0276	0,17075	-1,8375	-0,2176	0,4474	0,8528
37	0,6454	-0,8257	0,14746	-1,5784	-0,0731	0,3947	0,8136
39	0,5916	-0,6445	0,13012	-1,3515	0,0625	0,3449	0,7719
40	0,5378	-0,4776	0,11684	-1,1476	0,1923	0,2976	0,7280
52	0,4781	-0,3038	0,10802	-0,9480	0,3404	0,2452	0,6787
54	0,4183	-0,1375	0,10096	-0,7603	0,4853	0,1970	0,6265
60	0,3585	0,0254	0,09553	-0,5804	0,6312	0,1526	0,5714
80	0,2988	0,1890	0,09171	-0,4046	0,7825	0,1122	0,5131
83	0,1992	0,4784	0,11543	-0,1875	1,1443	0,0433	0,4365
84	0,0996	0,8358	0,15045	0,0755	1,5960	0,0072	0,3401

*Equação 4.6 da variância de Greenwood para $ln(\hat{\Lambda}_{km}(t))$

4.5 Tempo de sobrevivência mediano

O tempo de sobrevivência mediano é a medida-sumário mais citada e interpretada nos artigos científicos que trabalham com análise de sobrevivência. Mais usada do que a média, pois como a distribuição do tempo de sobrevivência é pouco simétrica, as medidas robustas são mais indicadas. Por definição, o tempo mediano é o tempo depois do qual 50% dos indivíduos estão vivos, ou seja, o tempo no qual $\hat{S}(t) = 0,5$. Como o tempo de sobrevivência normalmente não é observado de forma contínua, a sobrevivência é uma função em degraus, e por isso o tempo de sobrevivência mediano é definido como o menor tempo para o qual o valor estimado de $S(t)$ é menor ou igual a 50%:

$$\hat{t}_{\text{mediano}} = \min\{t_j | \hat{S}(t_j) \leq 0,5\},$$

em que j é o índice dos tempos observados de ocorrência do evento.

Numa situação ideal **sem censura**, tempo mediano é aquele imediatamente depois do qual 50% da amostra ainda está em observação. Vejamos o que acontece com a coorte de Aids (dados da Tabela 4.2):

```
> survfit(Surv(tempo,status)~1, data=ipec90)
```

```
Call: survfit(formula=Surv(tempo,status)~1, data=ipec90)
```

records	n.max	n.start	events	median	0.95LCL	0.95UCL
21	21	21	15	52	37	NA

O tempo de sobrevivência mediano é igual a 52 dias, ou seja, 52 dias é o tempo mínimo no qual espera-se que praticamente 50% dos pacientes estejam vivos. Verifique, no sumário do comando *survfit*, que aos 40 dias a função de sobrevivência é $S(40) = 0,5378$ e aos 52 dias $S(52) = 0,4781$.

```
> summary(survfit(Surv(tempo,status)~1, data=ipec90))
```

time	n.risk	n.event	survival	std.err	lower	95% CI	upper	95% CI
16	21	1	0.9524	0.0465		0.8655		1.000

18	20	1	0.9048	0.0641	0.7875	1.000
21	19	1	0.8571	0.0764	0.7198	1.000
22	17	1	0.8067	0.0869	0.6531	0.996
29	15	1	0.7529	0.0963	0.5859	0.968
35	14	1	0.6992	0.1034	0.5232	0.934
37	13	1	0.6454	0.1085	0.4642	0.897
39	12	1	0.5916	0.1120	0.4082	0.857
40	11	1	0.5378	0.1140	0.3550	0.815
52	9	1	0.4781	0.1160	0.2972	0.769
54	8	1	0.4183	0.1158	0.2431	0.720
60	7	1	0.3585	0.1137	0.1926	0.667
80	6	1	0.2988	0.1093	0.1459	0.612
83	3	1	0.1992	0.1092	0.0680	0.583
84	2	1	0.0996	0.0891	0.0172	0.575

Se voltarmos aos dados vamos observar que após 52 dias, 8 pacientes estão vivos, o que não equivale exatamente aos 50% dos pacientes, mas sim o que se esperaria que acontecesse, caso não houvesse censuras.

4.5.1 Intervalo de confiança

Existem várias fórmulas para calcular o intervalo de confiança para o tempo mediano. Vamos agora ilustrar graficamente como podem ser obtidos os intervalos de confiança de 95% para a mediana, e, por extensão, para qualquer ponto da curva de sobrevivência. Como podemos ver na Figura 4.4, o tempo mediano corresponde à interseção entre a linha horizontal em $S(t) = 0,5$ e a curva de sobrevivência.

Estimadas as curvas de sobrevivência e a dos seus limites do intervalo de confiança de 95% através da fórmula exponencial de Greenwood, o intervalo de confiança de 95% para o tempo mediano é dado pela interseção da linha horizontal em $S(t) = 0,5$ e as curvas do intervalo de confiança para $S(t)$, como vemos na Figura 4.4. Observe que, como a linha horizontal não encontra com a curva superior, não é possível calcular o limite superior para intervalo de confiança de 95% para a mediana, exatamente como está na análise apresentada dos dados da Tabela 4.2, onde o valor para o intervalo superior (0.95UCL) é infinito.




Figura 4.4: Tempo de sobrevivência mediano e intervalo de confiança de 95% dos pacientes com Aids (Tabela 4.1)

4.6 Kaplan-Meier com estratificação

Pessoas não adoecem ou morrem da mesma forma. Peculiaridades dos indivíduos, como características genéticas, sociais ou resultantes de comportamentos contribuem para diferentes curvas de mortalidade (e sobrevivência) de grupos populacionais. Cada característica, isoladamente, como idade, sexo, exposição a determinados agentes, entre outras, contribui para determinar a sobrevivência. A Figura 4.5 mostra curvas de sobrevivência e risco acumulados da coorte completa de Aids (193 pacientes do Ipec), na qual 90 pacientes foram a óbito durante o período de observação.

Será esta uma boa estimativa da curva de sobrevivência tanto para homens quanto para mulheres? Em outras palavras, a variável sexo afeta o tempo de sobrevivência do paciente? Ainda utilizando o método Kaplan-Meier, pode-se comparar curvas de sobrevivência de diferentes grupos. Para isso, divide-se o conjunto total de observações em grupos distintos – estratos – de acordo com as covariáveis de interesse, e estima-se as funções de sobrevivência separadamente para




Figura 4.5: Curvas de sobrevivência e risco acumulados para a coorte completa de Aids (*ipec.csv*)

cada estrato. No caso dos pacientes com Aids, como estamos interessados em comparar homens e mulheres, os dois estratos são: pacientes do sexo masculino e pacientes do sexo feminino. A curva de sobrevivência é estimada separadamente para cada estrato, utilizando-se o método Kaplan-Meier descrito na Seção 4.2.

Estratificando os dados dos pacientes com Aids por sexo, observamos uma predominância de pacientes do sexo masculino (75%), e que 82% das mortes se concentram neste grupo. Essa proporção parece ser maior em homens.

```
> survaids <- survfit(Surv(tempo,status)~sexo,data=ipec)
> survaids
```

```
Call: survfit(formula=Surv(tempo,status)~sexo,data=ipec)
      records n.max n.start events median 0.95LCL 0.95UCL
sexo=F      49   49     49     16    NA    1371     NA
sexo=M     144  144    144     74  1116     887  1563
```

A saída do R fornece o tempo de sobrevivência mediano `median = NA` e `1116`, respectivamente para mulheres e homens, indicando que nesse caso não foi possível estimar o tempo de sobrevi-

vência mediano para mulheres, simplesmente porque 67% das mulheres estão vivas. Nesse caso é comum utilizar outro percentil para descrever o tempo de sobrevivência, por exemplo, o tempo no percentil 70 para as mulheres é de 905 e para os homens, 516. As duas últimas colunas fornecem um intervalo de confiança para a estimativa da mediana. Toda a informação da tabela de sobrevivência, inclusive os intervalos de confiança para cada ponto da curva de sobrevivência, pode ser visualizada através do comando `summary(survivals)`.

A Figura 4.6 mostra as curvas de sobrevivência, estimadas para cada sexo.




Figura 4.6: Curvas de sobrevivência por sexo (Kaplan-Meier) para a coorte completa de Aids (*ipcc.csv*)

Observe que a curva de sobrevivência dos homens está sempre abaixo da curva de sobrevivência das mulheres. Esse padrão sugere que, para qualquer que seja o tempo de sobrevivência considerado, a probabilidade de sobreviver por mais do que este tempo é sempre menor para homens do que para mulheres. Isto é, o risco de morrer parece maior para homens do que para mulheres em todos os pontos da trajetória pós-diagnóstico. Mas será essa diferença significativa?

Gráfico de sobrevivência no R

O gráfico da Figura 4.6 foi produzido da seguinte forma:

```
> fit <- survfit(formula=Surv(tempo,status)~sexo,
  data=ipec)
> plot(fit, conf.int = F, xlab="Dias", ylab="S(t)",
  mark.time=F, lty=c(1,2))
> legend(x="bottomleft", legend= c("Fem", "Masc"),
  lty=c(1,2), title="Sexo", bty="n")
```

Alguns argumentos são comuns a todos os gráficos feitos no R, e podem ser vistos na função `par()`. Nesse exemplo os argumentos representam:

- `conf.int = F` → não desenhar os intervalos de confiança (o *default* é desenhá-los);
- `xlab="dias"` e `ylab="S(t)"` → nome dos eixos;
- `mark.time=F` → não marcar os tempos de censura (o *default* é marcá-los);
- `lty=c(1,2)` → mudar o padrão da linha (contínua, tracejada, pontilhada, traço-ponto, etc.);
- `col` → indicar a cor das linhas, quando desejado, estando disponíveis mais de 600 tonalidades, que podem ser indicadas através de nomes (veja na função `colors()`).

No gráfico das curvas de sobrevivência com intervalos de confiança para cada estrato (Figura 4.7), fica visível a sobreposição dos limites estimados para 95% (método de Greenwood), sugerindo que a diferença observada na sobrevivência de homens e de mulheres não é significativa. Observe, porém, que em alguns intervalos de tempo, principalmente no início do acompanhamento, a banda de confiança do estrato masculino parece estar toda abaixo da do estrato feminino. Isso sugere uma sobrevivência menor em homens durante esse período. Mais dados são necessários para confirmar essa tendência.




Figura 4.7: Curvas de sobrevivência por sexo e respectivos intervalos de confiança de 95% para a coorte completa de Aids (*ipec.csv*)

Legenda de gráfico no R

A legenda é criada separadamente, com a função `legend()`. Muito cuidado para garantir que a legenda represente corretamente cada elemento. Para isso coloque o texto na mesma ordem em que as categorias são organizadas no R. Essa ordem a princípio é alfabética, mas pode ser definida pelo usuário. Para verificar a ordenação das categorias usa-se a função `levels(banco$fator)`.

- A posição da legenda é indicada pelas coordenadas x e y, ou pela posição no gráfico com um dos seguintes argumentos: `"bottom-right"`, `"bottom"`, `"bottomleft"`, `"left"`, `"topleft"`, `"top"`, `"topright"`, `"right"` ou `"center"`.
- O texto das categorias da legenda, na mesma sequência na qual o R reconhece os fatores → `legend=c("Fem", "Masc")`.
- O tipo e cor das linhas, na mesma ordem do texto → `lty=c(1,2), col=...`
- O título da legenda → `title="Sexo"`.

4.7 Teste log-rank

Para comparar as curvas de sobrevivência mais formalmente, deve-se recorrer a testes de hipóteses. O mais simples é o teste de Mantel-Haenzel, ou log-rank, que compara os valores observados e esperados de cada estrato sob a hipótese de que o risco é o mesmo em todos os grupos. Testar se curvas de sobrevivência são iguais equivale a testar se a incidência de eventos é semelhante em cada estrato. Se for semelhante, a curva de sobrevivência será a mesma. Assim, a hipótese nula é definida como:

$$H_0 : \lambda_1(t) = \lambda_2(t) = \cdots = \lambda_k(t),$$

em que k é número de estratos. Note que esta é uma hipótese que se refere à função de risco em todo o tempo de observação e não às diferenças/semelhanças em trechos da curva. Rejeitar a hipótese nula significa que pelo menos uma curva difere das outras, significativamente, em algum momento do tempo.

O teste log-rank compara a distribuição da ocorrência dos eventos observados em cada estrato com a distribuição que seria esperada se a incidência fosse igual em todos os estratos. Se a distribuição observada for equivalente à distribuição esperada, dizemos que a curva de sobrevivência dos pacientes pertencentes ao estrato é equivalente à curva de sobrevivência dos pacientes em geral, ou seja, essa variável não afeta a sobrevivência.

Para realizar o teste, calcula-se a estatística em duas etapas: primeiro, estima-se o número de eventos esperados para cada estrato k , segundo a hipótese nula de incidência igual em todos os estratos. Chamamos esse número esperado de $E_k(t)$. Em seguida, calcula-se a estatística do teste. Esta estatística segue uma distribuição χ^2 , com $k - 1$ graus de liberdade, quando a hipótese nula é verdadeira.

Considere o caso da comparação das curvas de sobrevivência de homens e mulheres com Aids. De acordo com a hipótese nula, homens e mulheres têm a mesma chance de sofrer um evento em todos os momentos de tempo. Assim, se um grupo é formado por 50 homens e 50 mulheres e 10 eventos são observados no primeiro mês,

a distribuição esperada de eventos será de 50% em homens e 50% em mulheres.

Se, por outro lado, o grupo fosse formado por 10 homens e 90 mulheres, esperaríamos um número proporcionalmente maior de eventos em mulheres, isto é, 10% entre homens e 90% entre mulheres. O maior número de eventos em mulheres não reflete uma diferença de risco, mas apenas uma diferença na proporção de homens e mulheres na amostra.

Formalizando, para calcular a distribuição esperada de eventos, o total de eventos precisamente no tempo t , $\Delta N(t)$, é redistribuído pelos k estratos, proporcionalmente ao número de pessoas presentes em cada estrato. Assim, para o estrato k , temos:

$$E_k(t) = N(t) \frac{R_k(t)}{R(t)}, \quad (4.8)$$

em que $\Delta N(t)$ é o número total de eventos observados em t , $R_k(t)$ é o número de pessoas em risco no estrato k no tempo t , e $R(t)$ é o número total de pessoas em risco no estudo no tempo t .

Quando apenas dois estratos estão sendo comparados, a estatística log-rank é calculada utilizando-se os dados de um dos estratos somente, por exemplo, o estrato 1. O resultado do teste para um estrato se estende ao outro estrato por simetria. Isto é, se o número esperado de casos é maior do que o esperado para o estrato 1, isto implica que o número de casos é menor do que o esperado no estrato 2.

Sendo E_1 o total de eventos esperados no estrato 1 e O_1 o total de eventos observados no estrato 1, a estatística log-rank é calculada a partir da diferença entre o número total de eventos observados e o número total de eventos esperados:

$$\text{Log-rank} = \frac{(O_1 - E_1)^2}{\text{Var}(O_1 - E_1)}, \quad (4.9)$$

que segue uma distribuição χ^2 com um grau de liberdade.

A variância, que entra no cálculo como um fator de padronização, tem a fórmula (para $k = 2$):

$$Var(O_1 - E_1) = \sum_t \frac{R_1(t)R_2(t)\Delta N(t)[R(t) - \Delta N(t)]}{R(t)^2[R(t) - 1]}.$$

Existem vários outros testes que ponderam as observações de acordo com a importância que se deseja dar ao início ou final do tempo de sobrevivência. A estatística Peto, apresentada a seguir, atribui maior peso aos eventos ocorridos nos períodos iniciais de observação.

4.8 Teste Peto

Retorne à Figura 4.6. As curvas de sobrevivência são claramente similares durante aproximadamente 300 dias (10 meses), e depois divergem. O teste de Peto é uma modificação do teste log-rank que dá maior peso ao perfil de sobrevivência de tempos menores, ou seja, às diferenças (ou semelhanças) no início da curva. A justificativa para isso é que os tempos iniciais concentram a maior parte dos dados, e por isso são mais informativos. Esse maior peso no início da curva é obtido pela inclusão de um fator de ponderação igual ao valor estimado da sobrevivência $S(t)$ no estimador log-rank. A estatística de Peto é dada por:

$$\text{Peto} = \frac{(O_1 - E_1)^2}{Var(O_1 - E_1)}, \quad (4.10)$$

sendo,

$$O_1 - E_1 = \sum_{t_j} S(t_j)(O_1(t_j) - E_1(t_j)).$$

Da mesma forma, a variância da estatística de Peto é igual à variância do log-rank, onde a cada tempo se pondera pelo quadrado da função de sobrevivência ($S(t_j)^2$). Assim como a estatística log-rank, a estatística Peto segue aproximadamente uma distribuição χ^2 com $k - 1$ graus de liberdade.

Exemplo

Vamos exemplificar a construção da distribuição esperada de ocorrência de eventos, $e_k(t)$, utilizando os dados de indivíduos com Aids pertencentes à coorte do Ipec. Incluiremos aqui apenas os 52 indivíduos com tempo de sobrevivência de 10 meses ou menos. Esse grupo é formado por 11 mulheres e 41 homens. Os tempos de sobrevivência são:

Mulheres: 1, 3+, 4, 4, 5, 5, 5, 6, 7+, 8, 10+

Homens: 1+, 1+, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2+, 2, 2, 2, 3+, 3, 3+, 3, 3, 4, 4, 5+, 5, 5, 5, 5, 6, 6+, 6, 6, 7+, 7, 7, 8, 8+, 9, 10, 10, 10+, 10, 10

Para construir a distribuição esperada, utilizam-se os termos $\Delta N_k(t)$, $R(t)$, $R_k(t)$, que fazem parte da tabela Kaplan-Meier (metade esquerda da Tabela 4.5). A partir desses valores, calcula-se o número de eventos esperados em cada estrato aplicando-se a Fórmula (4.8).

Note que o número de eventos por unidade de tempo é preservado no cálculo da distribuição esperada, isto é, $E(t) = \Delta N(t)$. A diferença está na distribuição desses eventos entre os estratos. Na última coluna da Tabela 4.5, encontram-se os totais de eventos por estrato. O total de eventos observados foi de 31 em homens, enquanto que o esperado pela hipótese nula seria de 30,1 eventos. Em mulheres, observaram-se 8 eventos enquanto que o número esperado seria 8,9. A diferença entre os valores observado e esperado parece pequena, pois esse é um banco muito pequeno.

Analisando o banco completo, com 193 pacientes, a diferença entre os testes log-rank e Peto pode ser melhor explorada. Começando pelo teste log-rank, obtemos:

```
> survdiff(Surv(tempo,status)~ sexo, data=ipec)
```

```
Call: survdiff(formula=Surv(tempo,status)~sexo, data=ipec)

      N Observed Expected (O-E)^2/E (O-E)^2/V
sexo=F  49       16    24.5      2.93     4.03
sexo=M 144       74    65.5      1.09     4.03
Chisq= 4 on 1 degrees of freedom, p= 0.0447
```

Tabela 4.5: Distribuição observada e esperada de eventos por estrato dos pacientes com tempo de sobrevivência menor ou igual a 10 meses

t_j	Eventos observados			Grupo de risco por estrato			Eventos esperados $E_k(t) = \Delta N(t) \frac{R_k(t)}{R(t)}$		
	Masc $\Delta N_1(t)$	Fem $\Delta N_2(t)$	Total $\Delta N(t)$	Masc $R_1(t)$	Fem $R_2(t)$	Total $R(t)$	Masc $E_1(t)$	Fem $E_2(t)$	Total $E(t) = \Delta N(t)$
0	0	0	0	41	11	52	0	0	0
1	8	1	9	41	11	52	7,10	1,90	9
2	3	0	3	31	10	41	2,27	0,73	3
3	3	0	3	27	10	37	2,19	0,81	3
4	2	2	4	22	9	31	2,84	1,16	4
5	4	3	7	20	7	27	5,18	1,82	7
6	3	1	4	15	4	19	3,16	0,84	4
7	2	0	2	11	3	14	1,57	0,43	2
8	1	1	2	8	2	10	1,60	0,40	2
9	1	0	1	6	1	7	0,86	0,14	1
10	4	0	4	5	1	6	3,33	0,67	4
Total	31	8	40				30,1	8,9	40

Nessa saída do R, indica-se para cada estrato o número de pessoas em risco no início do estudo (N) e o número total de eventos observados (**Observed**) e esperados (**Expected**). A última coluna da saída da função `survfit()` nos dá a estatística de teste log-rank. Veja que ela é igual para os dois estratos e, por isso, basta utilizar um estrato para o cálculo. O resultado do teste χ^2 é dado no final da tabela e aponta para a rejeição da hipótese nula ($p = 0.0447$). O R também calcula a estatística $(O - E)^2/E$. Esta é uma estatística de teste aproximada, sendo seu resultado mais conservador. A estatística log-rank é exata, e por isso, preferível.

Testando agora com a estatística de Peto, observe que os valores são diferentes, e mesmo os valores observados não são inteiros. A ponderação adotada no teste influencia todos os valores.

```
> survdiff(Surv(tempo,status)~sexo, rho=1,data=ipec)
```

Call:

```
survdiff(formula=Surv(tempo,status)~sexo, data=ipec, rho=1)
```

	N	Observed	Expected	(O-E)^2/E	(O-E)^2/V
sexo=F	49	12.1	18.2	2.011	3.54
sexo=M	144	55.1	49.0	0.746	3.54

Chisq= 3.5 on 1 degrees of freedom, p= 0.0598

Ou seja, ainda que a diferença no p-valor seja pequena, considerando um erro de 5%, o teste log-rank rejeitaria a hipótese nula. Olhando novamente a Figura 4.7, a diferença na sobrevivência por sexo é maior mais tardiamente, ou seja, o teste de Peto com maior peso para os tempos menores não detecta essa diferença.

Testes log-rank e Peto no R

O comando `survdif()` calcula os testes log-rank e Peto. A sintaxe do comando é:

```
> survdiff(Surv(tempo,status)~cov,data=database,rho=0)
```

O argumento `rho` determina o tipo de teste a ser realizado. Para o log-rank, use `rho = 0`. Para o teste Peto, use `rho = 1`. Se o argumento `rho` for omitido, o teste padrão (*default*) é o log-rank. O argumento `data=` determina o objeto que contém os dados. Os comandos abaixo permitem calcular o teste log-rank para os dados da coorte do Ipec.

```
> survdiff(Surv(tempo,status) ~ sexo, data = ipec)
```

Resumo

Neste capítulo foram apresentados:

- método não paramétrico para estimação da função de sobrevivência – Kaplan-Meier;
- método não paramétrico para estimação da função risco acumulado – Nelson-Aalen;
- intervalos de confiança para as duas funções;
- cálculo e interpretação do tempo de sobrevivência mediano;
- intervalos de confiança para o tempo de sobrevivência mediano;
- testes para comparação das curvas de sobrevivência entre diferentes estratos – log-rank e Peto.

Exercícios

4.1 Considere os dados de tempo de aleitamento de 15 crianças, descrito no exercício 2.1.

6 12 10 3 5 1 6 8 1 5 2 2 5 8 1

(a) Complete a tabela Kaplan-Meier abaixo com esses dados:

t	Intervalo	$N(t)$	$R(t)$	$\hat{\Lambda}(t)$	$\hat{S}_{\text{km}}(t)$
0		0			
1	(0, 1]	3	15		
2	(1, 2]	2			
3					
5					
6					
8					
10					
12					

- (b) Desenhe a curva Kaplan-Meier correspondente aos dados.
- (c) Qual a probabilidade de uma criança ser amamentada pelo menos até o sexto mês de vida?
- (d) Qual a probabilidade de ser amamentada por mais de 3 meses?
- (e) Qual é a probabilidade de ser amamentada por mais de 10 meses?
- (f) Qual é o tempo mediano de aleitamento?

4.2 Ainda com os dados do aleitamento construa a tabela de risco usando os estimadores Kaplan-Meier e Nelson-Aalen.

t	Intervalo	$N(t)$	$R(t)$	$\hat{\Delta}(t)$	$\hat{\Lambda}_{\text{km}}(t)$	$\hat{\Lambda}_{\text{na}}(t)$
0		0				
1	(0, 1]	3	15	1	0	0
2	(1, 2]	2	12	1	0,223	0,2
3						
5						
6						
8						
10						
12	(10, 12]	1	1	2	2,708	2,133

4.3 Os dados completos de tempo de aleitamento (estudo fictício) estão presentes no arquivo `leite.txt`, Apêndice.12.4. Abra este banco de dados no R e:

- (a) Construa a tabela Kaplan-Meier. Verifique qual é o tempo mediano de aleitamento na saída do R.
- (b) Construa a curva de sobrevivência do aleitamento indicando o seu ponto mediano.
- (c) Calcule as estimativas de Nelson-Aalen usando a função `coxph()`.

4.4 Em que situação se deve dar preferência ao método de Nelson-Aalen?

4.5 Suponha que os tempos de aleitamento de 60 bebês estejam agrupados em quatro comunidades diferentes:

```
Comunidade 1:  6 12 10 3 5 1 6  8 1 5 2 2 5  8 1
Comunidade 2:  5 12 10 4 4 3 6  9 2 6 4 1 7 10 1
Comunidade 3: 13 14 20 3 5 1 8 15 2 5 3 2 6 15 1
Comunidade 4:  1 16 20 1 1 1 1  2 2 13 3 1 1 14 2
```

O arquivo `leite2.txt` (descrito no Apêndice.12.4) contém esses dados. A variável `grupo` indica a comunidade à qual cada criança pertence. Carregue este arquivo no R e:

- Ajuste um modelo Kaplan-Meier estratificado por comunidade e compare o tempo mediano de aleitamento em cada comunidade.
- Desenhe, no mesmo gráfico, as curvas de Kaplan-Meier, estratificadas por grupo. Como se comporta a curva de sobrevivência das outras comunidades quando comparadas à Comunidade 1?
- Use os testes log-rank e de Peto para a variável `grupo`. Analise as funções de sobrevivência das quatro comunidades. A que conclusões você chega com esta análise? Existe diferença entre as comunidades quanto ao tempo de aleitamento?

Dicas

- No Apêndice.12.4 você encontra o histórico e a descrição do banco de dados usado nos exercícios.
- Leia o arquivo e não se esqueça de carregar o pacote `survival`, usando o comando `library(survival)`
- Use o comando `y<-Surv(time,status)` para indicar a variável de sobrevivência.
- Use o comando `survfit(y ~ 1, data = dados)` para obter as estimativas de Kaplan-Meier.
- Para obter as estimativas de Nelson-Aalen é necessário utilizar a função `coxph()` antes da função `survfit()`:

```
y <- coxph(Surv(tempo,status))
sobrevida.na <- survfit(y ~ 1, data = dados)
sobrevida.na
summary(sobrevida.na)
```

4.6 O banco de dados *ippec.csv* contém os dados de uma coorte de pacientes com Aids atendidos no Ipec e descritos no Apêndice.12.4. Para este estudo foi definido, como tempo de sobrevivência, o tempo entre o diagnóstico de Aids (critério CDC-1993) e o óbito.

- (a) Amplie a análise exploratória desses dados usando o R:
 - (i) Qual é a idade média desses pacientes?
 - (ii) Qual é a razão homens:mulheres nessa coorte?
 - (iii) Quantos receberam tratamento?
 - (iv) Quantos foram a óbito e quantos foram censurados?
 - (v) Os óbitos e as censuras se concentraram no fim do estudo ou ocorreram durante todo o período?
 - (vi) Qual o tempo de sobrevivência mediano?
- (b) Existe diferença entre homens e mulheres quanto ao tempo de sobrevivência pós-diagnóstico de Aids?
- (c) Compare homens e mulheres segundo os tempos de sobrevivência mediano e percentis 75 e 90.
- (d) Existe diferença na sobrevivência dos pacientes submetidos aos diferentes tipos de tratamento (variável *tratam*)?
- (e) Existe diferença na sobrevivência de pacientes com diferentes graus de escolaridade?
- (f) Faça os gráficos de sobrevivência e risco e aplique os testes log-rank e Peto.

Dicas

- Para análise exploratória dos dados, use comandos como:

```
> summary(dados)
> mean(dados$x)
> table(dados$x)
> boxplot(y ~ x, data=dados)
> hist(dados$x)
```

- Para avaliar como os óbitos e censuras se distribuem durante o tempo, uma sugestão é fazer um histograma dos tempos dos pacientes censurados e dos que foram a óbito.
- Para comparar a curva de sobrevivência estratificada pela variável *sexo* (ou outra covariável), use o comando:

```
> dados.km <- survfit(Surv(tempo,status) ~ sexo,
  data=dados)
> plot(dados.km)
> legend("bottomleft", legend=c("F","M"), title="sexo",
  col=1:2, lty=1:2, bty="n")
> survdiff <- survdiff(Surv(tempo,status) ~ sexo,
  rho=0, data=dados) # ou rho=1 para teste de Peto.
```

- Os tempos censurados estão assinalados no gráfico por um traço vertical sobre a curva.
- O `summary()` da função `survfit()` apresenta todos os tempos e respectivas probabilidades de sobrevivência a cada evento. A simples saída da função `survfit()` (sem `summary()`) apenas coloca os tempos medianos. Para encontrar exatamente os percentis desejados pode-se utilizar a função `quantile()`:

```
> quantile(objeto.survfit, quantiles=c(.5,.75,.9))
```

- Lembre-se que a variável de estratificação deve ser categórica (fator): `banco$varfator <- factor(banco$variavel)`.

5

Modelo paramétrico de sobrevivência

Ao término do Capítulo 5, espera-se que o leitor seja capaz de:

Identificar as distribuições estatísticas mais utilizadas para modelar as funções de sobrevivência.

Ajustar o modelo de regressão paramétrico a dados de sobrevivência utilizando o R.

Avaliar o ajuste do modelo.

Analisar e interpretar o efeito das covariáveis.

5.1 Introdução

A insuficiência renal tem alta prevalência em todo o mundo, estimando-se cerca de um milhão de pacientes utilizando alguma forma de diálise. No Rio de Janeiro, entre 1998 e 2000, 6.805 pacientes foram hemodialisados em 67 clínicas, segundo informações obtidas do Sistema de Informações Ambulatoriais para Procedimentos de Alta Complexidade – Apac. Qual é o efeito da idade em que o paciente inicia a diálise sobre o tempo de sobrevivência? Existem diferenças no tempo de sobrevivência conforme a doença de base causadora da insuficiência renal? É possível estimar o efeito da idade na sobrevivência

controlado pela doença de base? Todas essas questões passam pela inclusão de covariáveis na modelagem das funções de sobrevivência.

No Capítulo 4, vimos a abordagem não paramétrica da análise de sobrevivência, na qual a estimação é feita sem atribuir uma distribuição de probabilidade específica do tempo de sobrevivência. Os estimadores não paramétricos para as funções $S(t)$ e $\lambda(t)$ são obtidos a partir dos dados, supondo que a cada momento do tempo existe um processo diferente gerando as observações. Como cada intervalo de tempo é estimado de forma independente, pode-se dizer que a estimação não paramétrica possui tantos “parâmetros” quantos intervalos de tempo. A inclusão de covariáveis na estimação por Kaplan-Meier não permite estimar o efeito da covariável, mas apenas comparar e testar a igualdade entre as curvas de sobrevivência.

O objetivo de um modelo de regressão é estimar o efeito de covariáveis, $x_1, x_2, \dots, x_p$, também chamadas variáveis independentes ou preditoras sobre uma variável resposta (ou variável dependente), Y . De acordo com a distribuição que acreditamos ter a variável resposta Y , e de acordo com a função escolhida para a relação com as covariáveis $x_1, x_2, \dots, x_p$, identificamos o modelo de regressão como: Linear, Poisson, Logístico, entre outros. O mesmo raciocínio pode ser aplicado à análise de sobrevivência, na qual o tempo até o desfecho de interesse é a variável resposta. E lembrando sempre das características inerentes a essa classe de problemas: quem está em risco a cada momento do tempo e se há censura ou truncamento.

Neste capítulo, veremos uma abordagem paramétrica para estimar as funções básicas da análise de sobrevivência, na qual se assume que o tempo T até o evento segue uma distribuição conhecida de probabilidade e os parâmetros correspondentes são estimados. Em seguida veremos como modelar, no contexto de modelagem paramétrica, a relação entre diversas variáveis de interesse e o tempo de sobrevivência. A modelagem sem assumir distribuição paramétrica para o tempo de sobrevivência será vista no Capítulo 6.

5.2 Distribuições do tempo de sobrevivência

Sendo o tempo de sobrevivência T uma variável aleatória, que tipo de distribuição de probabilidade poderia representá-la? A primeira característica de T que orienta a escolha de uma distribuição de probabilidade é que esta é uma quantidade contínua não negativa. Dessa forma, a distribuição normal, que permite valores negativos, não é adequada para modelar o tempo de sobrevivência. Além disso, frequentemente o tempo de sobrevivência T apresenta forte assimetria, com uma grande cauda à direita (Figura 5.1). Este formato assimétrico decorre de observarmos grande parte dos tempos de sobrevivência com valores pequenos e poucas pessoas com tempos muito longos.




Figura 5.1: Distribuição do tempo de sobrevivência de pacientes da coorte de Aids do Ipec (banco de dados *ipec.csv*)

Entre os modelos paramétricos, a classe denominada **tempo de vida acelerado** é muito utilizada. Nessa, o tempo de vida T obedece à seguinte relação:

$$\ln(T) = \mu + \sigma W, \quad (5.1)$$

sendo μ o parâmetro que representa a média de $\ln(T)$ e σ a dispersão, mais usualmente denominados, respectivamente, parâmetros de locação e escala. W é uma variável aleatória que segue alguma distribuição de probabilidade que possa representar o $\ln(T)$. A denominação **tempo de vida acelerado** se justifica quando da inclusão de covariáveis nos modelos paramétricos de regressão para sobrevivência, que serão apresentados na Seção 5.4.

Diversas distribuições de probabilidades podem ser adotadas para se ajustar a distribuição do tempo de sobrevivência T . Serão descritas a seguir as distribuições exponencial, Weibull e lognormal por se adaptarem a uma grande variedade de situações. Outras distribuições, como por exemplo a log-logística, também podem ser utilizadas.

5.2.1 Distribuição exponencial

Historicamente, a distribuição exponencial foi a mais amplamente utilizada na modelagem de tempo de sobrevivência. Inicialmente, no final dos anos 1940, era utilizada em estudos de confiabilidade de sistemas eletrônicos e posteriormente em estudos de tempos de vida e em remissão de doenças crônicas e infecciosas.

Ao assumir que a variável aleatória tempo de sobrevivência T possui uma distribuição exponencial, a função de densidade de probabilidade é dada por:

$$f(t) = \alpha \exp(-\alpha t), \quad (5.2)$$

sendo $t \geq 0$ e $\alpha > 0$.

Utilizando as relações entre as funções básicas estudadas na Seção 3.7, a função de sobrevivência resultante é:

$$S(t) = \exp(-\alpha t). \quad (5.3)$$

Pela Equação (5.3), fica claro que o parâmetro α representa a velocidade de queda da função de sobrevivência ao longo do tempo, e por isso α deve ser positivo. A função de risco, estimada a partir das funções de densidade e de sobrevivência, é constante e igual a α :

$$\lambda(t) = \frac{f(t)}{S(t)} = \frac{\alpha \exp(-\alpha t)}{\exp(-\alpha t)} = \alpha = \text{constante} \quad (5.4)$$

para todo o tempo de observação t .

Sendo a função de risco constante, o risco acumulado é uma função linear do tempo, ou seja, uma reta cuja inclinação é dada por α :

$$\Lambda(t) = -\ln S(t) = \alpha t. \quad (5.5)$$

A Figura 5.2 ilustra as funções de sobrevivência, de risco e de risco acumulado segundo a distribuição exponencial. Como a função de risco é constante, as curvas de risco apresentam-se como paralelas ao eixo do tempo. Note que quanto maior for o risco α , mais abruptamente a função de sobrevivência $S(t)$ decresce e maior inclinação possui a reta que representa o risco acumulado.

Pelo fato da distribuição exponencial ser expressa por um único parâmetro, e portanto ser matematicamente a mais simples, supor que o tempo de sobrevivência possui um comportamento exponencial é uma atitude análoga à suposição de uma distribuição normal em outras áreas da estatística aplicada à saúde, ou seja, é uma distribuição que simplifica a modelagem. Na prática, entretanto, é uma situação rara. No exemplo da Aids, a suposição de uma distribuição exponencial implicaria em assumir que o tempo após o diagnóstico de Aids não afeta o tempo de sobrevivência, ou seja, que o risco de ocorrência do óbito é constante ao longo do tempo e independe do fato de o indivíduo já ter Aids há um dia, um ano ou dez anos. Por este motivo diz-se que a distribuição exponencial **não tem memória**. Essa suposição é pouco plausível, pois o próprio envelhecimento do indivíduo aumenta naturalmente seu risco de morte.

A distribuição exponencial é conhecida como distribuição exponencial padrão quando $\alpha = 1$. A média, $E(T)$, e a variância, $var(T)$, do tempo de sobrevivência, de acordo com a distribuição exponencial, são calculadas a partir da recíproca do risco, ou seja, o inverso de α é o tempo médio de sobrevivência. Quanto maior o risco, menor o tempo médio de sobrevivência e menor a variabilidade deste em torno da média:




Figura 5.2: Função de sobrevivência, de risco e de risco acumulado para a distribuição exponencial considerando diferentes valores de α

$$E(T) = \frac{1}{\alpha}$$

$$var(T) = \frac{1}{\alpha^2}.$$

Assumir que o tempo de sobrevivência T segue uma distribuição exponencial equivale a dizer que na Equação (5.1), W segue uma distribuição **valor extremo** padrão, e $\sigma = 1$. Ou seja, para cada tempo t , a Equação (5.1) fica definida por: $\ln(t) = \mu + w$, e como $E(T) = \frac{1}{\alpha}$ na distribuição exponencial, tem-se:

$$\mu = -\ln(\alpha). \quad (5.6)$$

Essa é a forma de parametrização dos modelos paramétricos utilizada no R, isto é, o parâmetro $\alpha = \exp(-\mu)$.

Como a distribuição do tempo de sobrevivência T é assimétrica, a estimativa do tempo mediano de sobrevivência em vez do tempo médio é mais usual. O tempo mediano de sobrevivência, definido como o valor de t para o qual $S(t) = 0,5$ é calculado como indicado:

$$\begin{aligned} S(t) &= \exp(-\alpha t) = 0,5 \\ -\alpha t &= \ln(1/2) \\ \alpha t &= \ln(2) \\ T_{mediano} &= \frac{\ln(2)}{\alpha}. \end{aligned}$$

Assim como o tempo médio, o tempo mediano é inversamente proporcional ao risco. No caso da distribuição exponencial, estima-se a função de risco como sendo uma função do número de eventos e do total de pessoas-tempo expostas ao risco. Os métodos baseados em pessoas-tempo assumem, de fato, a suposição de incidência constante. Na Seção 5.3 estes resultados serão demonstrados.

Apesar da simplicidade matemática do modelo exponencial, a suposição de risco constante no tempo é pouco plausível na maioria

dos fenômenos da saúde. Em geral, o modelo exponencial é uma aproximação válida quando o tempo de acompanhamento é curto o suficiente para que o risco naquele período possa ser considerado constante, por exemplo, o risco de acidentes domésticos em crianças de quatro a seis anos.

5.2.2 Distribuição Weibull

Para a maioria dos fenômenos de saúde, é mais plausível supor que o risco não é constante no tempo. A distribuição Weibull, atualmente a mais utilizada para modelar tempos de sobrevivência, particularmente na área biomédica, permite essa variação do risco no tempo. A distribuição exponencial é um caso particular da distribuição Weibull, como veremos a seguir.

Assumindo que o tempo de sobrevivência T apresenta uma distribuição Weibull ($T \sim Weibull(\alpha, \gamma)$), a função de densidade de probabilidade, $f(t)$, e a função de sobrevivência, $S(t)$, são definidas como:

$$f(t) = \gamma \alpha^\gamma t^{\gamma-1} \exp(-(\alpha t)^\gamma), \quad (5.7)$$

$$S(t) = \exp(-(\alpha t)^\gamma), \quad (5.8)$$

sendo $t \geq 0$, α o parâmetro taxa e γ o parâmetro de forma. Ambos os parâmetros sempre positivos.

A função de risco varia no tempo de acordo com a expressão:

$$\lambda(t) = \gamma \alpha^\gamma t^{\gamma-1}, \quad (5.9)$$

e a função de risco acumulado da distribuição de Weibull é dada por

$$\Lambda(t) = -\ln S(t) = (\alpha t)^\gamma. \quad (5.10)$$

O parâmetro γ determina a forma da função de risco da seguinte maneira:

- $\gamma < 1 \rightarrow$ a função de risco decresce,
- $\gamma > 1 \rightarrow$ a função de risco cresce,
- $\gamma = 1 \rightarrow$ a função de risco é constante, caso particular da distribuição exponencial.

Para encontrar o tempo mediano de sobrevivência, de acordo com a distribuição Weibull, iguala-se a probabilidade de sobrevivência a 0,5:

$$\begin{aligned} S(t) &= \exp(-(\alpha t)^\gamma) = 0,5 \\ -(\alpha t)^\gamma &= \ln(1/2) \\ \alpha t &= \ln(2) \\ T_{\text{mediano}} &= \frac{\ln(2)^{1/\gamma}}{\alpha}. \end{aligned}$$

A Figura 5.3 mostra a flexibilidade da distribuição Weibull, quando diferentes valores do parâmetro de forma γ são utilizados.

Retornando à Equação (5.1). Assim como na distribuição exponencial, W segue uma distribuição **valor extremo** padrão. Entretanto, σ pode ser diferente de 1. Logo, a relação entre as duas formas de parametrizar o modelo paramétrico é dada por:

$$\mu = -\ln(\alpha), \quad (5.11)$$

$$\sigma = 1/\gamma. \quad (5.12)$$

5.2.3 Distribuição lognormal

Outra possibilidade de modelagem paramétrica do tempo de sobrevivência assume que T segue distribuição lognormal, isto é, que a transformação exponencial de T segue uma distribuição normal com parâmetros μ e σ^2 . Neste caso, a função de densidade é dada por:

$$f(t) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{\ln(t) - \mu}{\sigma} \right)^2 \right]. \quad (5.13)$$

As funções de sobrevivência e de risco para este modelo envolvem a integração incompleta da distribuição normal padrão, dando origem à expressão para a função de sobrevivência dada por:

$$S(t) = 1 - \Phi \left(\frac{\ln(t) - \mu}{\sigma} \right), \quad (5.14)$$




Figura 5.3: Função de sobrevivência, de risco e de risco acumulado da distribuição Weibull com parâmetro $\alpha = 1$ e diferentes valores do parâmetro de forma γ

em que Φ é a função de distribuição acumulada da normal. Novamente, a partir das relações entre as funções de sobrevivência apresentadas no Capítulo 3, pode-se encontrar a função de risco e a função de risco acumulado. A Figura 5.4 ilustra essas funções para diferentes valores de σ .

Nesse caso, pela Equação (5.1), W segue uma distribuição normal padrão e os parâmetros μ e σ são os mesmos apresentados aqui.

Uma propriedade pouco atrativa da distribuição lognormal é o comportamento decrescente da função de risco para valores grandes de T . Esse decréscimo é pouco plausível na maioria das situações. Ainda assim, em algumas situações as propriedades dessa distribuição ajustam-se bem ao problema em estudo. São bons exemplos: a modelagem do risco de óbito em recém-nascidos, que diminui a cada hora, e o risco de rejeição aguda de órgãos transplantados.

Exemplo

No Capítulo 2 foi visto o exemplo da coorte de 193 pacientes com Aids no Ipec, onde observou-se o tempo desde o diagnóstico da Aids até o óbito (ou censura). Como exemplo, vamos considerar que o pesquisador modelou o tempo de sobrevivência utilizando uma distribuição exponencial e estimou o parâmetro α em 0,000497, sendo:

$$S(t) = \exp(-0,000497 \times t). \quad (5.15)$$

A Figura 5.5 mostra a curva de sobrevivência, obtida a partir do modelo ajustado. Observando a figura, pode-se verificar as propriedades gerais de todas as curvas de sobrevivência:

- $S(t) = 1$ quando $t = 0$;
- $S(t)$ é uma função decrescente.

O acompanhamento da coorte se encerra em $t = 3.500$ dias, quando espera-se que cerca de 20% dos pacientes ainda estejam vivos. Contudo, sabemos que teoricamente uma função de sobrevivência assume




Figura 5.4: Função de sobrevivência, de risco e de risco acumulado da distribuição lognormal para diferentes valores de σ e $\mu = 0$

que todas as pessoas sofrerão o evento, no caso, o óbito, e a curva tenderá a zero. Isso de fato aconteceria se o estudo se prolongasse tempo suficiente para que todas as pessoas fossem acompanhadas até o óbito.

Do modelo exponencial para a sobrevivência, podemos extrair diversas informações. Por exemplo, o que se verifica no gráfico sobre o tempo mediano de sobrevivência – aproximadamente 1.400 dias (3,8 anos) – pode ser estimado igualando $S(t)$ a 0,5. Da mesma forma se calcula, por exemplo, a probabilidade de um paciente estar vivo após 500 ou 1.000 dias de acompanhamento. Supondo uma distribuição exponencial, sabemos que a função de risco é constante, com $\lambda(t) = \alpha = 0,000497$ (ver Equação (5.15)). A partir do parâmetro α , calcula-se o tempo médio e mediano de sobrevivência:

- Tempo médio de sobrevivência = $\frac{1}{\alpha} = \frac{1}{0,000497} = 2.012$ dias;
- Tempo mediano de sobrevivência = $\frac{\ln(2)}{\alpha} = \frac{\ln(2)}{0,000497} = 1.394$ dias.




Figura 5.5: Curva de sobrevivência da coorte de Aids do Ipec segundo o modelo paramétrico exponencial

5.3 Estimação

Na seção anterior, vimos algumas distribuições de probabilidade alternativas para modelar o tempo de sobrevivência T . Para estimar os parâmetros das funções básicas de sobrevivência assumindo uma distribuição para a variável aleatória T utiliza-se o método da máxima verossimilhança, adaptado para a ocorrência da censura.

Retornando ao exemplo da coorte de Aids, supondo que T , o tempo entre o diagnóstico de Aids e o óbito, tem distribuição exponencial, será necessário estimar somente um único parâmetro α para calcular as funções básicas de sobrevivência descritas pelas Equações (5.2) a (5.5). Como há apenas censuras à direita, a função de verossimilhança descrita pela Equação (3.14) será reescrita usando-se a notação (T_i, δ_i) , na qual T_i é o tempo de sobrevivência do indivíduo i e δ_i indica o status, seja a ocorrência do evento ou censura:

$$\mathcal{L} = \prod_{i=1}^n \left(f(t_i)^{\delta_i} S(t_i)^{1-\delta_i} \right). \quad (5.16)$$

E agora, substituindo-se as funções de densidade (5.2) e de sobrevivência (5.3) da distribuição exponencial na função de verossimilhança (5.16), tem-se:

$$\begin{aligned} \mathcal{L} &= \prod_{i=1}^n (\alpha \exp(-\alpha t_i))^{\delta_i} \exp(-\alpha t_i)^{1-\delta_i} \\ l &= \ln \mathcal{L} = \sum_{i=1}^n \delta_i (\ln \alpha - \alpha t_i) + (1 - \delta_i)(-\alpha t_i) \\ &= \sum_{i=1}^n \delta_i \ln \alpha - \alpha t_i. \end{aligned} \quad (5.17)$$

O estimador de máxima verossimilhança para o parâmetro α é obtido a partir do cálculo da derivada do logaritmo da função de verossimilhança (5.17), resultando em:

$$\hat{\alpha} = \frac{\sum_{i=1}^n \delta_i}{\sum_{i=1}^n t_i} = \frac{\text{Total de eventos}}{\sum_{i=1}^n t_i}.$$

Ou seja, o parâmetro α é calculado como número total de eventos dividido pela soma de todos os tempos observados, o que equivale a calcular o número de eventos por pessoa-tempo. Perfeitamente adequado, uma vez que o risco é considerado constante. Assim, quando calculamos a taxa de mortalidade por pessoa-tempo de um estudo de coorte, estamos considerando que o tempo de sobrevivência tem uma distribuição exponencial, ou seja, não tem memória. Não importa quanto tempo decorreu desde o início do estudo, a probabilidade de evento em qualquer instante de tempo, ou seja, o risco, é constante.

Exemplo

No exemplo dos pacientes com Aids da Tabela 4.1, feita a suposição de que o tempo entre o diagnóstico de Aids e a morte segue uma distribuição exponencial, o parâmetro desta distribuição será estimado como:

$$\hat{\alpha} = \frac{\text{Total de eventos}}{\sum_{i=1}^n t_i} = \frac{15}{1.012} = 0,0148,$$

o que equivale à 0,015 morte por pessoa-mês, ou 17,8 por 100 pessoas/ano. O tempo médio de sobrevivência é $1/\alpha = 67,5$ meses, e a função de sobrevivência é estimada por $S(t) = \exp(-0,015t)$.

Assim, as estimativas paramétrica e não paramétrica para a probabilidade de um paciente estar vivo depois de 16 meses do diagnóstico de Aids seriam, respectivamente:

- Distribuição exponencial:
 $S(16) = \exp(0,015 \times (-16)) = 0,786;$
- Kaplan-Meier: $S(16) = 0,952.$

Observe que as estimativas são bastante diferentes, uma vez que a suposição de distribuição exponencial não é a mais adequada aos dados.

E se o tempo do diagnóstico até à morte fosse ajustado segundo uma distribuição Weibull ou lognormal? A construção da verossimilhança é feita da mesma forma, substituindo-se apenas as

funções de densidade e de sobrevivência. No entanto, neste caso, as equações não podem ser resolvidas analiticamente para todos os parâmetros e processos iterativos de maximização (por exemplo, o método de Newton-Raphson) são utilizados.

A Figura 5.6 mostra a estimativa Kaplan-Meier de $S(t)$ e as estimativas paramétricas obtidas para o tempo de sobrevivência ajustando uma distribuição exponencial e uma Weibull. Considerando que o estimador não paramétrico é o que melhor reflete o processo de sobrevivência observado, a distribuição Weibull é a mais próxima dos dados, se afastando somente para tempos de sobrevivência mais longos.




Figura 5.6: Estimativas paramétrica e não paramétrica da curva de sobrevivência da coorte de Aids do Ipec

5.4 Modelo de regressão paramétrico

O efeito de covariáveis sobre o tempo de sobrevivência é estimado através de um modelo de regressão, no qual o tempo de sobrevivência é a variável resposta e $\mathbf{x} = (x_1, x_2, \dots, x_p)$ é o vetor de covariáveis (variáveis independentes) possivelmente associadas ao tempo.

Assim o modelo terá um componente aleatório, que descreve probabilisticamente o comportamento do tempo de sobrevivência, e um componente sistemático ou estrutural, que descreve a relação entre os parâmetros da distribuição de probabilidade e as covariáveis.

Sendo T a variável aleatória que denota o tempo até a ocorrência de um evento, o modelo de regressão estabelece que a função de risco de um indivíduo no tempo t , dado o vetor de covariáveis fixas $\mathbf{x}$ é:

$$\lambda(t|\mathbf{x}) = \lambda_0(t)g(\mathbf{x}\boldsymbol{\beta}), \quad (5.18)$$

em que β' s são os coeficientes a estimar, $g(\cdot)$ é uma função positiva e contínua das covariáveis e $\lambda_0(t)$ é o risco basal de um indivíduo que possui $g(\mathbf{x}\boldsymbol{\beta}) = 1$.

A razão de riscos de dois indivíduos diferentes é uma função das covariáveis e não depende do tempo. Logo, de acordo com a Equação (5.18) diferentes indivíduos com covariáveis x_1 e x_1^* , por exemplo, possuem **riscos proporcionais**:

$$\frac{\lambda_i(t|x_1)}{\lambda_j(t|x_1^*)} = \frac{g(x_1\beta_1)}{g(x_1^*\beta_1)}.$$

Para ajustar um modelo de regressão paramétrico é necessário supor uma distribuição de probabilidade, como as descritas na Seção 5.3, para o tempo de sobrevivência T , que define a forma da função de sobrevivência, de risco e de risco acumulado. Os parâmetros da distribuição adotada (não confundir com os parâmetros β' s da regressão) definem a forma dessas funções. O efeito das covariáveis (agora sim falamos dos β' s da regressão) dos modelos de regressão paramétricos de sobrevivência são estimados por máxima verossimilhança, levando em conta as censuras.

Extensões dos modelos paramétricos de sobrevivência, inclusive métodos de suavização *spline* e fragilidade, estão implementadas da mesma forma como no modelo semiparamétrico de Cox, sendo apresentadas respectivamente nos Capítulos 9 e 12. Entretanto, a modelagem por processo de contagem, que permite a inclusão de covariável mudando no tempo (Capítulo 8) ou eventos múltiplos (Capítulo 10) não está implementada.

5.4.1 Modelo de regressão exponencial

No modelo de regressão exponencial, usado quando se assume que o risco é constante ao longo do tempo, o parâmetro α depende das covariáveis $\mathbf{x}$ da seguinte forma:

$$\alpha(\mathbf{x}) = \exp(\mathbf{x}\boldsymbol{\beta}), \quad (5.19)$$

sendo $\boldsymbol{\beta}$'s as estimativas dos efeitos das covariáveis e α o parâmetro que define o risco exponencial. Ou seja, o risco é uma função das covariáveis. Isso equivale a dizer, por exemplo, que a idade aumenta o risco de óbito por insuficiência renal, ou que a categoria de transmissão “usuário de drogas injetáveis” tem risco maior do que a categoria “transmissão sexual” para o tempo de sobrevivência com Aids.

As funções de risco e sobrevivência para o modelo de regressão exponencial ficam assim definidas:

$$\lambda(t|\mathbf{x}) = \alpha(\mathbf{x}) = \exp(\mathbf{x}\boldsymbol{\beta}); \quad (5.20)$$

$$S(t|\mathbf{x}) = \exp(-\alpha(\mathbf{x})t) = \exp(-\exp(\mathbf{x}\boldsymbol{\beta})t). \quad (5.21)$$

Exemplo

Voltemos ao exemplo inicial: entre os 6.805 pacientes em diálise acompanhados durante um ano, 1.603 morreram durante este período. Assumindo que o risco de morrer é constante ao longo do tempo, podemos estimar o efeito de idade na sobrevivência e no risco através do modelo exponencial:

$$\lambda(t|idade) = \exp(\beta_0 + \beta_1 \times idade). \quad (5.22)$$

As estimativas de máxima verossimilhança dos parâmetros do modelo descrito em (5.22) são: $\hat{\beta}_0 = -6,136$ e $\hat{\beta}_1 = 0,037$. Substituindo-se na equação por esses valores, a estimativa do risco no tempo t é:

$$\hat{\lambda}(t|idade) = \exp(-6,136 + 0,037 \times idade).$$

Temos então que, para cada ano a mais de vida, o risco aumenta $\exp(0,037) = 1,037$ vezes, ou seja, aproximadamente 4% a cada ano. Essas estimativas também permitem, por exemplo, a comparação entre dois indivíduos submetidos à diálise, um com 30 anos e outro com 70 anos. Considerando o risco constante no tempo, substituímos as estimativas dos parâmetros β na Equação (5.22):

$$\begin{aligned}\frac{\hat{\lambda}(t|idade = 70)}{\hat{\lambda}(t|idade = 30)} &= \frac{\exp(\hat{\beta}_0 + \hat{\beta}_1 \times 70)}{\exp(\hat{\beta}_0 + \hat{\beta}_1 \times 30)} \\ &= \exp(\hat{\beta}_1 \times 40) = 4,4.\end{aligned}$$

O efeito da idade sobre o risco $\lambda(t)$ indica que o risco de um indivíduo em diálise morrer aos 70 anos é 4,4 vezes maior do que o de morrer aos 30 anos. É como se o indivíduo com 70 anos progredisse 4,4 vezes mais rápido ao longo do tempo, acelerando a uma taxa constante (Figura 5.7). Como o modelo é de riscos proporcionais, quaisquer dois indivíduos com diferença de 40 anos entre si gera um um risco relativo estimado em 4,4.




Figura 5.7: Curva de sobrevivência ajustada de dois indivíduos em diálise com 30 e 70 anos, de acordo com o modelo de regressão exponencial

5.4.2 Modelo de regressão Weibull

Da mesma forma que na distribuição exponencial, utilizar a distribuição Weibull no contexto da modelagem de sobrevivência significa que o tempo T segue uma distribuição de Weibull, e o parâmetro α é modelado pelas covariáveis. Existem outras formas de incluir covariáveis na distribuição Weibull, mas essa é a mais utilizada. Assumindo-se a mesma forma funcional utilizada para o parâmetro α da distribuição exponencial da Equação (5.19) e substituindo-o na função de risco da Equação (5.9) e na função de sobrevivência (Equação (5.8)) da distribuição Weibull, tem-se:

$$\begin{aligned}\lambda(t|\mathbf{x}) &= \gamma t^{\gamma-1} \alpha(\mathbf{x})^\gamma \\ &= \gamma t^{\gamma-1} \exp(\mathbf{x}\boldsymbol{\beta})^\gamma;\end{aligned}\tag{5.23}$$

$$\begin{aligned}S(t|\mathbf{x}) &= \exp(-(\alpha(\mathbf{x})t)^\gamma) \\ &= \exp(-(\exp(\mathbf{x}\boldsymbol{\beta})t)^\gamma).\end{aligned}\tag{5.24}$$

No caso do modelo descrito pela Equação (5.23), na qual somente o parâmetro α depende de covariáveis, os riscos para diferentes indivíduos também são proporcionais. Entretanto, caso o parâmetro de forma γ da distribuição Weibull também varie com as covariáveis, o modelo de regressão deixa de ser um modelo de riscos proporcionais. Relembrando a Seção 5.2.2, o parâmetro γ determina a forma da função de risco: se $\gamma > 1$, o risco aumenta no tempo; se $\gamma < 1$, o risco diminui; e se $\gamma = 1$, a função de risco é constante, equivalendo ao modelo exponencial.

Assumindo-se uma distribuição Weibull para o tempo até o óbito dos pacientes hemodialisados, pode-se estimar o efeito da idade no risco de morte substituindo-se na Equação (5.23) a expressão $\alpha(\mathbf{x})$ por $\exp(\beta_0 + \beta_1 \times idade)$, da seguinte forma:

$$\lambda(t|idade) = \gamma t^{\gamma-1} \exp(\beta_0 + \beta_1 \times idade)^\gamma.\tag{5.25}$$

Nos modelos de regressão paramétricos é possível utilizar estratos que permitem estimar diferentes parâmetros γ da distribuição

segundo subgrupos populacionais, mantendo os coeficientes estimados para as covariáveis comuns para todo o conjunto. Dessa forma se permite a variação da curva de risco basal entre os estratos, melhorando a qualidade da estimativa do efeito das covariáveis. Também é possível estimar para cada estrato separadamente, caso indicado, o efeito das variáveis.

Modelo paramétrico de sobrevivência no R

O comando `survreg()` estima modelos paramétricos de sobrevivência. A sintaxe do comando segue a forma:

```
> m <- survreg(formula, data=dados, dist="distribuição")
```

O argumento `dist` é a distribuição a ser ajustada: `dist = "exp"` ajusta a distribuição exponencial; `dist = "weibull"` ajusta distribuição Weibull.

O argumento `formula` possui o seguinte formato: `Surv(tempo,status)~1` no caso da estimação de modelos sem covariáveis e `Surv(tempo,status)~ var1 + var2` para modelos de regressão. Pode-se também estratificar o modelo de regressão paramétrico Weibull através da inclusão do comando `strata()` no argumento `formula`, assim:

```
> m <- survreg(Surv(tempo,status) ~ covariáveis +
  strata(var), data=dados, dist="weibull")
```

No argumento `formula`, o símbolo `*` (`var1*var2`) representa interação entre duas variáveis, incluindo a estimação do parâmetro de cada variável separadamente. O símbolo `:` (`var1:var2`) somente inclui o termo de interação no modelo.

Exemplo

Os dados do exemplo de sobrevivência de pacientes em hemodiálise estão disponíveis no arquivo `dialise.csv`. Vamos estimar parametricamente o efeito da idade no R.

```
> dialise <- read.csv("dialise.csv",header=T)
> regweib <- survreg(formula=Surv(tempo,status) ~ idade,
  data=dialise, dist="weibull")
> summary(regweib)
```

```
Call: survreg(formula = Surv(tempo, status) ~ idade,
  data = dialise, dist = "weibull")

      Value Std. Error      z      p
(Intercept)  6.7512    0.14693  45.95 0.00e+00
idade        -0.0436    0.00224 -19.50 1.12e-84
Log(scale)   0.1987    0.02083   9.54 1.49e-21

Scale= 1.22
```

```
Weibull distribution
Loglik(model)=-7877.7 Loglik(intercept only)=-8104.2
  Chisq= 453.16 on 1 degrees of freedom, p= 0
Number of Newton-Raphson Iterations: 7
n= 6805
```

Observe que na última linha da tabela com os parâmetros tem-se o logaritmo do inverso do parâmetro forma ($\gamma = 1/\text{Scale} = 1,22$), e os respectivos erro padrão e teste de significância do parâmetro estimado. Pode-se concluir que o parâmetro forma (γ) é significativamente diferente de 1.

Como a forma de parametrizar os modelos paramétricos no R é diferente da apresentada no texto, algumas adaptações são necessárias para compatibilizá-las (ver Equações 5.11 e 5.12). Fique atento ao sinal do parâmetro, que está invertido em relação ao que utilizamos no texto:

- Parâmetro $\alpha = \exp(-x\beta)$ (atenção para o sinal $-$);
- Parâmetro γ é igual ao inverso do **Scale** ($= 1/\text{Scale}$).

Logo, temos: $\beta_0 = -6,7512$ e $\beta_1 = 0,0436$. Então, para cada ano a mais de idade, o risco de morrer é $\exp(0,0436) = 1,045$ vezes maior, ou seja, ocorre um aumento de 4,5%.

O parâmetro de forma γ é igual a $1/\text{Scale} = 1/1,22 = 0,81$. Ou seja, o risco de morrer diminui à medida que aumenta o tempo do

paciente em hemodiálise. Isso pode estar relacionado a um excesso de óbitos logo no início do processo, em função do baixo preparo dos pacientes em processo de insuficiência renal, fazendo com que o início da hemodiálise seja feito de emergência.

Comparando então o risco de morrer em pacientes com 30 e 70 anos de idade, temos:

$$\begin{aligned}\lambda(t|idade = 70) &= 0,81t^{(0,81-1)} \exp(-6,7512 + 0,0436 \times 70)^{0,81}; \\ \lambda(t|idade = 30) &= 0,81t^{(0,81-1)} \exp(-6,7512 + 0,0436 \times 30)^{0,81}.\end{aligned}$$

Para calcular o risco relativo de morte entre os pacientes com 30 e 70 anos de idade, basta calcular a razão entre as expressões $\lambda(t|idade = 30)$ e $\lambda(t|idade = 70)$:

$$\begin{aligned}\frac{\lambda(t|idade = 70)}{\lambda(t|idade = 30)} &= \left(\frac{\exp(-6,7512 + 70 \times 0,0436)}{\exp(-6,7512 + 30 \times 0,0436)} \right)^{0,81} \\ &= \exp(40 \times 0,0436)^{0,81} = 4,11.\end{aligned}$$

Considerando que o padrão da sobrevivência pode ser muito diferente quando a causa da insuficiência renal é a doença congênita – são pacientes mais jovens e que são mais transplantados – pode-se verificar tal hipótese utilizando a variável *doença congênita* (*sim* ou *não*) aditivamente no modelo, como estrato ou com interação entre o estrato e a idade.

```
> cong.simpl <- survreg(Surv(tempo,status) ~ idade + congenita,
  data=dialise, dist="weibull")
> cong.strat <- survreg(Surv(tempo,status) ~ idade + strata(congenita),
  data=dialise, dist="weibull")
> cong.inter <- survreg(Surv(tempo,status) ~ idade * strata(congenita),
  data=dialise, dist="weibull")
```

Antes de passarmos à interpretação dos resultados, vamos mostrar o passo a passo da construção das medidas de interesse a partir das informações dos modelos que são apresentadas na função *summary()* do objeto resultante da modelagem. A Tabela 5.1 reúne,

resumidamente, as estimativas dos três modelos ajustados. Observe que o coeficiente para doença congênita não é estimado quando essa variável é usada para estratificação, mas o parâmetro de escala é diferente para cada categoria.

Tabela 5.1: Informações a serem retiradas da saída do R dos modelos paramétricos para calcular os parâmetros de interesse

	Modelos		
	<i>cong.simpl</i>	<i>cong.strat</i>	<i>cong.inter</i>
Coefficientes (β)			
(Intercept)	6.7357	6.7385	6.74462
idade	-0.0437	-0.0434	-0.04375
congenita	0.9781	-	-
idade:strata(congenita)=1	-	-	0.00735
Scale			
global	1.22	-	-
congenita=0		1.227	1.222
congenita=1		0.762	0.894

O inverso do parâmetro de escala, que é igual ao parâmetro de forma γ , e a exponencial dos coeficientes de regressão β elevado ao parâmetro de forma, que é a razão de riscos, podem ser extraídos diretamente do objeto a que foi atribuído o modelo, como exemplificamos a seguir para cada modelo:

```
#Parâmetro de Forma
#Modelos simples:
1/cong.simpl$scale
#Modelo estratificado
1/cong.strat$scale
#Modelo estratificado com interação
1/cong.inter$scale

#Risco relativos:
#Modelos simples:
exp(-cong.simpl$coeff[-1])^(1/cong.simpl$scale)
#Modelo estratificado para congenita=0
exp(-cong.strat$coeff[-1])^(1/cong.strat$scale[1])
#Modelo estratificado para congenita=1
exp(-cong.strat$coeff[-1])^(1/cong.strat$scale[2])
```

```
#Modelo estratificado com interação para congênita=0
exp(-cong.inter$coeff[2])^(1/cong.inter$scale[1])
#Modelo estratificado com interação para congênita=1
exp(-sum(cong.inter$coeff[2:3]))^(1/cong.inter$scale[2])
```

Comparando os resultados dos três modelos (Tabela 5.2), observamos que o parâmetro forma da distribuição Weibull é bastante diferente para o estrato de pessoas cuja insuficiência renal foi causada por problema congênito. O parâmetro de forma global (modelo *cong.simpl*) e do estrato não congênito do modelo *cong.strat* são semelhantes porque somente 2% dos pacientes possuem doença congênita. Além disso, quando incluímos interação entre idade e estrato (modelo *cong.inter*), o efeito da idade se mantém praticamente inalterado, pois o efeito da interação não é estatisticamente significativo ($p\text{-valor}=0,09$).

Tabela 5.2: Estimativas do risco relativo ($\exp(\beta)^\gamma$) dos modelos paramétricos (Weibull) não estratificado, estratificado sem e com interação com a idade para os dados da diálise

Variáveis	Modelos		
	Simple	Estratificado	Interação
Idade	1,036		
Congênita=Não		1,034	1,036
Congênita=Sim		1,058	1,041
Congênita	0,448		
Forma (γ)	0,821		
Congênita=Não		0,815	0,818
Congênita=Sim		1,312	1,118

A seguir encontram-se as equações dos modelos estimados de acordo com a notação do respectivo capítulo:

Modelo simples
$\lambda(t \mathbf{x}) = 0,821t^{0,821-1} \exp(-6,735 + 0,044 \times idade - 0,978 \times congenita)^{0,821}$
Modelo estratificado
Congênita=Não
$\lambda(t \mathbf{x}) = 0,815t^{0,815-1} \exp(-6,739 + 0,0433 \times idade)^{0,815}$
Congênita=Sim
$\lambda(t \mathbf{x}) = 1,312t^{1,312-1} \exp(-6,739 + 0,043 \times idade)^{1,312}$
Modelo estratificado com interação
Congênita=Não
$\lambda(t \mathbf{x}) = 0,818t^{0,818-1} \exp(-6,745 + 0,044 \times idade)^{0,818}$
Congênita=Sim
$\lambda(t \mathbf{x}) = 1,118t^{1,118-1} \exp(-6,745 + (0,044 - 0,007) \times idade)^{1,118}$

Exemplo

Retomando o exemplo da coorte de Aids do Ipec apresentada no início do capítulo (ver Figura 5.1), ajustamos dois modelos de regressão paramétrico com distribuição exponencial e Weibull, para estimar o efeito do tratamento controlado por idade e sexo.

```
> hiv<-read.table("ipec.csv",header=T,sep=)
> modhiv.exp <- survreg(formula=Surv(tempo,status) ~
  idade + sexo + tratam, data=hiv, dist="exponential")
> summary(modhiv.exp)
```

```
Call:
survreg(formula = Surv(tempo, status) ~ idade +
  sexo + tratam, data = hiv, dist = "exponential")
Value Std. Error      z      p
```

```
(Intercept)  6.11597      0.4921 12.429 1.83e-35
idade        0.00829      0.0112  0.739 4.60e-01
sexoM       -0.19455      0.2841 -0.685 4.93e-01
tratam       1.37541      0.1920  7.164 7.83e-13
```

Scale fixed at 1

Exponential distribution

```
Loglik(model)= -743.5  Loglik(intercept only)= -774.6
      Chisq= 62.3 on 3 degrees of freedom, p= 1.9e-13
Number of Newton-Raphson Iterations: 5
n= 193
```

```
> modhiv.wei <- survreg(formula=Surv(tempo,status) ~
      idade + sexo + tratam, data=hiv, dist="weibull")
> summary(modhiv.wei)
```

Call:

```
survreg(formula = Surv(tempo, status) ~ idade + sexo + tratam,
      data = hiv, dist = "weibull")
```

	Value	Std. Error	z	p
(Intercept)	6.0684	0.5674	10.695	1.07e-26
idade	0.0095	0.0130	0.731	4.65e-01
sexoM	-0.2363	0.3277	-0.721	4.71e-01
tratam	1.4861	0.2273	6.538	6.25e-11
Log(scale)	0.1419	0.0862	1.647	9.97e-02

Scale= 1.15

Weibull distribution

```
Loglik(model)= -742  Loglik(intercept only)= -770.3
      Chisq= 56.64 on 3 degrees of freedom, p= 3.1e-12
Number of Newton-Raphson Iterations: 5
n= 193
```

O resultado de ambos os modelos serão utilizados nas próximas seções.

O objeto resultante do modelo paramétrico de sobrevivência no R

O objeto *m* contém o resultado do ajuste da distribuição e uma série de estatísticas de interesse que podem ser vistos com a função *summary()*, que traz as seguintes informações:

> summary(m)

- *Call* → o modelo ajustado;
- *Value* → os parâmetros estimados para o intercepto, variáveis, o logaritmo da escala;
- *Std.Error* → erro padrão do parâmetro estimado;
- *z* → estatística-z para a estimativa dos parâmetros;
- *p* → p-valor da estatística z;
- *Scale* → Weibull = $1/\gamma$, Exponencial = 1;
- *Loglik(model)* → logaritmo da verossimilhança do modelo completo com covariáveis;
- *Loglik(intercept only)* → logaritmo da verossimilhança do modelo nulo, sem covariáveis;
- *Number of Newton-Raphson Iterations* → número de iterações para determinar as estimativas dos parâmetros;
- *n* → número de observações.

Importante: a parametrização dos modelos paramétricos de sobrevivência no R é aquela descrita através da Equação (5.1). Logo, no caso da distribuição exponencial, o parâmetro α corresponde a $\exp(-\text{Intercept})$. E, no caso da distribuição Weibull os parâmetros são encontrados da seguinte forma: $\alpha = \exp(-\text{Intercept})$ e $\gamma = 1/\text{Scale}$. Na presença de covariáveis, os parâmetros de regressão β ficam com o sinal inverso ao que aparece no *output*. As transformações acima foram apresentadas nas Equações 5.6, 5.11 e 5.12.

5.5 Seleção de modelos

Para comparar modelos paramétricos de sobrevivência aninhados são utilizados os mesmos métodos dos modelos lineares generalizados: o teste da **razão de verossimilhanças** e o teste de **Wald**.

5.5.1 Teste da razão de verossimilhanças

O teste da razão de verossimilhanças é utilizado para comparar modelos aninhados, isto é, o modelo com maior número de parâmetros estimados tem que conter todos os parâmetros do modelo menor. A estatística, que segue assintoticamente uma distribuição χ^2 com número de graus de liberdade igual à diferença no número de covariáveis dos modelos, fica definida como:

$$RV = 2 \times (l_{maior} - l_{menor}) \quad (5.26)$$

sendo l_{menor} igual ao logaritmo da função de verossimilhança do modelo com menos parâmetros e l_{maior} igual ao do modelo com mais parâmetros. Esta técnica está melhor detalhada no Capítulo 6, Seção 6.6.1, onde é utilizada para comparar modelos de regressão de Cox.

Uma primeira aplicação permite comparar um modelo com distribuição exponencial e outro com distribuição Weibull. Isso equivale a testar a hipótese nula de que o parâmetro de forma, γ , da distribuição Weibull é igual a um.

Comparando os dois modelos ajustados para os dados de Aids (*modhiv.exp* e *modhiv.wei*), a estatística é:

$$RV = 2 \times (l_{weibull} - l_{exponencial}) = 2 \times [(-742) - (-743,5)] = 3,$$

resultando em valor de $p = 0,08$. Ou seja, houve uma melhora no ajuste, ainda que marginalmente significativa, pois o número de observações é muito pequeno.

O comando `anova(modhiv.wei,modhiv.exp)` reproduz exatamente o que descrevemos acima.

O valor de `Chisq=56.64` na saída do R da regressão paramétrica `modhiv.wei` é o teste da razão de verossimilhanças comparando o modelo estimado com o modelo nulo (sem covariáveis). Pela Equação (5.26), a estatística de teste é igual a 2 vezes a log verossimilhança do modelo Weibull ajustado menos a log verossimilhança do modelo Weibull nulo.

5.5.2 Teste de Wald

A estatística de Wald testa a significância de covariáveis uma a uma, ou seja, testa a hipótese nula H_0 de que o parâmetro β_j da regressão é igual a zero contra a hipótese alternativa de que é diferente de zero. Esta estatística é definida por:

$$z_j = \frac{\hat{\beta}_j}{ep(\hat{\beta}_j)}, \quad (5.27)$$

em que $ep(\hat{\beta}_j)$ é o erro padrão da estimativa de β_j . Sob a hipótese nula, tem-se que a estatística z_j segue uma distribuição normal padrão.

Analisando o resultado do modelo de regressão de Weibull `modhiv.wei` e olhando o p-valor da estatística `z`, tem-se que nem sexo nem idade apresentam efeito significativo. Somente o número de medicamentos antirretrovirais tem efeito protetor no risco de morte dos pacientes da coorte.

5.6 Qualidade do ajuste do modelo

Para avaliar a qualidade do ajuste de um modelo paramétrico, pode-se utilizar uma medida global de qualidade do ajuste denominada **função desvio** (ou *deviance*) ou uma ferramenta gráfica.

5.6.1 Medida global de qualidade do ajuste

A função desvio (ou *deviance*) pode ser utilizada para obter uma estatística global de qualidade de ajuste do modelo. A hipótese nula H_0

de que o modelo se ajusta aos dados pode ser testada pela estatística:

$$D = 2 \times (l_{\text{saturado}} - l_{\text{modelo}}),$$

em que l_{modelo} e l_{saturado} são, respectivamente, o logaritmo da função de verossimilhança do modelo avaliada nas estimativas de máxima verossimilhança e o logaritmo da função de verossimilhança do modelo saturado.

Um modelo saturado é aquele que ajusta n parâmetros para todas as n observações, perfeitamente. Para calcular a *deviance*, os parâmetros de perturbação (ou seja, aqueles parâmetros comuns aos dois ajustes, e nos quais não há interesse no estimador) são mantidos fixos em ambos os modelos, o saturado e o que se deseja avaliar.

No modelo de regressão Weibull, por exemplo, o único parâmetro de perturbação é o de forma (γ). O valor estimado de γ obtido no modelo ajustado será mantido fixo no modelo saturado. Quanto maior for a *deviance* do modelo, pior a qualidade do ajuste. A estatística D segue, assintoticamente, uma distribuição qui-quadrado (χ^2) com número de graus de liberdade igual a $n - p - 1$, ou seja, o número de observações menos o número de covariáveis do modelo menos um. Nesse caso, quanto menor a estatística, maior o *p-valor* e melhor a qualidade de ajuste do modelo.

No R, a *deviance* de um modelo ajustado é obtida assim:

```
> modhivexp.dev <- sum(resid(modexp.hiv,type="deviance")^2)
```

O *p-valor* da estatística de teste da *deviance* é encontrado da seguinte forma: `1-pchisq(modhivexp.dev,gl)`, em que $gl = 193 - 3 - 1 = 189$. O resultado para o modelo exponencial é 0,00020. Logo, rejeita-se H_0 e esse modelo não se ajusta bem aos dados. Testemos então um modelo Weibull.

```
> modhivwei.dev<-sum(resid(modhiv.wei,type="deviance")^2)
> gl<-193-3-1
> 1-pchisq(modhivwei.dev,gl)
```

```
[1] 0.01004656
```

O teste de qualidade global de ajuste também rejeita a hipótese nula, embora com *p-valor* um pouco maior: 0,010. Ainda assim, para cada medicamento acrescido ao tratamento o risco de óbito diminui em 72,5%: $\exp(-1,486)^{(1/1,15)} = 0,275$. Lembre-se sempre de inverter os sinais dos coeficientes no cálculo do risco.

5.6.2 Análise gráfica do ajuste do modelo

Este método tem o intuito de auxiliar na escolha da família de distribuições paramétricas. É portanto, uma ferramenta exploratória para escolha de distribuições candidatas.

O gráfico do logaritmo da função de risco (ou logaritmo do risco acumulado) contra o logaritmo do tempo serve para avaliar a premissa de proporcionalidade dos riscos e a forma do risco $\lambda(t)$. No caso do modelo paramétrico de Weibull, espera-se encontrar retas paralelas, e no caso do modelo paramétrico exponencial espera-se que a inclinação das retas seja igual a um. Curvas coincidentes indicam que o parâmetro referente à covariável provavelmente não será significativo quando do ajuste do modelo paramétrico. A Figura 5.8 ilustra esse gráfico para o modelo de regressão paramétrico com distribuição Weibull e presença de diabetes como covariável para os dados de diálise.

Outra análise gráfica útil é a comparação das curvas de sobrevivência geradas pelo estimador não paramétrico de Kaplan-Meier com as estimadas parametricamente. Quanto mais próximo o modelo paramétrico estiver da curva de sobrevivência do estimador Kaplan-Meier, melhor o modelo. Como exemplo, foram estimados dois modelos (exponencial e Weibull), considerando-se os dados da diálise e como covariável a presença ou ausência de diabetes no paciente.

```
> # Estimativa não paramétrica Kaplan-Meier
> km <- survfit(Surv(tempo,status)~cdiab,data=dialise)
> # Modelo paramétrico Exponencial
> modexp <- survreg(formula=Surv(tempo,status)~ cdiab,
  data=dialise, dist="exponential")
> # Modelo paramétrico Weibull
```




Figura 5.8: Logaritmo do risco acumulado contra logaritmo do tempo para os pacientes com e sem diabetes (dados da diálise)

```
> modwei <- survreg(formula=Surv(tempo,status)~ cdiab,
  data=dialise, dist="weibull")
```

A Figura 5.9 mostra que o modelo que mais se aproxima da estimação não paramétrica é o modelo Weibull. Outras distribuições podem ser assumidas para o tempo de sobrevivência T , sendo mais raras na literatura. No R estão disponíveis as distribuições normal (`dist="gaussian"`), lognormal (`dist="lognormal"`), logística (`dist="logistic"`) e loglogística (`dist="loglogistic"`).

Uma observação importante é que as análises gráficas de avaliação da qualidade do ajuste do modelo são mais indicadas do que testes estatísticos formais de qualidade global de ajuste, que tendem a ter baixo poder estatístico para amostras pequenas e rejeitar o modelo para amostras grandes. Os métodos gráficos apresentados nesta seção, no entanto, devem ser usados para descartar modelos claramente inapropriados, e não para demonstrar que um modelo paramétrico em particular é melhor, pois para isso a análise de resíduos seria mais apropriada.




Figura 5.9: Comparação das curvas de sobrevivência do Kaplan-Meier e dos modelos paramétricos. As três curvas em cinza referem-se aos pacientes sem diabetes e as três curvas pretas, aos pacientes com diabetes (dados da diálise)

Na prática, é bastante comum diferentes modelos paramétricos terem ajustes razoáveis para um mesmo conjunto de dados, especialmente nos intervalos de tempo que concentram um maior número de observações, em geral no início do período, e apresentarem resultados semelhantes das quantidades de interesse.

5.7 Análise de resíduos

A definição de uma medida de resíduo no contexto de sobrevivência não é tão clara e direta como em modelos lineares, mas existem algumas medidas propostas na literatura. Algumas, específicas para modelos paramétricos, são apresentadas aqui. Uma discussão mais detalhada será feita no Capítulo 7, que trata de resíduos para o modelo de Cox (Capítulo 6), uma vez que são definidos e interpretados da mesma forma.

Alguns resíduos não estão disponíveis para modelos paramétricos. É o caso do resíduo de Schoenfeld, para avaliação do pressuposto de proporcionalidade, que somente está disponível para o modelo de Cox e suas extensões. Outros, como o resíduo martingale, *deviance* e *score*, serão apresentados no Capítulo 7. No presente capítulo apresentaremos somente os resíduos que são específicos para a avaliação global dos modelos paramétricos.

São três tipos de resíduos ditos de “perturbação” para modelos de tempos de vida acelerados que avaliam o impacto da retirada de uma observação no ajuste global do modelo. O primeiro mede a mudança no vetor estimado de parâmetros da regressão; o segundo mede, em unidades de desvio padrão, a mudança na resposta predita; e o último avalia o efeito sobre o parâmetro de forma.

Em todos os casos, o objetivo é identificar observações que são pontos influentes no modelo, e o seu impacto sobre:

- o conjunto de parâmetros da regressão $\rightarrow$ *ldcase*;
- os valores preditos $\rightarrow$ *ldresp*;
- o parâmetro de forma $\rightarrow$ *ldshape*.

Calculamos para os dados da coorte de Aids os resíduos do modelo paramétrico de Weibull *modhiv.wei* (p. 158). Os gráficos permitem identificar possíveis pontos influentes (Figura 5.10).

Identificação de pontos em gráficos no R

Para identificar os indivíduos muito afastados do predito pode-se usar a função *identify()*. Ao executá-la o cursor muda de forma e aguarda que pontos no gráfico sejam identificados através de um simples clique do *mouse*. Ao assinalar os pontos no próprio gráfico, o número da linha correspondente no banco de dados é apresentada. Clicando no botão da direita do *mouse* encerra-se a função. Na janela de comando a função retorna o número da linha do indivíduo no banco de dados.


```
> res.ldcase <- residuals(modhiv.wei, type="ldcase")
> plot(res.ldcase, main="Vetor de Parâmetros", xlab="Índice")
```

Os mesmos comandos, mudando somente o argumento *type*, permitem calcular e fazer os gráficos dos demais resíduos.




Figura 5.10: Resíduos de perturbação da verossimilhança do modelo Weibull para a coorte de Aids do Ipec

Os casos identificados nos gráficos são esses:

```
> hiv[c(9,10,49,82,182),c(4,5,6,8,13)]
      tempo status sexo idade tratam
```

9	1563	1	M	44	0
10	1247	1	M	23	0
49	1344	0	M	30	0
82	1272	0	M	22	0
182	16	1	M	42	3

Pode-se notar que os casos 9 e 10 sobreviveram um longo tempo, assim como os censurados (49 e 82), sem receber antirretrovirais. Por outro lado, o caso 182 morreu rapidamente e recebeu três medicamentos. Retirando o caso 82, que aparece nos três gráficos, o modelo se altera bastante.

```
> summary(survreg(formula=Surv(tempo,status)~
  idade + sexo + tratam, data=hiv, dist="weibull",
  subset= -82))
```

Call:

```
survreg(formula = Surv(tempo, status) ~ idade + sexo + tratam,
  data = hiv, subset = -82, dist = "weibull")
```

	Value	Std. Error	z	p
(Intercept)	5.7996	0.5760	10.069	7.60e-24
idade	0.0151	0.0133	1.137	2.55e-01
sexoM	-0.2603	0.3231	-0.806	4.20e-01
tratam	1.5490	0.2266	6.836	8.16e-12
Log(scale)	0.1281	0.0857	1.496	1.35e-01

Scale= 1.14

Weibull distribution

Loglik(model)= -739.2 Loglik(intercept only)= -769.7

Chisq= 61.03 on 3 degrees of freedom, p= 3.5e-13

Number of Newton-Raphson Iterations: 5

n= 192

Observe que:

- o conjunto das estimativas dos parâmetros de regressão se altera (*ldcase*);
- a verossimilhança passa de -742 para -739.198 (*ldresp*);
- a estimativa do parâmetro de forma muda de $1/1,15 = 0,87$ para $1/1,14 = 0,88$ (*ldshape*).

Resumo

O quadro a seguir resume as funções básicas de cada uma das distribuições paramétricas estudadas para modelos de sobrevivência.

Distribuição	Características
$T \sim \textit{Exponencial}(\alpha)$ $f(t) = \alpha \exp(-\alpha t)$ $S(t) = \exp(-\alpha t)$ $\Lambda(t) = -\ln S(t) = \alpha t$ $\lambda(t) = f(t)/S(t) = \alpha$	Distribuição mais simples que ajusta um risco constante no tempo.
$T \sim \textit{Weibull}(\alpha, \gamma)$ $f(t) = \gamma \alpha^\gamma t^{\gamma-1} \exp(-(\alpha t)^\gamma)$ $S(t) = \exp(-(\alpha t)^\gamma)$ $\Lambda(t) = -\ln S(t) = (\alpha t)^\gamma$ $\lambda(t) = \gamma \alpha^\gamma t^{\gamma-1}$	A função mais utilizada na modelagem paramétrica em saúde. Muito flexível, o parâmetro γ modela a variação do risco no tempo.
$T \sim \textit{Lognormal}(\mu, \sigma^2)$ $f(t) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left[-\frac{\left(\frac{\ln(t)-\mu}{\sigma}\right)^2}{2}\right]$ $S(t) = 1 - \Phi((\ln(t) - \mu)/\sigma)$ $\lambda(t) = f(t)/S(t)$	Comportamento decrescente da função de risco.

O modelo de regressão paramétrico assume que os parâmetros das distribuições são funções das covariáveis, no caso que $\alpha = \exp(\mathbf{x}\boldsymbol{\beta})$. Assim, as funções básicas de sobrevivência de cada distribuição podem ser escritas como:

- Modelo exponencial
 - Função risco: $\lambda(t|\mathbf{x}) = \exp(\mathbf{x}\boldsymbol{\beta})$
 - Função sobrevivência: $S(t|\mathbf{x}) = \exp(-\exp(\mathbf{x}\boldsymbol{\beta})t)$
- Modelo Weibull
 - Função risco: $\lambda(t|\mathbf{x}) = \gamma t^{\gamma-1} \exp(\mathbf{x}\boldsymbol{\beta})^\gamma$
 - Função sobrevivência: $S(t|\mathbf{x}) = \exp(-(\exp(\mathbf{x}\boldsymbol{\beta})t)^\gamma)$

A análise de resíduos permite verificar o ajuste do modelo:

- o conjunto de parâmetros da regressão $\rightarrow \mathbf{ldcase}$;
- os valores preditos $\rightarrow \mathbf{ldresp}$;
- o parâmetro de forma $\rightarrow \mathbf{ldshape}$.

A qualidade de ajuste desses modelos é analisada através de:

H_0	Estatística	Dist.	Graus de liberdade
$\beta = 0$	$z = \hat{\beta}/ep(\hat{\beta})$	$N(0,1)$	
modelo ajusta-se aos dados	$D = 2(l_{saturado} - l_{modelo})$	χ^2	n ^o observações menos n ^o covariáveis menos 1
exponencial versus Weibull	$RV = 2(l_{weib} - l_{expo})$	χ^2	1
modelo menor é melhor	$RV = 2(l_{maior} - l_{menor})$	χ^2	diferença do n ^o de covariáveis


Exercícios

5.1 Em um estudo, ajustou-se um modelo exponencial aos tempos de sobrevivência observados (em meses) nos grupos controle e tratamento. Os modelos encontrados foram:

$$\begin{aligned}S_c(t) &= \exp(-0,07t), & \text{para o grupo controle} \\S_{tr}(t) &= \exp(-0,04t), & \text{para o grupo tratamento}\end{aligned}$$

Com base nesses modelos, responda:

- (a) Qual foi o risco instantâneo estimado para o grupo controle? E para o grupo recebendo tratamento?
- (b) Qual foi a sobrevivência média e mediana no grupo controle? E no grupo recebendo tratamento?
- (c) As duas curvas estimadas de sobrevivência são apresentadas na figura a seguir. Localize, nessa figura, o tempo mediano e médio calculado. Analisando o gráfico, você acha que o tratamento teve efeito na sobrevivência desses pacientes?



Dicas

- Use o comando `curve` para fazer o gráfico de uma função:

```
> alfa = 0.1
> curve(exp(-alfa * x), from = 0, to = 25,
  ylab = "S(t)", xlab = "Tempo")
```

- Para obter a mediana e os percentis do modelo exponencial:

```
> px <- log(1/x)/alfa
> p50 <- log(1/0.5)/alfa
> p90 <- log(1/0.9)/alfa
```

- Use os comandos `segments()` e `points()` para incluir novas linhas e marcadores em um gráfico existente:

```
> segments(p90, 0, p90, exp(-alfa * p90),
  lty = 3, col = "red")
> points(p90, 0, pch = 1, col = "blue")
```

5.2 Estude no R o efeito do parâmetro α no modelo paramétrico exponencial:

- Construa gráficos da função de sobrevivência utilizando $\alpha = 0, 1$, $\alpha = 0, 5$ e $\alpha = 0, 7$.
- Calcule o tempo mediano de sobrevivência para modelos com $\alpha = 0, 1$, $\alpha = 0, 5$ e $\alpha = 0, 7$.
- Calcule os percentis 90% (P90) e 10% (P10), isto é, os tempos em que 90% e 10% dos pacientes ainda não tinham sofrido o evento.
- O que você conclui sobre o parâmetro α e seu efeito no comportamento do modelo exponencial de sobrevivência?

5.3 Com relação ao modelo paramétrico Weibull, responda:

- (a) Por que o modelo Weibull é considerado mais flexível do que o modelo exponencial?
- (b) Em que situação particular o modelo Weibull é equivalente ao exponencial?
- (c) Qual a relação entre o parâmetro de forma γ e o comportamento da função de risco?
- (d) Quais das curvas de risco apresentadas na Figura 3.3 não poderiam ser modeladas pela função Weibull, nem mesmo aproximadamente?

5.4 Seja T o tempo de sobrevivência até a ocorrência de um evento que segue uma distribuição Weibull com parâmetros $\gamma = 1,5$ e $\alpha = 0,13$.

- (a) Faça gráfico das funções de sobrevivência $S(t)$, de risco $\lambda(t)$ e risco acumulado $\Lambda(t)$.
- (b) Use o R para construir os gráficos das funções acima.
- (c) Calcule o tempo mediano de sobrevivência, e os percentis 80 e 10 dessa distribuição.
- (d) Fixe o valor do parâmetro $\alpha = 0,13$ e faça gráficos da função de risco e da função de sobrevivência para diversos valores do parâmetro de forma γ :
 - (i) $0 < \gamma < 1$
 - (ii) $\gamma = 1$
 - (iii) $\gamma > 1$
- (e) Interprete como o parâmetro de forma γ afeta o comportamento do risco e da sobrevivência.

Dicas

- O mesmo comando `curve` deve ser usado para as equações de sobrevivência Weibull:

```
> curve(exp(-(alfa * x)^gama), from = 0, to = 20,
  ylab = "S(t)", xlab = "t") # Sobrevivência
> curve(alfa * gama * (alfa * x)^(gama - 1), from = 0,
  to = 20, ylab = "Risco", xlab = "t")
> curve((alfa * x)^gama, from = 0, to = 20,
  ylab = "Risco Acumulado", xlab = "t")
```

- Para dividir a área do gráfico, em l linhas e c colunas:

```
> par(mfrow = c(l,c))
```

- O tempo mediano ou qualquer percentil é calculado utilizando a equação:

```
> t50 <- log(1/0.5)^(1/gama)/alfa
> tx <- log(1/x)^(1/gama)/alfa
```

5.5 Em um estudo sobre o tempo de incubação de uma infecção, verificou-se que T é adequadamente descrito por uma função Weibull com parâmetros $\gamma = 1,2$ e $\alpha = 0,07$.

- Calcule o tempo mediano de incubação desta infecção.
- É correto dizer que 10 horas após a infecção, espera-se que 80% das pessoas já tenham desenvolvido sintomas?
- O risco de surgimento de sintomas é crescente ou decrescente ao longo do tempo?

5.6 Mil crianças não vacinadas são acompanhadas, a partir do nascimento, em um estudo cujo objetivo é identificar a idade em que adquirem hepatite A. Os resultados do estudo indicam que a idade

média de soroconversão das crianças foi de 4,5 anos e que o risco de contrair hepatite A foi constante e independente da idade.

- (a) Proponha um modelo paramétrico para o tempo até a aquisição de hepatite A.
- (b) Faça no R o gráfico da função de sobrevivência, de acordo com esse modelo.
- (c) Com base nesse modelo, em que idade espera-se ter 90% das crianças soropositivas?
- (d) Após este estudo, um projeto de saneamento é implementado nesta comunidade. Para avaliar o efeito do saneamento na transmissão de hepatite A, uma nova coorte é montada, semelhante à anterior. Ao analisar os dados dessa nova coorte, encontramos que um modelo Weibull com parâmetros $\gamma = 1,3$ e $\alpha = 0,1$ descreve bem a curva de sobrevivência. Com base nessa informação, avalie qual foi o efeito do saneamento no risco de contrair hepatite A nessa comunidade. Sugestão: compare os gráficos das funções de sobrevivência.

Dicas

- Não esqueça que a parametrização das distribuições no R diferem das apresentadas no texto.
- Para comparar os dois modelos, que diferem por um grau de liberdade, pode-se utilizar a razão de verossimilhança dos dois modelos. O modelo de maior verossimilhança (ou menor módulo de *loglik*) é o melhor modelo.

5.7 Retorne ao exemplo do primeiro exercício do Capítulo 4, sobre tempo de aleitamento de crianças (arquivo: *leite.txt*).

- (a) Ajuste uma distribuição Weibull ao tempo de aleitamento. Existe evidência de que o modelo Weibull seja mais adequado do que o exponencial?
- (b) Qual o tempo mediano de amamentação estimado por esse modelo?
- (c) Faça um gráfico da curva de sobrevivência ajustada pelo modelo Weibull, junto com o gráfico de Kaplan-Meier. O modelo paramétrico representa bem os dados?

5.8 O banco de dados *leite2.txt* contém dados de tempo de aleitamento de crianças de quatro comunidades. No ajuste não paramétrico a esses dados, observamos que pertencer a uma comunidade não teve efeito no período de aleitamento. Confirme este achado, ajustando um modelo paramétrico a esses dados. Experimente com as distribuições exponencial e Weibull.

Dicas

- Para ajustar um modelo exponencial aos dados, considerando a covariável grupo, use:


```
> survreg(Surv(tempo,status) ~ factor(grupo),
           data=dados, dist="exponential")
```
- Para ajustar um modelo Weibull aos dados, considerando a covariável grupo, use:


```
> survreg(Surv(tempo,status) ~ factor(grupo),
           data=dados, dist="weib")
```
- O comando *factor* não é necessário se a variável *grupo* já estiver definida como fator no objeto *dados*.

5.9 Um estudo foi realizado para estimar o efeito do transplante de medula óssea na sobrevivência de pacientes com leucemia. As covariáveis analisadas foram: idade, fase da doença, ter ou não desenvolvido doença enxerto crônica e ter ou não desenvolvido doença enxerto aguda (para mais detalhes acerca desse estudo, refira-se ao Apêndice.12.4). Um modelo exponencial ajustado aos dados, apresenta a seguinte saída do R:

	Value	Std. Error	z	p
(Intercept)	7.13536	0.4992	14.293	2.44e-46
idade	-0.00179	0.0146	-0.122	9.03e-01
fase interm	-0.79363	0.3651	-2.174	2.97e-02
fase avançada	-1.29759	0.4995	-2.598	9.39e-03
doençacronica	0.92521	0.3335	2.775	5.53e-03
doençaaguda	-1.43654	0.3158	-4.549	5.40e-06

Scale fixed at 1

Exponential distribution

Loglik(model)= -348.3 Loglik(intercept only)= -374.2

Chisq= 51.96 on 5 degrees of freedom, p= 5.5e-10

Number of Newton-Raphson Iterations: 5

Observe a saída do R e responda:

- (a) O modelo com covariáveis é melhor do que o modelo nulo (sem covariáveis)?
- (b) Que covariáveis estão associadas com maior sobrevivência? Quais estão associadas com a redução da sobrevivência?
- (c) Escreva a função de risco, $\lambda(t)$, estimada para esta coorte.
- (d) Qual seria o risco de óbito de um paciente de 30 anos, em fase intermediária, com doença crônica?
- (e) Qual seria o risco de óbito de um paciente de 30 anos, em fase intermediária, com doença aguda?
- (f) Um segundo modelo, mais simples, foi ajustado aos dados, contendo apenas a covariável fase. O logaritmo da função de verossimilhança deste modelo simples foi de -363.6 . Compare este

modelo com o mais completo ajustado anteriormente e indique se este último resultou em melhor ajuste.

5.10 A Aids passou a ter tratamento apenas em 1991. Desde então a terapia antirretroviral evoluiu da monoterapia para a terapia combinada (2 ou mais componentes) e, por fim, para a terapia de alta potência (no mínimo 3 componentes, sendo um inibidor de protease). Espera-se que as terapias mais recentes sejam mais efetivas em aumentar a sobrevivência. Teste esta hipótese, ajustando um modelo exponencial aos dados da coorte de Aids (banco *ipec.csv* – Apêndice.12.4).

- (a) Ajuste um modelo com a variável tratamento apenas. O modelo com a variável tratamento é melhor do que o modelo sem covariáveis? Interprete o efeito dos tratamentos na sobrevivência (lembrando-se que os efeitos dos tratamentos estão sendo estimados em relação à ausência de tratamento).
- (b) Faça uma análise gráfica do ajuste do modelo, comparando-o com a curva de Kaplan-Meier estratificada por tratamento. O que você tem a dizer sobre a adequação do modelo exponencial?
- (c) Faça a análise de resíduos do modelo estimado. Existe algum ponto influente, sobre a estimativa dos parâmetros (*ldcase*), sobre os valores preditos (*ldresp*) ou sobre o parâmetro de forma?
- (d) Caso considere algum ponto muito influente, retire-o e refaça a análise.
- (e) Ajuste um outro modelo exponencial, adicionando variáveis de controle (sexo, idade e tipo de atendimento). Quais variáveis tiveram efeito significativo? Quais tiveram efeito protetor?

Dicas

- A variável indicativa do tratamento deve ser modelada como um fator, e não como numérica, lembrando que efeito de tratamento deve ser estimado em relação à ausência de tratamento (*tratam=0*).
- Para calcular o risco deve-se substituir os valores das variáveis indicadoras na expressão do risco do modelo exponencial que é $\Lambda(t|x) = \alpha(x) = \exp(x\alpha)$.
- Como o R parametriza as distribuições de forma diferente da usada no livro, é necessário trocar o sinal dos coeficientes para interpretar de acordo com o texto.
- Para avaliar o ajuste basta adicionar as curvas de sobrevivência estimadas por Kaplan-Meier de acordo com o modelo exponencial em cada categoria de tratamento.
- A função `residuals(modelo.ajustado, type=)` recebe no argumento *type* um dos três tipos de resíduos.
- O gráfico é feito sobre o objeto que recebeu o resíduo, um para cada tipo.

5.11 Use a distribuição Weibull, para ajustar um modelo para os pacientes em diálise (arquivo *dialise.csv*) descritos no Apêndice.12.4.

- Avalie qual é o efeito da doença de base na sobrevivência, controlado por idade.
- Existe evidência a favor da utilização de um modelo mais simples (exponencial)?
- Existe evidência a favor da utilização de um modelo com menos variáveis?
- Existe evidência de pontos influentes?
- Exclua do modelo as variáveis com p-valor $> 0,1$ e compare o novo modelo com o anterior, calculando a razão de verossimilhanças entre os dois.

Dica

- Considerando que a variável *doenca* é categórica, a categoria de referência deve ser indicada. Por *default* o R indica a primeira considerando ordenação alfabética ou numérica. No exercício é importante trocar de *cong* (congenita), muito rara, para *hiper* (hipertensão), mais frequente:

```
> banco$causa <- relevel(banco$causa, "hiper")
```

- Para comparar modelos, use a função *anova*:

```
> anova(modelo1, modelo2)
```


6

Modelo semiparamétrico de sobrevivência

Coautora: *Rita Byington*

Ao término do Capítulo 6, espera-se que o leitor seja capaz de:

- Indicar os pressupostos do modelo.
- Explorar os pressupostos de proporcionalidade.
- Analisar e interpretar o efeito das covariáveis.
- Ajustar e analisar modelo de Cox estratificado.
- Selecionar covariáveis do modelo.
- Avaliar a qualidade do ajuste do modelo.

6.1 Introdução

Até recentemente, quando surgiu uma nova droga capaz de corrigir o mecanismo molecular que desencadeia a leucemia mieloide crônica (LMC), o transplante utilizando medula óssea (TMO) de doador

compatível era o único tratamento comprovadamente curativo para essa patologia. Entretanto, complicações decorrentes dos regimes quimioterápicos e radioterápicos – altamente tóxicos, porém necessários à realização do transplante – são comuns. Além disso, uma das causas de insucesso do procedimento é a doença do enxerto contra o hospedeiro (DECH), que ocorre em 25-30% dos pacientes submetidos ao transplante. A DECH é uma complicação do transplante de medula óssea no qual células imunes funcionais da medula óssea transplantada atacam células e tecidos do organismo receptor. Pode ser classificada em aguda (até 100 dias após o transplante) e crônica, ambas usualmente tratadas com terapia de imunossupressão. Pacientes transplantados que chegam a apresentar doença crônica do enxerto sobreviveram ao menos 100 dias.

O Centro de Transplantes de Medula Óssea do Instituto Nacional de Câncer (Inca) realizou, entre 1986 e 1998, 96 transplantes de medula óssea para tratamento de LMC. A análise dos dados dessa coorte buscava identificar fatores passíveis de intervenções profiláticas e/ou terapêuticas que pudessem melhorar o prognóstico de portadores de LMC candidatos ao TMO ou mesmo contraindicar a realização do procedimento num subgrupo de maior risco, avaliando a possibilidade de condutas terapêuticas alternativas. Estudou-se o efeito de fatores prognósticos para cinco desfechos principais: ocorrência de DECH aguda e crônica, ocorrência de recaída, sobrevivência global e sobrevivência livre de doença. As principais variáveis estudadas foram: sexo, idade, tempo do diagnóstico até o transplante, fase da doença ao transplante, regime de condicionamento utilizado, compatibilidade de sexo doador/receptor, tipo de profilaxia contra DECH e tempo para recuperação de plaquetas.

No capítulo anterior, vimos como ajustar um modelo de regressão paramétrico ao tempo de sobrevivência, considerando as distribuições exponencial e Weibull. Vimos também que a regressão paramétrica exige que se suponha uma distribuição estatística para o tempo de sobrevivência, e essa suposição, caso não seja adequada, pode fazer com que as estimativas sejam incorretas. Entretanto, frequentemente o interesse do estudo não é estimar os parâmetros da distribuição do tempo de sobrevivência, mas estimar o efeito de co-

variáveis. Foi partindo dessas questões que Cox propôs um modelo, denominado **modelo semiparamétrico de riscos proporcionais**, que passou a ser o mais utilizado na análise de dados de sobrevivência. Mais recentemente, a partir da utilização da teoria do processo de contagem, este tipo de modelo foi estendido para abranger situações mais complexas, chamadas de extensões do modelo de Cox, que serão apresentados nos Capítulos 8 a 12.

6.2 Modelo de riscos proporcionais

Da mesma forma que na modelagem paramétrica (Capítulo 5), o modelo de Cox ajusta a função de risco $\lambda(t)$, considerando um risco basal $\lambda_0(t)$ e incluindo o vetor de covariáveis $\mathbf{x}$, de forma que:

$$\begin{aligned}\lambda(t|\mathbf{x}) &= \lambda_0(t) \exp(x_1\beta_1 + x_2\beta_2 + \cdots + x_p\beta_p) \\ &= \lambda_0(t) \exp(\mathbf{x}\boldsymbol{\beta}).\end{aligned}\tag{6.1}$$

Essa formulação assume que as covariáveis têm um efeito multiplicativo na função de risco e, assim, a razão entre o risco de ocorrência do evento para dois indivíduos k e l , com covariáveis $\mathbf{x}_k = (x_{k1}, x_{k2}, \dots, x_{kp})$ e $\mathbf{x}_l = (x_{l1}, x_{l2}, \dots, x_{lp})$, é:

$$\frac{\lambda_k(t|\mathbf{x}_k)}{\lambda_l(t|\mathbf{x}_l)} = \frac{\exp(\mathbf{x}_k\boldsymbol{\beta})}{\exp(\mathbf{x}_l\boldsymbol{\beta})},\tag{6.2}$$

ou seja, é constante no tempo. Isso significa, por exemplo, que o risco do desenvolvimento de câncer de pulmão para quem fuma é sempre o mesmo ao longo do tempo. Algumas pessoas vão desenvolver câncer rapidamente e outras mais tarde, mas sempre na mesma proporção, estimada pela exponencial do coeficiente ($\exp(\beta_{fumo})$). Por esse motivo, esse modelo é denominado modelo de riscos proporcionais. Ele também pode ser escrito em termos da função de risco acumulado ou da função de sobrevivência:

$$\begin{aligned}\Lambda(t|\mathbf{x}) &= \Lambda_0(t) \exp(\mathbf{x}\boldsymbol{\beta}); \\ S(t|\mathbf{x}) &= [S_0(t)]^{\exp(\mathbf{x}\boldsymbol{\beta})}.\end{aligned}$$

Através das relações descritas na Seção 3.7, temos que o risco basal acumulado é dado por:

$$\Lambda_0(t) = \int_0^t \lambda_0(s) ds.$$

A estimativa do risco basal é feita através da Equação (6.3), na qual $\Delta N_i(t)$ é a diferença entre a contagem de eventos até o instante t e a contagem no momento imediatamente anterior a t .

$$\hat{\Lambda}_0(t) = \sum_{i: t_i \leq t} \frac{\Delta N_i(t)}{\sum_{j \in R(t_i)} \exp(\mathbf{x}_j \hat{\boldsymbol{\beta}})}. \quad (6.3)$$

A sobrevivência basal, utilizando as relação entre as funções de sobrevivência, é dada por:

$$\hat{S}_0(t) = \exp(-\hat{\Lambda}_0(t)).$$

6.3 Modelo de Cox

Partindo do pressuposto de proporcionalidade anteriormente descrito, é possível estimar os efeitos das covariáveis sem que seja necessário fazer qualquer suposição a respeito da distribuição do tempo de sobrevivência. O modelo de Cox é dito semiparamétrico, pois não assume qualquer distribuição estatística para a função de risco basal, $\lambda_0(t)$. Assume apenas que as covariáveis agem multiplicativamente sobre o risco, sendo esta a parte paramétrica do modelo.

6.3.1 Estimativa dos coeficientes

No Capítulo 5, vimos que para estimar os coeficientes da regressão paramétrica, a função de verossimilhança é construída a partir da função de densidade de probabilidade calculada nos tempos de ocorrência do evento, multiplicada pela função de sobrevivência calculada nos tempos de censura.

Aqui, o vetor de parâmetros $\boldsymbol{\beta}$ é estimado a partir de uma **verossimilhança parcial**. Nesta, elimina-se a função de risco basal,

considerando-se apenas, a cada tempo t , a informação dos indivíduos sob risco. Essa formulação é semelhante aos modelos não paramétricos (Kaplan-Meier), mas permite que sejam estimados os efeitos das covariáveis, ou seja, o efeito de fatores de risco no tempo de sobrevivência.

Os m diferentes tempos até a ocorrência do evento em uma amostra, sem considerar a ocorrência de eventos em um mesmo tempo t (ocorrências simultâneas, denominadas empates, serão discutidas na sessão 6.7), são ordenados de forma que:

$$t_1 < t_2 < \dots < t_m.$$

Para entender a função de verossimilhança parcial, $\mathcal{L}(\beta)$, considere a contribuição de cada indivíduo para o tempo de sobrevivência t_i , denominada verossimilhança individual $\mathcal{L}_i$, como sendo a razão entre o risco de o indivíduo i apresentar o evento em t_i e a soma dos riscos até a ocorrência do evento em todos os indivíduos em risco. Logo, se $\lambda_i(t_i)$ é o risco do indivíduo i apresentar o evento em t_i , então a verossimilhança individual, $\mathcal{L}_i$, será:

$$\mathcal{L}_i = \frac{\lambda_i(t_i)}{\sum_{j \in R(t_i)} \lambda_j(t_j)} = \frac{\exp(\mathbf{x}_i \beta)}{\sum_{j \in R(t_i)} \exp(\mathbf{x}_j \beta)}. \quad (6.4)$$

Para não precisar especificar que a cada momento estamos nos referindo apenas aos indivíduos que estão em risco, podemos utilizar a notação de processos de contagem. Neste caso, a definição da verossimilhança individual fica sendo:

$$\mathcal{L}_i = \frac{\exp(\mathbf{x}_i \beta)}{\sum_{t \geq 0} Y_j(t) \exp(\mathbf{x}_j \beta)},$$

com $Y_j(t)$ representando uma variável indicadora que assume o valor 1 se o indivíduo j estiver em risco no tempo t e 0, caso contrário.

A verossimilhança parcial $\mathcal{L}(\beta)$ é o produto das verossimilhanças individuais que, utilizando-se a mesma notação, é expressa da seguinte forma:

$$\mathcal{L}(\beta) = \prod_{i=1}^n \prod_{t \geq 0} \left\{ \frac{Y_i(t) \exp(\mathbf{x}_i \beta)}{\sum_j Y_j(t) \exp(\mathbf{x}_j \beta)} \right\}^{\Delta N_i(t)}, \quad (6.5)$$

em que $\Delta N_i(t)$ é a diferença entre a contagem de eventos até o instante t e a contagem no momento imediatamente anterior a t .

É interessante notar que o numerador da verossimilhança parcial depende apenas da informação dos indivíduos que experimentam o evento, enquanto o denominador utiliza informações a respeito de todos os indivíduos que ainda não experimentaram o evento, inclusive aqueles que serão censurados mais tarde. Observe que a função de verossimilhança parcial não depende da suposição de uma distribuição paramétrica para o risco basal $\lambda_0(t)$. O estimador de máxima verossimilhança para os parâmetros do modelo (β) baseia-se nessa definição de verossimilhança parcial.

Exemplo

Utilizamos o modelo de Cox para avaliar os fatores prognósticos associados ao transplante de medula óssea nos pacientes com leucemia mieloide crônica tratados no Inca. Os dados encontram-se no arquivo *tmoclas.dat*. Nesse exemplo, visando verificar o efeito de potenciais fatores prognósticos para o tempo de sobrevivência decorrido desde o transplante até o óbito (*os*), analisamos o efeito das seguintes covariáveis: sexo, idade, fase da doença no momento do transplante (*fase*), a ocorrência ou não de doença enxerto contra hospedeiro aguda (*deag*) ou crônica (*decr*).

Como ferramenta exploratória, utilizamos inicialmente as curvas de sobrevivência estimadas pelo método Kaplan-Meier para verificar visualmente o pressuposto de proporcionalidade do risco das covariáveis a serem incluídas no modelo. Para covariáveis com um pequeno número de categorias, o gráfico da curva de sobrevivência do Kaplan-Meier estratificado já poderá dar uma ideia dessa proporcionalidade. Curvas que são razoavelmente paralelas ao longo de todo

o tempo indicam proporcionalidade no risco entre as categorias e, ao contrário, o seu entrelaçamento ou uma variação nas distâncias entre as curvas de diferentes categorias podem indicar ausência de proporcionalidade. Outra forma de visualização é o gráfico do logaritmo da função de risco acumulado em cada categoria, no qual se vê duas retas paralelas, caso proporcionais. Esse assunto será melhor discutido no Capítulo 7.

Na Figura 6.1 apresentam-se as curvas de Kaplan-Meier pós-transplante de medula óssea, segundo covariáveis selecionadas. Podemos observar que para as quatro covariáveis a serem estudadas, o pressuposto de proporcionalidade ao longo do tempo parece ser razoável, uma vez que não há cruzamento entre as categorias das variáveis. Mesmo para a variável *sexo*, as duas categorias estão praticamente sobrepostas, afastando-se apenas no final, em que o número de observações é pequeno.

Inicialmente, vamos considerar o resultado do modelo de Cox que inclui as covariáveis idade e sexo. A variável *sexo*, numérica no banco de dados, foi transformada em categórica, através da função *factor*.

```
> tmo <- read.table("tmoclas.dat", header=T, sep=",")
> tmo$sexo<-factor(tmo$sexo)
> m1 <- coxph(Surv(os,status)~idade+sexo,data=tmo,x=TRUE)
> summary(m1)
```

```
[...]
      coef exp(coef) se(coef)      z Pr(>|z|)
idade -0.02167   0.97857  0.01399 -1.548   0.122
sexo2  -0.37649   0.68626  0.32120 -1.172   0.241
```

```
      exp(coef) exp(-coef) lower .95 upper .95
idade    0.9786      1.022    0.9521    1.006
sexo2     0.6863      1.457    0.3657    1.288
```

```
Rsquare= 0.03      (max possible= 0.986 )
Likelihood ratio test= 2.92 on 2 df,   p=0.2320
Wald test            = 2.85 on 2 df,   p=0.2408
Score (logrank) test = 2.85 on 2 df,   p=0.2406
```




Figura 6.1: Análise exploratória da sobrevivência pós-transplante de medula óssea. As curvas de Kaplan-Meier permitem uma avaliação inicial da proporcionalidade do efeito das covariáveis no tempo de sobrevivência

A coluna `coef` apresenta os valores de β estimados pela verossimilhança parcial. Valores positivos indicam variáveis que contribuem para o aumento do risco de óbito e valores negativos de β indicam variáveis que contribuem para a redução do risco. A coluna `se(coef)` indica o erro padrão dessas estimativas, a coluna `z` apresenta a estatística de Wald e a coluna `p`, o p-valor do teste da hipótese nula de $\beta = 0$, assumindo que a estatística de Wald segue uma distribuição normal.

Modelo de Cox no R

O comando `coxph()` ajusta os parâmetros do modelo de regressão de Cox. A sintaxe do comando segue a forma:

```
> m <- coxph(formula, data=dados)
```

O argumento `formula` possui o seguinte formato:

Surv(tempo,status) ~ covariáveis. O objeto, chamado aqui de `m`, contém o resultado do ajuste do modelo de Cox e uma série de estatísticas de interesse que podem ser vistos com a função `summary()` da seguinte forma:

```
> summary(m)
```

Digitar somente o nome do objeto que recebeu o modelo equivale a `print(modelo)`, o que envia para a tela um resultado bem resumido do modelo. A função `summary()` lista o resultado mais completo do modelo estimado. O argumento opcional `x = TRUE` é incluído na estimação do modelo de Cox quando for necessário salvar a matriz das covariáveis para outras análises.

O R também calcula `exp(coef)`. Este valor é interpretado como um risco relativo ou uma razão de riscos (*Hazard Ratio*): valores acima de 1 indicam sobrerisco, valores entre 0 e 1 indicam proteção. Assim, nessa coorte, um paciente do sexo feminino tem risco 0,68 vezes (ou 32%) menor de ir a óbito do que um paciente do sexo masculino. O intervalo de confiança para essa razão de riscos é apresentado nas colunas `lower .95` e `upper .95` ([0,365; 1,288]). Tam-

bém podemos interpretar o resultado da seguinte forma: um paciente do sexo masculino tem risco 1,45 ($=\exp(-\text{coef})$) vezes (ou 45%) maior de ir a óbito a cada unidade de tempo do que um paciente do sexo feminino com intervalo de confiança igual a $[1/1, 288; 1/0, 365] = [0, 78; 2, 74]$. Todavia, essa estimativa de risco atribuída ao sexo não é significativa, pois o intervalo de confiança engloba a unidade, o mesmo acontecendo para idade.

6.4 Modelo de Cox estratificado

Em algumas situações não podemos assumir que o risco basal $-\lambda_0(t)$ – seja o mesmo para todos os indivíduos do estudo, seja por característica da própria variável ou devido ao desenho do estudo, estratificado *a priori*. Nesses casos, a variável que os separaria em diferentes grupos, com $\lambda_{0_A}(t) \neq \lambda_{0_B}(t) \neq \lambda_{0_C}(t)$, define diferentes estratos.

Este tipo de recurso também é utilizado quando alguma variável não atende ao pressuposto de proporcionalidade de riscos (ver Capítulo 7), o que equivale a afirmar que o risco de base não é igual para os estratos. Utilizando o mesmo exemplo do transplante de medula óssea, pode-se modelar a sobrevivência dos pacientes considerando que o aparecimento da doença do enxerto crônica divide-os em dois estratos, com linhas de base diferentes. O raciocínio que estaria por trás dessa opção é considerar que para que ocorra doença **crônica**, o paciente necessariamente sobreviveu algum tempo, e por consequência o efeito desta variável varia com o tempo. Cabe lembrar que para a variável que estratifica o risco basal não é possível estimar o efeito.

Em uma situação genérica em que existem s estratos, o modelo estratificado para o estrato j é definido por:

$$\lambda_j(t) = \lambda_{0_j}(t) \exp(\mathbf{x}\boldsymbol{\beta}), \quad j = 1, \dots, s. \quad (6.6)$$

Nesse modelo assume-se que os coeficientes de regressão são os mesmos em todos os estratos, embora o risco de base varie. A verossimilhança é estimada para cada indivíduo da mesma forma que

na Equação (6.4), mas no conjunto de indivíduos em risco somente participam aqueles que pertencem a um mesmo estrato. Em outras palavras, a verossimilhança parcial total $\mathcal{L}(\beta)$, é o produto das verossimilhanças parciais para cada estrato, da seguinte forma:

$$\mathcal{L}(\beta) = \prod_{j=1}^s \mathcal{L}_j(\beta), \quad (6.7)$$

em que $\mathcal{L}_j(\beta)$ é a verossimilhança parcial definida na Equação (6.5), usando-se somente os dados daqueles indivíduos pertencentes ao estrato j .

Modelo de Cox estratificado no R

O comando `strata()` incluído como um termo na fórmula do modelo ajusta os parâmetros do modelo, permitindo que o risco basal varie. A sintaxe do comando segue a forma abaixo, sendo `var` a variável que define o(s) estrato(s):

```
> m <- coxph(Surv(tempo,status) ~ covariáveis +
  strata(var), data=dados)
```

Exemplo

Examinemos dois modelos, um estimando o efeito da variável `decr` e outro estratificando-o por esta variável. Assim como foi feito para a variável `sexo`, transformaremos as variáveis `fase`, `deag` e `decr` em categóricas através da função `factor()`.

```
> tmo$fase <- factor(tmo$fase)
> tmo$deag <- factor(tmo$deag)
> tmo$decr <- factor(tmo$decr)
```

```
> m4 <- coxph(Surv(os,status) ~ idade+sexo+fase+
  deag+decr, data=tmo,x=T)
> summary(m4)
```

Call:

```
coxph(formula = Surv(os, status) ~ idade + sexo + fase +
  deag + decr, data = tmo, x = T)
```

[...]

	exp(coef)	exp(-coef)	lower .95	upper .95
idade	0.9950	1.0050	0.9663	1.0245
sexo2	0.7619	1.3126	0.3974	1.4607
fase2	1.8112	0.5521	0.8746	3.7508
fase3	2.5559	0.3912	0.9182	7.1151
deag1	3.2883	0.3041	1.7307	6.2479
decr1	0.3459	2.8914	0.1782	0.6714

Observe que nesse modelo a doença do enxerto crônica (*decr*) exerce um efeito protetor importante.

```
> mstrata <- coxph(Surv(os,status)~idade+sexo+fase+
  deag+strata(decr), data=tmo,x=T)
> summary(mstrata)
```

Call:

```
coxph(formula = Surv(os, status) ~ idade + sexo + fase + deag +
  strata(decr), data = tmo, x = T)
```

[...]

	exp(coef)	exp(-coef)	lower .95	upper .95
idade	0.9921	1.0080	0.9639	1.021
sexo2	0.7628	1.3110	0.4007	1.452
fase2	1.9835	0.5042	0.9534	4.127
fase3	2.1757	0.4596	0.7863	6.020
deag1	3.1100	0.3215	1.6336	5.921

Os efeitos estimados das variáveis nos modelos *m4* e *mstrata* são semelhantes, mas os intervalos de confiança do modelo estratificado são em geral ligeiramente maiores. Tal efeito é esperado, já que agora o número de quantidades a serem estimadas no modelo estratificado é maior (*s* riscos de base $\lambda_{0s}(t)$ a serem estimados) e, portanto, é maior a incerteza nas estimativas dos coeficientes do modelo. A interpretação dos riscos é a mesma. Entretanto, no modelo

estratificado, os efeitos estão controlados pela variação no risco de base atribuível aos estratos. Assim, trata-se de efeitos **controlados** por presença de doença do enxerto crônica. O coeficiente da variável **decr** não foi estimado, mas os efeitos das demais variáveis foram ajustados pela sua presença.

6.5 Seleção de modelos

Para comparar diferentes modelos de regressão de Cox, utilizamos os mesmos métodos aplicáveis aos modelos lineares generalizados: teste de **Wald** e teste da **razão de verossimilhanças**, vistos inicialmente no Capítulo 5 – Modelo paramétrico de sobrevivência.

6.5.1 Teste de Wald

A estatística de Wald testa a hipótese nula H_0 de que o parâmetro da regressão β_j é igual a zero. É definida por:

$$z = \hat{\beta}_j / ep(\hat{\beta}_j), \quad (6.8)$$

sendo $ep(\hat{\beta}_j)$ o erro padrão de $\hat{\beta}_j$. Sob a hipótese nula, a estatística z segue uma distribuição normal padrão. Nos resultados do modelo de regressão de Cox no R, esta estatística está na coluna **z** e o seu respectivo p-valor na última coluna.

6.5.2 Teste da razão de verossimilhanças

O teste da razão de verossimilhanças compara modelos aninhados avaliando se a inclusão de uma ou mais covariáveis no modelo aumenta de modo significativo a verossimilhança de um modelo em relação ao modelo mais parcimonioso. A estatística do teste é definida pela razão das verossimilhanças ($\mathcal{L}$) ou pela diferença entre os logaritmos da função de verossimilhança da seguinte forma:

$$RV = 2 \times (l_{maior} - l_{menor}), \quad (6.9)$$

que, sob a hipótese nula (H_0) de que não há diferença entre os modelos, segue uma distribuição χ^2 com graus de liberdade igual à diferença no número de covariáveis dos modelos em questão.

A Tabela 6.1 mostra o valor do logaritmo da função de verossimilhança de alguns modelos.

Tabela 6.1: Funções de verossimilhança dos modelos de Cox para o exemplo de transplante de medula óssea

Modelo	l_{modelo}	R^2	% Variabilidade Explicada
Nulo	-203,40	0,000	0,0%
Saturado	-1,39	0,986	100,0%
m1: <i>idade+sexo</i>	-201,940	0,030	3,0%
m2: m1+ <i>fase</i>	-194,70	0,166	16,8%
m3: m2+ <i>deag</i>	-188,15	0,272	27,6%
m4: m3+ <i>decr</i>	-183,07	0,345	35,0%

Comparando os quatro modelos *m1*, *m2*, *m3*, *m4*, temos:

```
> anova(m1,m2,m3,m4)

Analysis of Deviance Table
Cox model: response is Surv(os, status)
Model 1: ~ idade + sexo
Model 2: ~ idade + sexo + fase
Model 3: ~ idade + sexo + fase + deag
Model 4: ~ idade + sexo + fase + deag + decr
      loglik   Chisq Df P(>|Chi|)
1 -201.94
2 -194.70 14.486  2 0.0007152
3 -188.15 13.109  1 0.0002939
4 -183.07 10.152  1 0.0014413
```

Na tabela do teste da razão de verossimilhanças estamos interessados na última coluna ($P(>|\text{Chi}|)$), que é o p-valor da estatística de teste segundo uma distribuição χ^2 . Analisando a segunda linha, que compara o modelo 1 com o modelo 2, estamos testando a hipótese nula de que os coeficientes da covariável *fase* sejam iguais a zero simultaneamente.

A terceira linha da tabela compara o modelo 2 com o modelo 3, e assim por diante. Pode-se afirmar que a inclusão de cada nova variável melhorou o ajuste. A hipótese nula de igualdade entre os modelos é rejeitada para cada nova variável incluída, com nível de significância de 5%.

A razão de verossimilhanças é assintoticamente semelhante à estatística de Wald quando o número de observações é grande. Caso esse número seja pequeno, o teste razão de verossimilhanças é mais robusto. Uma ressalva que deve ser feita para a utilização do teste da razão de verossimilhança: presença de valores faltantes ou omissos. Caso exista alguma variável incluída em algum dos modelos com valores omissos, mesmo que aninhados, os modelos perdem a comparabilidade. Exemplo: se a variável *fase* tivesse 4 valores ausentes, o modelo 2 seria baseado no número total de observações (96) menos as 4 ausentes, isto é, seria baseado em 92 observações, enquanto o modelo 1 seria baseado no número total de observações (96). Ou seja, para que se possa comparar os modelos, além de aninhados, eles devem basear-se no mesmo conjunto de observações.

Teste da razão de verossimilhanças no R

O comando `anova()` retorna o teste da razão de verossimilhanças dos modelos de Cox através da seguinte sintaxe:

```
> anova(m1, m2, m3)
```

Os objetos *m1*, *m2*, *m3* contêm o objeto resultante do ajuste de modelos de Cox aninhados.

Observação: Para que seja possível comparar os modelos *m1*, *m2*, *m3*, eles devem ter sido estimados com o mesmo conjunto de dados. Para verificar a presença de valores omissos, utilize a função `summary(dados)`. Para retirar os registros com valores omissos nas covariáveis incluídas nos modelos a comparar, use o comando `complete.cases`, e rode novamente todos os modelos com o mesmo conjunto de dados.

```
> dados2 <- dados[complete.cases(dados[,c("x2", "x3")]),]
```

O modelo estratificado não pode ser incluído nesse processo de escolha, pois modelos estratificados e não estratificados não são aninhados. A opção por modelos estratificados baseia-se ou no desenho do estudo, ou no conhecimento *a priori* do problema, ou em uma avaliação do pressuposto da proporcionalidade, conforme será visto no próximo capítulo.

6.6 Qualidade do ajuste do modelo

Na seção anterior, o modelo selecionado foi o modelo *m4*, que incluía todas as covariáveis. Mas será que esse modelo se ajusta bem aos dados? Qual o poder explicativo de um modelo incluindo idade, sexo, fase da doença em que foi feito o transplante e presença de doença do enxerto aguda ou crônica? A medida de qualidade de ajuste nos modelos lineares, quando a variável resposta é normal, é o conhecido R^2 . Já para modelos lineares generalizados, quando a resposta tem distribuição binomial, por exemplo, não existe medida similar. Nesse caso, utiliza-se medidas baseadas na função de verossimilhança.

Poucas são as medidas estatísticas disponíveis na literatura para avaliar globalmente a qualidade de ajuste de um modelo de sobrevivência, e menos ainda as que estão implementadas em programas estatísticos usuais. Apresentaremos nesta seção a análise da função desvio (ou *deviance*), que é uma medida análoga ao R^2 da teoria de modelos lineares. Descreveremos também um método gráfico, conhecido como o gráfico de sobrevivência por índice de prognóstico, que contribui para a análise do ajuste dos modelos, que apesar de não estar implementado na biblioteca *survival*, pode ser facilmente programado no R.

6.6.1 Medida global de qualidade de ajuste

Como apresentado no Capítulo 5, uma estatística global de qualidade de ajuste do modelo é obtida comparando o modelo ajustado ao modelo saturado através da função desvio (*deviance*):

$$D = 2 \times (l_{\text{saturado}} - l_{\text{modelo}}),$$

em que l_{modelo} e l_{saturado} são, respectivamente, o logaritmo da função de verossimilhança do modelo avaliada nos estimadores de máxima verossimilhança e o logaritmo da função de verossimilhança do modelo saturado.

A estatística D , considerando a hipótese nula de que o modelo se ajusta aos dados, segue assintoticamente uma distribuição qui-quadrado (χ^2), com o número de graus de liberdade igual a $(n - p - 1)$, ou seja, o número de observações menos o número de covariáveis do modelo menos um. Nesse caso, quanto menor a estatística, maior o p-valor e melhor a qualidade de ajuste do modelo.

Outra forma de avaliar o ajuste de um modelo consiste em obter uma medida global que informe que proporção da variabilidade total da resposta é explicada pelas covariáveis. Essa medida encontra-se entre dois extremos. O menor poder de explicação possível é o de um modelo sem covariáveis, na qual a verossimilhança é apenas a da linha de base, usualmente denominado modelo nulo. O limite superior de explicação seria um modelo em que cada indivíduo estivesse totalmente explicado, resultando em um modelo sem resíduos (modelo saturado). Com base nessas duas possibilidades pode-se construir uma medida relativamente simples baseada na seguinte razão de verossimilhanças:

$$\begin{aligned} R_{LR}^2 &= 1 - \{\mathcal{L}(0)/\mathcal{L}(\hat{\beta})\}^{2/n} \\ &= 1 - \exp(2\{l(0) - l(\hat{\beta})\}/n), \end{aligned} \quad (6.10)$$

em que $\mathcal{L}(0)$ é a função de verossimilhança do modelo nulo, e $\mathcal{L}(\hat{\beta})$, a função de verossimilhança sob o modelo ajustado, sendo $l(0)$ e $l(\hat{\beta})$, respectivamente, os logaritmos neperianos de $\mathcal{L}(0)$ e $\mathcal{L}(\hat{\beta})$.

Observe que, apesar de o valor mínimo possível dessa medida ser 0 quando $\mathcal{L}(0) = \mathcal{L}(\hat{\beta})$, o valor máximo não é 1 (ou 100%), mas a razão entre as verossimilhanças do modelo saturado e do modelo nulo. O R^2 do modelo nulo é, evidentemente, 0.

Retomemos então a análise no R do banco de dados do transplante de medula. Além dos modelos já ajustados na seção anterior, vamos ajustar mais dois modelos, o modelo nulo e o modelo saturado:


```
> mod.nulo <- coxph(Surv(os,status)~1, data=tmo)
> mod.nulo
```

```
Call: coxph(formula = Surv(os, status) ~ 1, data = tmo)
Null model
  log likelihood= -203.404
  n= 96
```

Já o modelo saturado seria equivalente a estimar um coeficiente para cada indivíduo. Este modelo não explica nem prediz coisa alguma, mas tem ajuste perfeito. A forma de estimá-lo é colocar uma variável *dummy* para cada indivíduo.

```
> mod.saturado<- coxph(Surv(os,status)~factor(id),
  data=tmo)
> summary(mod.saturado)
```

```
Call:
coxph(formula = Surv(os, status) ~ as.factor(id), data = tmo)

  n= 96, number of events= 49
[...]
```

```
RRsquare= 0.985    (max possible= 0.986 )
Likelihood ratio test= 404 on 95 df,  p=0
Wald test           = 0.03 on 95 df,  p=1
Score (logrank) test = 394.1 on 95 df,  p=0
```

A medida R^2 pode ser interpretada como o poder explicativo das covariáveis no tempo de ocorrência do evento em estudo. Vejamos, no exemplo TMO, o que conseguimos explicar sobre o tempo de sobrevivência dos transplantados.

Para facilitar a interpretação, observe que a última coluna da Tabela 6.1 (p. 196) – percentual de variabilidade explicada – nada mais é que o R^2 de cada modelo dividido pelo R^2 do modelo saturado. Concluimos então que o modelo m4, apesar de ser melhor que os outros três, só explica 35% da variabilidade dos dados. Em modelos de sobrevivência, é raro encontrar poder explicativo muito maior que esse, pois o tempo de sobrevivência, bem sabem os médicos,

tem enorme variabilidade individual, devido a condições impossíveis de mensurar, ao menos com o conhecimento disponível atualmente. Ainda assim, diferenças causadas por fatores passíveis de serem incorporados aos modelos trazem informação substancial na avaliação de terapêuticas, fatores prognósticos e fatores de risco ou proteção.

6.6.2 Probabilidade de concordância

Uma outra medida global de ajuste, útil quando o objetivo do estudo é obter um modelo preditivo, é a estimativa da probabilidade de concordância. Mais especificamente, essa medida é usada para avaliar o poder discriminatório e a acurácia preditiva do modelo de Cox.

Concordância significa que, ao selecionar aleatoriamente duas observações, a que possui menor tempo de sobrevivência é também aquela que possui o maior risco estimado (predito) pelo modelo de Cox. Analogamente, se considerarmos um modelo de regressão logística, temos que a concordância é equivalente a área sob a curva ROC deste modelo. Como regra geral, pode-se considerar que se a probabilidade de concordância estimada pelo modelo de Cox:

- estiver entre 0,3 e 0,4, tem-se que o modelo possui um baixo poder preditivo (ou discriminatório);
- for a 0,5 significa que a concordância pode ser por acaso;
- estiver entre 0,6 e 0,7, tem-se um resultado comum para na análise de dados de sobrevivência;
- estiver entre 0,7 e 0,8, tem-se um resultado discriminatório muito bom;
- estiver entre 0,8 e 0,9, tem-se um resultado excelente.

Na saída do modelo `m4` é apresentada a estimativa da probabilidade de concordância, que no caso foi de 0,768. Logo, conclui-se que o poder preditivo ou discriminatório deste modelo é muito bom.

```
> summary(m4)
```

```
Call:
coxph(formula = Surv(os, status) ~ idade + sexo + fase + deag +
      decr, data = tmo, x = T)

n= 96, number of events= 49

[...]

Concordance= 0.768 (se = 0.044 )
Rsquare= 0.345 (max possible= 0.986 )
Likelihood ratio test= 40.67 on 6 df, p=3.365e-07
Wald test = 38.46 on 6 df, p=9.113e-07
Score (logrank) test = 47.62 on 6 df, p=1.405e-08
```

Para maiores detalhes de como é calculada a probabilidade de concordância, consulte a ajuda no R da função *survConcordance()*.

6.6.3 Sobrevivência por índice de prognóstico

Um procedimento exploratório útil para avaliar a qualidade de ajuste do modelo é o gráfico de sobrevivência estratificado por índice de prognóstico. O índice de prognóstico (IP) nada mais é do que o preditor linear do modelo de Cox, $x\beta$, calculado para cada indivíduo utilizando-se as covariáveis observadas e as estimativas dos coeficientes de regressão do modelo ajustado. Segundo o modelo 4 para o TMO (*m4*), temos os seguintes parâmetros estimados:

```
Call:
coxph(formula = Surv(os, status) ~ idade + sexo + fase + deag +
      decr, data = tmo, x = T)

n= 96, number of events= 49
```

	coef	exp(coef)	se(coef)	z	Pr(> z)
idade	-0.005019	0.994993	0.014912	-0.337	0.736415
sexo2	-0.271984	0.761866	0.332115	-0.819	0.412816
fase2	0.593973	1.811171	0.371427	1.599	0.109784
fase3	0.938411	2.555918	0.522357	1.796	0.072416
deag1	1.190381	3.288332	0.327485	3.635	0.000278 ***
decr1	-1.061750	0.345850	0.338452	-3.137	0.001706 **

```
[...]
Rsquare= 0.345    (max possible= 0.986 )
Likelihood ratio test= 40.67 on 6 df,    p=3.365e-07
Wald test          = 38.46 on 6 df,    p=9.113e-07
Score (logrank) test = 47.62 on 6 df,    p=1.405e-08
```

Para exemplificar, suponhamos dois indivíduos:

A – sexo masculino (**sexo2** = 0), 56 anos (**idade** = 56), fase intermediária (**fase2** = 1 e **fase3** = 0) e com manifestação de doença do enxerto aguda (**deag**=1, **decr**=0);

B – sexo feminino (**sexo2** = 1), 20 anos (**idade** = 20), na fase avançada (**fase2** = 0 e **fase3** = 1) e também com **deag**=1 e **decr**=0.

Os índices de prognóstico para esses dois indivíduos são, respectivamente, 1,50329 e 1,756428, como mostram os cálculos a seguir.

Indivíduo A

$$\beta_{idade} \times 56 = -0,005019 \times 56 = -0,281064$$

$$\beta_{sexo} \times 0 = -0,271984 \times 0 = 0$$

$$\beta_{fase2} \times 1 = 0,593973 \times 1 = 0,593973$$

$$\beta_{fase3} \times 0 = 0,938411 \times 0 = 0$$

$$\beta_{deag} \times 1 = 1,190381 \times 1 = 1,190381$$

$$\beta_{decr} \times 0 = -1,061750 \times 0 = 0$$

$$\text{Total} = 1,50329$$

Indivíduo B

$$\beta_{idade} \times 20 = -0,005019 \times 20 = -0,10038$$

$$\beta_{sexo} \times 1 = -0,271984 \times 1 = -0,271984$$

$$\beta_{fase2} \times 0 = 0,593973 \times 0 = 0$$

$$\beta_{fase3} \times 1 = 0,938411 \times 1 = 0,938411$$

$$\beta_{deag} \times 1 = 1,190381 \times 1 = 1,190381$$

$$\beta_{decr} \times 0 = -1,061750 \times 0 = 0$$

$$\text{Total} = 1,756428$$

Utilizando-se os valores do IP, os indivíduos são estratificados em grupos de tamanhos aproximadamente iguais – por exemplo, grupos de alto, médio e baixo IP. Uma vez criados os grupos por valor de IP, os valores médios de cada uma das covariáveis dentro de cada grupo são utilizados para obtenção de curvas de sobrevivência sob o modelo ajustado. Estas são então comparadas às curvas estimadas por Kaplan-Meier para cada grupo. Espera-se, se o modelo for razoável, que as curvas ajustadas pelo modelo em cada estrato sejam próximas das estimadas por Kaplan-Meier e que os melhores modelos sejam mais capazes de diferenciar os grupos criados pelo valor do índice de prognóstico.

Para facilitar essa análise gráfica no R, escrevemos uma função denominada `plot.pi()` para desenhar o gráfico, que está disponível na *homepage* do livro, no *script Rfun.r*. O argumento principal dessa função é o objeto gerado pela função `coxph()`, estimada utilizando-se o argumento `x = T`.

```
> source("Rfun.r")
> par(mfrow=c(2,2))
> plot.pi(m1,main="M1")
> plot.pi(m2,main="M2")
> plot.pi(m3,main="M3")
> plot.pi(m4,main="M4")
```

Observe nos gráficos da Figura 6.2 que apenas o primeiro modelo está de fato muito mal ajustado. Os demais são mais capazes de discriminar os grupos, e ajustam-se razoavelmente bem, melhorando a cada nova variável incluída, de acordo com o aumento detectado no percentual de variância explicada, que vai de 16,8% para 27,6% e 35% (Tabela 6.1).




Figura 6.2: Gráfico de sobrevivência estratificado por índice de prognóstico para os quatro modelos da Tabela 6.1. Linha sólida representa o modelo ajustado e linha pontilhada, a estimativa de Kaplan-Meier

Lendo funções no R

Para utilizar qualquer função desenvolvida para o R é necessário criar um objeto da classe *function*, onde estão armazenados os comandos necessários. Pode-se criar esse objeto na linha de comando, utilizando-se a função *function()* seguida da lista de comandos que se deseja realizar com a função. Mais usual, entretanto, é organizar o conjunto de comandos em um arquivo texto, chamado, por exemplo *funcao.r*, que, ao ser lido, cria o objeto com os comandos. A forma de incorporar estas novas funções é através do comando *source("diretorio/funcao.r")*.

```
> source("Rfun.r")
```

6.7 Tempos de vida empatados

Um pressuposto importante do modelo de Cox se refere à natureza da variável tempo de sobrevivência, que é contínua. Por ser contínua, a probabilidade de que duas pessoas tenham exatamente o mesmo tempo de sobrevivência é 0, por definição. Na prática, porém, é comum se utilizar uma escala de tempo discreta (dias, semanas, meses ou anos), e assim é frequente se observarem tempos de sobrevivência iguais para dois ou mais indivíduos da amostra.

O modelo de Cox, porém, assume que não há empate entre os tempos dos eventos, embora possa haver empate entre os tempos de censura e entre censuras e eventos. Neste último caso, considera-se que o evento ocorreu primeiro, o que acarreta a inclusão do indivíduo censurado no conjunto de indivíduos em risco de sofrer o desfecho no instante t_i , sendo t_i o tempo observado para o indivíduo i cujo desfecho ocorreu no mesmo tempo do indivíduo com o tempo censurado.

Quando ocorrem empates nos tempos de sobrevivência dos indivíduos em que foi observado o evento, a função de verossimilhança parcial exata envolve permutações e pode consumir muito tempo de computação para ser calculada. Duas alternativas para a obtenção da verossimilhança parcial são as funções propostas por Efron e por

Breslow. No caso de não haver empates ou de ocorrerem poucos empates, os resultados obtidos são equivalentes. Em geral, os resultados obtidos com as duas alternativas mais rápidas são inteiramente satisfatórios. Todos os três métodos estão implementados no R, e por *default* o método utilizado é o proposto por Efron. Para mudar de método, basta incluir o argumento *method* na função *coxph()* com as opções *"exact"* ou *"breslow"*.

Escrevendo funções no R

Para escrever suas próprias funções, comece adaptando de funções já criadas. Você pode olhar as funções lidas anteriormente e disponíveis no *workspace*, após o comando *source*. Veja os novos objetos, entre os quais o *plot.pi*.

```
> ls()
```

```
[1] "plot.frail"    "plot.pi"
```

Pode-se listar o que a função *plot.pi* faz simplesmente digitando-se *plot.pi* sem passar qualquer argumento e sem os parênteses.

```
> plot.pi
```

```
function(fit,lwd=1,...)
{
  if(is.null(fit$x))
    cat("Rode a função coxph() com o argumento x=TRUE\n")
  else{
    ...
  }
}
```

Resumo

O modelo de Cox pode ser escrito como $\lambda(t|\mathbf{x}) = \lambda_0(t) \exp(\mathbf{x}\boldsymbol{\beta})$, sendo que:

- não se assume distribuição de probabilidade para o tempo T de sobrevivência;

- os coeficientes β são estimados por máxima verossimilhança parcial;
- modelos estratificados permitem a variação do risco basal $\lambda_0(t)$ entre os estratos;
- a avaliação da qualidade de ajuste dos modelos baseia-se na análise da função desvio, no R^2 e em análises gráficas (gráfico do índice prognóstico);
- modelos aninhados são selecionados através do teste da razão de verossimilhanças.

Sobre o modelo de Cox no R:

- o ajuste é feito pela função `coxph(fórmula)`;
- a fórmula indica do lado esquerdo o objeto do tipo sobrevivência `Surv(tempo, status) ~ covariáveis`;
- a inclusão de estrato é feita pela inclusão do argumento `strata(variável)` na fórmula;
- a comparação de modelos ajustados é por meio do comando `anova(modelo1, modelo2, ... )`;
- a análise gráfica é feita pela função `plot.pi`, disponível na *homepage* do livro.

Exercícios

6.1 Para os dados da coorte de transplante de medula óssea vistos neste capítulo, refaça toda a análise utilizando o arquivo `tmoclas.csv` (Apêndice.12.4).

- (a) Faça os gráficos de Kaplan-Meier para as variáveis *sexo*, *deag*, *decr* e *fase* e verifique o pressuposto de proporcionalidade.
- (b) Ajuste os quatro modelos de Cox apresentados no texto e compare os modelos usando o teste da razão de verossimilhanças.
- (c) Qual o poder explicativo do modelo?
- (d) Calcule o índice de prognóstico do modelo final para um indivíduo com 35 anos, do sexo feminino, na fase intermediária da doença e que tenha tido doença do enxerto crônica, mas não aguda.
- (e) Faça o gráfico dos índices de prognóstico do modelo escolhido, utilizando a função `plot.pi(modelo escolhido)`. Avalie visualmente o ajuste do modelo à curva de Kaplan-Meier.

Dicas

- Para calcular o Kaplan-Meier estratificado por sexo usando o banco *tmo*:

```
> KMsexo <- survfit(Surv(os,status) ~ sexo, data = tmo)
```
- Para fazer o gráfico da curva Kaplan-Meier:

```
> plot(KMsexo,main="sexo")
```
- Para ajustar o modelo de Cox com as variáveis *idade* e *sexo*, usando o banco *tmo*:

```
> mod1 <- coxph(Surv(os,status) ~ idade+sexo, data=tmo)
```
- Para comparar vários modelos aninhados usando o teste da razão de verossimilhanças:

```
> anova(mod1,mod2,mod3,mod4)
```

- O valor de R^2 está presente na saída do comando `summary()` de cada modelo.
- Acrescente o argumento $x = T$, na especificação da função `coxph()`, para que depois possa obter os índices de prognóstico.
- A função `plot.pi()` não existe na biblioteca `survival` do R. Antes de utilizar a função `plot.pi()`, é preciso executar o comando `source("Rfun.r")` para carregá-la.
- Para fazer o gráfico de sobrevivência para um determinado perfil:

```
> paciente1 <- survfit(modelo, newdata = list(var1=xx,
var2=factor(1,levels=0:1), ... ))
> plot(paciente1, conf = F, lty = 2, ylab="S(t)",
xlab="t", main="Paciente com var1=xx, var2...")
```

6.2 Três modelos aninhados são propostos para explicar a sobrevivência de pacientes em diálise. O primeiro considera apenas a variável *idade*, o segundo inclui as doenças de base (*cdiab*, *congenita*, *crim*) e o terceiro inclui uma variável contextual que classifica o tamanho da unidade de tratamento (*grande*).

Modelo I: *idade*

Modelo II: *idade + cdiaab + congenita + crim*

Modelo III: *idade + cdiaab + congenita + crim + grande*

- Utilizando o banco de dados *dialise.csv* (Apêndice.12.4), faça gráficos de Kaplan-Meier estratificados por cada covariável categórica e verifique (visualmente) se há fortes indícios de não proporcionalidade (o que inviabilizaria o ajuste do modelo de Cox tradicional).
- Ajuste cada modelo explicativo acima utilizando o modelo de riscos proporcionais de Cox, tomando o cuidado de interpretar os parâmetros de cada modelo.

- (c) Compare os modelos usando o teste da razão de verossimilhanças e escolha o modelo com melhor ajuste.
- (d) Qual o poder explicativo do modelo escolhido? Calcule a razão entre o R^2 do modelo escolhido e o R^2 máximo.
- (e) Faça o gráfico do índice prognóstico.
- (f) Construa a curva de sobrevivência esperada pelo modelo III de um paciente com diabetes como doença de base, 40 anos de idade, e tratado em uma unidade pequena.
- (g) Faça o mesmo para um paciente com mesma idade e local de tratamento, mas com doença de base congênita.

6.3 No Capítulo 5, ajustamos um modelo explicativo para sobrevivência em Aids contendo as variáveis sexo, idade, tratamento e tipo de acompanhamento, utilizando regressão paramétrica (banco de dados *ipec.csv* – Apêndice.12.4). Faça agora uma análise desses dados utilizando o modelo de Cox, considerando três modelos explicativos aninhados.

Modelo I: *idade + sexo*

Modelo II: *idade + sexo + acompan*

Modelo III: *idade + sexo + acompan + tratam*

- (a) Faça gráficos de Kaplan-Meier estratificados por cada covariável categórica para verificar o pressuposto do modelo de Cox.
- (b) Ajuste cada modelo acima utilizando o modelo de riscos proporcionais de Cox, tomando o cuidado de interpretar os parâmetros de cada modelo.
- (c) Compare os modelos usando o teste da razão de verossimilhanças e o gráfico dos índices de prognóstico.
- (d) Qual o poder explicativo do modelo escolhido? Calcule a razão entre o R^2 do modelo escolhido e o R^2 máximo.

7

Análise de resíduos

O objetivo deste capítulo é capacitar o leitor a:

Verificar premissas e ajuste de modelo quanto à:

- proporcionalidade do risco;
- observações mal ajustadas pelo modelo (pontos aberrantes e influentes);
- forma funcional das covariáveis.

Analisar, utilizando o R, os seguintes resíduos:

- Schoenfeld;
- martingale;
- *deviance*;
- *escore*.

7.1 Introdução

Um aspecto importante a ser verificado ao ajustar o modelo de **riscos proporcionais** é exatamente a **proporcionalidade** dos riscos. Ou seja, será que o sobrerisco encontrado devido à fase da doença em

que o transplante de medula óssea foi realizado é o mesmo ao longo de todo o tempo de acompanhamento, ou é maior no início e após algum tempo essa diferença decresce? No capítulo anterior, apresentamos o modelo de Cox e métodos para avaliação da qualidade do ajuste global do modelo. Neste capítulo, verificaremos se o efeito estimado para cada variável é mantido ao longo de todo o tempo de acompanhamento, ou seja, se a proporcionalidade pressuposta pelo modelo de fato existe.

Outros aspectos da análise de resíduos, esses compartilhados com os modelos lineares generalizados, também devem ser investigados, como a presença de pontos aberrantes (*outliers*), de pontos influentes, ambos também avaliados nos modelos lineares generalizados, ainda que as técnicas aqui utilizadas sejam diferentes, por conta da censura. Esses resíduos são também empregados nos modelos paramétricos de sobrevivência.

Uma questão importante diz respeito à forma funcional, ou seja, a forma como a covariável se associa ao tempo de sobrevivência. Lembremos que a função de risco $\lambda(t)$ tem uma estrutura log-linear. Isso significa que para uma variável contínua como a idade, a razão de risco entre um indivíduo de 45 anos e um de 50 anos, além de ser independente do tempo, é idêntica àquela entre um indivíduo de 80 anos e um de 85 anos. Tal suposição, ainda que aceitável em uma série de situações, às vezes não se sustenta. Ou seja, talvez o risco não comece a subir antes de 65 anos, ou até mesmo cresça e então decresça novamente em idades mais avançadas. Quando a relação entre variável resposta e covariável não é log-linear, deve-se investigar a melhor forma de tratar a variável independente para estimar adequadamente o modelo.

A definição de uma medida de resíduo para modelos de sobrevivência não é tão simples e direta quanto no contexto da regressão linear. Por exemplo, o resíduo obtido pela diferença entre observado e esperado não pode ser usado para os dados de sobrevivência, pois não leva em consideração o tempo observado de um indivíduo censurado. Assim, diversas medidas estatísticas, úteis no exame de diferentes aspectos, têm sido propostas para os modelos de sobrevivência.

Neste capítulo, descreveremos alguns métodos para verificar o ajuste do modelo, através da análise de resíduos. Para cada aspecto listado abaixo será apresentada um tipo de resíduo, e o seu respectivo gráfico. Os aspectos a investigar são:

- a proporcionalidade do risco;
- a linearidade (na verdade log-linearidade) da relação entre razão de risco e covariável, chamada de forma funcional;
- pontos aberrantes (*outliers*);
- pontos influentes.

7.2 Resíduos de Schoenfeld: proporcionalidade dos riscos

Como responder à seguinte pergunta: o efeito – o risco relativo ou *hazard ratio* — de uma covariável é sempre o mesmo durante todo o tempo de observação? Caso não seja, o efeito da covariável é tempo-dependente. Para investigar a proporcionalidade de cada covariável k utiliza-se os **resíduos de Schoenfeld** definidos para cada indivíduo i :

$$r_{ik} = \delta_i(x_{ik} - a_{ik}), \quad (7.1)$$

em que δ_i é o indicador de ocorrência de evento no indivíduo i , e por isso quando ocorre censura o resíduo é nulo. Define-se a_{ik} como uma média ponderada dos valores das covariáveis dos indivíduos em risco no tempo t_i :

$$a_{ik} = \frac{\sum_{j \in R(t_i)} x_{jk} \exp(\mathbf{x}_j \hat{\boldsymbol{\beta}})}{\sum_{j \in R(t_i)} \exp(\mathbf{x}_j \hat{\boldsymbol{\beta}})}.$$

Observe que $R(t_i)$ é o conjunto de indivíduos em risco no tempo t_i e x_{jk} representa o valor da covariável k do indivíduo j

pertencente ao grupo de risco. Pode-se dizer que esse resíduo é a diferença entre o valor da covariável x_{ik} e essa média ponderada dos valores das covariáveis dos indivíduos em risco naquele instante. O peso do indivíduo j que pertence ao grupo de risco no tempo t_i é dado pela Equação (7.1) e é igual a:

$$\frac{\exp(\mathbf{x}_j \hat{\boldsymbol{\beta}})}{\sum_{j \in R(t_i)} \exp(\mathbf{x}_j \hat{\boldsymbol{\beta}})}.$$

Cabe ressaltar que haverá tantos vetores de resíduos quanto covariáveis ajustadas no modelo, e que esses são definidos somente nos tempos j em que ocorreu um evento.

Suponhamos que o vetor de coeficientes $\boldsymbol{\beta}$ varia com o tempo t . Logo, esse vetor $\boldsymbol{\beta}$ pode ser dividido em duas partes: uma média constante e uma função $\mathbf{U}(t)$ que representa valores que variam no tempo. Seja o resíduo padronizado de Schoenfeld em t_i definido por:

$$\mathbf{r}_i^* = [\hat{\mathbf{V}}(\mathbf{r}_i)]^{-1} \mathbf{r}_i, \quad (7.2)$$

em que $\hat{\mathbf{V}}(\mathbf{r}_i)$ é a matriz de covariância estimada do vetor de resíduos de Schoenfeld.

Demonstra-se que o valor esperado desse resíduo padronizado é aproximadamente igual à parte de $\boldsymbol{\beta}$ que varia no tempo – a função $\mathbf{U}(t)$. Assim, o gráfico dos resíduos padronizados de Schoenfeld contra os tempos de sobrevivência permite verificar se estes estão distribuídos igualmente ao longo do tempo, ou se aparece uma forma sugestiva de não proporcionalidade. Em outras palavras, se a suposição de riscos proporcionais for satisfeita não deverá existir tendência sistemática no gráfico de $\mathbf{r}_{ik}^*$ contra o tempo de sobrevivência. Eventualmente, a forma da dispersão dos resíduos pode sugerir transformações de covariáveis para se obter a proporcionalidade desejada. Para identificar a transformação necessária, podemos investigar a distribuição gráfica dos resíduos contra alguma função do tempo, por exemplo, o logaritmo ou a raiz quadrada do tempo.

Resíduo de Schoenfeld no R

Para calcular os resíduos de Schoenfeld utiliza-se a função `cox.zph()`. O principal argumento dessa função é o objeto que recebeu o modelo de Cox (suponha que este objeto seja chamado `modelo`). Essa função já retorna o resíduo de Schoenfeld padronizado. A função `residuals(modelo, "schoenfeld")` também calcula o resíduo de Schoenfeld, mas não padronizado.

```
> residuo.sch <- cox.zph(modelo)
```

A interpretação pode ser facilitada adicionando-se ao gráfico uma linha que permita melhor visualização da tendência, tal como o *spline*. O *spline* é uma função não paramétrica de suavização, que permite desenhar uma linha que sobe ou desce suavemente acompanhando a densidade de pontos. Este tipo de técnica é utilizado em modelos aditivos generalizados (ver o livro de Hastie & Tibshirani, 1990). Para essa curva pode-se estimar o intervalo de confiança do tipo $\pm 2 \times$ desvio padrão, de forma a verificar se as oscilações estão ou não significativamente afastadas do valor do coeficiente em cada período de tempo. Maiores detalhes sobre técnicas de suavização/alisamento serão apresentadas no Capítulo 9.

7.2.1 Escala do tempo de sobrevivência

Outro procedimento útil para investigar a proporcionalidade do risco é reescalonar o eixo do tempo de sobrevivência de forma a espalhar igualmente os pontos no gráfico, tornando mais fácil a visualização de quaisquer tendências nos resíduos. Uma proposta é mudar a escala do tempo de sobrevivência utilizando o complementar da estimativa de Kaplan-Meier ($1 - S_{km}$). Assim, quando um desvio de uma linha constante for detectado, pode existir uma estrutura tempo-dependente do efeito da covariável não incluída no modelo. Por *default*, a função `cox.zph()` utiliza esta escala no cálculo dos resíduos padronizados de Schoenfeld.

Cabe ressaltar que a escolha da escala de tempo altera o gráfico. Essa escala pode ser a própria escala de tempo observada, a ordem dos eventos no tempo – *rank* – ou uma escala baseada no Kaplan-Meier. A escala *rank* é útil quando os tempos observados são muito dispersos, com sobrevivências muito longas. A escala do complementar da função de sobrevivência de Kaplan-Meier coloca no eixo das abscissas os valores $(1 - \hat{S}_{km})$, e verifica os resíduos em cada um destes ponto. É o método mais usado. Utilizar diretamente o tempo, quando os eventos estão muito agrupados no início da observação, dificulta a análise dos resíduos. Já quando utilizamos o tempo-calendário, os eventos ficam melhor distribuídos, não sendo necessária outra escala.

Escala do tempo de sobrevivência do resíduo de Schoenfeld no R

Por *default*, a escala do tempo de sobrevivência adotada no cálculo do resíduo de Schoenfeld através da função `cox.zph()` é o complementar da estimativa de Kaplan-Meier. Para alterar a escala do tempo de sobrevivência é necessário acrescentar o argumento `transform=`, que pode tomar os seguintes valores:

- `transform="km"` - $1 - S_{km}$ (valor por *default*)
- `transform="rank"` - ordem dos eventos
- `transform="identity"` - tempo de sobrevivência

Vale ressaltar que os pontos que aparecerão no gráfico são os resíduos de Schoenfeld somados aos valores de $\widehat{\beta}_k$. É interessante assinalar o valor da estimativa para verificar se os intervalos de confiança desenhados incluem a estimativa média ao longo de todo o tempo. Outra ressalva importante é que por *default* a escala do gráfico dos resíduos de Schoenfeld é a escala Kaplan-Meier.

Gráficos dos resíduos de Schoenfeld no R

O gráfico dos resíduos de Schoenfeld que utiliza o resíduo calculado pela função `cox.zph` já traz incorporado as curvas de suavização *splines*. O comando `par` permite incluir vários gráficos na mesma janela, em tantas linhas e colunas quantas aparecem em `c(linhas,colunas)`. No comando abaixo a janela gráfica poderá incluir $3 \times 2 = 6$ gráficos separados em 3 linhas e 2 colunas.

```
> par(mfrow=c(3,2))
> plot(residuo.sch)
```

Múltiplos gráficos no R

Pode-se abrir uma nova janela para cada gráfico de resíduo e salvá-los em algum formato comum, como *ps* ou *jpeg*. Para automatizar esse procedimento utiliza-se um *loop* que salva cada gráfico em um arquivo. Para direcionar os gráficos para figuras nas quais apenas um número no nome do arquivo varia (`fig1.jpg`, `fig2.jpg`, etc.), basta colocar no nome do arquivo de saída o sinal `%02d`, que indica arquivos com numeração sequencial de dois dígitos. Todas as figuras geradas serão arquivadas com o nome escolhido até que se feche o *device* de saída com o comando `dev.off()`.

Dessa forma é possível também acrescentar a reta que representa o efeito estimado do coeficiente, para compará-lo ao *spline*. O comando `abline` é utilizado para desenhar uma reta paralela ao eixo X no valor do coeficiente estimado `h=modelo$coefficients[k]`, sendo *k* o índice das covariáveis.

```
> jpeg(file="nome%02d.jpg")
> for(k in 1:m){
  plot(residuo.sch[k])
  abline(h=modelo$coefficients[k], lty=4, col=2)
}
> dev.off()
```

7.2.2 Correlação linear com o tempo

Além da análise gráfica, pode-se testar a presença de correlação linear entre o tempo de sobrevivência e o resíduo. Sob a hipótese nula, de correlação igual a zero, tem-se que a distribuição do teste é uma qui-quadrado com um grau de liberdade. Logo, se a hipótese nula não é rejeitada, a premissa de proporcionalidade dos riscos não é rejeitada. O teste para cada covariável é baseado em uma regressão, da seguinte forma:

$$\beta_k(t) = \beta_k + \theta_k U_k(t), \quad (7.3)$$

no qual θ_k é o parâmetro de variação no tempo. A hipótese nula é que $\theta_k = 0$.

Exemplo

Retomando o estudo do transplante, o ajuste de cada covariável do modelo mais completo *m4* (p. 202) pode ser avaliado na Figura 7.1. A linha horizontal de cada gráfico da Figura 7.1 mostra o efeito constante da covariável assumido sob o modelo de Cox.

Se a premissa de riscos proporcionais não é violada, então espera-se que essa reta esteja dentro dos intervalos de confiança da curva de suavização *spline* dos resíduos. Podemos fazer as seguintes observações nestes gráficos:

- O efeito da idade e da fase intermediária da doença no momento do transplante são totalmente proporcionais ao longo do tempo.
- O efeito do sexo no final do período de observação parece ser diferente do início, mas como são poucas observações, essa variação não é importante, podendo ser considerada proporcional.
- O efeito da fase adiantada da doença também varia no tempo, embora não muito, mas como são apenas nove pessoas, também essa variação pode ser atribuída à flutuação aleatória.




Figura 7.1: Resíduos de Schoenfeld para o modelo m4 (p. 202)

- A doença do enxerto aguda (*deag*) tem comportamento oscilatório, mas as curvas do intervalo de confiança sempre incluem o valor do parâmetro estimado.
- A doença do enxerto crônica (*decr*) apresenta visível tendência. Os resíduos padronizados aumentam de forma consistente com o tempo. Esse tipo de tendência, bem definida, deve ser mais valorizada na análise de resíduos do que flutuações em torno do zero. A covariável (*decr*) não deve entrar no modelo diretamente.

O resultado do teste da correlação linear dos resíduos das covariáveis com o tempo de sobrevivência foi:

```
> m4.sch <- cox.zph(m4)
> m4.sch
```

	rho	chisq	p
idade	-0.02226	2.92e-02	0.8644
sexo2	-0.18004	1.86e+00	0.1721
fase2	-0.00212	2.81e-04	0.9866
fase3	0.20766	2.91e+00	0.0881
deag1	0.05110	1.52e-01	0.6971
decr1	0.35133	7.22e+00	0.0072
GLOBAL	NA	1.35e+01	0.0362

Teste de correlação linear no R

Para obter o resultado do teste da correlação linear entre o tempo de sobrevivência e o resíduo, basta listar o objeto que recebeu o cálculo do resíduo pela função *cox.zph()*.

```
> residuo.sch <- cox.zph(modelo)
> residuo.sch
```

A primeira coluna é o nome das covariáveis, a segunda é o coeficiente de correlação linear (*rho*), a terceira é a estatística qui-quadrado (*chisq*) e a última é o p-valor da estatística (*p*). A última linha da tabela resultante mostra um teste global de proporcionalidade que também segue uma distribuição qui-quadrado.

Observe que a única covariável para a qual se rejeita a hipótese nula de risco proporcional é a doença do enxerto crônica. Note que nesse caso o efeito da covariável parece ter uma tendência crescente linear ao longo do tempo, ao contrário da doença de enxerto aguda. Além disso, a função também estimou a proporcionalidade global do modelo, rejeitando a hipótese nula de proporcionalidade de todas as covariáveis. Pensando sobre o significado disso, é fácil compreender que uma doença crônica relacionada ao enxerto deve mesmo aumentar o risco à medida que o tempo passa. Aliás, na nossa experiência, quando a proporcionalidade de uma covariável é claramente rejeitada, em geral trata-se de variável que tem um forte componente temporal. Por exemplo, ocorrência de doença tardia ou crônica, como o nome já indica, está relacionada ao tempo. Também variáveis que são contadas como tempo, por exemplo, o número de dias de internação em unidade intensiva como *proxis* de gravidade, apresentam o mesmo tipo de dependência temporal. Toda covariável que seja de alguma forma temporal terá comportamento tempo-dependente, resultando num risco não proporcional.

7.2.3 Tratando a não proporcionalidade

O que fazer então quando os riscos não são proporcionais? Antes de mais nada, deve-se verificar se a não proporcionalidade encontrada é realmente importante. A variação em $\hat{\beta}_k(t)$ pode ser pequena em relação ao parâmetro estimado $\hat{\beta}_k$. A segunda questão é verificar se a não proporcionalidade é real. Alguns poucos pontos *outliers* podem estar influenciando a significância do teste.

Caso a não proporcionalidade seja importante, uma estratégia bastante utilizada é estratificar o modelo pela respectiva covariável, como vimos no Capítulo 6. Nesse caso resolve-se a não proporcionalidade, mas o efeito desta variável não será estimado, pois o modelo será ajustado considerando como independentes os riscos de base de cada estrato. No caso de covariáveis contínuas, estas deverão ser categorizadas, sempre lembrando que as análises estratificadas são menos eficientes, pois aumentam os intervalos de confiança das demais covariáveis. O efeito estimado das covariáveis presentes no modelo deve

ser interpretado como um efeito médio para todos os estratos, controlado pela variável de estratificação.

Tratar as covariáveis como funções do tempo não resolve o problema, pois as inferências não são válidas quando $x(t)$ é uma função da variável resposta (tempo de sobrevivência). Uma possibilidade é particionar o eixo do tempo, analisando cada trecho em que há proporcionalidade, separadamente. Para tal, censura-se todo tempo acima do qual não há proporcionalidade ($t > \tau$) e ajusta-se um modelo de Cox para se obter β_1 . Em seguida, censura-se todo $t \leq \tau$ e reajusta-se o modelo de Cox para se encontrar β_2 . O valor de τ deve ser escolhido de tal forma que maximize o produto da verossimilhança dos dois períodos analisados.

Uma outra alternativa é usar outro tipo de modelo. Existem modelos próprios para analisar riscos não proporcionais, como por exemplo os modelos de tempo de vida acelerado, cujas ideias básicas foram apresentadas no Capítulo 5. Sugerimos a leitura de Kalbfleish & Prentice (2002) e de Freitas & Colosimo (1997).

Exemplo

Como a doença crônica é definida como a que ocorre a partir de 100 dias, dividiremos a análise em dois blocos: tempo de sobrevivência até 100 dias e igual ou maior que 100. Para isso é necessário criar o novo status dos pacientes, no qual os eventos sejam censurados conforme o período em que ocorram. O processo é simples:

```
> tmo$statusaguda <- ifelse(tmo$os < 100, tmocens$status, 0)
> tmo$statuscronica <- ifelse(tmo$os >= 100, tmo$status, 0)
> summary(coxph(formula = Surv(os, statuscronica) ~ idade +
  sexo + fase + deag + decr, data = tmo, x = T))
> summary(coxph(formula = Surv(os, statusaguda) ~ idade +
  sexo + fase + deag + decr, data = tmo, x = T))
```

Os coeficientes estimados para cada um dos modelos e o teste da correlação linear do resíduo de Schoenfeld estão na Tabela 7.1. Observe que os efeitos estimados mudam substancialmente.

Tabela 7.1: Estimativa da razão de riscos dos modelos com tempo de sobrevivência particionado e seus respectivos teste da correlação linear (resíduo de Schoenfeld)

Variável	Razão de Riscos		Resíduos de Schoenfeld (p-valor)	
	< 100 dias	≥ 100 dias	< 100 dias	≥ 100 dias
idade	0,98	1,00	0,662	0,1180
sexo2	0,79	0,77	0,245	0,0192
fase2	1,94	1,89	0,839	0,5899
fase3	1,15	11,02*	0,252	0,3253
deag1	3,02*	3,00*	0,114	0,8063
decr1	0,05*	0,61	0,397	0,0813

* Efeito significativo ao nível de significância de 5%

Como o número de eventos se altera, uma vez que são censurados os eventos ocorridos nos tempos para os quais não se deseja estimar, a significância estatística será menor. As variáveis problemáticas, entretanto – doença do enxerto aguda e crônica – apresentam efeito aumentado nos modelos correspondentes, e deixam de ser tempo-dependentes. Os gráficos também indicam melhor ajuste (Figura 7.2). Observe a mudança na escala do tempo nos gráficos dos dois modelos.

7.3 Resíduos martingale: pontos aberrantes e forma funcional


Os resíduos martingale, M_i , são baseados no processo de contagem individual e definidos por:

$$M_i = N_i - E_i, \quad (7.4)$$


tal que N_i é igual ao número de eventos observados no intervalo $[0, \infty)$ e E_i é o número de eventos esperados sob o modelo ajustado no intervalo $[0, \infty)$. Estima-se o resíduo martingale como:

$$\widehat{M}_i = \delta_i - \widehat{\Lambda}_0(t_i) \exp(\mathbf{x}_i \widehat{\boldsymbol{\beta}}) = \delta_i - r_{C_i}, \quad (7.5)$$

em que r_{C_i} é denominado **resíduo de Cox-Snell**.



(a) Tempo de sobrevivência < 100



(b) Tempo de sobrevivência ≥ 100

Figura 7.2: Resíduos de Schoenfeld para os modelos com o tempo particionado (dados TMO)

São propriedades dos resíduos martingale, algumas das quais semelhantes aos resíduos dos modelos de regressão linear:

- o valor esperado de M_i é 0, quando avaliado no valor verdadeiro (e desconhecido) do vetor de parâmetros β ;
- os resíduos M_i não são simetricamente distribuídos em torno de 0, variando de $(-\infty, 1]$ e quando o tempo de sobrevivência é censurado o resíduo é negativo;
- o somatório dos resíduos observados baseados no valor estimado de β é igual a 0; e
- os resíduos M_i calculados usando o verdadeiro vetor de parâmetros β são não correlacionados, mas as estimativas $\widehat{M}_i$ são negativamente correlacionadas, ainda que fracamente.

Apesar da semelhança com a decomposição dos dados utilizada em modelos de regressão linear (resíduo = valor observado – valor esperado), os resíduos martingale possuem propriedades diferentes dos resíduos dos modelos lineares. Primeiro, a soma de quadrados dos resíduos não auxilia na avaliação do ajuste global do modelo. Em outras palavras, o melhor modelo de Cox ajustado não apresenta, necessariamente, a menor soma de quadrados de resíduos martingale. Além disso, em modelos lineares assume-se que a distribuição dos resíduos deve ser aproximadamente normal, o que também não acontece. E nem os resíduos seguem uma distribuição exponencial, como poderia se supor devido à forma do modelo de Cox.

Uma outra ferramenta de diagnóstico usada em modelos lineares é o gráfico de resíduos contra valores ajustados. Novamente esse procedimento não funciona para resíduos martingale, pois estes são negativamente correlacionados com os valores ajustados. Por exemplo, considere um conjunto de dados de sobrevivência sem censura, em que cada indivíduo sofre exatamente um único evento. Nesse caso, $N_i(\infty) = 1$ para todo i , e portanto o gráfico de $1 - \widehat{E}_i$ versus $\widehat{E}_i$ é uma reta com inclinação -1 , qualquer que seja o modelo ajustado aos dados.

Mesmo com essas restrições, os resíduos martingale são úteis na avaliação da qualidade de ajuste do modelo em duas situações importantes, observadas graficamente:

- M_i contra o índice do indivíduo – permite revelar indivíduos mal ajustados pelo modelo (pontos aberrantes ou *outliers*);
- M_i do modelo nulo (sem covariáveis) contra covariável com a superposição de uma curva de suavização – sugere a forma funcional de uma covariável contínua.

O primeiro tipo de uso do resíduo martingale serve para apontar possíveis valores aberrantes no estudo, ou seja, indivíduos que demoram muito tempo para sofrer o evento ou que sofrem o evento muito rapidamente, dadas as covariáveis. Valores de M_i positivos indicam que o número de eventos observado é maior que o estimado pelo modelo e vice-versa.

O resíduo martingale do modelo nulo permite explorar a forma funcional de uma covariável contínua, isto é, se é linear ou se alguma transformação é necessária, por exemplo, fazendo uso da raiz quadrada ou do logaritmo da covariável, ou ainda se uma forma não paramétrica deve ser usada.

A Figura 7.3 ilustra alguns exemplos de padrões de associações usuais. O gráfico (a) mostra o caso em que não há associação entre o tempo de sobrevivência e a idade, como foi observado no exemplo do transplante de medula óssea. Os outros gráficos são situações hipotéticas da forma funcional que a idade poderia assumir. No gráfico (b) existe uma relação e ela é linear, isto é, a covariável não precisa de nenhuma transformação, e terá um parâmetro β estimado corretamente, medindo o efeito de cada ano de vida a mais na sobrevivência do paciente. No gráfico (c) essa relação não é linear, parece ser quadrática, e a raiz quadrada da variável poderia linearizar a relação. O gráfico sugere que o modelo ajusta bem entre 40 e 60 anos, mas que entre os mais jovens e os mais velhos ele subestima o efeito da idade, gerando resíduos positivos. Por fim, no gráfico (d) a relação não parece ser linear, e neste caso não existe uma simples

transformação de linearização, sendo necessário incluir uma função adequada no modelo, por exemplo, um polinômio ou uma função não paramétrica de suavização, como por exemplo a função *spline*. O ajuste de funções não paramétricas será apresentado no Capítulo 9.




Figura 7.3: Resíduos do modelo nulo contra covariável para investigação da forma funcional

Resíduo martingale no R

A função para calcular os resíduos martingale é `resid()`, com o argumento `type="martingale"`.

```
> res.mart <- resid(modelo,type="martingale")
```

em que `modelo` é o objeto que recebeu o modelo de Cox.

O gráfico do resíduo contra o índice de cada observação é simplesmente o `default` do comando `plot()`. Acrescenta-se uma linha horizontal no zero para facilitar a visualização, assim:

```
> plot(res.mart)
> abline(h=0)
```

O gráfico para analisar a forma funcional coloca no eixo das abcissas a variável original e nas ordenadas o resíduo martingale do modelo nulo. O `lowess` é desenhado sobre os pontos para ajudar na visualização de uma possível não linearidade. O `lowess` é uma curva de suavização definida por regressões lineares ponderadas dos valores do eixo das ordenadas, no nosso caso, o resíduo martingale, para janelas do eixo das abcissas com pesos maiores para os pontos mais próximos. Utiliza-se o argumento `iter=0` da função de suavização `lowess()` para que a curva estimada não elimine valores extremos, e não suavize demais os pontos aberrantes (*outliers*). Isso é importante para dados com um grande número de indivíduos censurados.

```
> modelo.nulo <- coxph(Surv(tempo,status)~1,data=dados)
> res.nulo <- resid(modelo.nulo,type="martingale")
> plot(banco$variavel,res.nulo)
> lines(lowess(banco$variavel,res.nulo,iter=0),lty=2)
> lines(lowess(banco$variavel,res.nulo),lty=3)
> legend("bottom", lty=c(2,3),
       legend=c("Com outlier","Sem outlier"))
```

7.4 Resíduos *deviance*: pontos aberrantes

O resíduo *deviance* D_i é definido por:

$$D_i = \text{sin}(\widehat{M}_i) \sqrt{-2 \times (l_{i(\text{modelo})} - l_{i(\text{saturado})})}, \quad (7.6)$$

sendo o sinal de $(\widehat{M}_i)$ simplesmente o sinal do resíduo martingale e $l_{i(\text{modelo})}, l_{i(\text{saturado})}$ os valores do logaritmo da função de verossimi-

lança para cada observação i do modelo em questão e do modelo saturado. Esses resíduos são simetricamente distribuídos em torno do zero, portanto são de interpretação gráfica mais fácil. No entanto, sua soma não é necessariamente zero.

Observe que a função desvio definida na Seção 5.6.1 também pode ser obtida através da soma dos quadrados dos resíduos *deviance*. Sem muita censura, os resíduos D_i parecerão uma amostra aleatória normal, e por isso são úteis na detecção de valores aberrantes. Para tal efeito, pode-se utilizar três gráficos: resíduos *deviance* contra o índice da observação ou contra os valores preditos do modelo e o gráfico quantil-quantil.

Exemplo

Alguns pontos no gráfico dos resíduos martingale e *deviance* para cada indivíduo (Figura 7.4) foram identificados como sendo possíveis valores aberrantes, pois estão bastante afastados do zero. O resíduo martingale permitiu identificar somente as observações com resíduos negativos, pois seu valor máximo é 1, enquanto o *deviance*, seja no gráfico quantil-quantil ou contra os valores predito pelo modelo identifica quatro observações com valores > 2 ou < -2 .

Os indivíduos identificados como mal ajustados estão listados a seguir. Observe que os dois indivíduos com resíduos negativos (11 e 79) foram censurados em tempos longos, apesar de terem doença do enxerto aguda. Os outros três indivíduos com resíduos positivos morreram em tempo muito curtos, mesmo que em fase inicial da doença (*fase=1*) e, nos casos 57 e 95, não tinham doença aguda.

```
> tmo[c(11,79,54,57,95),]
```

id	sexo	idade	status	os	deag	decr	fase
11	2	18	0	1000	1	0	1
79	2	14	0	531	1	0	1
54	2	12	1	31	1	0	1
57	1	29	1	32	0	0	1
95	1	19	1	32	0	0	1




Figura 7.4: Resíduos martingale e *deviance* identificando indivíduos mal ajustados pelo modelo *m4* (p. 202). Observe que o resíduo *deviance* detecta indivíduos com grandes resíduos positivos, o que não foi possível com o resíduo martingale

Resíduo *deviance* no R

A função para calcular os resíduos *deviance* é `resid()`, com o argumento `type="deviance"`.

```
> res.dev <- resid(modelo, type="deviance")
```

em que `modelo` é o objeto que recebeu o modelo de Cox.

O gráfico do resíduo contra o índice de cada observação é simplesmente o *default* do comando `plot()`. Acrescenta-se uma linha horizontal no zero para facilitar a visualização, assim:

```
> plot(res.dev)
> abline(h=0)
```

Para avaliar o resíduo contra o valor predito pelo modelo, é necessário calcular o valor predito, usando a função `predict`. Usa-se a função `identify()` para identificar os pontos aberrantes.

```
> plot(res.dev, predict(modelo))
> abline(h=0)
> identify(res.dev, predict(modelo))
```

Pode-se fazer um gráfico quantil-quantil, com o comando:

```
> qqnorm(res.dev)
> qqline(res.dev, lty=3)
```

A Figura 7.5 mostra o resíduo martingale do modelo nulo contra a covariável idade para avaliar a sua forma funcional. O gráfico sugere um efeito não linear, com resíduos negativos a partir de aproximadamente 30 anos.

7.5 Resíduos escore: pontos influentes

Os resíduos escore, também conhecidos como *dfbeta*, são úteis para verificar a influência de cada observação no ajuste do modelo e para a estimação robusta da variância dos coeficientes de regressão. Uma forma simples de verificar essa influência nos parâmetros do modelo de Cox é, para cada observação i , calcular a diferença entre o vetor de parâmetros estimado pelo modelo e o mesmo estimado sem o indivíduo i : $\Delta\beta = \hat{\beta} - \hat{\beta}_{(-i)}$. Se essa diferença for igual a zero, então a




Figura 7.5: Idade contra resíduos martingale do modelo nulo

i -ésima observação tem pouca influência na estimativa. Para que não seja necessário estimar $(n + 1)$ modelos de Cox, sendo n o número de observações, utiliza-se uma aproximação com base nos resíduos de escore, da seguinte forma:

$$\begin{aligned}\Delta\beta &= \hat{\beta} - \hat{\beta}_{(-i)} \\ &= 1'(U\mathcal{I}^{-1}) \\ &\approx 1'D.\end{aligned}$$

U é a matrix de resíduos escore em que cada elemento (indivíduo i e covariável j) é definido por $U_{ij} = \int [X_{ij} - \bar{x}(\hat{\beta}, t)]d\widehat{M}_i(t)$, sendo $\mathcal{I}$ a matrix de informação de Fisher observada e D aproximadamente igual à matriz de resíduos escore escalonada pela variância dos parâmetros β . Uma vantagem desses resíduos sobre os outros é que eles são definidos para todos os tempos, o que é especialmente importante quando o percentual de censuras é grande.

Esse resíduo representa a mudança aproximada que o vetor de parâmetros β sofreria se a observação fosse eliminada. Quanto maior o valor de $\Delta\beta_k$, maior a influência da observação. Ou seja, retirando essa observação, a estimativa muda em $\Delta\beta_k$. O gráfico do

resíduo escore para cada covariável – $\Delta\beta_k$ contra x_i – revela os pontos influentes, ou seja, os indivíduos que influenciam fortemente a estimativa do parâmetro de cada covariável. O gráfico dos resíduos escore escalonados pelo erro padrão da respectiva covariável torna melhor a visualização dos pontos. Para as variáveis contínuas é feito um gráfico de dispersão, para as variáveis categóricas, um *boxplot* para cada categoria. Observe na Figura 7.6 referente ao modelo *m4* que os resíduos escore para todas as covariáveis apresentam uma escala muito reduzida e nenhuma evidência de pontos influentes.

Os resíduos escore também são utilizados para se encontrar uma estimação robusta da variância de $\hat{\beta}$ que será utilizada quando cada indivíduo sofre mais de um evento, como apresentado no Capítulo 10.

Resíduos escore no R

A função para calcular o resíduo escore é a mesma usada no resíduo martingale, basta trocar o argumento para *type=dfbetas*. Os gráficos também são semelhantes: cada variável contra o valor do seu resíduo escore. O valor do resíduo fica arquivado nas colunas do objeto *res.esco*, na ordem em que aparecem no modelo. Para conferir a ordem das variáveis, veja o objeto *modelo\$call*.

```
> res.esco <- resid(modelo,type="dfbetas")
> par(mfrow=c(1,2))
> plot(banco$var1,res.esco[,1],xlab="Var1",ylab="Resíduos")
> plot(banco$var2,res.esco[,2],xlab="Var2",ylab="Resíduos")
```




Figura 7.6: Resíduos escore para o modelo *m4* (p. 202)

Resumo

Para...	Faça...
avaliar proporcionalidade global	teste de proporcionalidade global: função <i>cox.zph</i>
avaliar proporcionalidade de cada variável	gráficos do resíduo de Schoenfeld contra tempo
identificar pontos aberrantes	resíduo martingale e resíduo <i>deviance</i>
estudar forma funcional da variável	gráficos do resíduo martingale do modelo nulo contra a covariável
identificar pontos influentes	gráficos do resíduo score contra covariável

Exercícios

Nos próximos exercícios serão feitas as análises dos resíduos dos modelos ajustados no Capítulo 6. Para tanto, é necessário ter realizado os exercícios do capítulo anterior.

7.1 No capítulo anterior, encontramos, ao ajustar o modelo de Cox aos dados de transplante de medula óssea (banco de dados *tmoclas.csv* – Apêndice.12.4), que o melhor modelo explicativo da sobrevivência incluiu as covariáveis *idade*, *sexo*, *fase*, *deag* e *decr*. Adotando-o como modelo final, refaça a análise de resíduos apresentada ao longo do texto.

- (a) Obtenha os resíduos de Schoenfeld para verificar a proporcionalidade dos riscos em cada variável do modelo final.

- (b) Verifique a correlação linear do tempo com cada variável e o ajuste global do modelo (proporcionalidade).
- (c) Faça o gráfico do resíduo de Schoenfeld de cada variável (altere a escala gráfica do tempo, se necessário).
- (d) Trate a não proporcionalidade da variável doença crônica particionando o tempo em $t = 100$ dias.
- (e) Avalie a existência de pontos aberrantes usando os resíduos *deviance*.
- (f) Verifique a existência de pontos influentes usando os resíduos *score*.
- (g) Compare os resultados da análise desses três diferentes resíduos. Foram sempre os mesmos pontos? Se não, o que os diferencia?
- (h) Analise a forma funcional das variáveis contínuas usando resíduos martingale.

Dicas

- Para obter os resíduos de Schoenfeld: `sch <- cox.zph(modelo)`.
- Para fazer o gráfico de Schoenfeld de cada variável, indicar a posição relativa i da variável no objeto resíduo:

```
> plot(sch[i], main="Nome da variável i")
```
- Escolhe-se o ponto de corte do tempo de forma que o produto da verossimilhança dos dois períodos analisados seja maximizado. Na prática, particiona-se o tempo no ponto P , em que alguma mudança no comportamento da variável foi observada.

```

> banco$novostatus1 <- ifelse(banco$tempo<100,
  banco$status, 0)
> banco$novostatus2 <- ifelse(banco$tempo>=100,
  banco$status, 0)
> summary(coxph(Surv(tempo, novostatus1) ~
  var1 + var2 + ..., data=banco, x=T))
> summary(coxph(Surv(tempo, novostatus2) ~
  var1 + var2 + ..., data=banco, x=T))

```

- Para os resíduos *deviance*, utiliza-se a função `resid()`, e respectivo gráfico, identificando os pontos aberrantes:

```

> res.dev <- resid(modelo,type="deviance")
> plot (res.dev, xlab = "Indice", ylab = "Resíduo")
> abline(h=0,lty=3)
> identify(res.dev)

```

- O resíduo *escore* indica indivíduos alavanca. O argumento da função `resid()`, muda para `dfbetas`:

```

> res.esco <- resid(modelo, type="dfbetas")
> par(mfrow=c(1,2))
> plot(banco$var1,res.esco[,1])
> plot(banco$var2,res.esco[,2])

```

- Para conferir a ordem das variáveis, veja o objeto usando o comando: `modelo$call`.
- O gráfico para avaliar a forma funcional de variável contínua tem na abscissa a variável original e na ordenada o resíduo do modelo nulo. A curva *lowess* desenhada sobre os pontos ajuda na visualização.

```

> res.nulo <- residuals(coxph(Surv(tempo,status)~1,
  data=banco))
> plot(banco$variável,res.nulo)
> lines(lowess(banco$variável, res.nulo, iter = 0),
  lty = 2)

```


7.2 No estudo de sobrevivência de pacientes em diálise (Exercício 6.2), encontramos que o modelo contendo variáveis demográficas, clínicas e contextuais (*idade*, *cdiab*, *crim*, *congenita* e *grande*) foi o que melhor se ajustou aos dados. Pela análise visual do gráfico de Kaplan-Meier realizada no exercício, todas as variáveis pareciam atender ao pressuposto do modelo de Cox. A única que levantou dúvidas foi a variável *congenita*.

- (a) Reavalie essas variáveis, agora utilizando os resíduos de Schoenfeld, fazendo uma análise visual dos resíduos e calculando o teste da correlação.
- (b) Faça também o gráfico dos resíduos escore para cada indivíduo. Há indicação de indivíduos mal ajustados pelo modelo?

7.3 No ajuste do modelo de Cox aos dados de sobrevivência em Aids dos pacientes do Ipec (Exercício 6.3), vimos que a variável tratamento não parece atender ao pressuposto do modelo de Cox. Faça a análise de resíduos do modelo final (Modelo III) e procure confirmar esse achado calculando os resíduos de Schoenfeld.

- (a) Obtenha os resíduos de Schoenfeld para verificar a proporcionalidade dos riscos em cada variável do modelo final.
- (b) Calcule a correlação linear do tempo com cada variável e o ajuste global do modelo (proporcionalidade).
- (c) Faça o gráfico do resíduo de Schoenfeld de cada variável.
- (d) Se alguma variável foi considerada não proporcional (tempo dependente), verifique se ela é realmente importante ou se não é devido à presença de pontos aberrantes.
- (e) Faça também o gráfico dos resíduos escore. Há indicação de observações mal ajustadas pelo modelo?

8

Covariáveis mudando no tempo

Coautora: *Rita Byington*

O objetivo deste capítulo é capacitar o leitor a:

Analisar a sobrevivência quando as covariáveis mudam ao longo do tempo.

Construir o banco de dados com covariáveis que mudam no tempo.

Ajustar no R e interpretar modelos com covariáveis mudando no tempo.

8.1 Introdução

Durante o período de acompanhamento de uma coorte, algumas variáveis dos indivíduos não mudam, como por exemplo o gênero e a etnia. Outras, como residência, idade, comportamentos, tratamento, podem mudar, sendo necessário adaptar os modelos a tal situação. Neste capítulo veremos como incluir covariáveis que mudam ao longo do tempo, situação relativamente comum. O modelo de Cox que incorpora covariáveis mudando no tempo é denominado **modelo de**

Cox estendido. A modelagem é direta, se utilizarmos a abordagem de processo de contagem. O maior problema é a construção correta do banco de dados.

8.2 Modelo de Cox estendido

O modelo de Cox estendido tem as mesmas premissas já estudadas no Capítulo 6, tendo a forma genérica dada por:

$$\lambda(t|\mathbf{x}(t)) = \lambda_0(t) \exp(\mathbf{x}(t)\boldsymbol{\beta}). \quad (8.1)$$

Exemplos comuns de covariáveis que mudam durante o tempo de acompanhamento são:

- medidas clínicas que são aferidas diversas vezes no mesmo indivíduo;
- alteração de alguma condição clínica ou socioeconômica;
- realização de algum procedimento ou mudança de tratamento durante o período de observação.

Como exemplo do primeiro tipo temos a análise do efeito do índice de massa corporal (IMC) no tempo até a ocorrência de infarto agudo do miocárdio em uma coorte acompanhada por 30 anos. Como o peso do indivíduo varia, a cada vez que é medido calcula-se um novo IMC para estimar corretamente o risco do sobrepeso/obesidade. Incluir apenas o IMC medido aos 30 anos certamente não seria adequado. Assim, a variação no IMC medido em intervalos irregulares pode ser representada como indicado a seguir. A entrada do indivíduo na coorte se deu no ano zero e o infarte ocorreu 28 anos depois:

intervalo (em anos)	IMC (kg/m ²)	status
(0,5]	21,7	0
(5,8]	23,7	0
(8,12]	26,9	0
(12,18]	30,4	0
(18,25]	32,6	0
(25,28]	35,8	1

A entrada no climatério em estudo de risco cardiovascular em mulheres é um outro bom exemplo de mudança de condição que deve ser necessariamente incorporada no estudo, pois caracteriza outro perfil de risco.

No terceiro tipo de problema tempo-dependente, o início da hemodiálise na sobrevivência de pacientes com doença renal, marca uma etapa nova no risco de complicações clínicas, e é necessário considerar o momento em que essa intervenção ocorreu. Nesse caso, para cada paciente registram-se duas linhas: uma que começa no início do período de observação daquele indivíduo e outra a partir do momento em que ele foi submetido à hemodiálise. Os indivíduos que faleceram antes de iniciar o procedimento serão representados por apenas uma linha, começando no início do período de observação e se prolongando até a ocorrência do óbito. No exemplo a seguir, o paciente 1 entrou no estudo no tempo zero, iniciou a hemodiálise no tempo 30 e morreu no tempo 90. Já o paciente 2 entrou no estudo no tempo 20, iniciou o procedimento no tempo 150 e ainda estava vivo no tempo 300, quando foi censurado. Finalmente, o paciente 3 entrou no estudo no tempo 15 e morreu sem iniciar a hemodiálise no tempo 400.

paciente	intervalo	hemodiálise	status
1	(0,30]	0	0
1	(30,90]	1	1
2	(20,150]	0	0
2	(150,300]	1	0
3	(15,400]	0	1

Temos ainda as situações em que se deseja estudar o efeito de múltiplas covariáveis mudando no tempo. Também nesses casos precisamos apenas construir o banco de dados adequado para que as mudanças nas diversas combinações de atributos ao longo do tempo possam ser incorporadas corretamente no modelo de Cox. Cabe observar que não está disponível no R a abordagem por processo de contagem, que permite a incorporação de covariáveis que mudam ao longo do tempo e eventos múltiplos para modelos paramétricos.

8.3 Estrutura dos dados mudando no tempo

No estudo da sobrevivência de pacientes submetidos ao transplante de medula óssea (TMO), descritos no Apêndice (seção Transplante de medula óssea), consideramos, além das variáveis medidas somente no início do estudo, as que mudam ao longo do tempo, como a ocorrência de doença do enxerto contra o hospedeiro (DECH) em suas formas aguda (`deag`) e crônica (`decr`) e a recuperação no número de plaquetas a um nível acima de 20.000/mm³ (`recplaq`). É necessário construir um banco de dados contemplando o momento de mudança de cada uma dessas três características.

id	sexo	idade	status	inicio	fim	deag	decr	recplaq	fasegr
1	2	31	0	0	9	0	0	0	CP1
1	2	31	0	9	1000	0	0	1	CP1
2	2	38	0	0	28	0	0	0	CP1
2	2	38	1	28	39	1	0	0	CP1

id	sexo	idade	status	inicio	fim	deag	decr	recplaq	fasegr
3	1	23	0	0	27	0	0	0	CP1
3	1	23	0	27	36	0	0	1	CP1
3	1	23	0	36	268	1	0	1	CP1
3	1	23	1	268	434	1	1	1	CP1
4	2	5	0	0	24	0	0	0	CP1
4	2	5	1	24	69	1	0	0	CP1
5	2	15	0	0	22	0	0	0	CP1
5	2	15	0	22	83	1	0	0	CP1
5	2	15	0	83	446	1	0	1	CP1
5	2	15	1	446	672	1	1	1	CP1

A variável `id` é o identificador de indivíduo no banco de dados. Observamos nesses dados que cinco pacientes constituem 14 linhas de registro no banco de dados. O paciente número 1, que recuperou as plaquetas a um nível acima de $20.000/mm^3$ mas não apresentou DECH aguda ou crônica, passou a ser representado por duas linhas. Já o paciente número 3 é representado por meio de 4 linhas: no dia 27 havia recuperado o número de plaquetas; no dia 36, apresentou DECH aguda; no dia 268, desenvolveu DECH crônica e faleceu no dia 434. Observe que nos tempos (`inicio` e `fim`), a variável indicadora de censura (`status`) e as variáveis que sofrem alteração ao longo do estudo mudam de uma linha para outra (`deag`, `decr` e `recplaq`), enquanto os valores das variáveis medidas no início do estudo – no exemplo, a idade no início do estudo (`idade`) e a fase da doença no momento do transplante (`fasegr`) – são repetidos em todas as linhas referentes a um mesmo indivíduo. A leucemia mieloide crônica tem três fases em sua evolução: fase crônica, fase acelerada e crise blástica, aqui definida em apenas dois níveis: primeira fase crônica (`CP1`) e as demais (`other`).

O tempo até a ocorrência do evento com o processo de contagem passa a ser assim representado:

paciente 1	(0,9+]	(9,1000+]		
paciente 2	(0,28+]	(28,39]		
paciente 3	(0,27+]	(27,36+]	(36,268+]	(268,434]
paciente 4	(0,24+]	(24,69]		
paciente 5	(0,22+]	(22,83+]	(83,446+]	(446,672]

Observe que a notação utilizada para os limites dos intervalos de tempo – parêntese no limite inferior do intervalo e colchete no limite superior – é importante. O parêntese “(” indica um intervalo aberto, que exclui o limite inferior do intervalo. O colchete “]” indica intervalo fechado, ou seja, o limite superior do intervalo de tempo está incluído. Para o paciente 1, por exemplo, qualquer cálculo no tempo $t = 9$ é parte do primeiro intervalo, $(0, 9+]$, e não do segundo. Além disso, quaisquer cálculos feitos em $t = 9$ devem utilizar as covariáveis conhecidas num tempo imediatamente anterior a 9 (ou seja, `recplac=0`).

Uma preocupação que pode surgir nesse caso – em que múltiplas linhas referem-se a um mesmo paciente, tais como as linhas 1 e 2 do paciente 1 – é que estas são correlacionadas e, portanto, os procedimentos usuais de estimação e inferência sobre parâmetros do modelo não poderiam ser utilizados. No entanto, como os intervalos de tempo definidos nas diferentes linhas de cada paciente são disjuntos, os resultados do modelo ajustado são inteiramente válidos. Isso porque o cálculo da verossimilhança parcial, que envolve a soma das observações de indivíduos sob risco num dado momento em que ocorre um evento, utilizará no máximo uma observação de cada paciente em qualquer momento. Ou seja, a soma ainda é feita sobre um conjunto de observações independentes. Para facilitar o entendimento, vejamos a Figura 8.1, que representa os dados de TMO para os cinco pacientes descritos anteriormente, com os tempos em que ocorrem eventos marcados com o símbolo $\times$ e as mudanças no valor das covariáveis indicados através de degraus nas linhas do tempo.

A linha vertical pontilhada no tempo de morte $t = 434$ para o paciente 3 indica que nenhuma das demais linhas dedicadas a esse




Figura 8.1: Representação gráfica dos dados de transplante de medula óssea para os cinco primeiros pacientes

paciente entrará no grupo de pacientes em risco naquele tempo, e no máximo uma única linha dos demais pacientes entrará no grupo em risco naquele tempo – a saber, a segunda linha do paciente 1 e a terceira do paciente 5. As covariáveis analisadas em cada momento serão, respectivamente, as da segunda linha do paciente 1 e da terceira do paciente 5, bem como da última linha do paciente 3. Os demais pacientes já estarão fora da análise.

A construção de bancos de dados com múltiplas linhas por indivíduo é simples quando o número de covariáveis variando no tempo é pequeno, mas pode tornar-se bastante complexa e sujeita a erros à medida que o número de covariáveis aumenta. Recomenda-se uma inspeção cuidadosa de diversas linhas do banco de dados criado, antes de iniciar qualquer análise. Para orientar a construção dos bancos de dados indicamos a leitura do roteiro disponível na página do livro: **criabanco.pdf**.

Exemplo

Para estudar os fatores de risco associados ao óbito em transplante de medula óssea, vamos ajustar um modelo de Cox estendido. Uma descrição mais detalhada do banco de dados encontra-se no Apêndice, seção Diálise – clássico e fragilidade.

```
> tmopc <- read.table("tmopc.csv",header=T,sep=";")
> #transformando as variáveis em fator
> tmopc$sexo<-factor(tmopc$sexo)
> tmopc$deag<-factor(tmopc$deag)
> tmopc$decr<-factor(tmopc$decr)
> tmopc$recplaq<-factor(tmopc$recplaq)
> tmopc$recplaq<-relevel(tmopc$recplaq,"1")
> tmo.cox <- coxph(Surv(inicio,fim,status)~idade+
  sexo+fasegr+deag+decr+recplaq,data=tmopc)
> tmo.cox
```

[...]

	coef	exp(coef)	se(coef)	z	p
idade	-0.0206	0.980	0.0140	-1.471	1.4e-01
sexo2	-0.1766	0.838	0.3093	-0.571	5.7e-01
fasegrOther	0.9266	2.526	0.3108	2.981	2.9e-03
deag1	1.0531	2.866	0.2917	3.610	3.1e-04
decr1	0.4370	1.548	0.3859	1.133	2.6e-01
recplaq0	1.9630	7.120	0.4671	4.203	2.6e-05

Likelihood ratio test=50.3 on 6 df, p=4.05e-09 n= 259,
number of events= 53

Cox estendido no R

A forma de estimar o modelo de Cox estendido é simples: utiliza-se o mesmo comando `coxph()` sendo agora o objeto sobrevivência gerado pela função `Surv()` formulado através do processo de contagem, ou seja, indica-se o início e o fim de cada período de acompanhamento.

```
> modelo <- coxph(Surv(inicio,fim,status) ~ x1+x2,
  data=dados)
> summary(modelo)
```

A interpretação dos coeficientes do modelo de Cox estendido é feita da mesma forma que nos modelos semiparamétricos usuais em que a exponencial do coeficiente estima a razão de riscos. No exemplo da TMO, através do teste de Wald, temos que *idade*, *sexo*, *decr* não têm efeito significativo, mas a fase da doença (*fasegr*), a presença de doença do enxerto aguda (*deag*) e a recuperação no número de plaquetas (*recplaq*) são significativas. O risco aumenta 2,5 e 2,8 vezes, respectivamente, para quem fez o transplante fora da primeira fase crônica da doença e para quem apresentou doença do enxerto aguda. Quem não recuperou o número de plaquetas, apresenta risco de morrer sete vezes maior.

Exemplo

Outro exemplo provém dos pacientes com Aids atendidos no Hospital Universitário Gaffrée Guinle/Unirio (HUGG). Para estudar o tempo de sobrevivência desde o diagnóstico de Aids até o óbito, o banco de dados foi organizado no formato descrito anteriormente: para cada mudança de tratamento, nova linha, mantendo-se as demais variáveis constantes: *sexo*, idade no início da doença (*idade*), escolaridade (*escol*). Observe que eventualmente as datas de início de uma linha não coincidem com a data final da linha anterior (paciente 323024), indicando que, naquele período, não havia informação sobre o paciente. Mais detalhes do estudo e do banco de dados estão disponíveis no Apêndice (seção Aids, terapia – mudança no tempo).

```
> muda <- read.table("gafcorr.dat", header=T)
> muda[47:54,]
```

reg	haart	ini	fim	sexo	escol	status	idade
32	N	665	804	F	Prim	1	36
33	S	1498	1820	M	Univ	0	76
33	S	2400	3297	M	Univ	0	76
34	N	686	3200	M	Sec	0	33
35	N	769	1577	M	Sec	0	30
35	S	1577	1597	M	Sec	1	31
36	S	3255	3297	F	Prim	0	52
37	N	1203	1341	M	Prim	1	31

Vamos então analisar o efeito da terapia antirretroviral de alta potência (Haart) na sobrevivência de Aids dos pacientes do HUGG.

```
> muda$escol<-relevel(muda$escol,"Univ")
> muda.cox <- coxph(Surv(ini,fim,status)~haart+idade+
  escol+sexo,data=muda)
> muda.cox
```

Call:

```
coxph(formula = Surv(ini, fim, status) ~ haart + idade + escol +
  sexo, data = muda)
```

	coef	exp(coef)	se(coef)	z	p
haartS	-0.7779	0.459	0.18508	-4.203	2.6e-05
idade	0.0185	1.019	0.00754	2.448	1.4e-02
escolAnalf	-0.2342	0.791	0.76547	-0.306	7.6e-01
escolGin	0.5364	1.710	0.32688	1.641	1.0e-01
escolPrim	0.7438	2.104	0.31075	2.394	1.7e-02
escolSec	0.3265	1.386	0.33905	0.963	3.4e-01
sexoM	0.2253	1.253	0.16929	1.331	1.8e-01

```
Likelihood ratio test=35.1 on 7 df, p=1.08e-05 n= 1377,
number of events= 184
```

A terapia Haart reduz o risco de óbito a menos da metade; para cada ano a mais de idade no momento de diagnóstico de Aids, o risco de morrer aumenta em 1,9%; comparando com o grau de instrução superior (Univ), o analfabetismo não implica aumento de risco, possivelmente por serem apenas 20 pacientes entre os 963 (30 registros ao todo); apenas escolaridade até a quarta série do ensino fundamental dobra o risco de morte por Aids se comparado com quem tem escolaridade superior; e não há diferença no tempo de sobrevivência por sexo.

A seleção de covariáveis no modelo e a inferência também são feitas da mesma forma que no modelo clássico de Cox, através da função desvio.

8.4 Diagnóstico do ajuste

Se um indivíduo com covariáveis mudando no tempo é representado usando a formulação de processos de contagem, tanto a definição quanto o cálculo dos resíduos de Schoenfeld, martingale e escore não diferem das que foram apresentadas no Capítulo 7.

8.4.1 Resíduos de Schoenfeld

Como os resíduos de Schoenfeld só são calculados para os tempos de ocorrência do evento, sua definição e cálculo ficam inalterados quando se utiliza o processo de contagem. Outra característica destes resíduos é o valor da covariável utilizado nos cálculos, que será aquele correspondente ao tempo ao final do qual ocorre o evento.

Note que a transformação *default* no R para a função do tempo no eixo das abscissas do gráfico de resíduos de Schoenfeld é a Kaplan-Meier, como visto no Capítulo 7. No caso da abordagem de processos de contagem, a escala, em geral utilizada, é o tempo propriamente dito. A justificativa para usar o tempo na escala do eixo das abscissas é que, sob o processo de contagem, em geral os eventos estão mais bem distribuídos ao longo do tempo porque seguem o tempo calendário, não havendo necessidade de uma transformação.

Resíduos de Schoenfeld do modelo de Cox estendido no R

Para calcular o resíduo de Schoenfeld com presença de covariáveis mudando no tempo, utilizamos o mesmo comando `cox.zph()` acrescentando o argumento `transform="identity"` para mudar a escala do eixo das abscissas para o tempo propriamente dito, ao invés do Kaplan-Meier (valor *default*).

```
> resíduo.sch <- cox.zph(modelo, transform="identity")
```

Para fazer os gráficos dos resíduos contra cada um dos parâmetros do modelo, ver p. 219.

Exemplo

Retornando ao exemplo dos pacientes do transplante de medula óssea, na Figura 8.2 pode-se observar que os intervalos em torno dos resíduos aumenta para os tempos mais longos, devido ao pequeno número de observações. Nenhuma das covariáveis, na verdade, tem o valor estimado de β fora dos intervalos de confiança da suavização *spline* dos resíduos. Entretanto, se eliminássemos as duas observações com tempos muito longos, é provável que a variável **sexo** apresentasse efeito não proporcional ao longo do tempo. Além disso, o teste de correlação da variável **sexo** com o tempo (*cox.zph*) apresenta p-valor próximo de 0,055 sugerindo não proporcionalidade. As demais covariáveis não têm efeito variando ao longo do tempo, apesar de estarem todas muito influenciadas pelo último ponto do gráfico. Temos então que as variáveis mudando no tempo *deag*, *decr* e *recplaq*, apesar de mudarem seus valores, têm efeito constante ao longo do tempo. Essa conclusão pode ser confirmada pelo teste com hipótese nula de que a correlação é igual a zero entre as variáveis e o tempo. Para continuar a análise deve-se reajustar os modelos retirando os pontos indicados.

```
> tmo.sch <- cox.zph(tmo.cox, transform="identity")
> tmo.sch
```

	rho	chisq	p
idade	-0.08369	0.41389	0.5200
sexo2	-0.25846	3.67790	0.0551
fasegr0ther	0.04967	0.16535	0.6843
deag1	-0.03694	0.06742	0.7951
decr1	0.01235	0.00958	0.9220
recplaq0	0.00507	0.00177	0.9665
GLOBAL	NA	4.41245	0.6210

Exemplo

Para o modelo ajustado aos dados de Aids (*muda.cox*), a análise dos resíduos de Schoenfeld é apresentada nas Figuras 8.3 e 8.4. Exceto para o tratamento, única variável a mudar no tempo, os resíduos de




Figura 8.2: Resíduos de Schoenfeld para o modelo `tmo.cox`

Schoenfeld sugerem proporcionalidade dos riscos. Essa observação é confirmada testando-se a hipótese nula de correlação entre as variáveis e o tempo de sobrevivência. Observe que somente a covariável tratamento não atende à premissa de proporcionalidade.

```
> muda.sch <- cox.zph(muda.cox,transform="identity")
> muda.sch
```

	rho	chisq	p
haartS	-0.26583	16.70605	4.36e-05
idade	0.00627	0.00775	9.30e-01
escolAnalf	-0.12455	2.86745	9.04e-02
escolGin	-0.12721	3.03844	8.13e-02
escolPrim	-0.07071	0.96321	3.26e-01
escolSec	-0.10421	2.03111	1.54e-01
sexoM	0.12002	2.94786	8.60e-02
GLOBAL	NA	24.41845	9.62e-04

8.4.2 Resíduos martingale

Os resíduos martingale podem ser calculados para cada um dos n indivíduos, ou para cada um dos $m > n$ registros que consistem em períodos de tempo onde não há mudança de covariável. Para gráficos dos resíduos contra índice ou contra uma covariável fixa no conjunto de dados, pode-se obter um valor de resíduo único para cada indivíduo. O resíduo total de um indivíduo será dado pela soma dos resíduos das observações daquele indivíduo nos diferentes intervalos de tempo.

Exemplo

No exemplo da TMO, a variável de identificação dos indivíduos é *id*. A análise de resíduos por registro, que permite verificar a forma funcional da uma variável contínua mudando ao longo do tempo, por exemplo, uma contagem de células CD4 ou uma dosagem bioquímica não pode ser feita nesse estudo, pois não temos este tipo de variável. Assim serão apresentados os resíduos para cada indivíduo.




Figura 8.3: Gráfico dos resíduos de Schoenfeld para as covariáveis tratamento (*haart*), idade e *sexo* do modelo *muda.cox*




Figura 8.4: Gráfico dos resíduos de Schoenfeld para a covariável escolaridade (*escol*) do modelo *muda.cox*

```

> tmo.mar <- resid(tmo.cox,type="martingale",collapse=tmo.cox$id)
> # martingale contra índice
> plot(tmo.mar,xlab="Índice", ylab="Resíduo", main="(a)")
> abline(h=0,lty=2)
> # modelo nulo contra covariável fixa
> #vetor idade com um único registro da idade por paciente
> idade <- tmo.cox$idade[!duplicated(tmo.cox$id)]
> tmo.nulo <- coxph(Surv(inicio,fim,status)~1,data=tmo.cox)
> res.mar <- resid(tmo.nulo,type="martingale",collapse=tmo.cox$id)
> plot(idade,res.mar,xlab="Idade",ylab="Resíduo", main="(b)")
> lines(lowess(idade,res.mar,iter=0),lty=2)

```

Na Figura 8.5 apresentamos os resíduos de martingale colapsados por indivíduo. No quadro (a), os resíduos do modelo `tmo.cox` ajustado anteriormente contra o índice dos indivíduos devem estar distribuídos uniformemente acima e abaixo da linha do zero, sem qualquer padrão detectável, como na figura, indicando que o modelo está bem ajustado. O quadro (b), dos resíduos do modelo nulo contra a idade, pode contribuir para identificar a forma funcional da variável. Neste exemplo, a linha pontilhada é praticamente zero, apresentando um caimento somente para pacientes mais velhos. Eventualmente, uma covariável cujo resíduo martingale sugira uma forma funcional parabólica, por exemplo, pode ter efeito não significativo, pois, entre associação positiva e negativa nos pontos extremos da variável, na média o efeito é zero. Por isso, mesmo no caso de covariáveis com efeito nulo, a forma funcional deve ser investigada.

Para as covariáveis que mudam ao longo do tempo, o gráfico dos resíduos do modelo nulo contra a covariável deve ser feito sem agrupar os resíduos por indivíduo, até porque não haveria um único valor de covariável para os indivíduos com tal covariável mudando no tempo. No R basta retirar da função `resid()` o argumento `collapse`, ficando assim:

```

> resid(modelo, type="martingale")

```




Figura 8.5: Gráfico dos resíduos de martingale (a) para o modelo `tmo.cox` contra índice (b) para o resíduo do modelo nulo contra idade

Resíduos martingale do modelo de Cox estendido no R

A função para calcular o resíduo martingale, quando há covariáveis mudando no tempo, é a mesma utilizada no modelo de Cox:

```
> res<-resid(modelo,type="martingale")
```

retornando um resíduo para cada linha do banco de dados. Caso o objetivo seja calcular um único resíduo para cada indivíduo, é indispensável acrescentar o argumento `collapse=dados$id` da seguinte forma:

```
> res<-resid(modelo,type="martingale",collapse=dados$id)
```

em que `id` é a variável de identificação dos indivíduos no banco de dados.

Observação: Caso haja valores omissos em alguma das covariáveis incluídas no modelo, o R elimina automaticamente as linhas do banco de dados com `NA`. Entretanto, para calcular os resíduos de martingale por indivíduo, essas linhas devem ser retiradas do banco **antes** da estimação do modelo, assim:

```
> #para retirar valores omissos das covariáveis x1, x2
> dados2 <- dados[complete.cases(dados[,c("x2", "x3")]),]
> modelo <- coxph(Surv(ini,fim,status)~x1+x2+x3,
  data=dados2)
> res <- resid(modelo,type="martingale",collapse=dados2$id)
```

8.4.3 Resíduos escore

Os resíduos escore são utilizados para identificar pontos influentes no modelo. Aqui, como nos resíduos martingale, haverá tantos resíduos escore quantas observações no banco de dados. No caso de covariável que não muda no tempo, podemos calcular os resíduos escore por indivíduo.

Exemplo

Calculando os resíduos escore do modelo `tmo.cox` para variáveis fixas, temos:

```
> tmo.score <- resid(tmo.cox,type="dfbetas",collapse=tmopec$id)
> indice <- !duplicated(tmopec$id)
> plot(tmopec$idade[indice],tmo.score[,1],
      xlab="Idade",ylab="Resíduos")
> plot(tmopec$sexo[indice],tmo.score[,2],
      xlab="Sexo",ylab="Resíduos")
> plot(tmopec$fasegr[indice],tmo.score[,3],
      xlab="Fase",ylab="Resíduos")
```

Observe o comando `!duplicated`. O ponto de exclamação indica **não**, ou seja, não duplicado. Para as variáveis que mudam ao longo do tempo, temos:

```
> tmoobs.score <- resid(tmo.cox,type="dfbetas")
> plot(tmopec$deag,tmoobs.score[,4],
      xlab="Doença Crônica",ylab="Resíduos")
> plot(tmopec$decr,tmoobs.score[,5],
      xlab="Doença Aguda",ylab="Resíduos")
> plot(tmopec$recplaq,tmoobs.score[,6],
      xlab="Rec. Plaquetária",ylab="Resíduos")
```

A Figura 8.6 apresenta os gráficos dos resíduos de escore para o modelo `tmo.cox`. Os únicos gráficos de resíduos agrupados por indivíduos são para as covariáveis idade, sexo e fase. Para idade não observamos qualquer padrão. Nos demais gráficos, ainda que aparentemente com pontos distoantes, nenhum ultrapassa o intervalo $(-0,5, 0.5)$, o que é pouco, uma vez que os resíduos são padronizados.

Resíduos escore do modelo de Cox estendido no R

A função para calcular o resíduo escore, quando há covariáveis mudando no tempo, é a mesma utilizada no modelo de Cox:

```
> res<-resid(modelo,type="dfbetas")
```

O comando acima retorna um resíduo para cada observação no banco de dados. Caso o objetivo seja calcular um resíduo para cada indivíduo, basta acrescentar o argumento `collapse=dados$id` da seguinte forma:

```
> res<-resid(modelo,type="dfbetas",collapse=dados$id)
```

em que `dados$id` é o vetor de identificação dos indivíduos.

8.5 Dados prevalentes

O uso de intervalos de tempo para o caso de covariáveis mudando no tempo é simplesmente um mecanismo (ou artifício) que permite aos programas estatísticos selecionar os valores corretos das covariáveis para cada indivíduo em um dado tempo. Esse mesmo mecanismo também permite o tratamento de dados prevalentes.

Duas abordagens são possíveis para representar adequadamente o momento em que o indivíduo entra em observação e passa a compor o grupo de risco, e, conseqüentemente, o momento do evento. A primeira é usar o tempo calendário, tendo como data de referência t_0 a data mais antiga no banco de dados e, a partir desta, calcular o tempo de entrada na coorte de cada indivíduo. Assim, cada indivíduo será incluído na coorte em sua janela temporal. Outra forma é considerar que todos começam a ser observados no seu tempo zero específico, mas o momento de entrada no modelo é o início do acompanhamento.

Observe na Figura 8.7 as duas formas de organizar o mesmo dado. No quadro de cima, o tempo inicial de contagem respeita o calendário. O fundo cinza indica a janela temporal de observação.




Figura 8.6: Resíduos escore para o modelo *tmo.cox*

No quadro inferior, exatamente com o mesmo dado, o tempo inicial de cada paciente é o seu tempo de início da diálise. Assim, os casos incidentes começam sempre no tempo 1, e os casos prevalentes serão analisados a partir do momento em que entraram em observação – na figura, indicado com um traço vertical (┆). Os indivíduos com todo tempo assinalado em linha tracejada são os indivíduos excluídos da análise, pois sofreram o evento antes do início do acompanhamento.

Observe que a população de comparação muda dependendo da estratégia adotada. No quadro inferior, a linha vertical tracejada a partir do evento do indivíduo B mostra apenas um outro paciente vivo no mesmo momento, enquanto no quadro superior, diversos pacientes com tempos de sobrevivência menores estão em risco dentro da janela temporal analisada.

A escolha da estratégia depende do que se deseja avaliar. Se o objetivo é analisar fatores de risco individuais, a melhor estratégia é utilizar o tempo de sobrevivência de cada indivíduo, como o apresentado no quadro inferior. Se o objetivo é estudar algum fator que está presente para todos os que foram observados no mesmo momento, por exemplo, novas técnicas terapêuticas ou serviços de saúde utilizados pelos participantes simultaneamente, a melhor opção é adotar o tempo calendário (quadro superior). Essa será a estratégia adotada para estimar o risco comum aos vários pacientes de um mesmo centro de diálise, em um mesmo período de tempo, como desenvolvido no Capítulo 12.

Seja qual for o objetivo, o tempo total de observação não deve ser usado, pois não permite corrigir o viés gerado pelo uso de dados prevalentes. Evidentemente a forma de interpretar os efeitos é condicional – dado que o indivíduo sobreviveu até entrar em observação.

Exemplo

Um conjunto de pacientes em hemodiálise é acompanhado por 44 meses (Apêndice, seção Diálise – clássico e fragilidade). Para estudar o impacto dos dados prevalentes, utilizamos esse exemplo truncando o dado, ou seja, analisando como se somente tivéssemos acompanhado




Figura 8.7: Dados prevalentes: o quadro superior mostra a janela temporal (tempo calendário) e o inferior o tempo de diálise de cada indivíduo. O indivíduo **A** foi excluído pois não sobreviveu até o início da coorte; **B** foi censurado à direita, considerando-se apenas o período de observação através do uso de processo de contagem; **C**, como é caso incidente, pode ser analisado respeitando a janela temporal (quadro superior) ou o tempo de diálise (quadro inferior)

a partir do vigésimo mês. O banco de dados a utilizar está no arquivo *dialise.csv*. A hipertensão (*hip*) será considerada categoria de base para as causas da insuficiência renal (covariável *causa*). Para truncar o tempo de sobrevivência, eliminamos primeiramente todas as observações que sofreram o evento ou foram censuradas até o mês 21. Ou seja, a base de dados completa tem 6.805 observações e a base de dados truncada possui 5.891. Para analisar o tempo de sobrevivência foram criadas duas novas variáveis para representar o início do tempo: *inijanela* e *inittto*. A primeira indica o momento em que cada indivíduo entra na coorte, respeitando a ordem dessa entrada (tempo calendário). A segunda indica o momento em que os casos prevalentes entraram na coorte, de forma a incluir somente o período de observação. Para os casos incidentes essa variável toma valor igual a 1 (início do tratamento). Nesses casos, o tempo final também foi recalculado, de forma a ficar com o valor correto do tempo total em diálise (variável *fimttto*).

```
> dialise <- read.csv("dialise.csv")
> dialise$causa <- relevel(dialise$causa, "hip")
> dialtrunc <- dialise[dialise$fim>21,]

> dim(dialise);dim(dialtrunc)

[1] 6805  11
[1] 5891  11

> dialtrunc$inijanela <- ifelse(dialtrunc$inicio<22,21,
  dialtrunc$inicio)
> dialtrunc$inittto <- ifelse(dialtrunc$inicio>20,1,
  dialtrunc$inijanela)
> dialtrunc$fimttto <- ifelse(dialtrunc$inicio>20,
  dialtrunc$fim-dialtrunc$inicio+1,dialtrunc$fim)
```

A seguir encontra-se a sintaxe dos diversos modelos estimados no R cujo resultados estão sumarizados na Tabela 8.1.

```
> # modelo com dado completo - tempo total
> summary(coxph(Surv(tempo,status) ~ idade + causa,
```

```

data=dialise))

> # modelo com dado completo - tempo calendário
> summary(coxph(Surv(inicio,fim,status) ~ idade + causa,
  data=dialise))

> # modelo com dado truncado - tempo total
> summary(coxph(Surv(tempo,status) ~ idade + causa,
  data=dialtrunc))

> # modelo com dado truncado - tempo de dialise
> summary(coxph(Surv(inittto,fimttto,status) ~ idade + causa,
  data=dialtrunc))

> # modelo com dado truncado - tempo calendario
> summary(coxph(Surv(inijanela,fim,status) ~ idade + causa,
  data=dialtrunc))

```

Observe que sendo todos casos incidentes, pode-se utilizar o tempo total de diálise. O tempo calendário só seria interessante se houvesse mudança de covariável ou interesse em tratar algum aspecto comum aos indivíduos em determinado momento.

Todos os modelos com dados truncados apresentaram uma maior redução no risco de morrer por doença congênita se comparado com resultados dos modelos que utilizam todos os dados. São poucos os casos de pacientes com doença congênita (somente 142 pacientes no banco completo), e qualquer diminuição no tempo de observação de alguns pacientes se reflete na estimativa.

Por outro lado, as três abordagens para dados truncados apresentaram resultados muito semelhantes. Na verdade, o risco de viés existe, mas considerando o número total de indivíduos e de eventos, o uso de dados prevalentes não afetou de forma importante as estimativas. Ainda assim, é recomendável que na presença de dados truncados se utilize a abordagem por processo de contagem.

8.6 Intervalos de tempo descontínuos

Não são raras as ocasiões em que, por diversas razões, certos indivíduos deixam de estar em risco por alguns períodos no decorrer do

Tabela 8.1: Razões de risco estimadas pelo modelo de Cox para dados prevalentes utilizando três abordagens: tempo calendário, tempo de diálise e tempo total de cada indivíduo

Covariável	Dados completos		Dados truncados		
	Tempo total	Calen- dário	Tempo total	Tempo em diálise	Calen- dário
Idade	1,04*	1,04*	1,04*	1,04*	1,04*
Causa:					
Congênita	0,49*	0,47*	0,51*	0,56*	0,53*
Diabetes	1,34*	1,38*	1,34*	1,32*	1,35*
Outras	1,04	1,07	1,04	1,02	1,05
Renal	1,04	1,04	1,07	1,09	1,09

*p-valor < 0, 05

estudo. Suponhamos um estudo sobre efeitos colaterais graves de um medicamento, em que por algum motivo há interrupção do tratamento. Durante esse período o indivíduo não está sob risco observável de sofrer o evento em estudo, logo deve sair do grupo de risco. Também é causa de perda temporária de seguimento o afastamento de um paciente, por exemplo, por viagem, retornando posteriormente. Como durante o período do afastamento ele não foi acompanhado, caso o evento ocorresse não teríamos a informação. Logo, não podemos incluir esse intervalo de tempo no conjunto de indivíduos do estudo em risco. Ainda outro exemplo ocorre em estudos com eventos múltiplos, em que ao longo da duração de um evento o paciente está temporariamente protegido de um novo evento (esse tema será tratado em detalhes no Capítulo 10).

O problema de descontinuidade também ocorre na ausência de informações sobre uma covariável fundamental por um período, pois o registro deste período não será incluído na análise (dados faltantes). Por qualquer dessas razões, o resultado é o mesmo: o indivíduo fica afastado do estudo por um ou mais períodos de tempo. A forma de tratar o problema é simples: retira-se o indivíduo do conjunto de observações em risco naquele(s) intervalo(s) de tempo em particular, seja retirando as linhas correspondentes aos períodos

sem informação do conjunto de dados ou simplesmente usando um indicador de dados perdidos (representado por **NA** no R) no lugar das informações faltantes. Portanto, assim como covariáveis mudando no tempo e dados prevalentes, o mecanismo de intervalos de tempo também permite tratar adequadamente dados de indivíduos com acompanhamento descontínuo no decorrer do estudo.

Resumo

O modelo de Cox estendido, utilizando-se processo de contagem, permite analisar variáveis mudando no tempo, dados prevalentes e descontinuidade no período de acompanhamento. A seleção de variáveis e a análise de resíduos são semelhantes às do modelo de Cox clássico visto nos Capítulos 6 e 7, respectivamente.

A principal questão é montar o banco de dados após identificar adequadamente:

- o **tempo inicial** do acompanhamento de cada indivíduo ou o que define mudança no valor da covariável;
- o **tempo final**, seja do acompanhamento, seja por mudança no valor da covariável;
- o **status** em cada período entre mudanças de covariável e ao final do acompanhamento do indivíduo.

Exercícios

Recomenda-se que o leitor revise o conceito de processo de contagem e sua representação gráfica, apresentados no Capítulo 2.

8.1 Em um estudo de sobrevivência de pacientes infectados pelo HIV, uma covariável importante é o momento em que a contagem

de células CD4 decresce abaixo de 200. Esse é um critério utilizado para classificar o indivíduo portador de HIV como caso de Aids. A tabela abaixo mostra um trecho do banco de dados que resultaria de um estudo como esse, com desfecho óbito, onde *id* é o identificador do paciente e *CD4* é um indicador do nível de CD4 (*CD4*=0, quando a contagem está acima de 200 e, *CD4*=1, quando a contagem está abaixo de 200).

<i>id</i>	<i>início</i>	<i>fim</i>	<i>status</i>	<i>CD4</i>
1	25	323	0	0
1	324	768	1	1
2	39	130	0	0
2	131	345	0	1
3	1	56	0	0
3	131	145	1	1

Com base nesses dados, descreva em palavras o que aconteceu com cada um dos três pacientes ao longo do período de acompanhamento.

8.2 O tipo de tratamento empregado na terapia de um paciente com Aids pode ser considerado uma covariável tempo-dependente. Considerando quatro tipos possíveis de terapia (0 = sem antirretrovirais; 1 = monoterapia, 2 = terapia combinada, 3 = terapia potente), pode-se observar o seguinte conjunto de dados:

id	início	fim	status	terapia
1	2	124	0	0
1	124	213	0	1
1	213	230	1	3
2	21	210	1	3
3	17	56	0	0
3	56	99	0	1
3	99	154	0	2
3	154	255	1	3

- (a) Com base nesses dados, descreva em palavras o que aconteceu com cada paciente ao longo do período de acompanhamento.
- (b) Acrescente linhas à tabela acima para incorporar as informações do paciente 4, que entrou na coorte no dia 61, quando passou a ser tratado com a monoterapia. No dia 367 do estudo, ele muda para a terapia combinada, no dia 401 muda para a terapia potente, e vem a falecer no dia 460.
- (c) Faça o mesmo para o paciente 5, que entrou na coorte no dia 100 e veio a receber seu primeiro tratamento antirretroviral (monoterapia) no dia 221. Dois meses depois, no dia 281, ele passa para a terapia potente e falece no dia 306.
- (d) Por fim, acrescente o paciente 6, que entrou na coorte no dia 47 recebendo monoterapia e passou para terapia combinada no dia 105. Esse paciente saiu da coorte, ou seja, houve perda de seguimento, no dia 223.
- (e) Considere agora que esses seis pacientes do banco devem ser analisados como sendo dados prevalentes. Que alterações o banco deve sofrer?

- (f) Considere ainda que o paciente 2 esteve um período afastado do estudo: após 100 dias de acompanhamento ele interrompeu o uso da terapia prescrita. Como representar essa trajetória no banco de dados?

8.3 O banco *tmopc.csv* traz os dados do transplante de medula óssea com variáveis tempo dependentes, já estruturado no formato de processo de contagem (veja no Apêndice.12.4 o significado das variáveis).

- (a) Liste as primeiras 20 linhas.
- (b) Descreva, em palavras, o que aconteceu com os pacientes 5, 6 e 7.
- (c) Acrescente linhas nesse banco de dados que correspondem a um paciente que não desenvolveu nenhuma doença enxerto, recuperou as plaquetas 10 dias após o transplante e saiu da coorte no dia 3.789 (perda de seguimento).
- (d) Faça o mesmo para um paciente que desenvolveu doença enxerto aguda no dia 20 e faleceu 10 dias depois, sem ter recuperado as plaquetas.
- (e) Idem para um paciente que recuperou as plaquetas no dia 8, mas desenvolveu doença enxerto aguda no dia 31, depois desenvolveu a crônica no dia 210 e faleceu no dia 520.

8.4 Continuando a análise iniciada no exercício anterior:

- (a) Ajuste quatro modelos explicativos para a sobrevivência após transplante de medula óssea, tratando adequadamente as covariáveis tempo-dependentes (*recplaq*, *deag* e *decr*):

Modelo 1: *idade + sexo*

Modelo 2: Modelo 1 + *recplaq*

Modelo 3: Modelo 2 + *deag*

Modelo 4: Modelo 3 + *decr*

- (b) Interprete os parâmetros dos modelos.
- (c) Compare os quatro modelos utilizando o teste da razão de verossimilhanças através do comando `anova()`. Qual modelo deve ser selecionado e por quê?
- (d) Faça o diagnóstico do modelo selecionado, verificando os pressupostos e avaliando os resíduos de Schoenfeld e martingale. O pressuposto de proporcionalidade foi atendido por todas as covariáveis? Há observações mal ajustadas?

Dicas

- Leia o banco e transforme as variáveis não numéricas em fator.
- Os modelos de Cox estendidos são ajustados da mesma forma já vista. A modelagem é direta quando se usa a estrutura do banco de dados no formato de processo de contagem (`Surv(inicio,fim,status)`).
- A seleção de covariáveis no modelo e a inferência também são feitas da mesma forma que no modelo clássico de Cox, usando o teste da razão de verossimilhanças: `anova(modelo1,modelo2,...)`.
- Também a análise de resíduos é semelhante. Veja as dicas nos exercícios do capítulo anterior.

8.5 Refaça a análise de sobrevivência em Aids dos pacientes atendidos no HUGG/Unirio que está apresentada no texto (dados no arquivo *gafcorr.dat* – Apêndice.12.4).

- (a) Leia, organize, explore os dados e descreva o que aconteceu com o paciente 35.
- (b) Ajuste um modelo de sobrevivência e analise os resultados encontrados.
- (c) Faça o diagnóstico do modelo.

9

Funções de suavização em modelos de sobrevivência

Coautor: *Geraldo Marcelo Cunha*

O objetivo deste capítulo é capacitar o leitor a:

Avaliar a forma funcional de covariáveis no modelo de sobrevivência

Identificar situações nas quais o uso de função de suavização é indicado.

Ajustar e interpretar modelo de sobrevivência com termo de suavização *spline*.

Avaliar o ajuste de modelo com função de suavização.

9.1 Introdução

Médicos intensivistas estão colocados diariamente frente a decisões sobre admitir pacientes, suspender terapias de suporte que já não mais funcionam, escolher quem será internado na Unidade de Terapia Intensiva (UTI) quando não há leitos para todos. Muitas dessas decisões baseiam-se em estudos de sobrevivência dos pacientes, que contribuem para que se tome decisões da forma mais honesta e objetiva possível.

Os pacientes assistidos no Instituto Nacional de Câncer (Inca) podem ser admitidos, caso necessário, na UTI dessa unidade, que conta com 10 leitos e admite anualmente cerca de 500-600 pacientes. Para ser admitido na UTI, os pacientes devem ter uma chance de cura ou de remissão do câncer. Um estudo analisou 1.863 pacientes internados durante 4 anos nessa UTI. Foram analisados todos os pacientes internados por mais de 24 horas por causas clínicas, exceto síndrome coronariana aguda. Dado o limitado número de leitos, dentre os vários aspectos que são avaliados nas condições clínicas dos pacientes, a idade é um componente importante, pois os mais jovens tem, em geral, maiores chances de sobreviver.

O objetivo deste estudo foi avaliar o comportamento da idade no tempo de sobrevivência sem, *a priori*, fazer suposições a respeito de como essa covariável afeta o tempo de sobrevivência. Esta abordagem parece coerente se esperamos que o efeito da idade não seja o mesmo ao longo de toda a vida. É comum o risco se manter constante até uma certa idade, e depois aumentar. É o caso, por exemplo, do risco de infarto agudo do miocárdio em mulheres, que muda de comportamento após a menopausa.

As soluções mais frequentes na literatura para modelagem dos dados, nesse caso, são particionar ou transformar a covariável que não apresente efeito linear com o log da função risco. No primeiro caso, a covariável é dividida em classes, e a escolha dessas classes é baseada em pontos de corte comuns da literatura da área ou que expressam medidas de dispersão, por exemplo, percentis. Esta alternativa é a mais usual nos artigos da área da saúde. Raramente

a idade, a renda ou o índice de massa corporal são utilizados como covariáveis contínuas nos modelos de regressão. Nossa crítica é que, ao basear-se em pontos de cortes já estabelecidos na literatura, ou em quartis, podemos reproduzir uma aproximação inadequada do efeito desta covariável no risco. A informação sobre essa associação passa a ser também limitada, uma vez que estamos perdendo informação ao particionar uma covariável.

Outra forma de tratar o efeito não constante de uma covariável é transformá-la, por exemplo, elevando-a ao quadrado ou considerando seu logaritmo. Embora uma transformação como a logarítmica possa ser útil, tornando a relação linear e, conseqüentemente, o efeito constante, a maioria das transformações causa problemas de interpretação. Por exemplo, em uma regressão linear, considerando uma transformação como o inverso da idade, qual seria o significado do coeficiente associado, estimado em $-1,3$ no ganho de peso? Para cada ano⁻¹, perde-se 1,3kg. Mas o que é inverso de um ano?

Neste capítulo, apresentamos uma abordagem semiparamétrica através da inclusão de funções de suavização, permitindo que a relação entre uma ou mais covariáveis e riscos associados seja estimada da maneira mais flexível possível, respeitando sua forma funcional. A literatura apresenta diferentes metodologias de ajustar funções não paramétricas, tais como a regressão kernel de Nadaraya-Watson, a regressão linear local ponderada (*lowess*) e as funções *spline*. O ponto comum desses métodos é que seus estimadores pertencem à mesma classe de estimadores conhecida como estimadores lineares. Essencialmente, esses estimadores atuam ajustando uma função localmente ao longo do suporte da covariável que se supõe ter um associação não linear com o desfecho.

9.2 Modelo de Cox estendido

O modelo proposto neste capítulo é uma extensão do modelo de Cox:

$$\lambda(t) = \lambda_0(t) \exp(\mathbf{x}\boldsymbol{\beta} + s(z)), \quad (9.1)$$

sendo $\lambda_0(t)$ o risco basal e $\mathbf{x}$ o vetor das covariáveis que assumem forma funcional loglinear, ou seja, linear com $\log(\lambda)$. Para simplificar, colocamos apenas uma covariável z que não assume essa forma funcional loglinear e que será ajustada através da função de suavização $s(\cdot)$.

A interpretação dos coeficientes β é simples e foi exaustivamente discutida no Capítulo 6. Os parâmetros da função de suavização $s(\cdot)$, entretanto, não possuem uma interpretação direta, sendo necessário o uso de recursos gráficos para descrever a relação entre z e o risco $\lambda(t)$.

As duas seções a seguir descrevem a regressão linear local ponderada (*locally weighted scatterplot smoothing – lowess*) e o ajuste por *spline*. Para facilitar a compreensão, vamos apresentá-lo de forma genérica no contexto de modelos de regressão, entre os quais o modelo de sobrevivência apresentado em (9.1) é um caso particular.

Apresentaremos mais detalhadamente os *splines* de suavização, por possuírem algumas propriedades interessantes e já estarem implementadas no R para análise de dados de sobrevivência. Eventualmente utilizaremos o *lowess* para auxiliar a interpretação dos gráficos de resíduos, em especial para avaliar e descrever a forma funcional de uma covariável, através do resíduo de martingale. O leitor que tenha maior interesse na formalização destes métodos poderá consultar Wasserman (2006).

9.3 Lowess

Três conceitos são essenciais na compreensão desse método:

- **vizinhança** – pois temos um ajuste **local**;
- **ponderação** – definida em função da distância entre o ponto para o qual se deseja estimar um valor suavizado e as observações vizinhas;
- **regressão** – expressa a forma da relação entre z e y dentro da vizinhança.

A função de regressão pode ser um polinômio de grau 1 (linear), de grau 2 (quadrática) ou de grau zero quando temos uma média móvel.

Os passos para estimar uma suavização por *lowess* no ponto z_0 são:

1. definir a **largura de banda** h , que será a vizinhança do ponto z_0 ;
2. identificar os pontos que pertencem a essa vizinhança de z_0 ;
3. atribuir pesos para cada ponto da vizinhança de z_0 através de uma função k , chamada *kernel*;
4. calcular o valor suavizado de z_0 , $s(z_0)$ através da estimação por mínimos quadrados ponderados para a regressão adotada dentro da vizinhança.

As funções kernel são usualmente simétricas e dependem da largura de banda h . Entre as várias possibilidades, as formas tricúbica e gaussiana para o kernel são muito utilizadas. A escolha da forma da função de ponderação na verdade afeta pouco a suavização final estimada. Por outro lado, a largura de banda h é muito importante para controlar o grau de suavização da curva. Considerar uma largura de banda grande, por exemplo, cobrindo mais de 80% dos possíveis valores de z faz com que a curva final ajustada seja muito suave, quase uma reta. Por outro lado, uma largura de banda pequena leva a um ajuste final muito rugoso, como pode ser visto na Figura 9.1, baseada em um pequeno conjunto de dados apresentados na Tabela 9.1. Observe que larguras de banda menores fazem a curva ajustada “perseguir” os pontos de forma mais próxima, embora eventualmente gerem quebras pouco suaves, como pode ser observado nas linhas tracejadas do gráfico.

Como, em geral, o parâmetro que define a largura de banda não é estimado pelo modelo, a escolha desse valor deve seguir algum critério razoável. Por exemplo, ajustando uma função para suavizar a relação entre idade e índice de massa corporal, podemos pensar em uma largura de banda que esteja entre 5 e 10 anos, pois esse é um




Figura 9.1: Suavização *lowess* com diferentes larguras de banda

Tabela 9.1: Conjunto de dados para exemplificar funções de suavização

	z	y		z	y		z	y
[1,]	1	1	[7,]	7	6	[13,]	13	8
[2,]	2	2	[8,]	8	5	[14,]	14	10
[3,]	3	3	[9,]	9	4	[15,]	15	10
[4,]	4	5	[10,]	10	3	[16,]	16	10
[5,]	5	4	[11,]	11	4	[17,]	17	10
[6,]	6	7	[12,]	12	6	[18,]	18	10

intervalo razoável para detectar inflexões no ganho de peso. No final deste capítulo descrevemos o método de validação cruzada que pode ser utilizado para a obtenção desse valor a partir dos dados.

9.4 *Spline*

O termo *spline* se refere a um tipo particular de função de suavização, definida como polinômios segmentados (*piecewise*). Novamente, temos janelas e curvas ajustadas, mas nesse caso com uma importante restrição: cada curva parcial se une à seguinte de forma suave, sem ângulos. Para entender melhor, retomemos o mesmo conjunto simples de dados da Tabela 9.1. A definição dos segmentos no caso do *spline* é dada através de **nós**. A Figura 9.2 considera um *spline* cúbico com dois nós, representados por ξ_1 e ξ_2 .




Figura 9.2: Polinômios segmentados de grau 3 (*spline* cúbico) ajustado com dois nós

Os polinômios mais utilizados na suavização *spline* são funções cúbicas, pela sua grande flexibilidade.

No exemplo, os nós definem um *spline* cúbico da seguinte forma. Sejam as funções de base $h_1(z) = 1$, $h_2(z) = z$, $h_3(z) = z^2$

e $h_4(z) = z^3$. Qualquer polinômio de grau 3 pode ser escrito como combinação linear dessas funções de base. Um *spline* cúbico, nesse caso, ajustará três polinômios de grau 3: um no intervalo abaixo de ξ_1 , um no intervalo entre ξ_1 e ξ_2 e um terceiro polinômio no intervalo acima de ξ_2 .

O problema em ajustar estes três polinômios separadamente é que não temos como garantir a continuidade nos nós ξ_1 e ξ_2 . Para solucionar este problema, definimos funções adicionais para compor a base: $h_5(z) = (z - \xi_1)_+^3$ e $h_6(z) = (z - \xi_2)_+^3$, sendo:

$$(z - \xi)_+^3 = \begin{cases} (z - \xi)^3, & \text{se } z > \xi; \\ 0, & \text{caso contrário.} \end{cases}$$

Finalmente o *spline* cúbico é dado pela combinação linear dessas funções da base:

$$s(z) = \sum_{j=1}^6 \beta_j h_j(z),$$

em que os polinômios são:

$$s(z) = \begin{cases} \beta_1 + \beta_2 z + \beta_3 z^2 + \beta_4 z^3, & \text{se } z \leq \xi_1; \\ \beta_1 + \beta_2 z + \beta_3 z^2 + \beta_4 z^3 + \beta_5 (z - \xi_1)^3, & \text{se } \xi_1 < z \leq \xi_2; \\ \beta_1 + \beta_2 z + \beta_3 z^2 + \beta_4 z^3 + \beta_5 (z - \xi_1)^3 + \beta_6 (z - \xi_2)^3 & \\ \text{se } z > \xi_2. \end{cases}$$

O objetivo final é estimar os coeficientes β_j através de algum critério de penalidade. Partimos então de uma suavização *spline* cúbico com os nós sendo definidos como cada um dos pontos de dados observados. Ou seja, no exemplo anterior teríamos 18 nós, todos conectados através de um polinômio cúbico. Nesse caso teríamos uma interpolação suave e perfeita sobre os dados observados. Porém, passar por todos os pontos não ajuda a identificar o padrão da associação

que se está buscando. É o equivalente ao “*overfitting*”, ou ao ajuste de uma regressão tendo como variável independente todos os indivíduos: ajuste perfeito, mas nenhum conhecimento gerado.

O que de fato se deseja é encontrar uma curva suave que permita entender a relação entre z e y . Essa pode ser obtida estimando-se os β_j a partir da minimização da seguinte soma dos quadrados penalizados:

$$\sum_{i=1}^n (y_i - s(z_i))^2 + \theta \int (s''(z))^2 dz, \quad (9.2)$$

na qual θ é o parâmetro que controla o grau de suavização. A primeira parcela da soma em (9.2) mede a proximidade da curva aos dados e o termo $\int (s''(z))^2 dz$ penaliza a curvatura ou a rugosidade da função. Deste modo, os seguintes cenários poderiam ser observados:

- se $\theta = 0$, temos que minimizar $\sum_{i=1}^n (y_i - s(z_i))^2$, o que fornece a solução $s(z_i) = y_i$ e portanto, a curva passa por todos os pontos, ou seja, interpola os dados;
- se $\theta \rightarrow \infty$, a expressão (9.2) é minimizada se $s''(z)^2 = 0$ para todo z e isto é obtido se $s(z_i)$ for uma reta.

Portanto, o parâmetro θ controla a suavidade da curva que vai de uma reta a uma interpolação perfeita. Esse parâmetro assume o mesmo papel que o parâmetro h no *lowess* e também poderá ser obtido segundo algum critério, como a validação cruzada. A Figura 9.3 apresenta três curvas ajustadas por *spline* para os dados da Tabela 9.1 em três diferentes cenários. No primeiro cenário, a curva foi ajustada utilizando o método de validação cruzada para encontrar θ . No segundo cenário, θ é fixado próximo de 0 e, finalmente, no terceiro cenário, θ assume um número relativamente grande.

Embora uma base definida como no exemplo permita estimar um *spline*, é mais conveniente do ponto de vista computacional operar com outras bases, como B-*spline* e P-*spline*. A solução é a mesma que a anterior, ou seja, uma vez definida essa base de forma conveniente, o problema consiste em obter os coeficientes associados aos termos




Figura 9.3: Curvas ajustadas por *spline* com diferentes graus de suavização (valores de θ)

dessa base que minimizam a soma dos quadrados penalizados como na Equação (9.2). O leitor interessado em entender como essas bases são construídas poderá consultar Wasserman (2006), Hastie, Tibshirani, & Friedman (2009) e Eilers & Marx (1996).

A função *P-spline* está incorporada aos modelos de sobrevivência, tanto no modelo de Cox como nos paramétricos, na biblioteca *survival*. Esta função considera um conjunto de nós regularmente espaçados. Isso traz uma vantagem adicional: como os parâmetros estimados para cada curva são regularmente espaçados, pode-se aplicar um teste para tendência linear. Ou seja, se o teste indicar que a sequência de parâmetros estimada é aproximada por uma reta, o termo não linear não deve ser incluído no modelo.

A incorporação dessas funções se dá dentro da mesma estrutura e pressupostos, tratadas como covariáveis usuais, inclusive quanto aos testes de hipóteses de proporcionalidade, medidas de ajuste e análise de resíduos. Além disso, intervalos de confiança também podem ser facilmente adicionados. A interpretação dos efeitos de variáveis

suavizadas é principalmente gráfica, como veremos a seguir nos exemplos.

Um aspecto importante ao comparar diferentes modelos é a estimativa dos graus de liberdade introduzidos pelo *spline*. Para cada trecho da curva, um parâmetro é estimado. Mas como essas estimativas não são independentes, o número de graus de liberdade efetivos será menor do que o total de nós.

9.5 Validação cruzada

Os métodos *lowess* e *spline* dependem dos respectivos parâmetros de suavização h e θ . A escolha deste parâmetro não é óbvia. Se o parâmetro de suavização θ , por exemplo, é muito grande, temos uma reta. Caso contrário, uma curva que tende a interpolar os dados.

A escolha arbitrária do grau de suavização pode ser considerada uma vantagem do método, e permite explorar diferentes comportamentos, em diferentes escalas. Desde a tendência mais global, quando θ é pequeno, até comportamentos locais que podem se revelar interessantes. Por outro lado, muita subjetividade nessa escolha pode ser indesejável, valorizando características locais pouco importantes, particularmente quando os dados são esparsos em determinados intervalos da variável suavizada.

Entre os métodos automáticos de ajuste de estimadores não paramétricos o mais comum é a validação cruzada. A ideia básica é escolher o valor de h ou θ que minimize as diferenças entre um conjunto de ajustes nos quais foi retirada aleatoriamente uma observação. Ou seja, tomamos o valor de h ou θ que minimiza:

$$\frac{1}{n} \sum_{i=1}^n (y_i - s_{-i}(z_i))^2,$$

em que $s_{-i}(z_i)$ é o estimador obtido quando se omite o par (z_i, y_i) .

Modelo com *spline* no R

O comando `pspline()` incluído como um termo na fórmula do modelo ajusta um termo não paramétrico apropriado quando o efeito da variável não é loglinear. A sintaxe do comando segue a forma abaixo:

```
> mod.spline <- coxph(Surv(tempo,status) ~ pspline(var) +
  covariáveis, data=dados)
```

Exemplo

A Figura 9.4 ilustra a verificação da forma funcional da variável *idade* do estudo dos pacientes internados na UTI do Inca. O gráfico dos resíduos martingale da variável *idade* contra o modelo nulo sugeriu uma associação não linear. Pode-se ver que há uma mudança de inflexão, por volta dos 60 anos de idade, claramente visível na curva suave (*lowess*) do gráfico. Além dessa curva, adicionamos ao gráfico duas retas que mostram o ajuste da idade em dois modelos separados: um modelo estimando o efeito da idade para os pacientes até 60 anos e outro com pacientes acima dos 60 anos. Observe as diferentes retas para o ajuste linear da idade, quando se analisa separadamente pacientes com mais de 60 anos, onde o risco aumenta com a idade, e pacientes mais jovens, onde a idade não afeta a sobrevivência. O ajuste linear global da idade é uma média do efeito dos dois grupos.

O modelo com função *spline* para a covariável *idade* no R através do comando `pspline(idade)` apresenta o seguinte resultado:

```
> cti<- read.table("ctinca.dat", header=T)
> idade.spl <- coxph(Surv(tempo, status) ~ pspline(idade),
  data=cti, x=T)
```

Call:

```
coxph(formula = Surv(tempo, status) ~ pspline(idade),
  data = cti, x = T)
n= 862
```




Figura 9.4: Resíduos martingale do modelo nulo contra a variável idade

	coef	se(coef)	se2	Chisq	DF	p
pspline(idade),linear	0.0089	0.0027	0.0027	10.39	1.00	0.0013
pspline(idade),nonlin				3.27	3.05	0.3600

	exp(coef)	exp(-coef)	lower .95	upper .95
ps(idade)2	0.962	1.039	0.450	2.05
ps(idade)3	0.918	1.089	0.291	2.89
ps(idade)4	0.866	1.154	0.251	2.99
ps(idade)5	0.916	1.092	0.275	3.05
ps(idade)6	0.983	1.018	0.307	3.14
ps(idade)7	0.960	1.042	0.304	3.03
ps(idade)8	1.116	0.896	0.353	3.53
ps(idade)9	1.287	0.777	0.406	4.08
ps(idade)10	1.495	0.669	0.465	4.81
ps(idade)11	1.736	0.576	0.507	5.95
ps(idade)12	2.066	0.484	0.461	9.26
ps(idade)13	2.482	0.403	0.317	19.42

Iterations: 6 outer, 15 Newton-Raphson
 Theta= 0.921
 Degrees of freedom for terms= 4
 Rsquare= 0.016 (max possible= 0.999)
 Likelihood ratio test= 13.7 on 4.05 df, p=0.00858
 Wald test = 13.6 on 4.05 df, p=0.00884

A saída do R mostra dois testes de hipóteses para esse termo: o primeiro refere-se ao efeito linear da covariável e o segundo refere-se aos efeitos não lineares ajustados pela função `pspline()`. Nesse caso, o efeito linear é significativo e o efeito da suavização da idade não é significativo. O termo suavizado acrescenta 3,05 graus de liberdade ao modelo e a estimativa do parâmetro de suavização θ é quase 1 (0,921). O teste da razão de verossimilhanças, feito da mesma forma – `anova()` – comparando-se os modelos com e sem o termo de suavização, não apontou vantagem do modelo mais complexo.

```
> idade.linear <- coxph(Surv(tempo,status) ~ idade, data=cti)
> anova(idade.linear, idade.spl)
```

```
Analysis of Deviance Table
Cox model: response is Surv(tempo, status)
Model 1: ~ idade
Model 2: ~ pspline(idade)
      loglik  Chisq Df P(>|Chi|)
1 -3183.3
2 -3181.4  3.7879 11   0.9757
```

Ainda que graficamente se observe um padrão não linear (Figura 9.4), a análise anteriormente feita não justifica a inclusão de um termo não linear. Contudo, ficou clara a existência de um ponto de corte definido, devendo ser investigada outra forma de modelar a covariável idade. Uma primeira possibilidade seria incluir no modelo uma covariável idade dicotomizada em duas categorias (≤ 60 e > 60) através da criação da variável *dummy* que recebe valor 0, para os pacientes com 60 anos ou menos e 1 para os com idade superior a 60 anos.

```
> cti$corteid <- ifelse(cti$idade<=60,0,1)
> summary(coxph(Surv(tempo, status) ~ corteid,data=cti))
```

```
[...]      coef exp(coef) se(coef)      z Pr(>|z|)
corteid 0.26211   1.29966  0.08996  2.914  0.00357 **
```

Ou seja, estar acima dos 60 anos aumenta o risco de morrer em 30%. Cabe lembrar que, ao incluirmos uma variável idade dicotomizada no modelo, estamos assumindo que o risco dentro de cada

grupo de idade não se altera. Entretanto, ao examinar novamente a Figura 9.4, verificamos que este risco aumenta com a idade para os pacientes com mais de 60 anos, sugerindo que o efeito da idade após os 60 anos pode ser estimado linearmente, aumentando para cada ano a mais de idade. Para isso, podemos particionar a idade em duas novas variáveis.

A variável *idade60* representa quantos anos o paciente esteve em risco após os 60 anos. Assim, ela recebe o valor 0 quando o paciente tem 60 anos ou menos, e recebe a própria idade subtraída de 60 para pacientes com mais de 60 anos. Com a variável *idademenor60*, por sua vez, deseja-se conhecer a idade exata daqueles com menos de 60 anos somente, e por isso, recebe a própria idade se esta for menor que 60 anos, e zero se for acima disso. O ajuste do modelo com essas duas variáveis permite estimar o efeito separadamente de cada faixa etária. Por exemplo, um paciente com 58 anos terá a covariável *idade60* igual a 0 e *idademenor60* igual a 58. Já um paciente com 65 anos terá *idade60* igual a 5 e *idademenor60* igual a 0.

Esse tipo de solução é denominado modelo de regressão segmentado. O ajuste obtido somando as duas partes da idade indica que até os 60 anos a idade é não significativa, e acima de 60, para cada ano a mais, o risco aumenta em 2%.

```
> cti$idade60<-ifelse(cti$idade>60,cti$idade-60,0)
> cti$idademenor60 <- ifelse(cti$idade>60,0,cti$idade)
> summary(coxph(Surv(tempo,status) ~ idademenor60 + idade60,
  data=cti))
```

```
[...]
              coef exp(coef)    se(coef)      z Pr(>|z|)
idademenor60 -0.0007127  0.9992875  0.0026028 -0.274  0.7842
idade60       0.0200318  1.0202337  0.0081274  2.465  0.0137*
---
              exp(coef) exp(-coef) lower .95 upper .95
idademenor60   0.9993     1.0007   0.9942     1.004
idade60        1.0202     0.9802   1.0041     1.037
```

```
[...]
```


A partir da identificação de um ponto de inflexão na idade, pode-se optar por analisar cada grupo de idade em separado para estimar independentemente os riscos de cada fator analisado, bem como incluir interações entre idade e outras variáveis. Alguns cuidados nessa escolha devem ser tomados, pois a idade pode capturar o efeito de outras variáveis que se deseja avaliar. É o caso, por exemplo, da presença de comorbidades, evidentemente mais comuns em idades mais elevadas. Pode ser vantajoso na estimativa do efeito dessa covariável realmente dividi-la em duas categorias e explorar possíveis interações.

Exemplo

Outro exemplo interessante é o estudo do efeito da baixa adesão ao tratamento Haart de Aids em coorte de pacientes acompanhados no Ipec. Não há um consenso na literatura em relação ao que considerar boa adesão, e a forma de recolher essa informação é complexa. Nesse estudo, a informação de atraso na obtenção do medicamento foi obtida a partir dos dados do Sistema de Controle Logístico de Medicamentos (SICLOM), desenvolvido pelo Ministério da Saúde/Brasil, para a dispensa de medicamentos antirretrovirais. Calculou-se a razão entre os dias acumulados com atraso no período e os dias de acompanhamento, sendo o desfecho a ocorrência de falha terapêutica composto pela ocorrência de pelo menos um dos eventos: falha virológica, imunológica ou clínica ou óbito. Maiores detalhes no Apêndice (seção Aids, adesão à Haart).

```
> adesao <- read.table("adesao.dat", header=T)
> #resíduo martingale do modelo nulo
> adesao.resnulo <- residuals(coxph(Surv(ini,fim,status) ~ 1,
  data = adesao), "m")
> plot(adesao$propatraso, adesao.resnulo,
  xlab = "Proporção de dias em atraso",
  ylab = "Resíduos Modelo Nulo")
> lines(lowess(adesao$propatraso, adesao.resnulo), lty=2, lwd=2)
```

Novamente, a forma funcional apresentada no gráfico dos resíduos da Figura 9.5 parece não ser linear. Ajustando um modelo com

spline, o resultado aponta que os dois ajustes – linear e não linear – são significativos.




Figura 9.5: Resíduos martingale do modelo nulo contra a covariável proporção de dias em atraso para obter o medicamento

O termo linear é exatamente o ajuste do modelo quando a variável é incluída diretamente. Entretanto, a presença de significância estatística no termo não linear deve ser compreendida. Como os nós na curva *P-spline* são espaçados regularmente, cada termo `ps(propatraso)` se refere a um ponto específico do escopo da variável. Nesse caso, temos 11 termos. Pode-se verificar que a partir do `ps(propatraso)4` o efeito da variável aumenta, ou seja, aumentando o atraso, aumenta o risco de falha terapêutica.

```
> adesao.spl <- coxph(Surv(ini, fim, status) ~
  pspline(propatraso), data = adesao)
> summary(adesao.spl)
```

Call:

```
coxph(formula = Surv(ini, fim, status) ~
  pspline(propatraso), data = adesao)
n= 819
```

coef	se(coef)	se2	Chisq	DF	p
------	----------	-----	-------	----	---

```
pspline(propatr), line 3.8 0.309    0.306 151.4 1.00 0.000
pspline(propatr), nonl          10.9 3.06 0.013
```

	exp(coef)	exp(-coef)	lower .95	upper .95
ps(propatraso)2	0.581	1.7222	0.241	1.40
ps(propatraso)3	0.416	2.4061	0.131	1.32
ps(propatraso)4	0.611	1.6375	0.198	1.89
ps(propatraso)5	1.017	0.9833	0.346	2.99
ps(propatraso)6	1.448	0.6904	0.503	4.17
ps(propatraso)7	2.242	0.4460	0.773	6.50
ps(propatraso)8	3.596	0.2781	1.236	10.46
ps(propatraso)9	6.141	0.1628	2.062	18.29
ps(propatraso)10	9.763	0.1024	3.049	31.26
ps(propatraso)11	13.735	0.0728	4.032	46.78
ps(propatraso)12	19.015	0.0526	4.433	81.56
ps(propatraso)13	26.538	0.0377	3.131	224.92

```
Iterations: 5 outer, 17 Newton-Raphson, Theta= 0.852
```

```
Degrees of freedom for terms= 4.1
```

```
Rsquare= 0.138 (max possible= 0.927 )
```

```
Likelihood ratio test= 121 on 4.06 df, p=0
```

```
Wald test          = 162 on 4.06 df, p=0
```

A visualização gráfica (Figura 9.6) do *spline* facilita a compreensão. Essa figura contém o gráfico do *spline* predito pelo modelo, isto é, o valor do coeficiente de cada nó estimado no modelo. À medida que aumenta a proporção de dias sem o uso do medicamento, aumenta linearmente o coeficiente da variável suavizada, exceto pelos primeiros valores, onde o efeito não parece ser importante. A partir de cerca de 10% de dias em atraso o risco começa a aumentar e acima de 30% o efeito da não adesão aparece significativamente acima de zero. Ou seja, não tomar o medicamento até cerca de 10% das vezes não está associado de forma imediata à falha terapêutica.

```
> termplot(adesao.spl,term="pspline(propatraso)", se=T,
  ylab="Spline Predito", xlab="Proporção de Dias em Atraso",
  col.term = 1, col.se = 1)
> abline(h=0,lty=3,col="gray")
> legend("topleft", title="Spline", lty=1:2, bty="n",col=1,
  legend=c("Curva dos coeficientes","Intervalos de confiança"))
```




Figura 9.6: Efeito da proporção de dias em atraso sobre falha terapêutica estimado no modelo `adesao.spl`

Gráfico do efeito suavizado com *spline* no R

Para visualizar o efeito não linear graficamente a função a utilizar é `termplot()`.

```
> termplot(model=modelo, term="pspline(variavel)", se=T)
> abline(h=0, lty=3, col="gray")
```

Os três argumentos representam:

- `model=modelo` → modelo é o objeto que recebeu o modelo de cox estendido;
- `term="pspline(variavel)"` → termo do efeito não linear;
- `se=T` → argumento lógico para que seja desenhado o intervalo de confiança.

O comando `abline(h=0)` adiciona uma linha horizontal no zero.

Resumo

Para...	Faça...
Ajustar forma funcional não linear	Suavização <i>spline</i> (<code>pspline()</code>) da covariável no modelo
Verificar significância estatística	P-valor dos termos linear e não linear
Interpretar o efeito não linear	Gráfico do <i>spline</i> (<code>termplot</code>)
Diagnóstico	Igual ao Capítulo 7

Exercícios

9.1 Analise o comportamento da variável *idade* no risco de óbito de pacientes em hemodiálise (banco *dialise.csv* – Apêndice.12.4), analisado no Capítulo 6.

- (a) Descreva o efeito aparente da idade no gráfico de resíduo martingale de um modelo com somente essa variável.
- (b) Ajuste um modelo que permita que o efeito da variável *idade* varie suavemente.
- (c) Interprete os resultados do ajuste da variável *idade* suavizada.
- (d) Faça e interprete um gráfico do efeito da variável na sobrevivência.

Dicas

- Para avaliar forma funcional utiliza-se o gráfico do resíduo martingale do modelo nulo contra a variável.
- Uma curva *lowess* nesse gráfico ajuda a visualizar o comportamento da variável.
- Varie o parâmetro de suavização do *lowess* para verificar as mudanças gráficas.
- Para ajustar um modelo suave da variável idade use a função *pspline* na equação do modelo chamado pela função *coxph*.
- O gráfico do efeito suavizado da variável é feito usando a função *termplot*.

```
> dialise <- read.csv("dialise.csv")
> res.nulo <- residuals(coxph(Surv(tempo,status) ~ 1,
  data=dialise), type="mar")
> plot(dialise$idade,res.nulo)
> lines(lowess(dialise$idade,res.nulo),
  col="red", lwd=2)
> lines(lowess(dialise$idade,res.nulo, f=.1),
  col="green", lwd=2)
> mod.spl <- coxph(Surv(tempo,status) ~
  pspline(idade), data=dialise)
> termplot(mod.spl, term="pspline(idade)", se=T)
```

9.2 Para estudar a sobrevivência de pacientes infartados foram analisadas as internações do SUS por essa causa. Foram considerados fatores de risco do paciente – sexo e idade – disponíveis no Sistema de Informações Hospitalares, registradas na AIH. Com os dados desse estudo (*infarto.dat* – no Apêndice.12.4):

- Descreva a relação entre idade e tempo de sobrevivência, procurando indicar com que idades o efeito sofre mudança importante de comportamento.
- Sugira uma hipótese biológica para explicar esse comportamento.

- (c) Indique outras formas de analisar sem o uso de *spline*.
- (d) Escolha um ou mais pontos de corte para a variável *idade*, e ajuste uma regressão segmentada.
- (e) Modele o efeito do sexo para cada classe de idade proposta. O que você conclui sobre o risco de ser do sexo masculino nas faixas etárias mais jovens?
- (f) Aponte vantagens e desvantagens de cada modelo ajustado.

Dicas

- A regressão segmentada, considerando um ponto de corte P de uma variável var , é feita da seguinte forma:

```
> banco$varmaiorP <- ifelse(banco$var>P,  
  banco$var-P, 0)  
> banco$varmenorP <- ifelse(banco$var>P,  
  0, banco$var)
```
- O modelo é ajustado da forma usual, incluindo as duas novas variáveis.

9.3 Refaça a análise apresentada no capítulo, utilizando o banco de dados `adesao.dat` descrito no Apêndice.12.4. Além disso, escolha um ou mais pontos de corte para a variável `adesao` e ajuste uma regressão segmentada.

10

Eventos múltiplos

O objetivo deste capítulo é capacitar o leitor a:

Conceituar os modelos para análise de sobrevivência com eventos múltiplos, indicando pressupostos e propriedades.

Indicar o tipo de modelo adequado a cada situação estudada.

Ajustar os modelos utilizando o R.

Interpretar as estimativas ajustadas em cada modelo.

10.1 Introdução

Até agora, vimos modelos de sobrevivência adequados para tratar problemas nos quais o desfecho acontece uma única vez durante todo o período de acompanhamento. Isto é, para cada indivíduo, só existe registro do tempo até um único evento, embora eventualmente dividido em alguns estados diferentes devido à mudança de covariáveis. Mas, mesmo nesses casos, o indivíduo sai do grupo de risco após a ocorrência do evento. O óbito por determinada causa é obviamente

um evento desse tipo. Outros exemplos de eventos únicos são diagnóstico de Aids, de hipertensão, menopausa, entre outros.

Existem problemas, porém, em que o interesse é estudar o tempo até eventos que podem acontecer mais de uma vez para um mesmo indivíduo: gestações, internações, cáries, infartos do miocárdio e fraturas são alguns exemplos. Em outras situações, o interesse não está relacionado a um único tipo de evento, mas a diferentes tipos de eventos decorrentes de um mesmo fator de risco em estudo. Por exemplo, efeitos adversos de medicamentos, doenças oportunistas da Aids, ou o desfecho de um paciente em diálise (que pode ser óbito decorrente da insuficiência renal *versus* óbito por outras causas). As duas perguntas básicas quando analisamos a ocorrência de eventos múltiplos são:

- Quais são os fatores de risco associados aos vários tempos até ocorrências de eventos em um mesmo indivíduo?
- Como analisar diferentes eventos como desfecho de uma mesma situação de risco?

A principal característica da análise de sobrevivência de eventos múltiplos é que para cada indivíduo registra-se mais de um tempo. Nesse caso, a utilização direta do modelo de riscos proporcionais de Cox não é adequada, mesmo se utilizarmos a formulação por processo de contagem, pois os intervalos de tempo de um mesmo indivíduo podem se sobrepor. Além disso, como a mesma pessoa sofre diversos eventos, esses podem ser correlacionados. O mecanismo pelo qual vários eventos ocorrem deve ser examinado cuidadosamente, pois a partir daí se define o modelo de análise, incorporando, caso necessário uma estrutura de dependência entre os tempos.

Outra particularidade da análise de eventos múltiplos é a composição do grupo de risco. Ao contrário do que ocorre no modelo de Cox clássico, e mesmo nos modelos com covariáveis mudando no tempo (Capítulo 8), quando os eventos são múltiplos, os indivíduos se mantêm no grupo de risco após a ocorrência de algum evento.

Entre as diversas abordagens possíveis, se os eventos são do mesmo tipo, pode-se considerar o número de eventos por indivíduo durante o período de estudo como a variável resposta. Nesse caso, considera-se que a variável dependente é uma contagem, que pode ser ajustada com um modelo de Poisson. Contudo, o tempo entre os eventos não é incorporado nessa análise. Mas o processo de Poisson é exatamente isso: um processo estocástico onde os eventos acontecem ao longo do tempo, de forma contínua, e independente uns dos outros. Ainda que exista relação entre o número de eventos e o tempo entre eles, esse modelo não será capaz, por exemplo, de tratar de forma diferenciada dois eventos com um ano de intervalo de outro par com dez dias de intervalo.

Outra estratégia de modelagem consiste na utilização do modelo de riscos proporcionais, considerando como variável resposta apenas o tempo até um dos eventos analisados. Modela-se somente o tempo até o 1º evento, ou o tempo entre o 1º e o 2º eventos, ignorando-se a multiplicidade. Ou, caso se esteja trabalhando com diferentes desfechos tais como doenças oportunistas, pode-se escolher apenas um deles, isoladamente. Nesse caso, a estimativa do efeito das covariáveis será válida somente para o evento analisado. Essa é uma abordagem simples de implementar, mas não permite conclusões muito abrangentes.

Um caso particular de eventos múltiplos é quando a ocorrência de um deles exclui a possibilidade de ocorrência do outro. São os denominados eventos competitivos, em geral óbitos por diferentes causas. Novamente, pode-se analisar cada um em separado, mas a análise conjunta permite estimar, por exemplo, o efeito de fatores de risco para diferentes desfechos. Esse tipo de modelo será tratado mais detalhadamente no Capítulo 11.

Uma terceira estratégia é o ajuste de modelos de efeitos aleatórios, denominados de modelos de fragilidade na área de análise de sobrevivência. Condicionados ao efeito aleatório (ou fragilidade) de cada indivíduo, considera-se que os eventos são independentes. São os denominados **modelos condicionais**. É aplicável a eventos do mesmo tipo, recorrentes, mas não se adapta a eventos de tipos

diferentes. Essa estratégia de modelagem será apresentada no Capítulo 12.

A abordagem que apresentaremos neste capítulo é denominada **modelos marginais**, que são também extensões do modelo de Cox. Considerando a diversidade de situações nas quais mais de um tempo e de um evento são possíveis, não é de se surpreender que haja também uma variedade de modelos marginais. Identificar qual modelo utilizar em cada situação é um dos aspectos fundamentais da modelagem. Para auxiliar nessa decisão, é útil ter um vocabulário para a classificação de eventos múltiplos, pois os modelos a serem ajustados serão guiados por essa classificação. A próxima seção apresenta uma descrição de alguns tipos básicos de eventos múltiplos, com diversos exemplos.

10.2 Classificação de eventos múltiplos

A classificação apresentada a seguir não é rígida nem definitiva. Por um lado, porque a evolução de métodos nesta área é grande e novos modelos são desenvolvidos, sempre buscando expressar melhor as características das várias situações analisadas. Por outro lado, o problema em si, que gera o aparecimento dos eventos, e o próprio desenho do estudo pode permitir diversas interpretações sobre o provável mecanismo gerador dos dados observados e consequentemente qual o modelo mais adequado. Assim, para orientar a escolha do modelo, as principais questões que devem ser observadas na análise do tempo para ocorrência de eventos múltiplos são:

- a população em risco;
- o risco basal (λ_0);
- a estrutura temporal (ordenação);
- a estrutura de dependência entre os eventos.

A questão de fundo mais importante é a identificação de quem está em risco a cada momento em que ocorre um dos possíveis eventos. O risco de base (λ_0), que não é estimado no modelo de Cox,

pode ser constante para todos os eventos múltiplos ou pode variar, se considerarmos que para cada evento o risco basal é diferente. Além disso, a formatação do banco de dados define também quem está em risco na ocorrência de cada evento. Por exemplo, em estudo de fatores associados à paridade, somente estará em risco de nova gestação mulheres não grávidas. Durante o período de gravidez a mulher não pode ser incluída na população em risco.

A estrutura temporal muitas vezes também não é de fácil definição, e diversos olhares são possíveis. A adoção de estimação por processo de contagem impõe necessariamente uma ordem aos eventos, que pode ser evitada com o uso da abordagem mais simples do tempo até o evento ou censura. Também é necessário avaliar se há sobreposição nos tempos até os eventos. Essa estrutura temporal é definida simultaneamente pela forma como o banco de dados é construído e pela indicação de ordenação entre os estratos de riscos relacionados a cada evento. Além disso, a estrutura de dependência gerada pelas múltiplas observações de cada indivíduo define a necessidade de métodos robustos para corrigir a variância dos estimadores.

Um primeiro tipo de eventos múltiplos são os desfechos ou **eventos paralelos**, em que a ocorrência de um evento não exclui a ocorrência de outro evento, e não há qualquer ordem preferencial. É o caso do estudo de doenças oportunistas relacionadas à Aids, suponha tuberculose, pneumocistose e diarreia. Todas podem ocorrer, somente algumas ou mesmo nenhuma. Também podem ocorrer ao mesmo tempo ou sucessivamente. Podemos adotar a estratégia de considerar desfecho a ocorrência da primeira doença, qualquer que seja ela, e neste caso temos novamente o modelo de Cox clássico. Entretanto, a ocorrência de mais de uma doença na mesma pessoa pode ter implicações importantes. Alternativamente, considera-se o tempo até a ocorrência de cada uma das três doenças monitoradas ou até a ocorrência de censura, eventos que podem ocorrer simultaneamente ou em qualquer ordem.

Um segundo tipo de problema ocorre quando os eventos são **ordenados**. Nos eventos ordenados a sucessão de tempos segue obrigatoriamente uma ordem, que é dada seja pela estrutura de datas de

início e fim de cada evento, seja por assumir uma ordem nos estratos de risco relacionados a cada desfecho, ou ambos.

A combinação entre definição de grupo sob risco e estrutura do risco basal (λ_0) permite identificar claramente dois tipos de problemas em que os eventos são ordenados:

- **Eventos ordenados independentes** - assume-se que o indivíduo sempre retorna ao grupo de risco após sofrer cada evento, e que o momento de ocorrência de cada evento não depende dos tempos anteriores.
- **Eventos ordenados estruturados** - assume-se que o indivíduo só entra em risco de sofrer o n -ésimo evento depois que o evento de ordem $n - 1$ tiver ocorrido. Isto é, o risco basal para um segundo evento é zero até que o primeiro ocorra, enquanto que o risco do terceiro evento é zero até que o segundo ocorra.

Um exemplo de **eventos ordenados independentes** é a ocorrência de infecções respiratórias agudas. Os episódios são ordenados, e na vigência de um episódio o indivíduo não está na população em risco. A hipótese de independência nesse contexto significa que o momento de ocorrência de cada evento é totalmente independente do tempo decorrido anteriormente ou do número de eventos até então. O risco basal não varia entre os eventos, o que é razoável supor, ainda que as crianças (ou idosos) com muitos episódios possam ter perfis diferentes, seja por concomitância de outras doenças ou processos alérgicos. Esses diferentes perfis devem ser modelados por meio da inclusão de covariáveis. Esse tipo de problema dá origem ao **modelo de eventos ordenados independentes** ou **AG** (Andersen-Gill), discutido na Seção 10.5.1.

No caso dos **eventos ordenados estruturados**, o infarto agudo do miocárdio é um exemplo no qual é razoável supor que o risco de sofrer o primeiro infarto é diferente do risco de sofrer o segundo. Reinternações hospitalares também se encaixam nesta classificação, se o risco de reinternação depender do número de internações já sofridas. Nesses casos, considera-se que o risco basal se altera à medida que o indivíduo sofre novos eventos, ou seja, os eventos, além de

ordenados no tempo, são ordenados também segundo o risco basal, podendo-se considerar que o indivíduo somente estará em risco de um segundo evento se o primeiro tiver ocorrido. Ou seja, o segundo evento está condicionado à ocorrência do primeiro evento e assim sucessivamente. Esse problema dá origem ao **modelo estruturado** ou **PWP** (Prentice, Williams & Peterson).

Outras abordagens são possíveis. Por exemplo, eventos ordenados com **risco concomitante**, na qual se assume que o indivíduo, ao iniciar o acompanhamento, está concomitantemente em risco de sofrer o primeiro, segundo, terceiro, enésimo evento. O risco só cessa quando o evento de ordem n , predefinida, acontece. Considera-se que cada evento tem um risco basal diferente, dependendo de sua posição na sequência de eventos, mas independente do tipo de evento. A ocorrência de reações adversas a medicamentos pode ser tratada como um exemplo teórico desse tipo. Entretanto, a suposição de ordenamento com risco concomitante significa que o tempo para a ocorrência de cada evento é sempre contado a partir do tempo zero, não sendo indicado o uso de estrutura de contagem. A ordem, neste caso, é dada pela enumeração do evento, sem condicionar a ocorrência de um evento à ocorrência do anterior, mas considerando um risco basal diferente conforme a ordem de ocorrência. Essa abordagem é denominada modelo marginal ou **WLW** (Wei, Lin & Weissfeld). Não nos deteremos nesse modelo, por não termos de fato nenhum exemplo realista no qual o tipo de evento ou sua estrutura temporal seja dispensável na análise. Para aqueles que desejarem maiores informações, consultar Signorovitch & Wei (2008).

Cabe uma observação: todos os modelos apresentados neste capítulo são classificados como **modelos marginais** do ponto de vista da estimação. O modelo de eventos ordenados estruturados é também conhecido como modelo de eventos condicionais, mas a palavra condicional aqui é somente porque a condição para que ocorra um segundo evento é ter acontecido o primeiro. Os modelos condicionais propriamente ditos são os modelos de efeitos aleatórios, que serão apresentados no Capítulo 12.

10.3 Modelos marginais

Os modelos marginais são utilizados em análise de sobrevivência quando os tempos são correlacionados, ou seja, quando existem várias observações de um mesmo indivíduo. A estratégia dessa abordagem é assumir que apenas a resposta média da população, modelada como uma função das covariáveis, é o foco de interesse. E por isso, os valores dos parâmetros de regressão β mantêm a mesma interpretação de um modelo para problemas com observações independentes. Nos modelos de regressão marginais as estimativas pontuais dos parâmetros de regressão são calculadas utilizando métodos baseados na verossimilhança parcial, assumindo que as observações são não correlacionadas.

A variância das estimativas dos parâmetros, no entanto, precisa ser calculada levando-se em consideração a estrutura de correlação dos dados intraindivíduo. A derivação de estimativas robustas de variância para o modelo de Cox na presença de dependência utiliza a mesma forma do cálculo dos resíduos score apresentada no Capítulo 7.

Para a modelagem de eventos múltiplos através do ajuste de modelos marginais, é necessário percorrer algumas etapas. A primeira delas, e a mais importante, é identificar conceitualmente, com base na classificação dos eventos apresentada na Seção 10.2, qual tipo de evento se aproxima mais do problema em questão. Por exemplo, vamos analisar os tempos até todos os eventos ou apenas até o primeiro evento? Os eventos são ordenados ou não? Em alguns casos, só existe uma forma de analisar o problema. Eventualmente, mais de uma abordagem é possível e até mesmo necessária. Além disso, além dos modelos marginais, outras abordagens também podem ajustar eventos múltiplos, sendo muito usados os modelos de fragilidade apresentados no Capítulo 12.

Com base na classificação do tipo de evento, a pergunta seguinte é: quem está sob risco em cada momento? A partir dessa definição, se organiza o banco de dados apropriadamente, pois esta formatação muda conforme a definição do grupo de risco. Com fre-


quência esta é a parte mais trabalhosa de todo o processo. Depois de organizado o banco, o modelo de Cox deve ser ajustado da forma usual, ignorando-se a estrutura de dependência dos dados. Os resultados servirão para comparação. Espera-se que as estimativas pontuais se mantenham razoavelmente similares e por isso compará-las com efeitos estimados por modelos mais complexos ajuda a detectar eventuais (e frequentes) erros na formatação do banco de dados.

Por fim, caso seja razoável para a análise em questão, pode ser interessante experimentar duas ou mais abordagens. Muitas vezes os parâmetros estimados por diversas abordagens são semelhantes, e nesse caso o modelo mais simples é o mais indicado.

Apresentaremos nas seções seguintes exemplos de como modelar os vários tipos de problemas com múltiplos eventos, ordenados ou não. Para facilitar a apresentação dos diferentes modelos para eventos múltiplos, faremos uso de uma representação esquemática por meio de modelos multiestados. Esta representação consiste em identificar os estados que cada indivíduo em observação pode assumir e as possíveis transições entre tais estados. Por exemplo, o modelo clássico de sobrevivência (com uma ocorrência de um único desfecho) tem apenas dois estados: vivo (em risco) e morto (fora de risco); ou, sem Aids (em risco) e com Aids (fora de risco); amamentando (em risco) ou não amamentando (fora de risco). Nesses casos, todos os indivíduos entram no estudo no primeiro estado e são observados até passarem para o outro estado. Modelos de eventos múltiplos, por sua vez, possuem mais do que dois estados possíveis. A forma como os estados se relacionam é o que define os diferentes tipos de modelos para eventos múltiplos (Figura 10.1). O que se busca estimar são os fatores associados ao risco de transição entre estados.


Analisaremos cada tipo de situação a partir de exemplos, organizando desde a descrição do dado até a interpretação dos resultados. No final do capítulo faremos algumas comparações entre modelos.

A – Modelo de Cox Clássico




Eventos Não Ordenados

B – Eventos Competitivos




C – Eventos Paralelos



Eventos Ordenados

D – Modelo AG



E – Modelo PWP




Figura 10.1: Representação gráfica de modelos de sobrevivência por meio de modelos multiestados

10.4 Eventos paralelos

O tempo até o aparecimento de doenças oportunistas em pacientes portadores de HIV pode ser investigado para se estudar, por exemplo, quais covariáveis estão mais associadas a uma ou outra complicação, se o tipo de doença muda conforme a terapia antirretroviral em curso, ou ainda para verificar se a linha de base do risco é a mesma, qualquer que seja a doença. Os eventos não são competitivos, pois a ocorrência de um não elimina o risco de ocorrência de outro. Eles também não são ordenados, pois podem ocorrer em qualquer ordem e mesmo simultaneamente. O objetivo é estimar o efeito de diversos fatores de risco para diferentes doenças oportunistas entre indivíduos que apresentaram alguma delas.

Para cada paciente HIV positivo, registra-se o tempo desde o início do acompanhamento até a ocorrência de algumas doenças oportunistas de interesse para o estudo, selecionadas entre as mais frequentes e incluindo alterações hematológicas que podem estar relacionadas ao uso dos antirretrovirais. Se um paciente experimenta n doenças, então n tempos são registrados (e n linhas são colocadas no banco de dados). A Figura 10.2 mostra os tempos até a ocorrência de doenças oportunistas para quatro pacientes. O paciente 2, por exemplo, teve herpes e pneumocistose 249 dias após sua entrada na coorte e posteriormente apresentou candidíase no dia 459. Como um evento não elimina o risco de ocorrência do outro, as linhas para cada evento possível correm paralelamente. O paciente 4, que teve um único evento (alterações hematológicas no dia 184 após sua entrada no estudo), é representado por apenas uma linha no gráfico.

Observe que os tempos de sobrevivência de um mesmo paciente apresentam sobreposição. Esta sobreposição é realista, pois o paciente está em risco, simultaneamente, para todas as doenças consideradas. Uma questão importante é a ausência de censura nesse banco de dados. Um paciente entra no estudo somente se apresenta ao menos uma complicação associada à Aids, e sai inteiramente do banco no momento da última doença registrada. Ou seja, somente se compara indivíduos que apresentaram doenças oportunistas, e não os que potencialmente poderiam apresentar doenças.




Figura 10.2: Tempo até a ocorrência de algumas doenças oportunistas em quatro pacientes portadores do vírus HIV

Organização do banco de dados – eventos paralelos

A seguir será ilustrada a estrutura do banco de dados para eventos paralelos. Cada paciente, identificado pela variável *reg*, tem uma linha para cada evento registrado. O tempo inicial (*ini*) corresponde à entrada do indivíduo na coorte (quando ele começa a ser observado), e o tempo final (*fim*) corresponde à ocorrência de cada evento registrado na variável *oport*. As doenças oportunistas analisadas foram candidíase (*Candida*), *Herpes*, pneumocistose (*Pneumoc*), tuberculose (*Tuberc*) e algumas alterações hematológicas (*Hemato*). Observe que a coluna *status* é sempre igual a 1 neste exemplo, pois todos os indivíduos apresentaram alguma doença oportunista. O número de linhas por indivíduo é igual ao número de ocorrências. As demais covariáveis são: *sex* = *M* (masculino) ou *F* (feminino); *udi* e *sexual*, que codificam a forma de transmissão em, respectivamente, usuários de drogas injetáveis e transmissão sexual; *esc*, que indica a escolaridade, categorizada em 0 = sem escolaridade, 1 = até 4 anos de estudo, 2 = ensino básico, 3 = ensino médio e 4 = ensino superior; *idade* e *tempo*, que é a duração entre o início e o fim do estudo.

```
> op <- read.csv("oportunista.csv")
```

reg	sex	esc	idade	udi	sexual	ini	oport	fim	status	tempo
2	M	2	38	1	0	2884	Herpes	3133	1	249
2	M	2	38	1	0	2884	Pneumo	3133	1	249
2	M	2	38	1	0	2884	Candida	3343	1	459
4	M	3	43	0	0	3780	Hemato	3964	1	184
5	F	3	32	0	1	2923	Candida	3588	1	665
5	F	3	32	0	1	2923	Pneumo	3987	1	1064
5	F	3	32	0	1	2923	Hemato	5243	1	2320
6	M	2	33	0	0	2938	Pneumo	4639	1	1701
6	M	2	33	0	0	2938	Candida	4828	1	1890
21	M	2	36	0	0	3625	Candida	3648	1	23
21	M	2	36	0	0	3625	Tuberc	3753	1	128

Observe que na construção do banco para eventos paralelos é imprescindível registrar o **tempo** de observação de cada indivíduo para cada evento. O uso da estrutura *Surv(inicio,fim,status)*, associada à estimação por processo de contagem, necessariamente **ordena** o evento. Nesse caso, não mais estaríamos modelando os eventos como não ordenados e paralelos, mas como ordenados, ainda que também possam ocorrer paralelamente. Uma observação importante: em princípio, nesse modelo **não** há ordem no aparecimento dos eventos, ou não há interesse em considerar possível ordenação. Evidentemente pode-se pensar que isso é importante e adotar outra lógica na formulação do problema.

Outra questão é a definição de censura. Se considerarmos que os indivíduos no estudo estão sempre em risco de ter alguma das doenças selecionadas, deveríamos incluir uma linha para cada um deles até o final do estudo ou o óbito, onde todos estariam em risco de em algum momento apresentar alguma das doenças. Entretanto, esse raciocínio, se levado de forma consistente, obrigaria a acrescentarmos para cada indivíduo tantas linhas quantas doenças estiverem em estudo, o que não faz muito sentido. Além disso, como cada doença pode ocorrer mais de uma vez, o grau de complicação extra, inclusive na interpretação dos resultados, não é razoável. O objetivo desse

modelo é estimar o efeito de covariáveis até a ocorrência de eventos necessariamente paralelos e não ordenados, se necessário permitindo que o risco de base para cada doença varie, considerando que todos os indivíduos estão sujeitos a apresentar algum evento em algum momento. **Não** é objetivo estimar o risco de alguma doença oportunista entre todos os pacientes, ou seja, entre os que tenham ou não alguma doença oportunista.

10.4.1 Modelo para eventos paralelos

Na Figura 10.1, o quadro C indica que a partir do estado original, qualquer das ocorrências é possível, inclusive mais de uma simultaneamente. Haverá tantas transições para cada indivíduo quantas doenças aparecerem, sem número fixo. O risco $\lambda(t)$ pode ser constante para todos os desfechos, ou variar, e neste caso haveria um $\lambda_A(t)$ para a doença oportunista **A**, um $\lambda_B(t)$ para a doença **B**, e assim por diante.

O modelo marginal para eventos paralelos tem a mesma formulação do modelo de Cox clássico. A estratificação pode ser necessária se houver diferenças no risco basal entre as várias doenças. O que caracteriza o modelo como de eventos paralelos não ordenados é a formatação do banco de dados, em que se usa o tempo transcorrido desde a entrada do paciente na coorte, e nunca a data de início e fim, pois assim se obteria uma ordenação não intencional. Além disso, somente é necessário incluir o termo `cluster()` para a correção da variância.

Ajustando-se um modelo para cada desfecho, é possível estimar o efeito das covariáveis para cada doença oportunista separadamente.

```
> hemo <- coxph(Surv(tempo,status) ~ udi + sexual + sex +
  factor(esc), data=op, subset=(oport=="Hemato"))
> herp <- coxph(Surv(tempo,status) ~ udi + sexual + sex +
  factor(esc), data=op, subset=(oport=="Herpes"))
> cand <- coxph(Surv(tempo,status) ~ udi + sexual + sex +
  factor(esc), data=op, subset=(oport=="Candida"))
> pneu <- coxph(Surv(tempo,status) ~ udi + sexual + sex +
  factor(esc), data=op, subset=(oport=="Pneumo"))
```

Tabela 10.1: Efeitos de covariáveis sobre o risco de desenvolver algumas doenças oportunistas. As razões de riscos foram estimadas em modelos separados

Covariáveis	<i>hemo</i>	<i>herp</i>	<i>cand</i>	<i>pneu</i>	<i>tb</i>
<i>udi</i>	0.82	0.45	0.92	0.59 [†]	2.60*
<i>sexual</i>	0.70*	0.78	0.78	0.65	0.94
<i>sexM</i>	1.30*	0.86	1.07	1.11	0.93
<i>esc1</i>	0.83	0.70	0.94	2.33*	4.34
<i>esc2</i>	0.80	0.79	0.98	2.69 [‡]	4.41
<i>esc3</i>	0.75	0.74	0.82	3.24 [‡]	5.37
<i>esc4</i>	0.55	0.55	0.81	NA	1.30

Efeito significativo ao nível de [†]10%, *5% e [‡]1%

```
> tb <- coxph(Surv(tempo,status) ~ udi + sexual + sex +
  factor(esc), data=op, subset=(oport=="Tuberc"))
```

Os efeitos das covariáveis sexo, tipo de transmissão (usuário de drogas injetáveis e sexual) e escolaridade são apresentados na Tabela 10.1.

A desvantagem dessa forma de modelar é a impossibilidade de estimar efeitos em comum para a ocorrência de qualquer das doenças. Além disso, como o número de observações varia entre os modelos ajustados, também varia a significância estatística de cada covariável. Observe, por exemplo, que não foi possível estimar o efeito da escolaridade superior (*esc4*) para a ocorrência de pneumocistose, pois não havia um número de observações suficiente. A alternativa é modelar simultaneamente o efeito das covariáveis para a ocorrência de qualquer das doenças listadas, assumindo que podem ocorrer paralelamente.

Em primeiro lugar é importante verificar se a linha de base do risco difere entre as doenças, indicando a necessidade de considerar

as doenças como estratos, como mostra a Figura 10.3 através da estimativa não paramétrica das curvas de sobrevivência de cada doença oportunista. Aparentemente o tempo de sobrevivência é muito semelhante para todas as doenças, ainda que não se possa testar diferenças pois os eventos não são independentes. Nessa situação não há necessidade de estratificação.




Figura 10.3: Curva de sobrevivência estimadas pelo Kaplan-Meier segundo doenças oportunistas

Modelando-se o efeito de diversos fatores de risco para a ocorrência de qualquer uma das doenças, a única novidade será a inclusão de um termo que permite identificar para um mesmo indivíduo seus diversos desfechos. No R isto é feito incluindo o argumento `cluster()`.

```
> summary(coxph(Surv(tempo,status)~udi+sexual+
sex+factor(esc)+cluster(reg),data = op))

[...]
```

	exp(coef)	exp(-coef)	lower .95	upper .95
udi	0.79	1.26	0.55	1.13
sexual	0.74	1.35	0.55	0.99
sexM	1.15	0.87	0.98	1.34

```

factor(esc)1      1.00      1.00      0.50      2.01
factor(esc)2      1.03      0.97      0.51      2.07
factor(esc)3      0.96      1.04      0.48      1.95
factor(esc)4      0.65      1.53      0.32      1.35
Rsquare= 0.028    (max possible= 1 )
[...]
```

Nesse modelo o efeito médio de todas as covariáveis para o conjunto de doenças oportunistas não foi estatisticamente significativo, exceto para forma de transmissão sexual, que apresenta efeito protetor comparado com qualquer outro tipo de transmissão. Uma possível explicação é que o efeito de cada covariável para cada doença é diferente, o que aliás pode ser visto nos modelos separados tendo como desfecho cada doença oportunista. Além disso, o método de estimação robusto é bastante conservador, ou seja, aumenta os intervalos de confiança.

Se houvesse indicação de diferença no risco basal segundo o evento, poderíamos ajustar um modelo considerando cada doença oportunista como um estrato, ou seja, tendo risco de base diferente, e estimando o efeito de cada covariável para qualquer um dos desfechos, ainda que o risco basal seja considerado diferente.

```

> summary(coxph(Surv(tempo,status)~udi+sexual+sex+
  factor(esc)+cluster(reg)+strata(oport),data = op))

[...]
```

	exp(coef)	exp(-coef)	lower .95	upper .95
udi	0.80	1.25	0.55	1.15
sexual	0.74	1.36	0.55	0.98
sexM	1.14	0.88	0.97	1.33
factor(esc)1	1.11	0.90	0.51	2.42
factor(esc)2	1.13	0.89	0.52	2.46
factor(esc)3	1.07	0.93	0.49	2.34
factor(esc)4	0.71	1.41	0.32	1.59

```

Rsquare= 0.028    (max possible= 1 )
[...]
```

Os resultados são muito semelhantes aos do modelo anterior, com intervalos de confiança ainda maiores. Pode-se observar na Fi-

gura 10.4 que o risco basal acumulado estimado não apresenta diferenças entre os eventos.




Figura 10.4: Risco basal acumulado do modelo de eventos paralelos com estratificação

10.5 Eventos ordenados independentes

Um estudo de coorte com crianças de 6 a 48 meses foi conduzido para testar a suplementação de vitamina A na proteção contra a diarreia infantil. O desfecho de interesse é o episódio de diarreia, e o tempo de sobrevivência é definido como tempo até a ocorrência de um episódio de diarreia (Apêndice.12.4). A Figura 10.5 mostra os tempos observados para as primeiras 10 crianças da coorte. O símbolo | indica o início do episódio (início do evento) e o símbolo o indica censura, que neste caso foi sempre ao término do estudo. Como uma mesma criança pode ter mais de um episódio de diarreia, trata-se de um exemplo de eventos recorrentes: a criança volta a fazer parte do grupo de risco, ao recuperar-se de um episódio de diarreia. Observe que logo após o início de cada episódio de diarreia há um pequeno intervalo que representa sua duração, durante o qual a criança não está em risco de um novo episódio.

Uma questão prática importante em um estudo como esse é a discriminação entre um evento e outro, o que nem sempre é claro. Observe a criança 4, por exemplo. Ela teve uma série de episódios de diarreia muito próximos, com intervalos de 2 ou 3 dias. Serão esses episódios separados ou será que deveríamos considerá-los como um episódio único de longa duração? Estas questões precisam ser respondidas antes do início de qualquer tentativa de modelagem, com base no conhecimento do pesquisador de seu objeto de estudo. A fragmentação indevida de um único episódio longo em vários eventos próximos pode inflacionar a taxa de incidência, uma vez que aumenta a frequência de tempos de sobrevivência pequenos.




Figura 10.5: Tempos observados entre episódios recorrentes de diarreia

Organização do banco de dados – eventos ordenados independentes

Observe os registros correspondentes à criança 2 da Figura 10.5. A variável *numcri* é o identificador de cada criança. A variável *ini* define a data de entrada ou de retorno da criança ao grupo em risco (de ter diarreia) e a variável *fim* determina o fim do período de risco, isto é, o início do episódio de diarreia. Assim, a criança *numcri*=2

(sexo feminino, grupo placebo) iniciou seu acompanhamento em $t = 1$ e ficou em risco até $t = 244$, quando teve seu primeiro episódio de diarreia ($status=1$). Essa criança, ao se recuperar, reingressa no grupo de risco no dia 247, quando começa a segunda linha do banco de dados. O segundo episódio ocorreu no dia 286 ($status=1$), durando até o dia 289, quando ela retorna ao grupo de risco. O terceiro episódio ocorreu no dia 291, durou dois dias (até o dia 293), e o quarto episódio foi no dia 361. Finalmente, ela retorna ao grupo de risco no dia 363 e permanece sem diarreia até a data final do estudo, quando sua observação é censurada ($status=0$).

```
> diarreia <- read.table("multdiarreia.txt",header=T)
```

numcri	grupo	sexo	idade	ini	fim	enum	status
2	pla	fem	48	1	244	1	1
2	pla	fem	48	247	286	2	1
2	pla	fem	48	289	291	3	1
2	pla	fem	48	293	361	4	1
2	pla	fem	48	363	379	5	0

Uma questão que precisa ser ressaltada no trato de eventos recorrentes é a duração do evento. Quando o evento é pontual, sem duração mensurável, como por exemplo um infarto do miocárdio, o tempo do indivíduo sob risco é “contínuo”, sem interrupção: o indivíduo pode ainda não ter se recuperado de um infarto, e já estar em risco de outro. Já eventos como diarreia têm duração com data de início e de fim. Durante esse intervalo de tempo, em que o indivíduo está passando pelo evento, ele é considerado fora de risco: não há possibilidade de iniciar um episódio de diarreia na vigência de outro.

10.5.1 Modelo AG

O quadro D da Figura 10.1 mostra, de forma esquemática, o modelo de eventos ordenados independentes. O indivíduo no estado inicial tem um risco $\lambda(t)$ de sofrer um evento. Após a ocorrência do evento, ele retorna ao estado inicial, com o mesmo risco $\lambda(t)$ de sofrer um novo evento. O pressuposto de risco igual para qualquer evento é

bastante forte, pois assume que o histórico do indivíduo não afeta o risco presente. Um tema que se poderia modelar com essa abordagem é o risco de engravidar, desde que a fertilidade não seja alterada pelo número de gestações e o período de observação seja curto o suficiente para não ser afetado pela idade.

Observe que no esquema da Figura 10.1 existem duas setas (em outras palavras, duas transições), mas só uma é associada a um risco $\lambda(t)$. Isso indica que somente há interesse em um tipo de transição. No exemplo da diarreia, a pergunta se refere ao risco de um episódio de diarreia e **não** aos fatores associados à duração do episódio de diarreia. Assim, o tempo que o indivíduo se encontra no segundo estado não é incorporado na análise. Observe na Figura 10.5 que os intervalos em que a criança está com diarreia, ou seja, o tempo em que ela está no estado A, é omitido do banco. Esse tempo é considerado um tempo censurado. Nada impede porém que se estude o risco de terminar o episódio de diarreia, ou o risco de receber alta. O banco de dados reflete a pergunta e deve ser construído de acordo com o objetivo do estudo. Também é possível modelar a probabilidade associada à transição entre estados, nos chamados modelos multiestados, que serão apresentados brevemente na Seção 11.7.

O modelo AG tem a seguinte expressão, utilizando a notação de processo de contagem:

$$\lambda_i(t|x_i(t)) = Y_i(t)\lambda_0(t)e^{\beta x_i(t)}, \quad (10.1)$$

em que $Y_i(t)$ é igual a 1 quando os indivíduos estão em risco, e igual a 0 nos períodos de duração da doença ou no fim do evento.

O modelo AG ajustado para modelar a diarreia infantil é apresentado a seguir. Os resultados indicam que o grupo placebo teve o risco mensal 17% maior de ter diarreia quando comparado às crianças que receberam suplementação de vitamina A. Já a idade se mostrou um fator protetor, diminuindo o risco de diarreia em 3,5% ($\exp(-\text{coef}) = 1.035$) para cada mês a mais na idade das crianças.

```
> diarreia$grupo <- relevel(diarreia$grupo,"vit")
> modeloAG <- coxph(Surv(ini,fim,status) ~ grupo + sexo + idade +
```

```

cluster(numcri), data=diarreia)
> summary(modeloAG)

[...]
```

	coef	exp(coef)	se(coef)	robust se	z	p
grupopla	0.1621	1.176	0.02911	0.06394	2.536	0.011
sexomasc	0.0597	1.061	0.02914	0.06398	0.933	0.350
idade	-0.0339	0.967	0.00122	0.00256	-13.265	0.000

	exp(coef)	exp(-coef)	lower .95	upper .95
grupopla	1.176	0.850	1.037	1.333
sexomasc	1.061	0.942	0.936	1.203
idade	0.967	1.035	0.962	0.971


```

Rsquare= 0.135    (max possible= 1 )

[...]
```

Retornando à definição do modelo AG, lembre-se que um dos pressupostos fundamentais é de que os tempos entre eventos de um mesmo indivíduo são independentes entre si. Como testar esse pressuposto? Bem, supor tempos independentes significa, em outras palavras, que não há uma estrutura de correlação das observações de um mesmo indivíduo, desde que as covariáveis incluídas no modelo expliquem as diferenças entre indivíduos. Se isso é correto, espera-se que a variância calculada assumindo-se independência entre todas as observações (modelo de Cox clássico) seja apenas um pouco menor que a variância robusta. Veja na saída do R acima que *robust se* é mais do que o dobro de *se(coef)*.

Observe novamente a saída do R do modelo que se encontra no objeto *modeloAG*. A variância robusta é duas vezes maior do que a variância estimada assumindo-se independência, o que sugere que, por algum motivo, o risco de sofrer novos episódios de diarreia é de alguma forma correlacionado aos episódios anteriores. Nesse caso, o modelo AG talvez não seja o mais indicado. Duas alternativas de modelagem devem ser experimentadas: o modelo estruturado PWP, apresentado a seguir, e o modelo com efeitos aleatórios do Capítulo 12.

Modelando eventos múltiplos no R

No R, o ajuste de modelos para eventos múltiplos é feito utilizando-se a mesma função `coxph()` utilizada para o modelo de Cox. As diferenças estão na formulação do modelo que, além das covariáveis, poderá incluir termos que permitam a inclusão de:

- Estratificação – `strata()`: permite que o risco basal varie entre os estratos, sem ordenação.
- Estratificação ordenada – `strata(1,2,3,...)`: risco de base varia obedecendo à variável indicadora de estrutura ordenada dos eventos.
- Variância robusta – `cluster(id)`: indica que o conjunto de linhas que tem o mesmo valor na variável `id` pertence à mesma pessoa.

10.6 Eventos ordenados estruturados

Os episódios de diarreia poderiam ter uma estrutura na qual o risco de um episódio aumentaria a cada novo episódio. Para verificar essa hipótese ajustamos um novo modelo aos dados de diarreia apresentados no Seção 10.5. A estrutura do banco de dados muda para incorporar a estratificação de risco gerada por cada novo episódio. Para isso uma variável de ordenação é criada, `enum`, e o modelo é ajustado estratificando-se por essa variável, de forma que riscos basais diferentes e ordenados sejam associados a cada evento.

10.6.1 Modelo PWP

A Figura 10.1, quadro E (p. 304) mostra a lógica conceitual do modelo estruturado ou PWP. Ao contrário do modelo anterior, nesse se assume que existe uma estrutura de dependência entre os tempos de um indivíduo. Isto é, considera-se que o risco $\lambda(t)$ do indivíduo sofrer o primeiro evento é diferente do risco de sofrer um segundo evento

(dado que sofreu o primeiro) e assim por diante, ou seja, $\lambda_1(t) \neq \lambda_2(t)$, e que o evento j somente ocorre após o evento $j - 1$ ter ocorrido.

O modelo de riscos proporcionais, neste caso, assume a forma:

$$\lambda_{ij}(t|x_i(t)) = Y_{ij}(t)\lambda_{0j}(t)e^{\beta x_i(t)}, \quad (10.2)$$

em que $\lambda_{ij}(t)$ é o risco do indivíduo i sofrer o evento j . Observe que neste caso, o índice j do evento é importante.

Na prática, o modelo estruturado assume que um indivíduo só estará em risco para o evento j após o evento $j - 1$. Na fórmula, isso implica dizer que $Y_{ij}(t) = 0$ até que o evento j ocorra e então se torne 1.

A incorporação da estrutura nos eventos ordenados é feita através da variável `enum`, presente no banco de dados apresentado na p. 314 para os dados da diarreia. Verifique que essa variável respeita a ordenação dos tempos de ocorrência da diarreia.

```
> modeloPWP <- coxph(Surv(ini,fim,status) ~ grupo + sexo +
  idade + strata(enum) + cluster(numcri), data=diarreia)
> summary(modeloPWP)
```

[...]

	coef	exp(coef)	se(coef)	robust se	z	p
grupopla	0.0470	1.048	0.02991	0.03574	1.31	0.19
sexomasc	0.0529	1.054	0.02974	0.03571	1.48	0.14
idade	-0.0160	0.984	0.00132	0.00153	-10.48	0.00

	exp(coef)	exp(-coef)	lower .95	upper .95
grupopla	1.048	0.954	0.977	1.124
sexomasc	1.054	0.948	0.983	1.131
idade	0.984	1.016	0.981	0.987

```
Rsquare= 0.027 (max possible= 0.999 )
Likelihood ratio test= 155 on 3 df, p=0
Wald test = 112 on 3 df, p=0
Score (logrank) test = 154 on 3 df, p=0, Robust = 105 p=0
[...]
```

Observe como as estimativas dos coeficientes se modificaram em relação ao modelo de eventos ordenados independentes (`modeloAG`). A variância robusta também ficou mais próxima da variância

que assume independência entre todas as observações (modelo de Cox clássico). Agora observe na Figura 10.6 as estimativas do risco basal acumulado para diarreia, segundo os dois modelos. O modelo AG estima uma única curva de risco basal, que pode ser interpretada como uma média dos riscos basais de cada evento. Já o modelo PWP ajusta uma curva para cada episódio de diarreia. Veja como o risco basal de um novo episódio aumenta conforme o número de episódios já sofridos. Parece, a partir desta figura, que o pressuposto de eventos ordenados independentes não é o mais adequado para esses dados.




Figura 10.6: Risco basal acumulado para ocorrência de novo episódio de diarreia: à esquerda, segundo o modelo de eventos ordenados independentes (AG); à direita, para cada episódio segundo a ordem de ocorrência. Note que o risco de acontecer um novo episódio aumenta conforme o número de episódios anteriores

10.7 Como escolher o modelo marginal

Novamente: não existem modelos perfeitos, mas modelos úteis. Além dos critérios apresentados para orientar a seleção e o ajuste dos modelos, outras questões devem ser consideradas, por exemplo, a ausência de covariáveis importantes. Nesse caso, sugere-se utilizar modelos com efeitos aleatórios que serão apresentados no Capítulo 12. O

ajuste dos modelos vistos neste capítulo depende de uma formatação apropriada do banco de dados e da inclusão, no modelo de Cox, de função para a correção da variância e para a estratificação, ordenada ou não, conforme o caso.

Sugerimos como estratégia para ajustar esses modelos:

- Pensar bem sobre o modelo conceitual para o problema, incluindo a avaliação do risco basal para cada evento, presença de covariáveis que mudam no tempo e definição de duração do evento. A construção do banco de dados pode ser trabalhosa e é uma etapa sujeita a erros. Por isso, defina cuidadosamente qual o modelo que será ajustado.
- É interessante nessa etapa inspecionar o gráfico de sobrevivência (ou risco) segundo os eventos observados. Esse gráfico pode indicar diferença no risco basal entre os tipos de eventos.
- Construir o banco de dados de acordo com o modelo conceitual, sempre verificando, em alguns (muitos, se possível) indivíduos, a estrutura temporal, a variável indicativa de censura, o tempo que indica término do estudo, as mudanças de covariáveis no tempo, a variável indicativa de estrato.
- Ajustar o modelo de Cox simples até o primeiro evento ou até cada um dos eventos paralelos.
- Corrigir a estimativa de variância, calculando variância robusta através do argumento `cluster()` caso necessário.
- Inspecionar as curvas de estimador não paramétrico para os eventos, e verificar se o risco basal pode ou não ser considerado igual para todos os eventos. Se o risco basal difere, deve-se introduzir a estratificação através do argumento `strata()`.
- Verificar as premissas e o ajuste do modelo escolhido.

Modelo AG e PWP no R

Nos dois modelos é indispensável utilizar a forma `Surv(inicio,fim,status)`, que ordena os eventos naturalmente. O argumento `cluster()` deve ser incluído para cálculo da variância robusta. O banco de dados terá a mesma forma do banco para covariáveis mudando no tempo. Por isso mesmo esses modelos incorporam facilmente esse tipo de covariável.

```
> modelo.AG <- coxph(Surv(inicio,fim,status)~ cov1 +
  cov2 +...+ cluster(id), data = banco))
```

No modelo PWP inclui-se também o termo de estratificação ordenada.

```
> modelo.PWP <- coxph(Surv(inicio,fim,status)~ cov1 +
  cov2 +...+ cluster(id) + strata(enum),
  data = banco))
```

Em ambos os casos a variável `id` é a variável indicativa do indivíduo.

A verificação das premissas é feita da mesma forma como foi apresentado no Capítulo 7. Nos modelos que utilizam a função de estratificação (`strata()`), a variável de estratificação obviamente não tem parâmetro de associação estimado. Logo, nesses casos, é necessário verificar a proporcionalidade das demais variáveis somente dentro de cada estrato, exatamente como no modelo de Cox com variáveis que mudam no tempo. No modelo AG, a única questão nova introduzida é a correção da variância através da função `cluster()`. Ou seja, não há qualquer impedimento para a verificação da proporcionalidade da forma já discutida no Capítulo 7.

Resumo

As principais características dos modelos de eventos múltiplos são:

Modelo	Evento	Risco de base
Eventos paralelos	Desfechos independentes, em número variável	Pode variar entre os desfechos
AG	Eventos independentes ordenados no tempo	Não varia de um evento para o outro
PWP	Assume dependência entre os eventos	Variável, cada evento pertence a um estrato

As estruturas dos bancos de dados estão apresentadas no quadro a seguir. Para eventos paralelos, a princípio, somente estão no grupo de risco os indivíduos que em algum momento futuro sofrerão alguns dos eventos em estudo. No caso de eventos ordenados, no exemplo com dois indivíduos, o primeiro sofreu o mesmo evento três vezes nos tempos 12, 33, 54 e o segundo indivíduo sofreu o evento apenas uma vez no tempo 20 e foi censurado no tempo 43. A pergunta em relação a quem está em risco em algum momento serve para conferir se o banco foi construído corretamente.

Grupo de risco: quem está sob risco no dia 38 quando um indivíduo experimentava a segunda ocorrência do evento?

AG: todos os indivíduos em observação no dia 38.

PWP: todos os indivíduos em observação no dia 38 que tenham experimentado a primeira ocorrência do evento e que ainda não tenham experimentado a segunda ocorrência do evento.

O quadro a seguir ilustra o formato do banco de dados para análise de eventos múltiplos.

Modelo	ind	ini	fim	tempo	status	estrato
Evento	1	-	-	9	1	A
Paralelo	1	-	-	11	1	C
com ou sem	1	-	-	15	1	C
estratificação	2	-	-	14	1	C
	2	-	-	14	1	A
	3	-	-	12	1	B
AG	1	0	12	-	1	-
sem	1	12	33	-	1	-
estratificação	1	33	54	-	1	-
	2	3	20	-	1	-
	2	20	43	-	0	-
PWP	1	0	12	-	1	1
estrato	1	12	33	-	1	2
ordenado	1	33	54	-	1	3
	2	3	20	-	1	1
	2	20	43	-	0	2

Sintaxe no R

Paralelo:

```
> coxph(Surv(tempo,status) ~ covariaveis +
  cluster(id) + strata(evento), data = dados1)
```

AG:

```
> coxph(Surv(ini,fim,status) ~ covariaveis +
  cluster(id), data = dados2)
```

PWP:

```
> coxph(Surv(ini,fim,status) ~ covariaveis +
  cluster(id) + strata(evento), data = dados2)
```

Exercícios

10.1 Em um estudo de fertilidade, acompanhou-se uma coorte de mulheres por 48 meses para medir o tempo desde o parto até a próxima concepção, junto com covariáveis potencialmente associadas ao risco de engravidar. Para cinco mulheres, as seguintes datas de concepção foram registradas (em meses desde o primeiro parto):

Mulher	Tempo até a próxima concepção (meses)			Estado	Contra-
	2ª gestação	3ª gestação	4ª gestação		
1	5	30		Casada	Não
2	12	41		Casada	Não
3				Solteira	Sim
4	2	24	43	Casada	Não
5	32			Solteira	Sim

Considerando que cada mulher retorna ao grupo sob risco de gravidez exatamente 10 meses após a concepção:

- (a) Faça, à mão, um gráfico das trajetórias das cinco mulheres. Use o gráfico referente aos dados de reincidência de diarreia como exemplo.
- (b) Concepção é um evento múltiplo ordenado. Neste capítulo, foram apresentados dois modelos marginais para eventos ordenados. Discuta os pressupostos assumidos em cada um deles para estimar o efeito das covariáveis indicativas do estado civil e do uso de contraceptivo no risco de engravidar.
- (c) Organize uma planilha para esses dados de forma a poder ajustar um modelo de eventos independentes ordenados no tempo (modelo AG).
- (d) Organize uma planilha para esses dados, como eventos ordenados estruturados, para que se possa ajustar um modelo PWP.

10.2 Um exemplo de evento ordenado é a reinternação hospitalar. Se o risco de reinternação for independente do fato de o indivíduo ter sofrido uma internação anterior, então o modelo de incrementos independentes é apropriado. Se esse pressuposto não for aceitável, então o modelo condicional é mais apropriado. O Apêndice.12.4 descreve um banco de dados (*reint.csv*) de pacientes que tiveram pelo menos uma internação em um hospital público regional.

- (a) Ajuste um modelo de incrementos independentes, com as covariáveis sexo e idade.
- (b) Que pressuposto está sendo assumido ao se utilizar esse modelo?
- (c) Compare as estimativas de variância. Como você interpreta esse modelo?
- (d) Você sugeriria outro modelo mais apropriado para descrever o risco de nova reinternação?

- (e) Ajuste um modelo condicional aos dados e interprete-o.

Dica

- Para corrigir a variância e indicar que há repetição de linhas para cada paciente use o termo `cluster` (variância robusta):

```
> modelo <- coxph(Surv(tempo,status) ~ sexo + variavel +
  cluster(id), data = arquivo)
```
- Para incluir a estrutura de dependência (modelo PWP) utilize-se o termo `strata=enum`, onde a variável `enum` está ordenada sequencialmente.

10.3 Um pesquisador estuda fatores de risco associados à ocorrência de doenças oportunistas em pacientes com Aids (banco de dados *oportunista.csv* – seção Aids, doenças oportunistas do Apêndice). Para isso, ele acompanha uma coorte de pacientes na qual registrou a data do diagnóstico da Aids (que define o início do período de acompanhamento – *ini*) e as datas de ocorrência das doenças de interesse: alterações hematológicas (*Hemato*), herpes (*Herpes*), tuberculose (*Tuberc*), pneumocistose (*Pneumocist*) e candidíase (*Candida*).

- (a) Liste as primeiras 10 linhas e descreva o que aconteceu com os pacientes 1 a 4. Observe a variável *status*, cujo valor é sempre 1. O que isso quer dizer em termos da composição do grupo sob risco?
- (b) Ajuste um modelo separadamente para os desfecho *Hemato*, *Herpes* e *Candida*. Além de sexo e idade, estime o efeito das covariáveis relacionadas a comportamento de risco (*udi* e *sexual*).

- (c) Compare o modelo acima com uma abordagem alternativa, na qual o efeito das covariáveis é modelado simultaneamente para os três desfechos, porém permitindo um risco basal diferente para cada doença oportunista.

Dica

- Use o comando `subset=` para separar os subconjuntos dos pacientes em relação a cada desfecho de interesse.

```
> modelo.categorial <- coxph(Surv(tempo,status) ~ var,  
  data=banco, subset=(condição))
```

- A condição para criar o subconjunto cria um vetor lógico (Verdadeiro e Falso). Pode-se usar igual `==`, diferente `(!=)`, maior `(>)` ou menor `(<)`.

11

Eventos competitivos

Coautor: *Antonio Guilherme Pacheco*

O objetivo deste capítulo é capacitar o leitor a:

Indicar as diversas abordagens para análise de eventos competitivos.

Definir conceitualmente os diversos modelos, descrever seus pressupostos e propriedades.

Indicar o tipo de modelo adequado a cada situação observada.

Ajustar os modelos utilizando o R.

Interpretar as estimativas ajustadas em cada modelo.

11.1 Introdução

Um problema clássico na modelagem do tempo de sobrevivência são os eventos ditos **competitivos**, nos quais somente é possível observar o tempo até a ocorrência do primeiro (e único) evento, que impede

que outros aconteçam. Assim, é como se eles competissem entre si, daí o porquê do nome.

Por exemplo, deseja-se modelar o efeito de fatores de risco, digamos a obesidade, para óbito por duas causas: acidente vascular cerebral ou infarto agudo do miocárdio, obviamente excludentes. Ou estudar as causas de óbitos relacionadas ou não à imunodeficiência em pacientes infectados pelo HIV: causas ligadas à Aids competem com outras causas, entre as quais as doenças cardiovasculares. Ou ainda queremos estudar diferentes desfechos em pacientes hemodialisados: óbito ou transplante renal. Essas são situações nas quais só é possível observar o tempo até a ocorrência de um dos eventos.

Observe, porém, que há diferenças conceituais. No primeiro caso, supõe-se que o mesmo fator de risco, a obesidade, contribui para a ocorrência dos dois eventos terminais. Já o perfil de pacientes transplantados é, em parte, oposto ao dos pacientes que morrem devido a complicações da doença renal terminal. Por exemplo, à medida que aumenta a idade, aumenta o risco para óbito e diminui a chance de transplante. Essas questões devem ser cuidadosamente consideradas ao se definir o modelo adotado.

Cabe observar que, excetuando-se razões administrativas, por exemplo o término do estudo, qualquer causa de censura durante o tempo de observação pode ser interpretada como um evento competitivo. Ou seja, a censura em um certo tempo t impede que um indivíduo sofra o evento, por exemplo, o óbito por uma determinada causa durante o período de seguimento. Conceitualmente é equivalente à morte por uma outra causa no mesmo tempo t . Ao considerar como censurado o tempo de um paciente que faleceu por outra causa, na prática significa assumir que essa outra causa não está associada à causa em estudo. Ou seja, adotando-se a formulação clássica do modelo de Cox esse tempo é considerado censura não informativa, o que, a rigor, raramente acontece.

11.2 Conceitos básicos

Na presença de riscos competitivos, cada indivíduo está simultaneamente em risco para k eventos, e a ocorrência de um elimina a chance de qualquer outro. Esquematicamente, este modelo pode ser representado como mostra a Figura 11.1, a mesma apresentada no Capítulo 10. Ao entrar no estudo, o indivíduo se encontra no estado vivo, isto é, ele se encontra em risco para os k eventos alternativos. O risco de sofrer o evento A é $\lambda_A(t)$, de sofrer o evento B é $\lambda_B(t)$, e assim por diante. Isso é indicado pelas setas, que indicam as transições possíveis. A passagem de um indivíduo para um novo estado (óbito pela causa A , por exemplo) é definitiva, e os demais estados não podem mais acontecer.




Figura 11.1: Representação gráfica em multiestados para eventos competitivos

Na ausência de riscos competitivos, mas com censura, uma maneira mais imediata e fácil de descrever os dados é por meio do gráfico da função de sobrevivência $S(t)$, calculada pelo estimador de Kaplan-Meier. Na presença de riscos competitivos, entretanto, a função de distribuição acumulada ($F(t)$ calculada dessa forma) será superestimada. Ou seja, $F(t)$, que é simplesmente igual a $1 - S(t)$ (ver Capítulo 3), não será mais uma função de distribuição de proba-

bilidades acumulada propriamente dita. Na prática, isso quer dizer que quando calculamos a $F(t)$ para todos os eventos competitivos juntos e depois comparamos com o somatório das funções de distribuição acumulada de cada evento $F_k(t)$, essa soma será maior que a $F(t)$ global. Nesse caso, $\sum_k F_k(t)$ pode inclusive ultrapassar o valor 1, o que não faz sentido para uma função de distribuição acumulada.

Suponha um exemplo simples com dois eventos competitivos A e B, onde a ocorrência de um deles exclui, por definição, a ocorrência de outro. Considerando que, por definição $S(t) + F(t) = 1$, quando comparamos graficamente $S_A(t)$ (sobrevivência do evento A) com a $F_B(t)$ (função de distribuição acumulada do evento B) esperamos que essas linhas nunca se cruzem, ou seja a sua soma nunca ultrapasse o valor 1.

Vamos visualizar esse fenômeno, utilizando um exemplo simples de 20 pacientes internados em um hospital, onde se observa o tempo decorrido entre a internação e dois possíveis desfechos: alta e óbito. Todos os pacientes sofrem um desses eventos, ou seja, não há censura. Esses dados estão descritos na Tabela 11.1.

A Figura 11.2 apresenta as curvas das funções de sobrevivência, de distribuição acumulada acumulada e as funções de incidência acumuladas para os dados apresentados na Tabela 11.1. No gráfico (a) vemos a $F(t)$ estimada pelo método de Kaplan-Meier considerando-se a função de distribuição acumulada global para ambos os desfechos. Sobrepostas a essa curva estão as curvas de F_{alta} e $F_{\text{óbito}}$ separadamente, supondo que não existe evento competitivo. Para isso é necessário censurar o desfecho alta para calcular $F_{\text{óbito}}$ e vice-versa, sendo essa a forma mais tradicional de lidar com eventos competitivos.

Entretanto, comparando a função de distribuição acumulada do óbito – $F_{\text{óbito}}(t)$ – com a função de sobrevivência da alta – $S_{\text{alta}}(t)$ – vê-se que as duas curvas se cruzam (Figura 11.2, gráfico (c)). Ou seja, a soma dos valores das funções de distribuição acumulada para cada desfecho individual é maior que os valores para a função de distribuição acumulada quando se leva em conta ambos os desfechos

Tabela 11.1: Tempos de alta ou óbito para 20 pacientes

Paciente	Tempo	Evento	Paciente	Tempo	Evento
1	38	alta	11	48	alta
2	28	alta	12	15	óbito
3	7	óbito	13	33	alta
4	63	alta	14	22	óbito
5	19	óbito	15	11	alta
6	32	óbito	16	18	alta
7	13	alta	17	13	alta
8	1	alta	18	18	óbito
9	29	alta	19	14	óbito
10	47	alta	20	4	alta

ao mesmo tempo. Consequentemente, a estimativa dessas funções em separado é enviesada.

11.2.1 Funções de incidência acumuladas

Para contornar o problema mencionado anteriormente, foi proposto a utilização de funções de incidência acumuladas (FIA), também chamadas de subdistribuições, que levam em conta não apenas o desfecho estudado, mas a totalidade dos desfechos, que no nosso exemplo simples são alta e óbito. A ideia aqui é que, para estimar corretamente o risco do óbito, a alta é um evento competitivo, e vice-versa. A cada momento olhamos para um dos eventos como de interesse, e para os demais como competitivos.




Figura 11.2: Exemplo de eventos competitivos para os dados da Tabela 11.1. No gráfico (a) estão as curvas $F(t)$, $F_{\text{Alta}}(t)$ e $F_{\text{Óbito}}(t)$ e no gráfico (c) estão as $F_{\text{Óbito}}(t)$ e $S_{\text{Alta}}(t)$ estimadas de forma tradicional pelo Kaplan-Meier. Nos gráficos (b) e (d) estão desenhadas as mesmas curvas, utilizando o método de estimação baseado em subdistribuições (FIA)

Observe no gráfico (c) da Figura 11.2 como a decomposição de $F(t)$ agora é perfeita e igual à soma de $F_{\text{alta}}(t)$ e $F_{\text{óbito}}(t)$. Além disso, como pode-se observar no gráfico (d), as curvas $F_{\text{óbito}}(t)$ e $S_{\text{alta}}(t)$ nunca se cruzam. Nessa abordagem, a soma das subdistribuições será exatamente a $F(t)$ global. Vale assinalar que as subdistribuições também não são funções de distribuição acumuladas, pois, como veremos a seguir, na presença de eventos competitivos elas nunca alcançam a unidade.

Vejam os mais formalmente como a função de incidência acumulada é definida. Sejam $0 < t_1 < t_2 < \dots < t_m$ os tempos ordenados da ocorrência de qualquer um dos eventos e $d_k(t_j)$ o número de pessoas que experimentaram o evento k no tempo t_j . O total de ocorrência por todos os eventos no tempo t_j é:

$$d(t_j) = \sum_{k=1}^K d_k(t_j).$$

Seja ainda $R(t_j)$ o número de pacientes ainda sob risco no tempo t_j . Lembrando então do estimador de Kaplan-Meier, podemos definir uma probabilidade geral de sobrevivência, isto é, sobrevivência a toda e qualquer causa como:

$$\hat{S}(t) = \prod_{j:t_j \leq t} \left(\frac{R(t_j) - d(t_j)}{R(t_j)} \right).$$

A FIA pode então ser calculada como a soma em todos os tempos t_j das probabilidades de se observar o evento k no tempo t_j entre indivíduos que não experimentaram qualquer dos possíveis eventos. A probabilidade de estar livre de qualquer evento antes do tempo t_j é dada por $\hat{S}(t_{j-1})$. Logo, a probabilidade acumulada de se sofrer o evento k e estar livre de qualquer evento em t , será:

$$\widehat{F}_k(t) = \sum_{\forall j, t_j \leq t} \hat{\lambda}_k(t_j) \hat{S}(t_{j-1}),$$

sendo $\lambda_k(t_j)$ o risco da causa específica para o evento k no tempo t_j . Como os indivíduos ainda sob risco não sofreram nenhum evento até

o tempo t_{j-1} , o risco pode ser calculado por $d_k(t_j)/R(t_j)$. Então, a FIA é uma proporção entre o número de indivíduos que sofreram o evento k e todos aqueles que não sofreram evento algum até aquele momento.

Utilizando a mesma ideia, pode-se desenvolver modelos de regressão baseados na mesma proposta de subdistribuições, uma vez que o modelo clássico de riscos proporcionais de Cox não permite estimar adequadamente o efeito de covariáveis quando os eventos são competitivos.

Assumindo o caso mais simples, temos um evento de **interesse**, outro evento **competitivo** e ainda alguns casos com censura não informativa. O modelo para tratar os riscos competitivos baseia-se na equação:

$$\lambda(t|\mathbf{x}) = \lambda_0(t) \exp(\mathbf{x}\boldsymbol{\beta}),$$

na qual λ é a função de risco da subdistribuição, λ_0 é a função de risco basal, $\mathbf{x}$ é o vetor de covariáveis e $\boldsymbol{\beta}$ é o vetor de coeficientes que desejamos estimar. A função de verossimilhança parcial desse modelo é bastante parecida com a que já foi vista para o modelo de riscos proporcionais apresentada no Capítulo 6.

A principal diferença está no conceito de grupo sob risco $R(t_j)$ para cada evento. Chamemos de evento de **interesse** aquele para o qual estamos estimando o modelo, e de evento **competitivo** os demais, considerados aqui como potenciais introdutores de viés das estimativas. Em primeiro lugar, a população sob risco $R^*(t_j)$ agora inclui, além de todos os indivíduos que não sofreram qualquer evento, todos os que sofreram o evento competitivo, e que até a censura administrativa não saem do conjunto de risco. Entretanto, não faz sentido que esses indivíduos contribuam para $R^*(t_j)$ da mesma forma que os demais. Por isso se atribui aos que sofreram um evento competitivo um peso que muda a cada tempo t_j no qual ocorre o evento de interesse.

Assim, indivíduos que sofreram o evento competitivo antes da ocorrência de qualquer evento de interesse nos pontos $t_j > t_i$ permanecem no grupo de risco, mas não contribuem de maneira integral para a função de verossimilhança. Cada indivíduo recebe um peso

sempre que ocorre um evento de interesse. Esse peso, denominado $w_l(t_j)$, de cada indivíduo l a cada momento t_j no qual ocorre um evento de interesse é definido como:

$$w_l(t_j) = \begin{cases} 1, & \text{se } l \text{ não tiver sofrido evento ou censura;} \\ \frac{\hat{G}_{\text{km}}(t_j)}{\hat{G}_{\text{km}}(t_i)}, & \text{se } l \text{ sofreu evento competitivo em } t_i < t_j; \\ 0, & \text{quando o indivíduo é retirado do estudo.} \end{cases} \quad (11.1)$$

Na prática, dizer que o peso é zero equivale a retirar o indivíduo l do banco de dados a partir do momento em que ele sofre o evento de interesse ou é censurado por qualquer motivo que não algum evento competitivo.

Essa ponderação decrescente foi definida tendo por base a curva observada de sobrevivência das censuras, considerando como censuras tudo que não for evento. Ou seja, no cálculo de $G(\cdot)$ censura vira evento, evento (qualquer que seja) vira censura, e a função de sobrevivência $\hat{G}_{\text{km}}(\cdot)$ é estimada de forma não paramétrica (Kaplan-Meier). Quando um evento competitivo ocorre no tempo $t_i < t_j$, o ponderador $w_l(t_j)$ recebe no denominador o valor da função de sobrevivência das censuras estimadas no ponto t_i , onde l sofreu seu evento competitivo, e por isso esse valor é sempre o mesmo para cada indivíduo. No numerador considera-se a função de sobrevivência das censuras a partir do ponto t_i onde o indivíduo l sofreu seu evento competitivo. Em síntese, a permanência dos indivíduos que sofreram o evento competitivo no grupo de risco é tanto menor quanto mais distante do evento de interesse, obedecendo à própria estimativa de decaimento no tempo dada pela estimativa de Kaplan-Meier das censuras.

Observe que censuras, por qualquer motivo, podem ser tratadas como eventos competitivos. Cabe ao pesquisador definir os casos em que a censura pode ser considerada realmente independente do evento em estudo.

As várias formas de se analisar problemas que tenham riscos competitivos serão apresentadas nas próximas seções. Vamos nos ater às três abordagens mais comuns:

- sobrevivência até o primeiro entre os desfechos, também denominada de *event-free survival* em inglês;
- o risco específico por causa;
- a modelagem da subdistribuição do risco.

As duas primeiras abordagens, como veremos, não necessitam de conceitos adicionais, já que são baseadas exclusivamente nos modelos clássicos já vistos em outros capítulos do livro.

11.3 Sobrevivência livre de eventos

Vamos iniciar a modelagem de eventos competitivos utilizando a abordagem por sobrevivência livre de eventos, ou seja, quando consideramos o tempo até o primeiro evento, independentemente de qual dos eventos competitivos ocorre. Esta abordagem faz sentido clínico no caso de um evento composto no qual qualquer um dos eventos é de interesse, quando se estuda vários possíveis efeitos de um fator de risco. Por exemplo, estudar o efeito do tabagismo sobre dois desfechos: infarto agudo do miocárdio e acidente vascular cerebral. Vale ressaltar, porém, que a variável independente na qual estamos interessados deve estar associada a todos os eventos competitivos na mesma direção – risco ou proteção – e nosso interesse é o efeito médio sobre qualquer um dos eventos. Associações divergentes não são interpretáveis, pois qual sentido teria estimar um efeito médio de 1, 1, combinando risco de 1, 4 com proteção de 0, 7?

O modelo marginal para riscos competitivos tem a mesma formulação do modelo de Cox clássico estratificado, pois permite que o risco basal seja diferente para os desfechos A e B. Assim, $\lambda_A(t) \neq \lambda_B(t)$, e estima-se o efeito médio das covariáveis para to-

dos os possíveis desfechos:

$$\begin{aligned}\lambda_A(t|\mathbf{x}) &= \lambda_{0A}(t) \exp(\mathbf{x}\boldsymbol{\beta}) \\ \lambda_B(t|\mathbf{x}) &= \lambda_{0B}(t) \exp(\mathbf{x}\boldsymbol{\beta}) \\ &\vdots \\ \lambda_K(t|\mathbf{x}) &= \lambda_{0K}(t) \exp(\mathbf{x}\boldsymbol{\beta})\end{aligned}$$

Mas, como no caso dos eventos competitivos cada indivíduo sofre no máximo um evento, já que por definição a ocorrência de um evento impede a ocorrência de outro, esse problema se reduz, na verdade, a uma análise de sobrevivência clássica. O evento de interesse é o primeiro a ocorrer, e analisa-se o tempo até esse evento. Outras formas de fazer essa análise, usando um banco longo com linhas repetidas para cada possível desfecho, e estratificando por cada tipo de desfecho, inclusive censura, são apresentadas em alguns livros (Therneau, 2000). Os resultados são exatamente iguais aos apresentados aqui, e por isso ficamos com essa abordagem mais simples.

Exemplo

Entre os pacientes com insuficiência renal, em hemodiálise, cria-se uma fila aguardando potencial doador. Em alguns casos, a doação surge rapidamente, seja da família ou de doador desconhecido. Outras vezes, o paciente morre por doença renal ou outra causa antes de obter um rim compatível. Assim, o paciente na fila de espera está em risco para três eventos que competem entre si: transplante, óbito por insuficiência renal, óbito por causa não relacionada à insuficiência renal. A ocorrência de um dos eventos exclui a possibilidade de ocorrência de outros eventos, ou seja, os eventos são **competitivos**. É claro que o paciente submetido a transplante renal também está sob risco de óbito, mas estamos analisando apenas os pacientes em hemodiálise, e o transplante retira o paciente deste grupo.

Queremos saber os efeitos das covariáveis idade e doença causadora da insuficiência renal para esses três eventos. Cabe questionar se interessa estimar o efeito comum das variáveis para transplante

renal e óbito, pois, embora competitivos, têm fatores de risco diferentes. Para o transplante, o paciente deve estar em bom estado geral, sendo usualmente mais jovem. Por outro lado, idade mais avançada é fator de risco para óbito. Além da idade, a causa da insuficiência renal está associada ao desfecho: diabetes tende a aumentar o risco de óbito por qualquer causa relacionada ou não à diálise, e doenças congênitas apresentam efeito protetor. Ainda assim, vamos ao exemplo.

Os dados deste estudo encontram-se em *dialcompete.dat* (Apêndice, seção Diálise – eventos competitivos). A hipertensão foi escolhida para categoria de base por ser a mais frequente e apresentar, em geral, risco intermediário entre as várias causas de insuficiência renal. A variável *status* indica se o evento ocorreu ou se houve censura. Além disso, a variável *motivo* do banco de dados indica o tipo de desfecho:

- óbito por insuficiência renal → *obrenal*;
- óbito por causa não relacionada à insuficiência renal → *oboutra*;
- transplante → *transpl*;
- *censura*.

```
> compete <- read.table("dialcompete.dat", header=T)
> compete$doenca <- relevel(compete$doenca, ref="hiper")
> dim(compete)
```

```
[1] 2453 6
```

```
> compete[1:5,]
```

	id	idade	doenca	motivo	tempo	status
1	1	50	outr	obrenal	27	1
2	2	51	hiper	censura	28	0
3	3	30	diab	transpl	18	1
4	4	33	diab	oboutra	14	1
5	5	35	diab	obrenal	1	1

As estimativas do modelo para qualquer que seja o primeiro evento a ocorrer entre os três desfechos potenciais – óbito por falência renal, óbito por outra causa e transplante – são apresentadas a seguir:

```
> sobre.livre <- coxph(Surv(tempo,status) ~ idade + doenca,
  data=compete)
> sobre.livre
```

```
[...]
              coef exp(coef) se(coef)      z      p
idade          0.0113    1.011  0.00285  3.976 0.00007
doencacong     0.1626    1.177  0.23711  0.686 0.49000
doencadiab     0.5121    1.669  0.11608  4.411 0.00001
doencaoutr    -0.0602    0.942  0.12731 -0.473 0.64000
doencarim     -0.1350    0.874  0.09478 -1.424 0.15000
[...]
```

A interpretação dos parâmetros é a mesma do modelo de Cox clássico. Para cada ano de vida a mais, o risco aumenta em 1,1%. Somente a doença de base diabetes se mostrou um fator de risco se comparada com a hipertensão. Mas risco de quê? De vir a fazer transplante ou de vir a morrer? Um leitor mais atento pode se perguntar: se são três desfechos possíveis, essas medidas de risco relativo se referem a qual deles? Bem, elas são estimativas médias para qualquer um dos três desfechos. O modelo ajustado sugere que o paciente que chegou à insuficiência renal por causa do diabetes tem um risco 66% maior de vir a óbito ou de ser transplantado do que um paciente cuja causa é a hipertensão.

Essa abordagem é talvez a mais usada, pela sua simplicidade. Mas como já mencionamos, não resolve a questão de que essas doenças causadoras da insuficiência renal podem estar associadas de maneira diferente com cada um dos diversos desfechos. Nesse caso, devemos abordar o problema de outra forma, buscando ver o efeito das variáveis para cada um dos desfechos separadamente.

11.4 Risco específico por causa

No caso do modelo de riscos específicos, a ideia é estimar o efeito de uma covariável sobre um desfecho específico, onde tratamos os demais

desfechos simplesmente como censura não informativa, mesmo que possivelmente não o sejam. Todos os pacientes que sofreram eventos que não o que estamos estudando são censurados nesse momento. A maneira mais intuitiva de fazer isso é trabalhando com o banco no formato clássico, simplesmente censurando os desfechos que não são os de interesse e olhando os efeitos isoladamente.

Exemplo

Para simplificar, vamos investigar apenas o papel do diabetes, sem considerar as demais doenças de base. Nesse caso, é necessário ajustar três modelos separadamente, um para cada desfecho:

Call:

```
coxph(formula = Surv(tempo, motivo == "obrenal") ~ I(doenca=="diab"),
      data = compete)
               coef exp(coef) se(coef)      z      p
I(doenca == "diab")TRUE 1.04      2.82    0.152 6.82 8.9e-12
Likelihood ratio test=37.7 on 1 df, p=8.34e-10 n= 2453,
               number of events= 268
```

Call:

```
coxph(formula = Surv(tempo, motivo == "oboutra") ~ I(doenca=="diab"),
      data = compete)
               coef exp(coef) se(coef)      z      p
I(doenca == "diab")TRUE 0.909      2.48    0.17 5.34 9.3e-08
Likelihood ratio test=23.5 on 1 df, p=1.23e-06 n= 2453,
               number of events= 227
```

Call:

```
coxph(formula = Surv(tempo, motivo == "transpl") ~ I(doenca=="diab"),
      data = compete)
               coef exp(coef) se(coef)      z      p
I(doenca == "diab")TRUE -1.18      0.307    0.453 -2.6 0.0093
Likelihood ratio test=10.1 on 1 df, p=0.0015 n= 2453,
               number of events= 191
```

O resultado indica aquilo que já desconfiávamos: o diabetes tem efeito muito diferente, inclusive quanto à direção, dependendo

do desfecho estudado. Aumenta o risco de morrer, seja pela própria insuficiência renal ou por outra causa, e diminui a chance de transplante. O mesmo raciocínio pode ser feito em relação à idade, uma vez que se espera um efeito diferencial para cada um dos desfechos e não um efeito único na mesma direção para os desfechos conjugados. Analisando conjuntamente idade e causa da insuficiência renal, obtemos os resultados apresentados na Tabela 11.2.

Tabela 11.2: Efeito das variáveis idade e diabetes como causa da insuficiência renal para três desfechos possíveis em pacientes hemodialisados: óbito por causa renal, óbito por outra causa e transplante

Desfecho	Variáveis	Risco Relativo	Intervalos de Confiança de 95%
Óbito Renal	Idade	1,026	1,017 ; 1,035
	Diabetes	2,249	1,656 ; 3,054
Óbito Outras Causas	Idade	1,042	1,033 ; 1,052
	Diabetes	1,765	1,258 ; 2,476
Transplante	Idade	0,958	0,948 ; 0,968
	Diabetes	0,468	0,191 ; 1,144

Observe que o diabetes mais do que dobra o risco de morrer por causa renal, e aumenta também o risco de óbito por outras causas, como esperado. Em relação ao transplante, ainda que a direção seja oposta, o efeito do diabetes não é significativo. Na verdade, apenas cinco indivíduos que tinham diabetes como doença de base foram transplantados. Também como esperado, a idade apresenta um efeito diferente para cada desfecho, aumentando o risco para óbito e diminuindo a chance de transplante. Embora o efeito seja pequeno, ele

está expresso para cada ano de vida e, portanto, é bastante significativo.

Nessa abordagem, entretanto, não podemos estimar o efeito comum de qualquer variável para desfechos competitivos, por exemplo, o efeito da diabetes para o óbito, seja por doença renal ou por qualquer outra causa. E as curvas da função de distribuição acumulada para cada desfecho, uma vez que são estimadas separadamente, se somadas, não são iguais à curva global. Além disso, e mais importante, para que as estimativas de associação sejam válidas, os tempos entre o evento de interesse e os competitivos devem ser independentes, o que frequentemente não é verdade.

Usando vetores lógicos em modelos no R

Como tudo no R, existem muitas maneiras de se fazer a mesma coisa. O código usado anteriormente permite que se estime os modelos, sem quaisquer alterações no banco, em uma linha de comando apenas. Foram usados os seguintes recursos:

- dentro da função `Surv(tempo,status)` – um vetor lógico que terá o valor `TRUE`, ou seja `status=1`, para o desfecho escolhido (`motivo=="obrenal"`) e `FALSE` (`status=0`) para os demais desfechos, inclusive a censura;
- na equação da regressão o mesmo expediente de gerar um vetor lógico foi aplicado para selecionar apenas uma das diversas categorias da variável como `sim`, ficando todas as demais como `não`;
- a função `()` dentro da equação do modelo diz simplesmente ao R que o que está dentro da função deve ser interpretado literalmente. Esse recurso é usado, por exemplo, para indicar quando se deseja fazer uma operação aritmética dentro da equação e não tratar cada termo da operação como uma variável independente.

11.5 Subdistribuições dos riscos

Agora que vimos as duas abordagens mais tradicionais para modelar eventos competitivos, vamos estudar a modelagem com o método descrito da subdistribuição dos riscos. Uma vantagem deste método é que ele não supõe, ao contrário da abordagem anterior, que os eventos competitivos sejam independentes – o que é bastante óbvio no caso dos dados que estamos analisando.

Exemplo

Primeiramente, vamos reorganizar o nosso banco de dados da diálise. A variável *status* terá agora tantos valores quantos forem os possíveis desfechos, incluindo censura. Como a variável *motivo* é categórica, a forma mais simples de transformá-la em numérica é apresentada a seguir. É sempre bom conferir se a nova codificação ficou correta, e se a censura ficou codificada com o valor zero.

```
> compete$status1 <- as.numeric(competes$motivo) - 1
> table(competes$motivo)
```

```
censura oboutra obrenal transpl
  1767      227      268      191
```

```
> table(competes$status1)
```

```
    0    1    2    3
1767 227 268 191
```

O gráfico (b) da Figura 11.2 apresentado na Seção 11.2 é feito com os comandos a seguir, agora para os dados da diálise. Versões mais recentes da biblioteca *survival* (testamos com a versão 2.36-8) permitem estimar a incidência acumulada por causa específica, utilizando o argumento *etype*.

```
> fia <- survfit(Surv(tempo,event=status1>0) ~ 1, etype=motivo,
  data=competes)
```

```
> plot(fia, ylab="FIA", xlab="Meses", fun="event", lty=c(2,1,4),
      ylim=c(0,.5))
> legend("topleft", c("Óbito Renal", "Outro Óbito", "Transplante"),
      lty=c(1,2,4), title="Tipo de desfecho", bty="n")
```




Figura 11.3: Função de incidência acumulada para pacientes em hemodiálise segundo os três desfechos estudados

Note que a Figura 11.3 indica as curvas de risco para os tipos de desfechos, sem levar em conta nenhuma covariável. A figura sugere que o risco de morrer, seja por causa associada à doença renal, seja por outra causa é maior do que obter um transplante.

Assim como nas análises clássicas de Kaplan-Meier, é possível observar a diferença na associação entre covariáveis categóricas e as várias curvas da função de incidência acumuladas. Podemos, por exemplo, avaliar se o efeito do diabetes varia segundo o desfecho, e visualizar as curvas de sobrevivência segundo a categoria para cada FIA. Na Figura 11.4 é possível ver a diferença entre ter ou não diabetes para cada um dos três desfechos analisados. Muito cuidado na hora de definir a legenda, pois as linhas são desenhadas dentro de cada categoria (ter ou não diabetes) por desfecho. Já para a legenda pode-se desejar outra ordem, como sugerido nos comandos a seguir:

```

> fia.diab <- survfit(Surv(tempo,event=status1>0) ~
  I(competes$doenca=="diab"), etype=motivo, data=competes)
> plot(fia.diab,ylab="FIA", fun="event", xlab="Meses", mark.time=F,
  ylim=c(0,0.5), lty = c(2,1,4,2,1,4), lwd = c(1,1,1,2,2,2))
> legend("topleft", c("Outro Óbito: com diabetes","sem diabetes",
  "Óbito Renal: com diabetes","sem diabetes",
  "Transplante: com diabetes","sem diabetes"), lty = c(2,2,1,1,4,4),
  lwd = c(2,1,2,1,2,1), bty="n")

```




Figura 11.4: Função de incidência acumulada para pacientes em hemodiálise para os três desfechos segundo a presença de diabetes registrada como causa da insuficiência renal

Observe que quando a doença de base não é o diabetes, as curvas são muito semelhantes, para qualquer um dos três desfechos. Evidentemente, se colocarmos o foco nas demais causas aparecerá efeito semelhante ao do diabetes. Por exemplo, pacientes com doenças congênitas têm maior chance de receber transplante do que pacientes cuja causa da insuficiência renal é a hipertensão. Mas essa análise ficará para os exercícios.

Como a função `survdiff()` para testar se há diferença significativa entre as categorias não está disponível para eventos competitivos, utilizaremos uma forma diferente, apresentada adiante.

Função de incidência acumulada no R

Para ajustar a função de incidência acumulada utilizando a biblioteca *survival* basta acrescentar o argumento *etype=* ao vetor onde estão registrados os diferentes eventos. Como a variável *status* pode ter tantos valores quantos desfechos possíveis, é necessário indicar no argumento *event=* da função *Surv()* os valores indicativos de evento, com o mesmo tipo de vetor lógico apresentado na p. 344.

```
> incid.acumulada <- survfit(Surv(tempo, event=status>0) ~
  covariável, etype=desfecho, data=dado)
> plot(incid.acumulada, fun="event", ylab = "FIA",
  xlab = "Tempo", lty=c(1,2,3,4))
> legend("local", legend=c("Desfecho 1: categoria 1",
  "Desfecho 2: categoria 1", "Desfecho 1: categoria 2",
  "Desfecho 2: categoria 2"), lty=c(1,2,3,4) )
```

O próximo passo é fazer a modelagem baseada na subdistribuição do risco, na qual se pode estimar o efeito de covariáveis para cada um dos desfechos estudados, levando-se em consideração os riscos competitivos, como descrito no início deste capítulo. Para isso utilizaremos a função *crprep* da biblioteca *mstate*, que calcula os pesos como descrito na Equação 11.1. Como o peso de cada indivíduo vai mudando à medida que ocorrem eventos competitivos, o banco precisa ser reorganizado como um banco de variável mudando no tempo, com *Surv(time1=inicio, time2=fim, event=status)*. Além disso, a função calcula os pesos considerando cada possível evento como de interesse, sendo os demais considerados competitivos. Ou seja, o novo banco fica com um grande número de linhas, onde cada paciente terá tantas linhas quantos mudanças de peso, repetindo o mesmo procedimento para cada evento de interesse.

Aplicando a função ao nosso banco da diálise (*compete*) passamos de 2.453 indivíduos a 42.949 linhas:

```
> compete.peso <- crprep(Tstop="tempo", status="status1", trans=1:3,
  id="id", keep=c("idade", "doenca", "motivo"), data=compete)
> dim(compete); compete[1:6,]
```

```
[1] 2453      7
```

	id	idade	doenca	motivo	tempo	status	status1
1	1	50	outr	obrenal	27	1	2
2	2	51	hiper	censura	28	0	0
3	3	30	diab	transpl	18	1	3
4	4	33	diab	oboutra	14	1	1
5	5	35	diab	obrenal	1	1	2
6	6	34	hiper	censura	43	0	0

```
> dim(competes.peso)
```

```
[1] 42949      10
```

```
> competes.peso[which(competes.peso$id==3),]
```

	id	Tstart	Tstop	status	weight.cens	[...]	motivo	count	failcode
	3	0	18	3	1.00000000		transpl	1	1
	3	18	19	3	0.98223538		transpl	2	1
	3	19	20	3	0.97177812		transpl	3	1
[...]									
	3	40	42	3	0.57428300		transpl	24	1
	3	42	43	3	0.00474614		transpl	25	1
	3	0	18	3	1.00000000		transpl	1	2
	3	18	19	3	0.98223538		transpl	2	2
	3	19	20	3	0.97177812		transpl	3	2
[...]									
	3	41	42	3	0.57428300		transpl	24	2
	3	42	43	3	0.00474614		transpl	25	2
	3	0	18	3	1.00000000		transpl	1	3

Observe que no novo banco de dados (*competes.peso*), o mesmo indivíduo (variável *id=3*) se repete em três blocos diferentes, que correspondem aos três desfechos. O que identifica cada bloco é a variável *failcode*. O indivíduo 3 foi transplantado no tempo $t = 18$. Ele permanece no banco de dados até o final do estudo, ou seja, até o último mês de observação. À medida que o tempo avança, depois que ele experimentou o seu desfecho, o peso $w_i(t_j)$, registrado na variável

weight.cens, diminui. Após o seu transplante em $t = 18$ ocorreram vários eventos em outros indivíduos, originando 25 tempos distintos. Esses tempos estão ordenados pela variável *count*, em cada bloco. Os tempos inicial e final de cada trecho no qual o peso é calculado são indicados nas variáveis *Tstart* e *Tstop*.

Preparação do banco de dados usando a biblioteca *mstate* do R

A única função da biblioteca *mstate* usada para modelos competitivos é a *crprep*, que calcula os pesos e prepara o banco de dados para a análise. Os principais argumentos são:

- *Tstop*= o vetor de tempos até o evento ou censura;
- *status*= o status, com tantos valores possíveis quanto desfechos, sendo a censura por *default* zero;
- *data*= o banco de dados já com a variável *status* com múltiplas categorias;
- *trans*= os valores de interesse para cálculo dos pesos (pode-se optar por usar somente alguns dos desfechos registrados);
- *id*= identificador do indivíduo;
- *keep*= as covariáveis que devem ser mantidas do banco original.

A função *crprep*, resumidamente, executa as seguintes ações:

- acrescenta linhas para cada indivíduo, após a ocorrência do seu desfecho, a cada momento onde ocorre eventos competitivos;
- cria as variáveis *TStart*, *TStop* que contém respectivamente o momento de início e fim de cada intervalo de tempo entre dois eventos competitivos;
- cria a variável *count*, que ordena os tempos de ocorrência de eventos competitivos posteriores;

- calcula os pesos para cada indivíduo conforme a Equação 11.1;
- cada desfecho competitivo é registrado na variável *failcode*.

Agora, com os dados preparados de forma adequada, fica fácil estimar os modelos utilizando as subdistribuições do risco com as usuais funções da biblioteca *survival*. Para isto, basta indicar os pesos, e selecionar o evento de interesse.

Exemplo

Retornemos ao problema anterior: testar se há diferença significativa entre as categorias ter ou não diabetes para cada desfecho. Lembrando do Capítulo 6, a estatística *score* do modelo semiparamétrico, que é indicada na saída da função *summary()* do modelo de Cox é exatamente o resultado do teste de log-rank comparando o modelo ajustado com o modelo nulo. Assim, para testar se ter ou não diabetes é significativamente diferente, considerando cada desfecho competitivo, basta olhar o resultado do teste log-rank do modelo somente com essa variável. O teste tem distribuição qui-quadrado com tantos graus de liberdade quantas categorias menos um, no caso apenas um grau de liberdade (ter ou não diabetes). Lembre-se que cada desfecho deve ser avaliado em separado. Por isso o indicador *failcode* deve ser usado para criar o subconjunto sobre o qual se ajusta o modelo, ou seja, qual é o desfecho de interesse. Fazendo apenas para o desfecho óbito por outra causa (*failcode=1*), teremos um valor altamente significativo. O mesmo p-valor que pode ser visto do sumário da função *coxph()*.

```
> teste.1 <- coxph(Surv(Tstart,Tstop,status==1) ~ I(doenca=="diab"),
  data=subset(competes.peso,failcode==1), weights=weight.cens)$score
```

```
[1] 23.30328
```

```
> 1 - pchisq(teste.1,1)
```



```
[1] 1.383636e-06
```

Analisando agora o modelo com idade e doença de base para o desfecho *obrenal* – óbitos associados à insuficiência renal:

```
> obitrim.cmp <- coxph(Surv(Tstart,Tstop, motivo=="obrenal") ~
  idade + doenca, data=compete.peso, subset=failcode==2,
  weights=weight.cens)
```

Call:

```
coxph(formula = Surv(Tstart, Tstop, motivo == "obrenal") ~ idade +
  doenca, data = compete.peso, weights = weight.cens,
  subset = failcode == 2)
```

	coef	exp(coef)	se(coef)	z	p
idade	0.0216	1.022	0.0045	4.794	1.6e-06
doencacong	0.2489	1.283	0.3457	0.720	4.7e-01
doencadiab	0.6098	1.840	0.1651	3.694	2.2e-04
doencaoutr	-0.2035	0.816	0.2126	-0.957	3.4e-01
doencarim	-0.4404	0.644	0.1662	-2.650	8.1e-03

Ajuste de modelo de Cox com subdistribuições da função de risco no R

A aplicação da função *coxph()* sobre o novo banco criado pela função *crprep()* tem as seguintes peculiaridades:

- o nome das variáveis de tempo são sempre *Tstart* e *Tstop*;
- o status é indicado por vetor lógico de forma a selecionar qual evento é o de interesse;
- o vetor de pesos está no banco preparado com o nome *weight.cens*;
- deve-se indicar sobre qual subconjunto se deseja ajustar o modelo, usando *subset=failcode==x*.

```
> mod.cmp <- coxph(Surv(Tstart,Tstop, status=riscocmp=="xx") ~
  covariáveis, data=banco.ponderado, subset=failcode==x,
  weights=weight.cens)
```

Os resultados apresentados na Tabela 11.3 permitem comparar os modelos de subdistribuição de riscos com os modelos de riscos específicos, nos quais os eventos competitivos são tratados como simples censuras. Nesse exemplo os resultados usando as subdistribuições foram mais conservadores. O efeito do diabetes como causa da insuficiência renal indica um risco 1,8 vezes maior, enquanto é quase o dobro na modelagem do risco específico. Evidentemente, os resultados dependem da distribuição dos eventos competitivos nos estratos das covariáveis. Mas é importante notar que as diferenças não são muito marcantes, apesar de presentes, pelo fato da incidência tanto do desfecho de interesse quanto dos eventos competitivos, principalmente, ser relativamente baixa.

Tabela 11.3: Comparação das estimativas segundo diferentes abordagens de modelos para eventos competitivos

Modelo	Variável	Óbito Renal	Outra Causa	Transplante
FIA	Idade	1,022*	1,041*	0,954*
	Congênita	1,283	0,601	2,486*
	Diabetes	1,840*	1,493*	0,406
	Renal	0,644*	0,813	1,198
	Outras	0,816	1,033	0,945
Risco	Idade	1,024*	1,042*	0,957*
	Congênita	1,278	0,637	2,458*
	Diabetes	1,982*	1,636*	0,503
Específico	Renal	0,641*	0,781	1,144
	Outras	0,824	1,030	0,930
Número de eventos		268	227	191

* Valores significativos a 5%

11.6 Verificação dos pressupostos do modelo

Os pressupostos para os modelos de eventos competitivos são os mesmos que já foram discutidos para os modelos clássicos, e tanto a proporcionalidade dos riscos quanto a linearidade em variáveis contínuas e ainda a análise de pontos de influência devem ser feitas da mesma forma já estudada. Como o modelo foi ajustado utilizando a função `coxph()`, todas as funções de análise de resíduos da biblioteca `survival` podem ser aplicadas da mesma forma.

Para analisar o ajuste dos modelos, vamos ajustar um modelo completo, de risco específico para óbito por doença renal.

```
> obitrim.espec <- coxph(Surv(tempo,motivo=="obrenal") ~ idade +
  doenca, data=compete)
> obitrim.espec
```

[...]	coef	exp(coef)	se(coef)	z	p
idade	0.0237	1.024	0.00456	5.186	2.2e-07
doencacong	0.2449	1.278	0.34581	0.708	4.8e-01
doencadiab	0.6836	1.981	0.16510	4.141	3.5e-05
doencaoutr	-0.1937	0.824	0.21268	-0.911	3.6e-01
doencarim	-0.4445	0.641	0.16628	-2.673	7.5e-03
[...]					

```
> cox.zph(obitrim.espec)
```

	rho	chisq	p
idade	0.05247	0.770077	0.3802
doencacong	-0.00127	0.000432	0.9834
doencadiab	-0.10404	2.971168	0.0848
doencaoutr	0.00903	0.021921	0.8823
doencarim	0.05485	0.809530	0.3683
GLOBAL	NA	5.154046	0.3974

O resíduo de Schoenfeld aponta que o teste de correlação linear do resíduo com o tempo é marginalmente significativo para diabetes no modelo de risco específico. Vejamos então a mesma análise para o modelo baseado nas subdistribuições de risco:

```
> cox.zph(obitrim.cmp)
```

	rho	chisq	p
idade	0.02835	0.21832	0.640
doencacong	-0.00425	0.00483	0.945
doencadiab	-0.12416	4.25961	0.039
doencaoutr	0.01274	0.04365	0.835
doencarim	0.05878	0.92929	0.335
GLOBAL	NA	6.95059	0.224

A diabetes relacionada à insuficiência renal, ajustando modelo de riscos competitivos com subdistribuições, parece não ter comportamento proporcional no tempo de sobrevivência.

O gráfico do resíduo de Schoenfeld (Figura 11.5) dos dois modelos é muito semelhante. Os intervalos de confiança do modelo de risco específico são um pouco maiores, mas sempre incluem a linha do coeficiente, como no outro gráfico. Nenhum dos dois sugere desvio importante do pressuposto de riscos proporcionais.




Figura 11.5: Resíduos de Schoenfeld para modelo risco específico e para subdistribuições da função de risco

Todas as demais funções para análise de resíduos funcionam da mesma forma. E a solução de um eventual problema de proporcionalidade, por exemplo, passa pelas mesmas soluções discutidas anteriormente: particionar o tempo ou usar modelos de tempo de vida acelerado.

11.7 Desenvolvimentos recentes

São suposições usuais em análise de sobrevivência, mesmo quando se trata de eventos múltiplos:

- sujeitos saudáveis ou doentes, sem estados intermediários;
- o tempo até o evento é conhecido com precisão;
- o evento é conhecido sem possibilidade de erro de classificação.

Entretanto, na maior parte das doenças crônicas há uma evolução clara, com um conjunto de estados que podem (ou não) progredir. Além disso, a própria identificação de um determinado estado em um indivíduo muitas vezes se caracteriza por pontos de corte relativamente arbitrários, e está sujeita a erro.

Por exemplo, na análise da sobrevivência de pacientes após transplante de medula óssea, consideramos a doença de enxerto como sendo uma covariável associada ao tempo até o óbito. Entretanto, pode-se abordar a própria doença do enxerto como parte do caminho do paciente até o óbito ou a recuperação. Assim, algumas variáveis podem estar associadas à ocorrência da doença do enxerto, e esse estado tem uma probabilidade de transição para a cura ou óbito (Figura 11.6). Observe que alguns caminhos não são possíveis, por exemplo, do transplante direto à doença do enxerto crônica. Além disso o estado *recuperação plaquetária*, por exemplo, é definido por valores na contagem de plaquetas que dependem de um exame, no qual erros de medida podem acontecer. Ou seja, alguns pacientes podem ser erroneamente classificados em um estado quando na verdade não chegaram a ele.

Uma abordagem recentemente desenvolvida para esse tipo de análise são os denominados modelos multiestados. A diferença com relação aos modelos de eventos múltiplos apresentados no livro é a possibilidade de estudar diferentes desfechos, alguns dos quais são eventos intermediários entre dois outros estados. Essa técnica tem grande potencial, especialmente frente a problemas cuja cadeia causal




Figura 11.6: Exemplo de cadeia causal para a TMO com diversos estados

percorre um trajeto longo e complexo. Abordagens como a denominada *Life Course Epidemiology*, para serem implementadas em pesquisas, da coleta de dados à análise, deverão utilizar modelos desse tipo.

A ideia básica é que o indivíduo se move através de uma série de estados em tempo contínuo, sendo possível estimar as probabilidades de transição entre os estados e o efeito das covariáveis associados a cada transição.

Diversas bibliotecas relativamente novas foram desenvolvidas no R para análise de sobrevivência multiestado. Entre outras, a *msm* e a *mstate*, essa última com funções que auxiliam a estruturação de bancos de dados para análise de eventos múltiplos. Entretanto, apesar do grande interesse despertado, na prática, os modelos ainda são de difícil especificação, com problemas para a estimação. Acreditamos que em breve será possível incorporá-los ao conjunto de ferramentas da análise de sobrevivência.

Resumo

Eventos competitivos podem ser analisados de três formas:

- **sobrevivência livre de eventos:** modelo de Cox clássico até o primeiro evento, seja qual for;
- **risco específico por causa:** modelo de Cox considerando um dos eventos como principal e os demais como censuras;
- **subdistribuições dos riscos:** ajuste do modelo utilizando função de incidência acumulada.

Funções de incidência acumuladas (FIA), também chamadas de subdistribuições, ponderam e levam em conta não apenas o desfecho estudado, mas a totalidade dos desfechos. No modelo de Cox estendido, incluindo as subdistribuições, ao sofrer um dos eventos competitivos o indivíduo não é censurado completamente, mas recebe um peso que decai gradativamente.

Exercícios

11.1 Os dados do estudo dos pacientes em hemodiálise para fins desse exercício estão no banco *dialcompete.dat* (Apêndice.12.4).

- (a) Liste as primeiras 25 linhas e descreva o que aconteceu com os pacientes 4, 5, 6 e 8;
- (b) Descreva como deve ser codificada a variável **status** no banco de dados para análise de eventos competitivos, para cada tipo de abordagem: até o primeiro evento; risco específico; subdistribuições de risco.

- (c) Quais das abordagens para análise de eventos competitivos seriam mais apropriadas para estes dados? Por que?

11.2 Podemos dizer que uma criança ao nascer está em risco para dois eventos competitivos, com relação a uma doença imunoprevenível: adquirir imunidade induzida pela vacina ou adquirir imunidade induzida pela doença. Ambos os desfechos, assumindo imunidade duradoura, retiram a criança do grupo sob risco de adquirir imunidade (um terceiro desfecho que tiraria a criança do grupo sob risco seria óbito por qualquer causa). Suponha que 1.000 crianças tenham sido acompanhadas a partir do nascimento até completarem 5 anos e que as datas da vacinação e da infecção ou censura tenham sido registradas. A tabela a seguir mostra os dados de algumas crianças.

Criança	Idade (meses)	Evento	Sexo	Pré-natal
1	5	Infecção	M	Não
2	6	Vacina	M	Sim
3	4,5	Vacina	F	Sim
4	12	Vacina	F	Não
5	9	Mudou endereço	F	Não
6	60	Fim do estudo	M	Sim
7	5,6	Óbito	M	Sim

- (a) Como deveriam ser organizados os dados para ajustar um modelo de Cox considerando subdistribuições de risco?
- (b) Como você classificaria a criança 7: evento competitivo ou censura? Que critério você usaria para definir se é um ou outro?
- (c) Descreva o modelo a ser ajustado no R para estimar o efeito da covariável pré-natal no risco de adquirir imunidade por qualquer causa, e separadamente por doença ou por vacina.

- (d) Descreva o modelo a ser ajustado no R para estimar o efeito da covariável pré-natal sobre o risco de adquirir imunidade, considerando subdistribuições do risco para cada desfecho. Indique como usar os argumentos *trans*, *id*, *keep* da função *crprep*. O que estaria registrado na variável *failcode*?

11.3 O banco de dados sobre eventos competitivos em Aids contém variáveis adaptadas a partir de uma coorte de pacientes infectados pelo HIV atendidos no Hospital Universitário Clementino Fraga Filho da UFRJ, com três desfechos possíveis: óbito relacionado à Aids, óbito não relacionados à Aids, além da censura (*competeaids.dat* – Apêndice.12.4). Analise a sobrevivência dos pacientes usando as abordagens discutidas nesse capítulo.

- (a) Ajuste e faça o gráfico da função de incidência acumulada para cada evento.
- (b) Avalie a significância estatística do *sexo* do paciente para cada desfecho considerado.
- (c) Compare o efeito da variável que mede o CD4 no início do seguimento no modelo de Cox clássico, considerando o óbito seja qual for a causa, com o modelo de risco específico por causa.
- (d) Observe o banco criado com a função *crprep*. Qual o nome da variável que registra o peso atribuído a cada indivíduo quando ele sofre o evento competitivo?
- (e) Ajuste um modelo de Cox com subdistribuições da função de risco, usando o banco criado.
- (f) Verifique os pressupostos do modelo de Cox – proporcionalidade de riscos, valores aberrantes, efeito de alavanca, e forma funcional de cada variável – do modelo ajustado no item anterior para todas as covariáveis.
- (g) Comente o impacto do uso dos modelos para eventos competitivos nesse estudo.

Dicas

- Para ajustar a função de incidência acumulada para cada evento utiliza-se a função `survfit()`, tratando o evento competitivo por meio do argumento `etype`.

```
> aids.cumul <- survfit(Surv(tempo, event=statusc>0) ~ 1,
  etype=statusc, data=dado)
```

- Pode-se ajustar modelos de risco específico recodificando o status por meio de vetores lógicos (página 348).
- O banco para ajustar o modelo de Cox com subdistribuições do risco é criado por meio da função `crprep()`.
- Para testar a significância de uma variável use o modelo de Cox somente com a variável em questão e verifique o escore registrado na saída do modelo.

```
> banco$tempo <- banco$fim - banco$ini
> banco.peso <- crprep(Tstop="tempo", status="statusc",
  trans=1:2, id="id", keep=c("var1", "var2",...),
  data=banco)
> teste.evento1.var <- coxph(Surv(tempo,status==1) ~ var,
  data=subset(banco.peso,failcode==1),
  weights=weight.cens)$score
> teste.evento2.var <- coxph(Surv(tempo,status==2) ~ var,
  data=subset(banco.peso,failcode==2),
  weights=weight.cens)$score
```

- O modelo de Cox é ajustado utilizando o banco criado pela função `crprep()`. As análises de resíduos são feitas da mesma forma anterior.

```
> modelo.compete <- coxph(Surv(Tstart,Tstop,
  status="condição") ~ var1 + var2 +...,data=banco.peso,
  subset=failcode==x, weights=weight.cens)
```


12

Fragilidade

Ao término do Capítulo 12, espera-se que o leitor seja capaz de:

Conceituar fragilidade ou efeito aleatório.

Indicar a inclusão de efeitos aleatórios na modelagem da sobrevivência, quando necessário.

Identificar as distribuições mais utilizadas e as formas de estimação do efeito aleatório.

Ajustar os modelos utilizando o R.

Interpretar as estimativas obtidas no ajuste de modelo com efeitos aleatórios.

12.1 Introdução

Para se estudar a sobrevivência de pacientes em hemodiálise, considerando que mais de 90% da terapia renal substitutiva realizada no país é financiada pelo SUS, decidiu-se utilizar as informações disponibilizadas pelo Sistema de Informações Ambulatoriais para Procedimentos de Alto Custo (Apac). Entre os fatores individuais reconhecidamente relacionados ao tempo de sobrevivência, e disponíveis nesse

sistema, estão a idade (quanto mais jovem maior a sobrevivência) e a doença de base, sendo a hipertensão a causa mais frequente de insuficiência renal, e tendo a diabetes o pior prognóstico. Evidentemente, a situação socioeconômica dos pacientes também se associa com a sobrevivência dos pacientes dialisados, refletindo, entre outros aspectos, o acesso a outros recursos de saúde.

A análise da sobrevivência dos pacientes poderia ser feita simplesmente aplicando-se o modelo de Cox. Entretanto, a falta de covariáveis importantes, como, por exemplo, o estado nutricional e o status socioeconômico, limita a capacidade explicativa do modelo. Isso se reflete na variabilidade das observações, que é muito maior que a esperada e afeta a estimação. Os pacientes apresentam grande **heterogeneidade** ou diferentes **fragilidades** não atribuíveis a qualquer característica medida. Eventualmente essa variabilidade poderá ser explicada através da inclusão de novas covariáveis. No entanto, se essa heterogeneidade é atribuída à variabilidade genética dos indivíduos, no atual estágio do conhecimento não há uma variável que possa medi-la diretamente. De qualquer forma, esta é uma situação muito comum nos mais diferentes problemas médicos: a cura inexplicável ou o agravamento clínico incompreensível.

Qual seria a solução, então? Obter informações cada vez melhores, sem dúvida. Mas, frequentemente, mesmo com a inclusão de todas as covariáveis reconhecidamente influentes, o tempo de sobrevivência pode ter uma variabilidade que é substancialmente maior do que a explicada pelo modelo. Essa variabilidade é usualmente denominada superdispersão.

Esse problema, comum em várias áreas da estatística, pode ser tratado com a introdução de um **efeito aleatório** para cada paciente que tornam as estimativas dos efeitos das covariáveis mais consistentes. Ou seja, ainda que estejam faltando algumas informações importantes, pelo menos para as variáveis medidas pode-se estimar o parâmetro e erro-padrão associado de forma mais precisa. Ao se incluir o efeito aleatório no modelo, a estimativa pontual se altera proporcionalmente à sua importância – quanto maior o efeito aleatório, maiores tendem a ser os intervalos de confiança para os parâmetros estimados. O ajuste mais conservador do modelo não aumenta a nossa

compreensão dos mecanismos que influenciam a sobrevivência, mas aumenta a confiança nas estimativas sobre o que foi possível medir.

Comparemos, apenas para exemplificar, o modelo de sobrevivência ajustado no Capítulo 6 para o Transplante de Medula Óssea (Apêndice, seção Transplante de medula óssea), com e sem efeito aleatório. Na Tabela 12.1 pode-se observar que, de forma geral, o erro-padrão aumenta. As alterações na estimativa pontual são pequenas e em diferentes direções. A alteração mais importante é na significância da fase da doença, que passa de 0,05 para 0,06. Ainda assim, considerando o número reduzido de observações, essa diferença é pequena.

O uso de efeito aleatório de grupo é, a nosso ver, mais interessante. Consideremos que no estudo da hemodiálise o objetivo principal seja identificar quais características dos serviços de diálise estão relacionadas ao tempo de sobrevivência dos pacientes. Evidentemente, modelar separadamente cada centro não permitiria a comparação entre eles. Por outro lado, para estimar o risco de cada centro, necessitaríamos incluí-los como uma variável *dummy* no modelo, o que significa 66 novas variáveis no estado do Rio de Janeiro, que em 2003 tinha 67 centros de hemodiálise. Além disso, se incluirmos a unidade como uma covariável, não podemos avaliar o efeito das covariáveis deste nível. Para exemplificar, suponha que se deseja verificar se o tamanho da unidade, que pode ser medido pelo número de máquinas de diálise, tem algum impacto na sobrevivência. Se incluirmos essa covariável não podemos incluir a própria unidade como variável, pois a unidade e a variável do nível da unidade teriam sempre o mesmo valor, totalmente iguais. Nesse caso, ou se inclui a unidade ou a variável relacionada à unidade. Entretanto, é razoável supor que os pacientes que fazem diálise na mesma unidade recebam tratamentos mais parecidos do que pacientes que são atendidos em diferentes unidades. Do ponto de vista estatístico, isso significa que deve existir uma estrutura de correlação intragrupo indicando que os pacientes de uma mesma unidade devem ter algum grau de semelhança no risco decorrente de fatores relacionados à performance da unidade.

Esse é um problema típico dos estudos **multinível**, aqui em um contexto de modelos de sobrevivência. A forma de incluir cova-

Tabela 12.1: Comparação de resultados utilizando modelo de Cox clássico e modelo com fragilidade individual para análise do exemplo da TMO

Variável	Modelo	Efeito	Erro-padrão	p-valor
Idade	Clássico	0,996	0,0149	0,77
	Fragilidade	0,995	0,0159	0,73
Sexo Masc.	Clássico	1,254	0,3329	0,50
	Fragilidade	1,222	0,3517	0,58
Fase Inicial	Clássico	0,358	0,5264	0,05
	Fragilidade	0,349	0,5326	0,06
Fase Interm.	Clássico	0,679	0,5440	0,48
	Fragilidade	0,699	0,5890	0,54
Doença Aguda	Clássico	3,501	0,3307	0,00
	Fragilidade	3,775	0,3548	0,00
Doença Crônica	Clássico	0,376	0,3404	0,00
	Fragilidade	0,339	0,3327	0,00

riáveis que pertencem a um nível de agregação dos indivíduos, útil na modelagem tanto da heterogeneidade não observada entre grupos quanto da estrutura de correlação intragrupos, é incluir um efeito aleatório de grupo. No exemplo, esse efeito aleatório permite mensurar o perfil de risco das unidades, controlando-o pelas variáveis de cada paciente e pelas variáveis disponíveis para cada centro.

12.2 Modelo de fragilidade

Na análise de sobrevivência, a forma de inclusão de efeitos aleatórios parte do modelo de riscos proporcionais com o efeito aleatório atuando multiplicativamente sobre o risco de base, da mesma forma que as covariáveis observadas. Assim, muito do que foi visto até agora, por exemplo, proporcionalidade dos riscos ou covariáveis mudando no tempo, continua válido. Neste capítulo, a teoria será apresentada mais formalmente, exigindo do leitor maior familiaridade com resultados estatísticos e com a notação matricial.

Note que se a forma de tratar a sobrevivência já considerar o indivíduo como um agrupamento de observações, como nos modelos de eventos múltiplos, não será possível incluir um efeito aleatório para esse nível. Mas, se o efeito aleatório que se deseja modelar está relacionado com um grupo de indivíduos, não há qualquer problema. Teoricamente, é possível incluir dois níveis de efeito aleatórios, por exemplo, o do indivíduo e o da unidade, ainda que a estimação seja mais difícil.

Partindo do modelo de Cox clássico, a inclusão de efeitos aleatórios será feita a partir de Z , uma variável aleatória desconhecida, que reflete a fragilidade do indivíduo ou do grupo, com média igual a um e variância ξ . Os altos valores de ξ indicam grande heterogeneidade entre os indivíduos ou grupos e baixos valores indicam pouca heterogeneidade, ou seja, é desnecessário incluir este termo aleatório no modelo. Assim, para um indivíduo com covariáveis representadas pelo vetor $\mathbf{x}$ e efeito aleatório $Z = z$, o modelo de riscos proporcionais passa a ser:

$$\lambda(t) = z\lambda_0(t)\exp(\mathbf{x}\boldsymbol{\beta}). \quad (12.1)$$

Observe que os indivíduos ou grupos com fragilidades acima de um tendem a experimentar o evento com uma taxa mais rápida que sob o modelo de Cox clássico. Por outro lado, aqueles com fragilidades menores do que um teriam tempos maiores até o evento. Quando a variância ξ de Z se aproxima de zero, o modelo se reduz ao modelo de Cox clássico.

Para estimar a variância ξ do efeito aleatório é necessário, em primeiro lugar, escolher uma distribuição estatística para a variável aleatória Z . As distribuições mais usadas na literatura são a gama e a lognormal. A escolha da distribuição gama facilita a implementação de algoritmos para ajuste do modelo, pois pode-se demonstrar que, se a distribuição da fragilidade entre os que sofreram o evento em um dado tempo é gama, então entre os sobreviventes também será. A distribuição lognormal não possui tal propriedade, porém também é uma boa escolha quando as fragilidades estão relacionadas a covariáveis perdidas, digamos x_m . Nesse caso, dada a relação $Z = \exp(x_m\beta_m)$, ao aplicarmos o teorema do limite central a $x_m\beta_m$, teremos uma distribuição lognormal para Z .

A suposição da distribuição da fragilidade precisa ter plausibilidade biológica, e tanto a distribuição gama quanto a lognormal permitem essa aproximação, pois são bastante flexíveis. Dependendo dos valores de seus parâmetros, as distribuições variam desde uma forma exponencial até uma curva em forma de sino similar à curva normal.

As duas distribuições são caracterizadas por dois parâmetros. Na gama eles serão aqui denotados por γ e α , sendo γ o parâmetro de forma e α o de escala, que se relacionam com o valor esperado e a variância como segue:

$$\begin{aligned} E(Z) &= \gamma\alpha \\ Var(Z) &= \gamma\alpha^2. \end{aligned}$$

Assumindo-se que $\gamma = 1/\xi$ e $\alpha = \xi$, tem-se que $E(Z) = 1$ e $Var(Z) = \xi$, como requerido. Observe que quando o efeito aleatório médio é igual a um, isso significa que não há impacto na sobrevivência média. Caso o efeito aleatório de cada indivíduo ou grupo seja maior que um, tem-se um risco relativo maior e vice-versa. A variância do efeito aleatório será maior ou menor dependendo da dispersão do risco atribuído à fragilidade. A Figura 12.1 apresenta, à esquerda, o gráfico da função de densidade de probabilidade da distribuição gama com média unitária para diversos valores de variância ξ .

A forma da curva sugere que uma pequena proporção de indivíduos terão fragilidades muito altas, acima de dois, ou seja, com risco superior a duas vezes o risco médio dos indivíduos, o que é bastante coerente com o que se espera observar na prática. Note que a obtenção de um número excessivo de valores extremos indica uma necessidade clara de identificação e inclusão de novas covariáveis no modelo.

A distribuição lognormal, por sua vez, é caracterizada por um parâmetro de locação e um de escala, respectivamente μ e σ^2 , que se relacionam com o valor esperado e a variância, como segue:

$$E(Z) = \exp(\mu + \sigma^2/2)$$

$$Var(Z) = \exp(\sigma^2) - 1.$$

Desse modo, para que $E(Z) = 1$ e $Var(Z) = \xi$, basta utilizar a seguinte parametrização: $\mu = -\sigma^2/2$ e $\sigma^2 = \log(1 + \xi)$.




Figura 12.1: Distribuição gama (à esquerda) e lognormal (à direita) com valor esperado igual a um e diferentes variâncias ξ

À direita, na Figura 12.1, estão diversas curvas para a distribuição lognormal com média unitária e diferentes valores de variância ξ . Note que esta distribuição tem a cauda direita mais pesada do que a gama, o que implica uma proporção maior de indivíduos com riscos

muito altos se comparado com a distribuição gama. Por outro lado, a cauda esquerda é mais leve do que a gama, significando que nessa distribuição é menor a proporção de indivíduos com riscos excepcionalmente baixos. Por exemplo, no estudo da hemodiálise pode ser razoável presumir um pequeno número de centros de diálise com riscos extremamente altos devido à baixa qualidade de atendimento, mas pode ser difícil aceitar o pressuposto de que algumas unidades terão risco praticamente nulo. A escolha da distribuição depende, portanto, do conhecimento que se tem a respeito do problema.

Fragilidade individual no R

O ajuste de modelos com fragilidade individual não é feito utilizando a biblioteca *survival*, mas a biblioteca *phmm*. A estimação é feita utilizando MCMC, sendo portanto necessário verificar a convergência do processo de simulação. O comando é simples e utiliza o objeto resultante da função *Surv*:

```
> modelo.phmm <- phmm(Surv(tempo,status) ~ covariáveis +
  (1|id), data=dados)
```

A função não permite o uso de processo de contagem, somente o binômio tempo-evento. Pode-se incluir efeito aleatório relacionado a alguma covariável específica. O ajuste de múltiplos níveis de efeitos aleatórios, por exemplo, indivíduo dentro de centros, não está disponível. O *default* para o número de iterações é 100, em geral muito pequeno. A função *plot(modelo.phmm)* permite verificar a convergência. Caso necessário pode-se aumentar as iterações através do argumento *MAXSTEP*. O exemplo apresentado na Tabela 12.1 levou cerca de 10 minutos rodando com 1000 iterações.

12.3 Inferência

A forma clássica de estimar modelos de sobrevivência com fragilidade é através do algoritmo Esperança-Maximização, conhecido como al-

goritmo EM. A ideia é tratar as fragilidades como dados não observáveis, que são então estimadas no passo E do algoritmo. No passo M são obtidos os valores dos coeficientes de regressão (os β s) que maximizam a verossimilhança parcial. As bibliotecas do R que utilizam essa abordagem são *ipdmeta* (*Individual Patient Data Meta-Analysis of Time-to-Events*) e *phmm* (*Proportional Hazards Mixed-effects Model*). A biblioteca *phmm* implementa o algoritmo EM utilizando MCMC (Cadeias de Markov com método Monte Carlo) no passo E, permitindo a inclusão de fragilidade a nível do indivíduo.

Nessa seção, apresentaremos o método de estimação baseado em penalização da função de verossimilhança, para o caso particular de modelos com fragilidade de grupo ou compartilhada, por exemplo, pacientes de um mesmo centro de diálise ou múltiplos eventos de um mesmo indivíduo.

Consideremos a seguinte formulação alternativa do modelo de fragilidade apresentado em (12.1), onde Z passa a ser expresso em termos de uma matriz $U\omega$:

$$\lambda(t) = \lambda_0(t) \exp(\mathbf{x}\beta + U\omega), \quad (12.2)$$

em que $\mathbf{x}$ é a matriz de covariáveis e o elemento u_{ij} da matriz U é igual a um se o indivíduo i é um membro do grupo j , e zero caso contrário. Essa matriz U pode, em outros casos, representar também uma matriz de covariáveis que estariam associados aos efeitos aleatórios, mas aqui optamos pela formulação mais simples.

Os parâmetros β correspondem aos p efeitos fixos no modelo (iguais para todos os indivíduos que possuem os mesmos valores de covariáveis, por exemplo, idade e sexo) e ω é um vetor que contém q efeitos aleatórios ou fragilidades.

A estimação nesse caso é feita maximizando-se o logaritmo da função de verossimilhança parcial penalizada:

$$LPP = l(\beta, \omega) - g(\omega, \theta), \quad (12.3)$$

em função de β e ω . Aqui, $l(\beta, \omega)$ é a log-verossimilhança parcial de Cox, $g(\cdot)$ é uma função que impõe penalidades a valores de ω , por exemplo, diminuindo a dispersão.

Dependendo da função de penalidade $g(\cdot)$ escolhida, o parâmetro θ pode ser interpretado como a variância dos efeitos ω_i ($i = 1, \dots, q$). Sendo $g(\boldsymbol{\omega}, \theta) = (1/\theta) \sum_i [\omega_i - \exp(\omega_i)]$, o modelo penalizado é equivalente ao modelo gama de efeitos aleatórios de grupo. Nesse caso, ω_i são os logaritmos de variáveis aleatórias gama independentes e identicamente distribuídas. Da mesma forma, se a função de penalidade é dada por $g(\boldsymbol{\omega}, \theta) = (1/2\theta) \sum_i (\omega_i^2)$, o modelo é equivalente ao modelo de fragilidade lognormal para $z_i = \exp(\omega_i)$, em que o parâmetro θ é a variância dos efeitos aleatórios.

A estimação do parâmetro θ pode ser feita minimizando o critério de informação de Akaike (AIC). Alternativamente, quando a fragilidade é gama, a variância pode ser estimada através de verossimilhança perfilada. Já para fragilidades lognormais, a estimação é feita com base em verossimilhança restrita aproximada. O detalhamento matemático foge ao escopo deste livro.

Os testes de hipóteses aplicados aos modelos de fragilidade são os mesmos aplicados aos modelos de Cox: teste de Wald e teste da razão de verossimilhanças, adaptados para incluir, além dos β s, a variância do efeito aleatório.

O teste de Wald segue uma distribuição normal multivariada e, na sua forma quadrática, segue assintoticamente uma distribuição qui-quadrado, no caso dos parâmetros fixos, com um grau de liberdade. Da mesma forma que na estimação de ajustes utilizando *splines* (Capítulo 9), o parâmetro θ terá um número de graus de liberdade variável, que depende da função $g(\cdot)$ de penalização.

O teste da razão de verossimilhança para a fragilidade é duas vezes a diferença entre a log-verossimilhança parcial integrada e a log-verossimilhança de um modelo sem fragilidade (modelo de Cox clássico). A distribuição assintótica desse teste é novamente qui-quadrado, mas agora com somente um grau de liberdade, relativo à inclusão do parâmetro θ .

Fragilidade compartilhada no R

Para ajustar modelos de fragilidade compartilhada, utiliza-se a mesma função `coxph()`. A diferença é apenas a inclusão do argumento `frailty` da seguinte forma:

```
> modelo <- coxph(Surv(inicio,fim,status) ~ covariáveis +
  frailty(grupo), data=dados)
```

Dentro do argumento `frailty()` coloca-se o nome da variável do banco de dados que identifica os grupos para os quais as fragilidades serão estimadas.

Observe que a saída da função `coxph` quando há fragilidade apresenta a estatística *Chisq*, ao invés de *z* do modelo clássico.

Exemplo

Apresentaremos dois exemplos, o primeiro voltado para a discussão dos diferentes modelos com inclusão de termos aleatórios e o segundo comparando modelos de eventos múltiplos com modelos de efeitos aleatórios.

Retornando ao exemplo da hemodiálise (seção Diálise – clássico e fragilidade do Apêndice): o tempo de sobrevivência dos pacientes em hemodiálise varia com a idade, a doença de base (*causa*) e outros aspectos que não estão disponíveis no Sistema de Informações dos Procedimentos de Alta Complexidade (Apac). O primeiro passo da modelagem é ajustar um modelo de riscos proporcionais para estimar o efeito das variáveis sobre o tempo de sobrevivência. Para facilitar a interpretação dos modelos, vamos usar um banco de dados menor, considerando apenas 20 centros de diálises.

```
> dial <- read.table("dialmenor.dat",header=T)
> names(dial)
```

```
[1] "unidade" "idade"   "sexo"    "inicio"  "fim"
[6] "status"  "tempo"   "grande"  "causa"
```

Listando as dez primeiras observações do banco:

```
> dial[1:10,]
```

	unidade	idade	sexo	inicio	fim	status	tempo	grande	causa
1	128	52	1	26	45	0	19	1	out
2	128	76	0	32	33	0	1	1	out
3	128	61	1	22	24	0	2	1	out
4	128	35	0	7	13	0	6	1	out
5	128	42	0	2	13	0	11	1	out
6	128	44	1	6	30	0	24	1	hip
7	128	41	1	1	6	1	5	1	out
8	128	39	1	10	13	0	3	1	out
9	128	57	0	7	45	0	38	1	out
10	128	71	1	16	33	0	17	1	out

Para garantir que hipertensão seja a categoria de referência utiliza-se o comando a seguir:

```
> dial$causa <- relevel(dial$causa,ref="hip")
```

Em primeiro lugar, vamos ajustar um modelo de Cox. Utilizaremos notação de processo de contagem porque as pessoas mudam de local de atendimento, e o banco está construído de acordo com essa característica.

```
> uni.cox <- coxph(Surv(inicio,fim,status)~idade+causa, data=dial)
> summary(uni.cox)
```

Call:

```
coxph(formula = Surv(inicio, fim, status) ~
idade + causa, data = dial)
```

```
n= 861
[...]
      exp(coef) exp(-coef) lower .95 upper .95
idade      1.036      0.965    1.025    1.05
causacon    0.366      2.733    0.147    0.91
causadia    1.887      0.530    1.335    2.67
causaout    1.088      0.919    0.684    1.73
causaren    1.422      0.703    0.956    2.12
```

```

Rsquare= 0.085   (max possible= 0.929 )
Likelihood ratio test= 76.5   on 5 df,   p=4.55e-15
Wald test         = 71.6   on 5 df,   p=4.82e-14
Score (logrank) test = 76.4   on 5 df,   p=4.66e-15

```

Em resumo, essa análise aponta que: para cada ano a mais de idade, o risco de óbito aumenta em 3,6%, com intervalo de confiança de 2,5% a 5,0%; quando a causa primária da insuficiência renal é diabetes (*causadia*), o risco de óbito aumenta significativamente em 88% se comparado com o de quem tem hipertensão como doença de base; quando a causa da insuficiência renal é doença congênita (*causacon*), o risco diminui 64% ($\exp(\text{coef})=0.366$), mas sem significância estatística.

Como os pacientes podem ter um risco comum associado à unidade de diálise em que são assistidos, continuamos a nossa análise incluindo cada unidade individualmente, como uma variável *dummy*.

```

> summary(coxph(Surv(inicio,fim, status)~
  idade+causa+factor(unidade),data=dial))

```

Call:

```

coxph(formula = Surv(inicio, fim, status) ~ idade + causa +
  factor(unidade), data = dial)

```

n= 861

[...]

	exp(coef)	exp(-coef)	lower .95	upper .95
idade	1.03e+00	9.68e-01	1.0220	1.04
causacon	4.41e-01	2.27e+00	0.1354	1.44
causadia	1.78e+00	5.62e-01	1.2371	2.56
causaout	1.20e+00	8.34e-01	0.6694	2.15
causaren	1.22e+00	8.19e-01	0.8039	1.86
factor(unidade)217	8.84e-01	1.13e+00	0.0995	7.85
factor(unidade)344	5.39e-01	1.86e+00	0.1374	2.11
factor(unidade)561	1.73e+00	5.78e-01	0.6022	4.97
factor(unidade)562	2.32e+00	4.31e-01	0.8122	6.62
factor(unidade)641	1.93e+00	5.17e-01	0.6901	5.42
factor(unidade)741	5.19e+00	1.93e-01	1.4148	19.05
factor(unidade)1048	2.50e-01	4.00e+00	0.0462	1.35
factor(unidade)1051	3.70e-01	2.70e+00	0.1063	1.29
factor(unidade)1053	1.18e+00	8.46e-01	0.3554	3.93
factor(unidade)1070	8.83e-01	1.13e+00	0.3161	2.47


```
factor(unidade)1071  2.31e+00  4.32e-01  0.1963  27.25
factor(unidade)1100  1.16e+00  8.60e-01  0.4179  3.24
factor(unidade)1159  1.11e+01  8.98e-02  4.0838  30.35
factor(unidade)1654  7.49e-01  1.34e+00  0.2330  2.41
factor(unidade)1692  1.48e+00  6.74e-01  0.5073  4.34
factor(unidade)2811  2.01e+00  4.97e-01  0.5094  7.96
factor(unidade)2844  4.78e+00  2.09e-01  1.6763  13.63
factor(unidade)5681  8.70e-07  1.15e+06  0.0000  Inf
factor(unidade)5692  3.34e+00  3.00e-01  0.2820  39.49
```

```
Rsquare= 0.22 (max possible= 0.929 )
Likelihood ratio test= 214 on 24 df, p=0
Wald test = 216 on 24 df, p=0
Score (logrank) test = 310 on 24 df, p=0
```

Observe que para a penúltima unidade listada o limite superior foi infinito, indicando que nessa unidade não ocorreu óbito algum. É isso que quer dizer o *Warning* abaixo:

```
Warning message:
Loglik converged before variable 23 ; beta may be infinite.
in: fitter(X, Y, strats, offset, init, control,
weights = weights,
```

Conferindo o número de óbitos por unidade, observamos que realmente, na unidade 5.681, não ocorreu qualquer óbito.

```
> table(dial$unidade,dial$status)
```

	0	1		0	1		0	1
128	24	5	1048	39	2	1654	39	7
217	4	1	1051	73	6	1692	52	16
344	47	4	1053	26	7	2811	5	4
561	30	16	1070	92	23	2844	29	20
562	27	16	1071	4	1	5681	5	0
641	53	23	1100	59	19	5692	6	1
741	6	5	1159	40	25			

Embora o *Rsquare* tenha aumentado de 0,085 para 0,22, utilizar a unidade como uma covariável impede a inclusão de qualquer outra variável do nível da unidade, como, por exemplo, o volume de

atendimentos da unidade (a literatura médica aponta que unidades com maior volume frequentemente apresentam melhor desempenho). Além disso, o perfil dos pacientes da unidade pode ter impacto no tempo de sobrevivência, sendo interessante incluir, por exemplo, a proporção de pacientes muito idosos. Ou seja, se o sobrerisco da unidade de número 741, cinco vezes maior que a primeira da lista (intervalo de confiança de 95% entre 1,4148 e 19,05) for devido a um grande número de pacientes mais idosos, por exemplo, não podemos testar essa hipótese. Isso porque a variável que indica a proporção de idosos é a mesma para todos os pacientes da unidade. Nesse caso, teríamos duas variáveis exatamente iguais: a unidade e a proporção de idosos, não sendo possível estimar o efeito separado de cada uma delas.

A inclusão do efeito aleatório para o nível de centros de diálise permite inserir covariáveis referentes ao serviço e estimar o risco de o paciente pertencer à unidade, além de corrigir as estimativas dos efeitos das variáveis fixas. Assumindo uma fragilidade gama, temos o seguinte resultado:

```
> uni.gama<- coxph(Surv(inicio,fim, status) ~
  idade + causa + frailty(unidade), data=dial)
> summary(uni.gama)
```

Call:

```
coxph(formula = Surv(inicio, fim, status) ~ idade + causa +
  frailty(unidade), data = dial)
```

n= 861

	coef	se(coef)	se2	Chisq	DF	p
idade	0.0325	0.00555	0.00552	34.26	1.0	4.8e-09
causacon	-0.9333	0.51228	0.48190	3.32	1.0	6.8e-02
causadia	0.5980	0.18320	0.18191	10.66	1.0	1.1e-03
causaout	0.1674	0.29820	0.29033	0.32	1.0	5.7e-01
causaren	0.2462	0.21095	0.20909	1.36	1.0	2.4e-01
frailty(unidade)				123.10	15.6	0.0e+00

	exp(coef)	exp(-coef)	lower .95	upper .95
idade	1.033	0.968	1.022	1.04
causacon	0.393	2.543	0.144	1.07
causadia	1.819	0.550	1.270	2.60

causaout	1.182	0.846	0.659	2.12
causaren	1.279	0.782	0.846	1.93

Iterations: 10 outer, 27 Newton-Raphson

Variance of random effect= 0.734 I-likelihood = -1059.8

Degrees of freedom for terms= 1.0 3.8 15.6

Rsquare= 0.216 (max possible= 0.929)

Likelihood ratio test= 210 on 20.4 df, p=0

Wald test = 54.4 on 20.4 df, p=6.09e-05

Comparando o modelo *uni.cox* com o modelo *uni.gama*, esperamos encontrar efeitos das covariáveis e erros padrões diferentes, a menos que a variância da fragilidade seja igual a zero (nesse modelo foi estimada em 0,734). Além da diferença na estimativa pontual e na precisão entre os modelos sem e com fragilidade, o primeiro estima o efeito **médio populacional** da doença de base no risco de morte por insuficiência renal e o segundo estima o efeito da doença de base dentro de uma unidade **típica**. A sutileza dessa interpretação pode ser explicada de outra forma. No modelo de Cox clássico ou nos modelos marginais vistos no Capítulo 10 estima-se o risco relativo médio populacional comparando-se duas amostras aleatórias, por exemplo, pacientes cuja doença de base é o diabetes e os hipertensos. Já o modelo de fragilidade estima o risco relativo da diabetes dado que os pacientes são assistidos na mesma unidade **típica**, isto é, que possui fragilidade igual a um.

Para estimar a variância do efeito aleatório, foram 27 iterações do algoritmo de Newton-Raphson, quase três para cada iteração que estima os efeitos fixos dada a variância (*Iterations: 10 outer, 27 Newton-Raphson*). Na nossa experiência, diversas vezes nos deparamos com uma mensagem do tipo:

Warning message:

```
Inner loop failed to converge for iterations 6 in:
coxpenal.fit(X, Y, strats, offset, init = init,
control, weights = weights,
```

Quando isso acontece, o modelo não será bem estimado. Isso porque, visando diminuir o tempo de processamento necessário para estimar os modelos de fragilidade, utiliza-se como padrão o argumento

sparse=TRUE, que utiliza somente a diagonal da matriz de informação para facilitar os cálculos matriciais. Neste caso, recomenda-se ajustar o modelo sem usar essa opção, com a seguinte sintaxe:

```
> uni.gama<- coxph(Surv(inicio,fim,status) ~ idade + causa +
  frailty(unidade, sparse= FALSE), data=dial)
```

A hipótese nula de que os efeitos aleatórios são iguais a zero pode ser testada pela estatística de Wald, no exemplo igual a 123,10 (na coluna *Chisq*, linha *frailty(unidade)* do modelo *uni.gama*), que segue aproximadamente uma distribuição qui-quadrado com 15,6 graus de liberdade (*p*-valor < 0,0001). Já o teste da razão de verossimilhança para a fragilidade, que é igual a duas vezes a diferença entre a log-verossimilhança parcial integrada fora os termos da fragilidade (denominada *I-likelihood* = -1059.8) e a log-verossimilhança de um modelo sem fragilidade, no nosso exemplo igual -1099,963, pode ser extraída do objeto *uni.cox*:

```
> uni.cox$loglik
```

```
[1] -1138.200 -1099.963
```

O primeiro valor é o logaritmo da verossimilhança do modelo nulo e o segundo, o do modelo estimado. A estatística do teste da razão de verossimilhança é igual a $2 \times (-1059,8 - (-1099,963)) = 80,33$ e segue uma distribuição qui-quadrado com um grau de liberdade (*p*-valor < 0,0001), semelhante a do teste de Wald.

O teste da razão de verossimilhança também pode ser usado como uma medida global de ajuste, assim como no modelo de Cox clássico. Nesse caso temos que a estatística do teste é igual a duas vezes a diferença da log-verossimilhança parcial do modelo no início da estimação (em que assume-se que o valor inicial de parâmetros fixos e aleatórios é igual a zero) e a do modelo no final da estimação. A saída da função *summary(uni.gama)* exhibe automaticamente esse valor, que é igual a:

```
Likelihood ratio test= 210 on 20.4 df, p=0
```

Quando estimamos um modelo de fragilidade, duas opções são mais usuais. A primeira é assumir a distribuição gama para a fragilidade e estimar a variância da fragilidade utilizando a verossimilhança perfilhada para θ (*method="em"*). A alternativa é assumir fragilidade com distribuição lognormal, em que o método padrão de estimação da variância é o da máxima verossimilhança restrita aproximada (*method="reml"*). Outros algoritmos de maximização podem ser empregados para se estimar a variância do efeito aleatório, por exemplo, através de minimização do AIC (critério de informação de Akaike). Não há método que permita identificar se a distribuição gama é melhor que a normal para ajustar o efeito aleatório, ou se uma particular abordagem para estimação da variância de fragilidade é melhor do que outra. O que se espera é que as diferentes possibilidades sejam razoavelmente consistentes, apontando as mesmas unidades com risco diferenciado, e mantendo estimativas de efeitos fixos e intervalos de confiança semelhantes.

O primeiro passo é verificar as alterações nos efeitos fixos, comparando os modelos com diferentes distribuições e diferentes métodos para estimar a variância da fragilidade (Tabela 12.2).

```
> uni.gama.aic <- coxph(Surv(inicio,fim, status) ~
  idade+causa+frailty(unidade,method="aic"), data=dial)
> summary(uni.gama.aic)

> uni.gauss<- coxph(Surv(inicio,fim, status) ~
  idade+causa+frailty(unidade,dist="gauss"), data=dial)
> summary(uni.gauss)

> uni.gauss.aic <- coxph(Surv(inicio,fim, status) ~
  idade+causa+frailty(unidade,method="aic",dist="gauss"),
  data=dial)
> summary(uni.gauss.aic)
```

Em relação às estimativas pontuais dos efeitos das covariáveis, podemos observar uma semelhança de todos os modelos de fragilidade. Vamos comparar agora a qualidade do ajuste desses quatro modelos de fragilidade analisando a Tabela 12.3.

A variação encontrada na estimativa da variância dos efeitos aleatórios entre os diferentes modelos é devida ao reduzido número de

Tabela 12.2: Comparação dos efeitos fixos dos modelos de fragilidade para os dados de diálise

	Efeito Gama (EM)			Efeito Gama (AIC)		
	$\exp(\beta)$	.95Inf	.95Sup	$\exp(\beta)$	.95Inf	.95Sup
idade	1,033	1,022	1,04	1,033	1,022	1,04
causacon	0,393	0,144	1,07	0,388	0,144	1,04
causadia	1,819	1,270	2,60	1,827	1,277	2,61
causaout	1,182	0,659	2,12	1,174	0,656	2,10
causaren	1,279	0,846	1,93	1,293	0,856	1,95
	Efeito lognormal (REML)			Efeito lognormal (AIC)		
	$\exp(\beta)$	.95Inf	.95Sup	$\exp(\beta)$	.95Inf	.95Sup
idade	1,033	1,022	1,04	1,033	1,022	1,04
causacon	0,419	0,157	1,12	0,415	0,157	1,09
causadia	1,814	1,267	2,60	1,820	1,273	2,60
causaout	1,168	0,660	2,07	1,161	0,658	2,05
causaren	1,247	0,824	1,89	1,254	0,829	1,90

eventos em cada centro de diálise, bem como ao também ao pequeno número de serviços. Logo, não deve ser muito valorizada. A hipótese nula de que os efeitos aleatórios são iguais a zero foi rejeitada pelo teste aproximado de Wald nos quatro modelos. Como visto anteriormente, podemos utilizar também o teste da razão de verossimilhança, que é mais robusto. Para isso é necessário obter a logverossimilhança integrada fora os termos da fragilidade, denominada *I-likelihood*, e a logverossimilhança do modelo sem fragilidade. No caso dos modelos de fragilidade gama, temos para os modelos com método de estimação EM e AIC, respectivamente:

$$\begin{aligned}
 2 \times (-1033, 19 - (-1099, 96)) &= 133, 54 \quad \text{e} \\
 2 \times (-1034, 11 - (-1099, 96)) &= 131, 70.
 \end{aligned}$$

Esses valores seguem uma distribuição qui-quadrado com um grau de liberdade (p-valor < 0,0001). Com resultado semelhante ao do

Tabela 12.3: Comparação das medidas de ajuste dos modelos de fragilidade

Medidas de ajuste	Cox Clássico	Gama EM	Gama AIC	lognormal REML	lognormal AIC
Wald Test*,†	—	123,10 (15,6)	118,81 (14,8)	128,26 (14,7)	123,82 (14,1)
Variância do efeito aleatório	—	0,734	0,55	0,697	0,55
Rsquare	0,085	0,216	0,215	0,216	0,215
Log-verossimil.	-1100	-1033	-1034	-1033	-1034
<i>I-likelihood</i>	—	-1059,8	-1059,9	—	—
Razão de verossimil.†,‡	76,5 (5)	210 (20,4)	208 (19,5)	210 (19,5)	209 (18,8)

* Teste para a fragilidade (graus de liberdade entre parênteses)

† Teste da razão de verossimilhanças (graus de liberdade entre parênteses)

‡ p-valor < 0,001

teste de Wald, a inclusão da fragilidade gama é estatisticamente significativa. Por enquanto o pacote *survival* do R só disponibiliza a *I-likelihood* para o modelo com fragilidade gama. Não sendo fragilidade gama, a única forma de testar é utilizar o teste aproximado de Wald. Entretanto, sendo o resultado significativo em uma distribuição, supõe-se que nas outras também o será. O problema é resolver qual distribuição é mais adequada aos dados. O gráfico da Figura 12.2 mostra a densidade de probabilidade de cada um dos valores das fragilidades estimadas pelos modelos.

Observe que existe uma certa flutuação para valores altos de fragilidade, que é maior nos modelos com fragilidade lognormal, cujos efeitos aleatórios chegam a ser seis vezes maiores que a média.




Figura 12.2: Distribuição das fragilidades estimadas segundo diferentes modelos para os dados de diálise – efeito das unidades de diálise

Por outro lado, no limite inferior, o efeito aleatório gama pode gerar unidades onde o risco é praticamente zero. Este pode ser um critério de escolha do modelo: o escopo da fragilidade, verificando-se qual o modelo que faz mais sentido do ponto de vista epidemiológico, sempre buscando mais parcimônia.

Continuando a modelagem, deve-se testar a inclusão das variáveis que pertencem às unidades. No nosso exemplo, a variável *volume* foi criada considerando-se que todas as unidades com mais de 50 pacientes no período são unidades grandes. Porém, essa variável não foi significativa, nada acrescentando ao modelo. Cabe lembrar que a inclusão de variáveis que caracterizam o nível do efeito aleatório frequentemente gera dificuldades na estimação, sendo recomendado utilizar o argumento *sparse=F* na função *frailty()*, caso o número de observações o permita, uma vez que a quantidade de cálculos aumenta muito.

O efeito de cada unidade deve também ser analisado, e para tal é necessário inspecionar o vetor das fragilidades estimadas pelos modelos. A forma gráfica é uma boa maneira de analisar a distribuição

do risco segundo unidades, ou seja, comparar as fragilidades geradas por diferentes modelos. Esse gráfico é útil também para apresentar a distribuição da fragilidade.




Figura 12.3: Estimativa pontual da fragilidade e seu intervalo de confiança de 95% para cada centro de diálise utilizando diferentes modelos: (a) Gama-EM, (b) Gama-AIC, (c) Gauss-REML e (d) Gauss-AIC

Na Figura 12.3, as unidades foram ordenadas pela estimativa pontual da fragilidade (sem exponenciar). Observe que a ordem não foi a mesma em todos os modelos. Entre as fragilidades com distribuição gama, o número de unidades com risco significativamente abaixo

de zero foi sempre maior que na fragilidade gaussiana. Ainda assim, duas unidades aparecem em todas as estimativas como apresentando risco significativamente baixo (unidades 1.048 e 1.051). Para a unidade 1.070, embora a estimativa pontual não seja a menor, em todos os modelos o risco é significativamente baixo, e o intervalo de confiança menor que as demais unidades, justificado pelo maior número de pacientes (92, com 23 óbitos). As duas unidades com maior efeito aleatório (5.692 e 1.654) são sempre identificadas em todos os modelos, e nem sempre com risco significativamente acima do risco médio.

Como escolher o melhor modelo? Na verdade, os modelos são muito semelhantes, e qualquer um deles pode ser útil na identificação de unidades candidatas a uma visita de supervisão para avaliação do seu funcionamento. O cuidado maior deve ser tomado na divulgação dessas estimativas, que podem variar conforme a escolha do modelo. Claro que com um número maior de observações as estimativas ficam mais consistentes: é só observar o intervalo de confiança para a unidade 1.070. Lembramos que nesse exemplo foram analisados 861 pacientes e no sistema de informações da Apac no Rio de Janeiro estão cadastrados mais de 15 mil.

Gráfico de fragilidade no R

O gráfico do tipo apresentado na Figura 12.3 é feito a partir de uma função disponível no *script Rfun.r*. Esta função está implementada para modelos de Cox com efeito aleatório quando se usa o argumento *sparse=T*. Os argumentos dessa função são: o vetor que indica o código do objeto para o qual foi estimada a fragilidade e o objeto resultante do modelo de Cox.

```
> plot.frail(banco$vetor,modelo)
```

Exemplo

No caso do estudo das diarreias infantis, que já foi modelado como eventos múltiplos apresentados no Capítulo 10, o efeito aleatório de cada criança é um efeito de grupo, uma vez que várias crianças têm mais de um episódio de diarreia.

```
> diarreja <- read.table("multdiarreia.txt", header=T)
> diarreja$grupo <- relevel(diarreja$grupo, "vit")
> diar.frail <- coxph(Surv(ini,fim,status) ~ grupo + sexo + idade +
  frailty(numcri), data=diarreia)
> summary(diar.frail)
```

Call:

```
coxph(formula = Surv(ini, fim, status) ~ grupo + sexo +
  idade + frailty(numcri), data = diarreja)
n= 5592
```

	coef	se(coef)	se2	Chisq	DF	p
grupopla	0.1740	0.06801	0.03044	6.54	1	0.011
sexomasc	0.0444	0.06828	0.03054	0.42	1	0.520
idade	-0.0349	0.00272	0.00133	164.14	1	0.000
frailty(numcri)				2964.02	675	0.000

	exp(coef)	exp(-coef)	lower .95	upper .95
grupopla	1.190	0.840	1.042	1.36
sexomasc	1.045	0.957	0.914	1.20
idade	0.966	1.036	0.961	0.97

Iterations: 9 outer, 24 Newton-Raphson

Variance of random effect= 0.769 I-likelihood = -30053.3

Degrees of freedom for terms= 0.2 0.2 0.2 674.8

Rsquare= 0.547 (max possible= 1)

Likelihood ratio test= 4427 on 675 df, p=0

Wald test = 172 on 675 df, p=1

A fragilidade é significativa (teste de Wald = 2964.02, p-valor < 0,0001), e o *Rsquare* é muito maior do que todos os modelos apresentados no Capítulo 10. Contudo, os coeficientes estimados são muito semelhantes aos do modelo AG. A fragilidade estimada, neste caso, a gama (o *default* do R), mostra que uma pequena parcela das crianças tem um sobrerisco que chega a ser cinco vezes maior que a média (Figura 12.4).




Figura 12.4: Distribuição das fragilidades gama estimadas dos dados de diarreia infantil

Vimos no Capítulo 10 que aparentemente o modelo PWP apresentava um ajuste melhor desses dados que o modelo AG. Entretanto, quando assumimos a possibilidade de diferentes fragilidades entre as crianças, a estratificação ordenada do risco de base entre os sucessivos episódios de diarreia não mais se justifica. Na verdade, o risco de apresentar um episódio de diarreia pode ser considerado constante, condicionado às diferenças entre as crianças. Esta é a interpretação mais fiel à ideia de modelo condicional de fato, como é o caso dos modelos de efeitos aleatórios.

Novamente, como escolher o modelo? Nesse caso, a escolha do modelo de efeitos aleatórios parece mais indicada, dada a magnitude dos efeitos. Também do ponto de vista epidemiológico faz sentido esse tipo de interpretação. Além disso, é importante lembrar que o objetivo desse estudo é avaliar o uso de vitamina A na prevenção de diarreias infantis. A Figura 12.5 mostra de duas formas a distribuição da fragilidade estimada segundo grupos de tratamento. O gráfico de densidade, à esquerda, mostra que o grupo placebo tem um pouco mais de massa em valores mais altos de fragilidade. À direita, o *boxplot* sugere que as medianas da fragilidade nos dois grupos são

diferentes. Ou seja, há uma indicação de que as crianças com maior fragilidade estavam fazendo uso de placebo. Seria interessante modelar uma interação entre grupo de tratamento e fragilidade, que poderia confirmar a hipótese de que a vitamina A atua sobre as crianças diminuindo essa fragilidade aumentada. Entretanto, não é possível ajustar esse tipo de modelo no R, nem foi possível aprofundar neste capítulo todas as possibilidades que se abrem para a modelagem com o uso de efeitos aleatórios.




Figura 12.5: Fragilidades segundo grupo de tratamento

12.4 Desdobramentos dos modelos de fragilidade

Os modelos de efeitos aleatórios trazem um amplo leque de possibilidades na modelagem. Apresentamos aqui as técnicas mais estabelecidas, e para as quais existem programas disponíveis. Algumas ideias, entretanto devem ser apresentadas neste final, visando aprofundar, ainda que de forma intuitiva, a compreensão sobre esse tipo de modelo e suas potencialidades.

Em primeiro lugar, ao se adotar um modelo de fragilidade compartilhada dentro de um grupo, sejam tempos até episódios de diarreia infantil ou pacientes de um mesmo serviço, supõe-se não so-

mente a existência de heterogeneidade não observada entre grupos mas também de **correlação** intragrupo (ou seja, correlação entre indivíduos assistidos em um mesmo local, ou entre tempos dentro de um mesmo indivíduo). Na forma mais simples, essa correlação é uniforme e é a mesma entre todos os que compartilham cada grupo. Pode-se pensar, entretanto, em uma estrutura para essa correlação. Por exemplo, suponhamos que o desempenho das unidades de hemodiálise é tanto pior quanto mais afastadas estiverem da capital do estado. Nesse caso, o efeito aleatório atribuído a cada centro de diálise teria também uma estrutura espacial. Ou, por exemplo, ao longo do ano de observação das crianças, verifica-se que o número de episódios de diarreia não é uniforme, mas variou, e não só pelo envelhecimento da coorte. Além de incluir um efeito aleatório para cada criança, seria importante incluir no modelo, de alguma forma, essa estrutura temporal. Ou ainda, como já foi dito, modelar simultaneamente fragilidade individual e compartilhada.

Por outro lado, os modelos de sobrevivência interessam aos epidemiologistas por permitirem estimar as diferenças de risco para a ocorrência de um desfecho categórico. Mas muitas vezes outra pergunta se impõe, no mesmo campo dos dados longitudinais: as medidas repetidas no mesmo indivíduo. Modelos para análise de dados longitudinais apresentam diversos pontos em comum com os modelos de sobrevivência, e eventualmente, quando se pode categorizar a variável resposta, ambos abordam situações semelhantes. O estudo da diarreia, por exemplo, foi primeiramente modelado no contexto de modelos longitudinais, sendo a contagem de episódios por semana a variável resposta. As estimativas principais foram semelhantes.

Resumo

Os modelos efeitos aleatórios, também denominados modelos de fragilidade, devem ser empregados em situações nas quais está presente superdispersão ou correlação entre observações pertencentes a um mesmo indivíduo ou indivíduos de grupos específicos. Nesse último caso, quando o efeito aleatório está associado a grupos, denomina-se modelos de fragilidade compartilhada.

As distribuições de probabilidade mais utilizadas para estimar efeitos aleatórios são a gama e a log-normal.

Para ajustar modelos com fragilidade compartilhada, na biblioteca *survival*, basta incluir na fórmula o termo *frailty()*.

Exercícios

12.1 Discuta, para cada uma das situações abaixo, por que utilizar o modelo com fragilidade.

- (a) Em um estudo de reinternação, no qual se procura estimar o efeito de covariáveis associadas ao hospital (tamanho, especialidade clínica) no risco de ocorrer reinternação.
- (b) Em um estudo sobre o efeito do tratamento na reincidência de doenças oportunistas em pacientes com Aids, no qual medidas repetidas são obtidas para cada indivíduo.
- (c) Em um estudo sobre o efeito do saneamento na ocorrência de episódios de diarreia numa certa área, no qual são observadas todas as crianças menores de 7 anos residentes nos domicílios da área, antes e após as obras.

12.2 Refaça a análise dos dados de diálise (*dialmenor.dat* – Apêndice.12.4) que foi vista neste capítulo.

- (a) Ajuste um modelo de Cox clássico considerando apenas as variáveis *sexo* e *idade*.

- (b) Ajuste outro modelo de Cox incluindo a variável unidade como fator, para ajustar um efeito para cada *unidade* de diálise.
- (c) Modele a unidade hospitalar como um termo de fragilidade gama.
- (d) Reajuste o modelo utilizando fragilidade log-normal.
- (e) Visualize, através de um histograma, os efeitos aleatórios estimados por cada um dos modelos.
- (f) Use a exponencial da fragilidade para obter a estimativa de risco.
- (g) Faça um gráfico das fragilidades estimadas.

12.3 Um estudo sobre infarto busca avaliar o efeito de variáveis relacionadas ao paciente (*sexo*, *idade*) e variáveis relacionadas ao hospital, na sobrevivência de pacientes lá atendidos. Para isso, um banco de dados foi criado, com informações de diversos hospitais. Abra o banco de dados *infarto.dat* descrito no Apêndice.12.4 no R e identifique as variáveis existentes para os indivíduos e para os hospitais. Note que cada paciente só tem uma linha, e que cada hospital (segundo nível) tem uma linha por paciente atendido, caracterizando uma estrutura aninhada.

- (a) Vamos começar supondo que temos apenas as variáveis no nível de indivíduo (*sexo* e *idade*). Ajuste um modelo de riscos proporcionais (clássico) e interprete o resultado.
- (b) Como existe uma estrutura de correlação, por termos indivíduos atendidos no mesmo hospital, podemos ajustar um modelo com um termo aleatório para cada hospital para estimar um perfil de risco neste nível. Qual é a significância estatística do termo aleatório?
- (c) Adicione ao modelo as variáveis de nível hospitalar: *luti*, *natureza* e *volume*. Elas podem explicar parte da fragilidade estimada no modelo acima. Observe o efeito da inclusão das novas covariáveis no termo aleatório.

- (d) Faça um gráfico das fragilidades em cada modelo ajustado. Por que à medida que se incluem novas variáveis do nível do hospital diminui a variância da fragilidade?

12.4 Compare as estimativas do modelo do modelo ajustado no exercício anterior, incluindo todas as variáveis, com um modelo semelhante que utilize uma distribuição gaussiana. Há diferença nas estimativas?

Dicas

- Para ajustar o modelo com fragilidade, use o comando:

```
> fit.gama <- coxph(Surv(inicio, fim, status) ~
  var1 + var2 +...+ frailty(grupo, sparse = F),
  data = banco)
```
- A distribuição *default* é a gama. Para indicar a distribuição gaussiana use o argumento *dist = "gauss"*.
- Os valores da fragilidade estimada ficam arquivados sob o nome *frail* no objeto resultante do modelo.
- Observe que o padrão do R é tomar como referência sempre a primeira categoria em ordem alfabética. Para alterá-la, use o comando *relevel* indicando a categoria desejada.
- Se ao ajustar o modelo utilizando as unidades como fator, um aviso indicar que o valor de beta foi infinito para alguma unidade, em geral, isso indica que não ocorreu nenhum evento de falha nesta unidade. Para confirmar, verifique a tabela de frequência:

```
> table(banco$grupo, banco$status)
```

- Para visualizar o gráfico das fragilidades de cada grupo (centro de diálise no exercício) utilize a função *plot.frail()*, disponível no arquivo *Rfun.r*. A função tem como argumentos a variável que indica o grupo e o modelo ajustado. O modelo deve ter sido ajustado utilizando *frailty(grupo, sparse=F)*.

```
> source("Rfun.r")
> plot.frail(banco$grupo, fit.gama)
```

12.5 No Capítulo 10 sobre eventos múltiplos, ajustou-se modelos marginais para se avaliar o efeito do tratamento com vitamina A no risco de ocorrência de diarreia infantil (Apêndice.12.4). Como múltiplos eventos eram observados por criança, uma primeira opção de modelo era o modelo marginal, que corrigia a variância dos efeitos para a presença de correlação entre tempos de sobrevivência observados para a mesma criança. Uma outra abordagem para esse problema pode ser feita agora, utilizando-se fragilidade. Podemos considerar que *criança* é a unidade de segundo nível, que agrega as medidas repetidas de tempo. Neste caso, a adição de um termo aleatório irá estimar o efeito da fragilidade das crianças, não explicada pelos efeitos fixos.

- (a) Ajuste um modelo marginal de incrementos independentes, como no Capítulo 10, e um modelo com fragilidade aos dados.
- (b) O termo aleatório é significativo? Qual a sua variância?
- (c) Os valores estimados para os efeitos fixos mudaram de um modelo para o outro. A interpretação deles também. Explique seu significado em cada modelo.

Bibliografia

ANDERSEN, P. K., BORGAN, O., GILL, RICHARD D. & KEIDING, N. *Statistical Models Based on Counting Processes*. New York: Springer, 1993.

ANDERSEN, P. K. & GILL, R. D. Cox's regression model for counting processes: a large sample study. *Annals of Statistics* 10, 4 (1982), 1100–1120.

ANDREOZZI, V. L. *Modelagem de Dados Longitudinais Aplicada a um Estudo Aleatorizado do Efeito da Vitamina A na Diarréia Infantil*. Tese de Doutorado, COPPE/UFRJ, Engenharia Biomédica, Rio de Janeiro, 2002.

BARRETO, M. L., SANTOS, L. M., ASSIS, A. M., ARAUJO, M. P., FARENZENA, G. G., SANTOS, P. A. & FIACCONE, R. L. Effect of vitamin a supplementation on diarrhoea and acute lower-respiratory-tract infections in young children in brazil. *Lancet* 344, 8917 (1994), 228–231.

BOLKER, B. M. *Ecological models and data in R*. Princeton University Press, Princeton, N.J., 2008.

BROOKMEYER, C. A confidence interval for the median survival time. *Biometrics* 38 (1982), 29–41.

BRUNET, R. C. & STRUCHINER, C. J. A non-parametric method for the reconstruction of age- and time-dependent incidence from the prevalence data of irreversible diseases with differential mortality. *Theoretical Population Biology* 56, 1 (1999), 76–90.

BRUNET, R. C. & STRUCHINER, C. J. Rate estimation from prevalence information on a simple epidemiologic model for health interventions. *Theoretical Population Biology* 50, 3 (1996), 209–226.

BRUNET, R. C., STRUCHINER, C. J. & LOINAZ, A. A method for estimating time dependent intervention benefits under arbitrarily varying age and exogenous components of hazard. *Lifetime Data Analysis* 7, 4 (2001), 377–392.

BUENO, M., SOUZA, J., SOUZA, S., PAZ, S., GIMENO, S. & SIQUEIRA, A. Riscos associados ao processo de desmame entre crianças nascidas em hospital universitário de São Paulo, entre 1998 e 1999: estudo de coorte prospectivo do primeiro ano de vida. *Cadernos de Saúde Pública* 19, 5 (2003), 453–460.

BYINGTON, R. Estudo de fatores prognósticos em pacientes submetidos ao transplante de medula óssea para tratamento de leucemia mieloide crônica. Dissertação de Mestrado. Saúde Coletiva. Universidade do Estado do Rio de Janeiro, 1999.

CAMPOS, D. P. Survival of AIDS patients using two case definitions, Rio de Janeiro, Brazil, 1986–2003. *AIDS*, 4 (2005), s22–s26.

CARVALHO, M. S., HENDERSON, R., SHIMAKURA, S. & SOUSA, I. P. S. C. Survival of hemodialysis patients: modeling differences in risk of dialysis centers. *International Journal for Quality in Health Care* 15, 3 (Jun 2003), 189–96.

CARVALHO, M. S. & KNORR-HELD, L. Modelling discrete time survival data with random slopes: evaluating haemodialysis centres. *Statistics in Medicine* 22, 22 (Nov 2003), 3543–55.

CASTRO, M. *As admissões hospitalares no Brasil são equitativas? Uma análise comparativa da experiência de hospitalização da população brasileira.* Tese de Doutorado. Saúde Pública. Fundação Oswaldo Cruz, 2004.

CASTRO, M. S. M. & CARVALHO, M. S. Agrupamento da classificação internacional de doenças para análise de reinternações hospitalares. *Cadernos de Saúde Pública* 21, 1 (2005), 317–23.

COLLETT, D. *Modelling Survival Data in Medical Research, Second Edition*, 2 ed. Chapman and Hall/CRC, 3 2003.

COLOSIMO, E. A. *Análise de Sobrevivência Aplicada*. Piracicaba: RBRAS, 2001.

COX, D. Regression models and life tables. *Journal of Royal Statistical Society* 34 (1972), 187:201.

DE WREEDE, L. C., FIOCCO, M. & PUTTER, H. mstate: An R package for the analysis of competing risks and multi-state models. *Journal of Statistical Software* 38, 7 (2011), 1–30.

DOBSON, A. *An Introduction to Generalized Linear Models*, 2a. ed ed. Texts in Statistical Science Series. New York: Chapman and Hall, 2001.

DONOHUE, M. & XU, R. *PHMM: Proportional Hazards Mixed-effects Model (PHMM)*, 2010. R package version 0.7-1.

MARILIA SÁ CARVALHO, M. S. M. C. Factors associated with readmission to a general hospital. *Cadernos de Saúde Pública* 24, 1 (2005), 1186–1200.

EILERS, P. H. C. & MARX, B. D. Flexible smoothing with b-splines and penalties. *Statistical Science* 11, 2 (1996), 89–121.

FARAWAY, J. J. *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models (Chapman & Hall/CRC Texts in Statistical Science)*, 1 ed. Chapman and Hall/CRC, 12 2005.

FLEMING, T. R. & HARRINGTON, D. P. *Counting processes and survival analysis*. Wiley, New York, N.Y., 1991.

FOX, J. *Rcmdr: R Commander*, 2010. R package version 1.5-5.

FOX, J. *RcmdrPlugin.survival: R Commander Plug-in for the survival Package*, 2010. R package version 13.

FREITAS, M.A. & COLOSIMO, E. *Confiabilidade: Análise de Tempo de Falha e Testes de Vida Acelerados*. Belo Horizonte: Fundação Christiano Ottoni, 1997.

GADELHA, A. *Casos de Aids notificados no Município do Rio de Janeiro, 1983-1993. Análise de sobrevida*. Tese de Doutorado. Saúde Pública. Universidade de São Paulo, 1997.

GESKUS, R. B. Cause-specific cumulative incidence estimation and the fine and gray model under both left truncation and right censoring. *Biometrics* 67, 1 (Mar 2011), 39–49.

GREEN, P. & SILVERMAN, B. W. *Nonparametric Regression and Generalized Linear Models: A roughness penalty approach (Chapman & Hall/CRC Monographs on Statistics & Applied Probability)*, 1 ed. Chapman and Hall/CRC, 5 1993.

HARRELL, F. E. J. *Regression Modeling Strategies*, corrected edition. Springer, 1 2001.

HARRELL, F. E. J. *Regression Modeling Strategies With Applications to Linear Models, Logistic Regression, and Survival Analysis*. Springer Series in Statistics. New York: Springer-Verlag, 2002.

HASTIE, T. & TIBSHIRANI, R. *Generalized Additive Models*. Monographs on Statistics and Applied Probability. London: Chapman & Hall/CRC, 1990.

HASTIE, T., TIBSHIRANI, R. & FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction.*, second edition. Springer, 2009.

HENDERSON, R. & SHIMAKURA, S. A serially correlated gamma frailty model for recurrent events. *Biometrika* 90 (2003), 355–366.

HOSMER, D.W. & LEMESHOW, S. *Applied survival analysis: regression modeling of time to event data*. Wiley series in probability and statistics. New York: John Wiley & Sons, 1999.

HOUGAARD, P. *Analysis of multivariate survival data*. Statistics for biology and health. New York: Springer, 2000.

JACKSON, C. H. Multi-state models for panel data: The msm package for R. *Journal of Statistical Software* 38, 8 (2011), 1–29.

JACKSON, C. H. Multi-state models for panel data: The msm package for R. *Journal of Statistical Software* 38, 8 (2011), 1–29.

JOFFE, M. M., TEN HAVE, T. R., FELDMAN, H. I. & KIMMEL, S. E. Model selection, confounder control, and marginal structural models: Review and new applications. *American Statistician* 58, 4 (2004), 272–279.

KALBFLEISCH, J. D. & PRENTICE, R. L. *The statistical analysis of failure time data*, 2a ed ed. Wiley series in probability and statistics. Hoboken, N.J.: John Wiley & Sons, 2002.

KEIDING, N. & ANDERSEN, P. K., Eds. *Survival and Event History Analysis (Wiley Reference Series in Biostatistics)*, illustrated edition. Wiley, 12 2006.

KELLY, P. & LIM, L. Survival analysis for recurrent event data: an application to childhood infectious diseases. *Statistics in Medicine* 19, 1 (Jan 2000), 13–33.

KLEIN, J. & MOESCHBERGER, M. *Survival analysis: techniques for censored and truncated data*. Statistics for biology and health. New York: Springer, 2003.

KLEINBAUM, D. & KLEIN, M. *Survival analysis: a self-learning text*. Statistics in the health sciences. New York: Springer, 1997.

KLEINBAUM, D., KLEIN, M. & PRYOR, E. *Logistic regression: a self-learning text*, 2a edition. Statistics for biology and health. New York: Springer, 2002.

KOVALCHIK, S. *ipdmeta: Tools for Individual patient data and Mixed-level Meta-analysis*, 2011. R package version 2.1.

VAN DER LAAN, M. J. & ROBINS, J. M. *Unified methods for censored longitudinal data and causality*. Springer series in statistics. New York: Springer-Verlag, 2003.

LAWLESS, J. F. *Statistical models and methods for lifetime data*. Wiley series in probability and mathematical statistics. Wiley, New York, 1982.

LEE, E. & WANG, J. *Statistical methods for survival data analysis*, 3rd ed ed. Wiley series in probability and statistics. Hoboken, N.J.: Wiley-Interscience, 2003.

LEVINS, R. Strategy of model building in population biology. *American Scientist* 54, 4 (1966), 421–431.

LEVINS, R. Formal analysis and the fluidity of science - a response. *Quarterly Review of Biology* 68, 4 (1993), 547–555.

LOUZADA-NETO, F., MAZUCHELI, J. & ACHCCAR, J. *Análise de Sobrevivência e Confiabilidade*. Monografias del IMCA. Lima, Peru: IMCA, 2002.

MALLER, R. & ZHOU, X. *Survival analysis with long-term survivors*. Wiley series in probability and statistics. Applied probability and statistics. Chichester; New York: Wiley, 1996.

MELO, E. *Variações no Uso de Serviços de Saúde: o Infarto Agudo do Miocárdio no Rio de Janeiro*. Tese de Doutorado. Saúde Pública. Fundação Oswaldo Cruz, 2004.

ORZACK, S. H. & SOBER, E. A critical-assessment of levins's the strategy of model-building in population biology (1966). *Quarterly Review of Biology* 68, 4 (1993), 533–546. Times Cited: 23.

PACHECO, A. G., TUBOI, S. H., MAY, S. B., MOREIRA, L. F. S., RAMADAS, L., NUNES, E. P., MERÇON, M., FAULHABER, J. C., HARRISON, L. H., AND SCHECHTER, M. Temporal changes in causes of death among HIV-infected patients in the haart era in Rio de Janeiro, Brazil. *Journal of Acquired Immune Deficiency Syndrome* 51, 5 (Aug 2009), 624–630.

PRENTICE, R., WILLIAMS, B. & PETERSON, A. On the regression analysis of multivariate failure time data. *Biometrika* 68, 2 (1981), 373–379.

PUTTER, H., GESKUS, R. B. & FIOCCO, M. Tutorial in biostatistics: Competing risks and multi-state models. *Statistics in Medicine* 26 (2007), 2389–2430.

ROBINS, J. M. Association, causation, and marginal structural models. *Synthese* 121, 1-2 (1999), 151–179.

ROLLA, V. *Manifestações Clínicas e laboratoriais de 104 pacientes HIV + no Hospital Rothschild (Paris): Estudo caso/controle pareado da infecção disseminada pelo complexo Mycobacterium avium e análise dos fatores determinantes da sobrevida na AIDS*. Tese de Doutorado. Biologia Parasitária. Fundação Oswaldo Cruz, 1999.

SHIMAKURA, S. E. *Statistical Methods for Spatial Survival Data*. Tese de Doutorado. Estatística. University of Lancaster, UK, 2003.

SIGNORINI, D. J. H. P. Elaboração de modelo de entrada de dados em hiv/aids visando estudos clínicos e análise de sobrevida dos pacientes atendidos no hospital universitário gaffrée e guinle, rio de janeiro, entre 1995 e 2002. Dissertação de Mestrado. Saúde Pública. Fundação Oswaldo Cruz, 2004.

SIGNOROVITCH, J. E. & WEI, L.-J. *Wei-Lin-Weissfeld Method for Multiple Times to Events*. Wiley Encyclopedia of Clinical Trials, 2008.

SOARES, M., CARVALHO, M. S., SALLUH, J. I. F., FERREIRA, C. G.; LUIZ, R. R., ROCCO, J. R. & SPECTOR, N. Effect of age on survival of critically ill patients with cancer. *Critical Care Medicine* 34 (2006), 715–721.

SOUZA, I. Risk factors and centre effects in survival of haemodialysis patients. Dissertação de Mestrado. Statistical Science. Lancaster University, UK, 2002.

TEAM, R. D. C. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2010.

- THERNEAU, T.. *survival: Survival analysis, including penalised likelihood.*, 2011. R package version 2.36-8.
- THERNEAU, T. M. & GRAMBSCH, P. M. *Modeling survival data: extending the Cox model.* Statistics for biology and health. Springer, New York, 2000.
- TURNBULL, B. The empirical distribution function with arbitrarily grouped, censored and truncated data. *Journal of the Royal Statistical Society B* 38 (1976), 290–295.
- VENABLES, W. N. & RIPLEY, B. D. *Modern Applied Statistics with S.* Springer New York, 2 2010.
- WANG, M., BROOKMEYER, R. & JEWELL, N. Statistical models for prevalent cohort data. *Biometrics* 49, 1 (Mar 1993), 1–11.
- WASSERMAN, L. *All of Nonparametric Statistics.* Springer, 2006.
- WEI, L., LIN, D. & WEISSFELD, L. Regression analysis of multivariate incomplete failure time data by modeling marginal distributions. *Journal of the American Statistical Association.* 84, 408 (1989), 1065–1073.
- WOOD, S. *Generalized Additive Models: An Introduction with R (Chapman & Hall/CRC Texts in Statistical Science)*, 1 ed. Chapman and Hall/CRC, 2 2006.

Descrição dos dados

Este apêndice contém a descrição dos dados utilizados nos exemplos e exercícios deste livro. Os dados aqui utilizados foram gentilmente cedidos por diversas instituições de pesquisa do país, para fins estritamente didáticos. Para restringir seu uso aos fins propostos e para preservar a privacidade dos pacientes, em cada banco de dados as variáveis identificadoras reais foram retiradas, as datas foram alteradas pela adição de ruído e algumas covariáveis tiveram seus valores trocados. Devido a essas alterações, os resultados da análise desses dados não devem ser considerados para inferências sobre a realidade dos fenômenos observados. Para fins didáticos, contudo, esses dados são valiosos na medida em que preservam as complexidades esperadas em um estudo de sobrevivência em epidemiologia.

Os dados e as soluções para os exercícios estão disponíveis em <http://sobrevida.fiocruz.br>.

Aids, adesão à Haart – suavização (Ipec/Fiocruz)

Um estudo sobre o efeito da adesão ao tratamento antirretroviral na falha terapêutica (viroológica, imunológica, clínica ou óbito) foi realizado com pacientes assistidos no Ipec/Fiocruz (Campos, 2009). As variáveis registradas para cada paciente estão listadas na tabela a seguir. A variável de interesse foi obtida a partir do Sistema de Controle Logístico de Medicamentos (SICLOM), desenvolvido para a dispensa de medicamentos antirretrovirais, e calculada como a razão entre o total de dias com atraso no contato com a farmácia para obter

a medicação e os dias de acompanhamento entre a entrada no estudo e a falha terapêutica.

Esses dados estão disponíveis no arquivo `adesao.dat`, que está organizado para análise de sobrevivência com uma linha para cada falha de cada paciente, mas sem covariáveis tempo-dependentes. Um trecho do banco está ilustrado a seguir.

Variáveis do banco de dados `adesao.dat`

Variável	Descrição
id	identificação do paciente
ini	data do início do acompanhamento da dispensação de medicamentos antirretrovirais (em dias)
fim	data da falha terapêutica ou fim do estudo
tempo	<i>ini</i> - <i>fim</i> (em dias)
status	0 = censura, 1 = falha terapêutica
linha	falha terapêutica ordenada, de 1 a 3
propatraso	proporção de dias sem medicamento/total de dias de acompanhamento para cada período entre falhas ou censura
comprimidia	número médio de comprimidos/dia previstos

```
> adesao <- read.table("adesao.dat",header=T)
> head(adesao)
```

	id	ini	fim	tempo	status	linha	propatraso	comprimidia
1	1	66	656	590	1	1	0.18644068	5
2	1	758	1073	315	0	2	0.23809524	5
3	2	64	961	897	0	1	0.33110368	3
4	3	94	192	98	1	1	0.69387755	3
5	3	472	821	349	1	2	0.08309456	3
6	3	913	1055	142	0	3	0.15492958	3

Aids – clássico (Ipec/Fiocruz)

Este livro trabalha com dados provenientes de coortes hospitalares de pacientes portadores de HIV. A primeira coorte é constituída dos pacientes portadores de HIV atendidos entre 1986 e 2000 no Instituto de Pesquisa Clínica Evandro Chagas (Ipec/Fiocruz). Dessa coorte, obteve-se uma amostra de 193 indivíduos que foram diagnosticados como portadores de Aids (critério CDC 1993) durante o período de acompanhamento.

As variáveis registradas para cada paciente estão listadas na tabela a seguir. Elas foram obtidas a partir dos prontuários clínicos, como descrito em Campos (2005). Nesse artigo também se encontra uma análise exploratória completa desses dados, assim como a análise de sobrevivência em Aids, utilizando modelos não paramétricos e modelos de Cox clássicos.

Esses dados estão disponíveis no arquivo *ipec.csv*, que está organizado para análise de sobrevivência usando os métodos não estendidos, isto é, com uma linha para cada paciente e sem covariáveis tempo-dependentes. Um trecho do banco é mostrado a seguir.

```
> ipec <- read.table("ipec.csv",header=T,sep=";")
> ipec[1:5,]
```

	id	ini	fim	tempo	status	sexo	escola	idade	risco
1	1	1243	2095	852	1	M	3	34	0
2	2	2800	2923	123	1	M	2	38	6
3	3	1250	2395	1145	1	M	NA	32	0
4	4	1915	4670	2755	0	M	NA	43	6
5	5	2653	4770	2117	0	M	NA	40	0

	acompan	obito	anotrat	tratam	doenca	propcp
1	1	S	1991	1	4	3
2	1	S	9	0	7	4
3	1	S	1992	1	3	4
4	0	N	1992	1	10	4
5	1	N	1992	1	5	4

Variáveis do banco de dados *ipec.csv*

Variável	Descrição
id	identificação do paciente
ini	data do diagnóstico da Aids (em dias)
fim	data do óbito (ou perda do paciente)
tempo	dias de sobrevivência do diagnóstico até o óbito
status	0 = censura, 1 = óbito
sexo	<i>F</i> = feminino, <i>M</i> = masculino
escola	0 = sem escolaridade, 1 = ensino fundamental, 2 = ensino médio, 3 = ensino superior
idade	idade na data do diagnóstico de Aids (20 a 68 anos)
risco	0 = homossexual masculino, 1 = usuário de drogas injetáveis, 2 = transfusão, 3 = contato sexual com HIV+, 5 = hetero c/múltiplos parceiros, 6 = dois fatores de risco
acompan	acompanhamento: 0 = ambulatorial/hospital-dia, 1 = internação posterior, 2 = internação imediata
obito	<i>S</i> = óbito, <i>N</i> = não óbito, <i>I</i> = ignorado
anotrat	ano do início do tratamento (1990 a 2000), 9 = sem tratamento
tratam	terapia antirretroviral: 0 = nenhum, 1 = mono, 2 = combinada, 3 = potente
doenca	de apresentação: 1 = pcp, 2 = pcp pulmonar, 3 = pcp disseminada, 4 = toxoplasmose, 5 = sarcoma, 7 = outra doença, 8 = candidíase, 9 = duas doenças, 10 = herpes, 99 = definido por cd4
propcp	profilaxia para pneumocistis: 0 = sem profilaxia, 2 = primária, 3 = secundária, 4 = ambas

Aids, doenças oportunistas – eventos múltiplos (Unirio)

Os dados utilizados para o tempo até a ocorrência de doenças oportunistas provêm de uma coorte de pacientes HIV positivos atendidos no Hospital Universitário Gaffrée e Guinle (Unirio). As variáveis foram obtidas a partir dos prontuários clínicos, como descrito em Signorini (2004).

Registrou-se, para cada paciente com Aids, o tempo até a ocorrência de cada doença ou sintomatologia caracteristicamente relacionada à imunodepressão: candidíase, tuberculose, alguns sinais hematológicos, herpes zoster, pneumonia por *Pneumocistis*. As variáveis do banco de dados estão descritas na tabela a seguir

Os dados estão armazenados no arquivo *oportunista.csv*. Cada linha do arquivo indica o tempo do diagnóstico de Aids até a ocorrência de uma doença oportunista. Esses dados são utilizados no Capítulo 10.

```
> op <- read.csv("oportunista.csv")
> op[1:7,]
```

	reg	sex	esc	idade	udi	sexual	ini	oport	fim	status	tempo
1	1	F	1	45	0	0	3127	Candida	3141	1	14
2	2	M	2	38	1	0	2884	Herpes	3133	1	249
3	2	M	2	38	1	0	2884	Pneumo	3133	1	249
4	2	M	2	38	1	0	2884	Candida	3343	1	459
5	3	F	4	34	1	0	3330	Hemato	3332	1	2
6	4	M	3	43	0	0	3780	Hemato	3964	1	184
7	5	F	3	32	0	1	2923	Candida	3588	1	665

Variáveis do banco de dados *oportunista.csv*

Variável	Descrição
reg	identificador do paciente
sex	sexo: <i>F</i> = feminino, <i>M</i> = masculino
esc	0 = sem escolaridade, 1 = até quatro anos de estudo, 2 = ensino fundamental, 3 = ensino médio, 4 = ensino superior
idade	idade em anos na entrada do estudo
udi	uso de drogas injetáveis: 0 = não, 1 = sim
sexual	comportamento sexual: 0 = não, 1 = sim
ini	data da entrada no estudo (diagnóstico de Aids)
oport	doença oportunista: <i>Candida</i> = candidíase, <i>Tuberc</i> = tuberculose, <i>Hemato</i> = algumas alterações hematológicas, <i>Herpes</i> = herpes zoster, <i>Pneumo</i> = pneumonia por <i>Pneumocistis</i>
fim	data do diagnóstico do evento relacionado à imunodepressão
status	0 = censura, 1 = ocorrência do evento
tempo	<i>fim</i> - <i>ini</i>

Aids – eventos competitivos (UFRJ)

O banco de dados para análise de eventos competitivos em Aids contém variáveis referentes a uma coorte de pacientes infectados pelo HIV, com 1.450 registros, acompanhados no Hospital Universitário Clementino Fraga Filho (UFRJ). Os óbitos ocorridos foram classificados, segundo um algoritmo especialmente desenvolvido para este fim, em relacionados ou não à Aids. As variáveis disponíveis estão listadas na tabela a seguir.

Variáveis do banco de dados *competeaids.dat*

Variável	Descrição
id	identificador do paciente
ini	início do acompanhamento em dias desde 01/01/1997
fim	fim do acompanhamento em dias desde 01/01/1997
statusc	0 = censura, 1 = óbito não relacionado à Aids, 2 = óbito relacionado à Aids
sexo	<i>Male</i> = masculino, <i>Female</i> = feminino
idade	idade no início do acompanhamento
cd4cat	cd4 no início do acompanhamento, categorizado em <200, [200,350), [350,500), >=500

Esses dados, utilizados nos exercícios do Capítulo 11, de eventos competitivos, estão no arquivo *competeaids.dat*.

```
> compaids <- read.table("competeaids.dat",header=T)
> head(compaids)
```

```
      id ini  fim statusc  sexo idade  cd4cat
1  690   5 3652        0 Female   37 [200-350)
2  625   5 3652        0  Male    32 [350-500)
3 1305   6 2248        0  Male    28 [200-350)
4  420   7 3652        0  Male    25 [350-500)
5  959   9 3652        0 Female    39    <200
```

Aids, terapia – mudança no tempo (Unirio)

Esses dados provêm dos pacientes com Aids atendidos no Hospital Universitário Gaffrée Guinle (Unirio). Para estudar o efeito da terapia antirretroviral de alta potência (Haart) no tempo de sobrevivência desde o diagnóstico de Aids até o óbito, o banco de dados foi organizado no formato covariável tempo-dependente. Para cada mudança

de tratamento (**haart**=S ou N), nova linha foi criada, mantendo-se as demais variáveis constantes. A tabela a seguir contém a descrição das covariáveis.

Variáveis do banco de dados *gafcorr.dat*

Variável	Descrição
reg	identificador do paciente
haart	tratamento Haart: <i>N</i> = não e <i>S</i> = sim
ini	data da entrada no estudo ou do início da mudança da covariável haart
fim	data de mudança da covariável ou fim do estudo
sexo	<i>F</i> = feminino, <i>M</i> = masculino
escol	escolaridade: <i>Prim</i> = até a quarta série, <i>Gin</i> = ensino básico completo, <i>Sec</i> = ensino médio e <i>Univ</i> = universidade
status	0 = censura, 1 = óbito
idade	idade na data do óbito

```
> muda <- read.table("gafcorr.dat", header=T)
> muda[1:10,]
```

	reg	haart	ini	fim	sexo	escol	status	idade
1	1	S	1752	3297	M	Prim	0	27
2	2	S	1982	3297	F	Gin	0	45
3	3	S	2809	3297	F	Prim	0	41
4	4	N	942	1448	M	Gin	0	38
5	4	S	1448	1939	M	Gin	0	38
6	4	N	1939	1959	M	Gin	0	38
7	4	S	1959	3297	M	Gin	0	38
8	5	N	1031	3297	M	Prim	1	32
9	6	N	1337	1725	F	Univ	0	34
10	6	S	1725	3297	F	Univ	0	34

Aleitamento – exemplo fictício

Os bancos `leite.txt` e `leite2.txt` foram criados para facilitar a compreensão do Capítulo 4. O primeiro contém 15 crianças, onde o tempo de duração do aleitamento foi registrado para todas. O outro tem 60 crianças de quatro comunidades, também com tempo de observação sem censura.

```
> leite <- read.table("leite.txt", header=T)
> leite[1:3,]
```

crianca	tempo	status
1	6	1
2	12	1
3	10	1

Diálise – clássico e fragilidade (SUS)

Esses dados provêm de uma coorte de 6.805 pacientes que foram submetidos a hemodiálise em 67 unidades de atendimento no Rio de Janeiro, no período de janeiro de 1998 a outubro de 2001. Os dados foram originados pelo sistema Apac (Autorização de Procedimentos de Alta Complexidade – DATASUS). Uma discussão detalhada do tema e da modelagem pode ser encontrada em Carvalho *et al.* (2003). A tabela a seguir contém a descrição das variáveis.

Estes dados estão disponíveis no arquivo `dialise.csv`, que está organizado para análise de sobrevivência usando os métodos não estendidos, isto é, com uma linha para cada paciente e sem covariáveis tempo-dependentes. Um trecho do banco é mostrado a seguir.

```
> dialise <- read.table("dialise.csv",header=T,sep=",")
> dialise[1:5,]
```

	unidade	idade	inicio	fim	status	tempo	grande	causa
1	120	59	35	36	0	1	1	hip
2	120	49	38	41	0	3	1	hip
3	120	49	22	40	0	18	1	out

4	120	52	21	23	0	2	1	hip
5	120	89	41	42	1	1	1	hip
	cdiab	crim	congenita					
1	0	0	0					
2	0	0	0					
3	0	0	0					
4	0	0	0					
5	0	0	0					

Variáveis dos bancos de dados *dialise.csv* e *dialmenor.dat*

Variável	Descrição
unidade	número do centro de diálise
idade	idade ao iniciar a diálise (0 a 97 anos)
inicio	data do início da primeira diálise
fim	data da interrupção do acompanhamento
status	0 = censura, 1 = óbito
tempo	tempo de sobrevivência (meses) (<i>fim</i> - <i>inicio</i>)
sexo	0 = feminino, 1 = masculino
causa	<i>hip</i> = hipertensão, <i>dia</i> = diabetes, <i>ren</i> = renal, <i>con</i> = congênita, <i>out</i> = outras
grande	número de salas de diálise na unidade de tratamento: 0 = uma ou duas salas e 1 = três salas ou mais
cdiab	1 = diabetes como causa da insuficiência renal e 0 = não
crim	1 = causas renais e 0 = não
congenita	1 = causas congênitas e 0 = não

Esse mesmo banco de dados foi reduzido para exemplificar os modelos de fragilidade (Capítulo 12), que estão no arquivo *dialmenor.dat*.

```
> dial <- read.table("dialmenor.dat",header=T)
> dial[1:6,]
```

unidade	idade	sexo	inicio	fim	status	tempo	grande	causa
128	52	1	26	45	0	19	1	out
128	76	0	32	33	0	1	1	out
128	61	1	22	24	0	2	1	out
128	35	0	7	13	0	6	1	out
128	42	0	2	13	0	11	1	out
128	44	1	6	30	0	24	1	hip

Diálise – eventos competitivos (SUS)

Os dados de diálise da coorte descrita na seção anterior foram também organizados para avaliar fatores de risco para três eventos distintos para os quais pacientes em diálise estão em risco: transplante, óbito por causa renal e óbito por outra causa. As variáveis incluídas no banco estão listadas na tabela a seguir.

Variáveis do banco de dados *dialcompete.dat*

Variável	Descrição
id	identificador do paciente
idade	idade ao iniciar a diálise
doenca	doença de base: <i>hiper</i> = hipertensão, <i>diab</i> = diabetes, <i>rim</i> = renal, <i>cong</i> = congênita, <i>outr</i> = outras
motivo	evento competitivo ocorrido: <i>obrenal</i> = óbito por causa renal, <i>oboutra</i> = óbito por outra causa, <i>transpl</i> = transplante, <i>censura</i>
tempo	tempo até a ocorrência de um dos possíveis eventos ou censura
status	0 = censura, 1 = um dos eventos competitivos

Os dados estão no arquivo *dialcompete.dat*. Esses dados são utilizados no Capítulo 11, de eventos competitivos.

```
> compete <- read.table("dialcompete.dat",header=T)
> compete[1:6,]
```

	id	idade	doenca	motivo	tempo	status
1	1	50	outr	obrenal	27	1
2	2	51	hiper	censura	28	0
3	3	30	diab	transpl	18	1
4	4	33	diab	oboutra	14	1
5	5	35	diab	obrenal	1	1
6	6	34	hiper	censura	43	0

Diarreia – eventos múltiplos (UFBA)

Os dados disponíveis para estudar o efeito da suplementação de vitamina A na diarreia no nordeste do Brasil em uma coorte de crianças de 6 a 48 meses são referentes ao ensaio comunitário randomizado placebo-controlado, realizado entre dezembro/1990 e dezembro/1991, conduzido por Barreto *et al* (1994), e cedido pelo Instituto de Saúde Coletiva da Universidade Federal da Bahia.

O banco de dados do exemplo do livro consiste em 860 crianças (426 no grupo placebo e 434 no grupo vitamina), gerando um total de 5.592 registros e 11 variáveis. Esse banco de dados é caracterizado pela presença de múltiplos eventos (cada criança pode ter um ou mais episódios de diarreia ao longo de sua permanência no estudo). Os dados estão no arquivo *multdiarreia.txt*, que está organizado para análise de sobrevivência para eventos múltiplos recorrentes. No arquivo, cada linha representa um tempo entre episódios de diarreia. No trecho do banco listado a seguir são mostradas todas as linhas que se referem a episódios sofridos pela criança 1. As covariáveis constantes (*grupo*, *sexo* e *idade*) têm seus valores repetidos em todas as linhas referentes a essa criança. As covariáveis que mudam de episódio para episódio são *diasant*, *mediadej* e *enum*.

```
> diarreia <- read.table("multdiarreia.txt",header=T)
> diarreia[1:12,]
```

	numcri	grupo	sexo	idade	ini	fim	diasant	mediadej	enum	status	tempo
1	1	vit	fem	32	1	24	0	0	1	1	23
2	1	vit	fem	32	26	29	1	5	2	1	3
3	1	vit	fem	32	34	50	4	2	3	1	16
4	1	vit	fem	32	52	56	1	4	4	1	4
5	1	vit	fem	32	58	63	1	4	5	1	5
6	1	vit	fem	32	65	73	1	4	6	1	8
7	1	vit	fem	32	75	109	1	3	7	1	34
8	1	vit	fem	32	111	188	1	4	8	1	77
9	1	vit	fem	32	190	232	1	4	9	1	42
10	1	vit	fem	32	235	245	2	4	10	1	10
11	1	vit	fem	32	247	307	1	4	11	1	60
12	1	vit	fem	32	309	379	1	5	12	0	70

Uma discussão detalhada destes dados pode ser encontrada em Andreozzi (2002). As variáveis registradas neste estudo estão listadas na tabela a seguir.

Variáveis do banco de dados *multdiarreia.txt*

Variável	Descrição
numcri	identificador da criança
grupo	<i>vit</i> = receberam vitamina A, <i>pla</i> = placebo
sexo	<i>fem</i> = feminino, <i>masc</i> = masculino
idade	idade em meses no início do estudo
ini	data no início do período sem diarreia
fim	data no fim do período sem diarreia
diasant	duração em dias do episódio de diarreia anterior
mediadej	média de dejeções líquidas ou semilíquidas do episódio de diarreia anterior
enum	numeração das observações para cada criança
status	0 = censura, 1 = evento (diarreia)
tempo	dias sem diarreia (<i>fim-ini</i>)

Infarto – suavização e fragilidade (SUS)

Um estudo sobre infarto busca avaliar o efeito de variáveis relacionadas ao paciente (sexo, idade) e de variáveis relacionadas ao hospital (natureza jurídica, número de internações, número de leitos de UTI) sobre a sobrevivência de pacientes assistidos no SUS no município do Rio de Janeiro. Para isso, um banco de dados foi criado, com informações dos hospitais, originalmente analisado por Melo (2004). A tabela a seguir contém a descrição dos dados.

Variáveis do banco de dados *infarto.dat*

Variável	Descrição
hospital	identificador do hospital
id	identificador do paciente
ini	momento do infarto
fim	momento do óbito ou da censura
status	0 = censura, 1 = óbito
sexo	<i>F</i> = feminino, <i>M</i> = masculino
idade	idade na data do infarto
volume	número de internações: <i>vp</i> = menor que 25, <i>vg</i> = maior ou igual a 25
luti	número de leitos de UTI: <i>n</i> = nenhum, <i>1a24</i> , <i>25+</i>
natureza	natureza jurídica do hospital: <i>PM</i> = público municipal, <i>C</i> = contratado, <i>PE</i> = público estadual, <i>PFU</i> = público federal e universitário

```
> infarto <- read.table("infarto.dat",header=T)
> head(infarto)

  hospital   id ini fim status sexo idade natureza volume luti
1         a 664 178 238      0    M   54      PFU      vg  25+
```

2	a	2389	180	188	1	F	94	PFU	vg	25+
3	a	2527	192	252	0	M	75	PFU	vg	25+
4	a	2666	131	191	0	F	46	PFU	vg	25+
5	a	3257	206	266	0	M	49	PFU	vg	25+
6	a	2661	214	274	0	F	81	PFU	vg	25+

Reinternação – eventos múltiplos (Hosp. Betim)

Os dados provêm do Sistema de Informações Hospitalares (SIH-SUS) de todas as internações no Hospital Regional de Betim, município da Região Metropolitana de Belo Horizonte (Minas Gerais), de julho de 1996 a junho de 2000. Esse hospital tem 270 leitos, oferecendo as especialidades básicas em clínica médica, cirurgia, pediatria e obstetrícia. Esse banco foi construído e analisado inicialmente por Castro (2004), e sua análise está publicada em Castro *et al* (2005). O objetivo do estudo foi avaliar os fatores relacionados às reinternações. A forma de criação dos grupos da CID aplicados nesse trabalho está descrita em Castro & Carvalho (2005). Estão disponíveis aqui 21.415 registros de internações entre 17.096 indivíduos, variando entre uma e 18 internações por pessoa.

Esses dados estão no arquivo `reint.csv` e descritos na tabela a seguir. A sequência de internações de cada paciente é registrada na variável `enum`.

```
> reint <- read.csv("reint.csv")
> reint[1:7,]
```

	id	sexo	diasperm	idade	numint	capcid	obitpos
1	1	1	26	52	4	CAPVIIIC	0
2	1	1	7	52	4	CAPVIIIC	0
3	1	1	5	52	4	CAPVIIIC	0
4	1	1	51	52	4	CAPVIIIC	0
5	2	3	1	29	3	CAPVIIB	0
6	2	3	1	29	3	CAPXI	0
7	2	3	1	29	3	CAPVIIB	0
	ini	fim	ini0	fim0	enum	status	tempo
1	0	21	0	21	1	1	21

2	28	69	28	69	2	1	41
3	74	100	74	100	3	1	26
4	151	1403	151	1403	4	0	1252
5	0	128	0	128	1	1	128
6	129	326	129	326	2	1	197
7	327	1428	327	1428	3	0	1101

Variáveis do banco de dados *reint.csv*

Variável	Descrição
id	identificador do paciente
sexo	1 = masculino , 3 = feminino
diaperm	dias de permanência na internação imediatamente anterior (indicador de gravidade)
idade	idade na primeira internação em anos
numint	número total de internações de cada paciente
capcid	enfermidade, classificada por grupos da CID 9 e CID 10
obitpos	óbito ocorrido na internação que encerra o período (<i>proxis</i> de gravidade)
ini	início do período não internado (data da alta)
fim	fim do período não hospitalar (data da reinternação)
ini0	data inicial do acompanhamento do paciente
fim0	data final do acompanhamento do paciente
enum	contador de internações
status	0 = censura, 1 = ocorrência de internação
tempo	tempo até reinternar (<i>fim - ini</i>)

Transplante de medula óssea – clássico e mudança no tempo (Inca)

Estes dados provêm de uma coorte de 96 pacientes submetidos a transplante de medula óssea para tratamento de leucemia mieloide crônica, no período de junho de 1986 a junho de 1998, no Centro de Transplante de Medula Óssea do Instituto Nacional do Câncer (Cemo – Inca). O acompanhamento dessa coorte possibilitou o estudo do efeito de fatores prognósticos para a ocorrência de doença do enxerto contra hospedeiro aguda e crônica, da sobrevivência livre de doença e da sobrevivência global. As covariáveis registradas para cada paciente estão descritas na tabela a seguir. Para mais detalhes acerca dessa coorte e do ajuste de modelo de sobrevivência de Cox clássico e Cox estendido, consulte Byington (1999).

Estes dados estão organizados em dois arquivos. O arquivo *tmoclas.dat* tem o formato clássico, com uma linha para cada paciente.

```
> tmo <- read.table("tmoclas.dat",header=T,sep=",")
> head(tmo)
```

	id	sexo	idade	status	os	plaq	tempplaq
1	1	2	31	0	1000	1	9
2	2	2	38	1	39	0	39
3	3	1	23	1	434	1	27
4	4	2	5	1	69	0	69
5	5	2	15	1	672	1	83
6	6	1	23	1	98	0	0

	deag	tempdeag	decr	tempdecr	fase
1	0	3527	0	3527	1
2	1	28	0	39	1
3	1	36	1	268	1
4	1	24	0	69	1
5	1	22	1	446	1
6	1	22	0	98	1

Variáveis dos bancos de dados *tmoclas.csv* e *tmopc.csv*

Variável	Descrição
id	identificador do paciente
sexo	1 = masculino, 2 = feminino
idade	idade na data do transplante (5 a 53 anos)
status	0 = censura, 1 = óbito
os	data do óbito ou censura
plaq	recuperação de plaquetas: 0 = não, 1 = sim
tempplaq	dias até a recuperação de plaquetas
deag	doença enxerto aguda: 0 = não, 1 = sim
tempdeag	dias até a ocorrência da doença enxerto aguda
decr	doença enxerto crônica: 0 = não, 1 = sim
tempdecr	tempo até a ocorrência da doença enxerto crônica
fase	fase da doença na data do transplante: 1 = crônica, 2 = aguda, 3 = crise blástica
recplaq	0 = plaquetas não recuperadas, 1 = recuperadas
fasegr	fase da doença na data do transplante agrupada: <i>CP1</i> = 1ª crônica e <i>Other</i> = outras
inicio	data do transplante ou da mudança de covariável
fim	data de mudança de covariável ou do fim do estudo

O arquivo *tmopc.csv* está preparado para uma análise de sobrevivência com covariáveis tempo-dependentes em que a variável que muda no tempo é a recuperação das plaquetas (*recplaq*), doença do enxerto crônica (*decr*) e aguda (*deag*).

```
> tmopc <- read.table("tmopc.csv",header=T,sep=";")
> head(tmopc,10)
```

	id	sexo	idade	status	inicio	fim	deag	decr	recplaq	fasegr
1	1	2	31	0	0	9	0	0	0	CP1
2	1	2	31	0	9	1000	0	0	1	CP1
3	2	2	38	0	0	28	0	0	0	CP1
4	2	2	38	1	28	39	1	0	0	CP1
5	3	1	23	0	0	27	0	0	0	CP1
6	3	1	23	0	27	36	0	0	1	CP1
7	3	1	23	0	36	268	1	0	1	CP1
8	3	1	23	1	268	434	1	1	1	CP1
9	4	2	5	0	0	24	0	0	0	CP1
10	4	2	5	1	24	69	1	0	0	CP1

UTI – suavização (Inca)

Esses dados são provenientes de uma coorte com 862 pacientes com câncer internados na UTI do Inca, cujo objetivo foi avaliar fatores associados à sobrevivência. Entre as muitas variáveis coletadas, são apresentadas na tabela a seguir as incluídas nos exemplos.

Variáveis do banco de dados *ctinca.dat*

Variável	Descrição
id	identificação do paciente
tempo	a partir do primeiro caso acompanhado em dias
status	óbito = 1, censura = 0
sexo	<i>Male</i> = masculino, <i>Fem</i> = feminino
idade	em anos completos
gptumor	tipo de tumor: <i>Loco</i> = sólido localizado; <i>Mtx</i> = metastático; <i>Hemato</i> = hematológico
desnut	<i>y</i> = perda de peso recente acima de > 10% ou IMC < 18; <i>n</i> = não
comorbi	<i>y</i> = comorbidades severas presentes; <i>n</i> = ausente
leucopenia	<i>y</i> = leucopenia presente; <i>n</i> = ausente

Os dados estão disponíveis no arquivo *ctinca.dat*.

```
> cti <- read.table("ctinca.dat",header=T)
> head(cti)
```

	id	tempo	status	sexo	idade	gptumor	desnut	comorbi	leucopenia
1	862	162	1	Fem	69	Loco	n	n	n
2	861	10	1	Male	67	Mtx	n	n	n
3	860	2	1	Male	69	Hemato	n	n	y
4	859	182	0	Male	35	Loco	n	n	n
5	858	182	0	Male	63	Loco	n	y	n
6	857	12	1	Male	63	Hemato	n	n	n

Índices

Figuras

1.1	Interação entre idade, coorte e período em estudo de diarreias infantis	35
1.2	Diagrama de Lexis: idade, tempo, coorte	36
2.1	Tempo de sobrevivência de 10 pacientes em diálise (Tabela 2.1)	49
2.2	Trajetórias individuais dos 10 pacientes em diálise (Tabela 2.2)	52
2.3	Representação gráfica de censura à direita, à esquerda e intervalar	54
2.4	Representação gráfica do truncamento à esquerda . . .	56
2.5	Representação gráfica do truncamento à direita	57
2.6	Representação gráfica dos tempos de observação ou trajetórias de pacientes em uma coorte aberta	58
2.7	Representação gráfica, na forma de processo de contagem, das trajetórias individuais de dois pacientes apresentados na Tabela 2.3	62
2.8	Trajetória de dois pacientes censurados	64
2.9	Trajetória dos pacientes 5 e 8 que entraram na coorte ao longo do estudo	65

3.1	Curva teórica da função de sobrevivência indicando o tempo mediano (35 unidades de tempo)	82
3.2	(A) Função de sobrevivência indicando o tempo de sobrevivência mediano e (B) Função de risco acumulado, estimadas para os dados de Aids (Tabela 3.1) . .	84
3.3	Função de risco com diversos formatos	89
4.1	Função de sobrevivência dos pacientes com Aids (Tabela 4.1) estimada utilizando o estimador produto Kaplan-Meier	105
4.2	Estimativa Kaplan-Meier da função de risco acumulado dos pacientes com Aids (Tabela 4.1)	108
4.3	Curva de sobrevivência por sexo estimada pelo Kaplan-Meier dos pacientes com Aids (Tabela 4.1) com intervalo de confiança de 95%	112
4.4	Tempo de sobrevivência mediano e intervalo de confiança de 95% dos pacientes com Aids (Tabela 4.1) . .	116
4.5	Curvas de sobrevivência e risco acumulados para a coorte completa de Aids (<i>ipecc.csv</i>)	117
4.6	Curvas de sobrevivência por sexo (Kaplan-Meier) para a coorte completa de Aids (<i>ipecc.csv</i>)	118
4.7	Curvas de sobrevivência por sexo e respectivos intervalos de confiança de 95% para a coorte completa de Aids (<i>ipecc.csv</i>)	120
5.1	Distribuição do tempo de sobrevivência de pacientes da coorte de Aids do Ipec (banco de dados <i>ipecc.csv</i>)	135
5.2	Função de sobrevivência, de risco e de risco acumulado para a distribuição exponencial	138
5.3	Função de sobrevivência, de risco e de risco acumulado da distribuição Weibull	142
5.4	Função de sobrevivência, função de risco e de risco acumulado da distribuição lognormal	144

5.5	Curva de sobrevivência da coorte de Aids do Ipec segundo o modelo paramétrico exponencial	145
5.6	Estimativas paramétrica e não paramétrica da curva de sobrevivência da coorte de Aids do Ipec	148
5.7	Curva de sobrevivência ajustada de dois indivíduos em diálise com 30 e 70 anos, de acordo com o modelo de regressão exponencial	151
5.8	Logaritmo do risco acumulado contra logaritmo do tempo para os pacientes com e sem diabetes (dados da diálise)	165
5.9	Comparação das curvas de sobrevivência do Kaplan-Meier e dos modelos paramétricos	166
5.10	Resíduos de perturbação da verossimilhança do modelo Weibull para a coorte de Aids do Ipec	168
6.1	Análise exploratória da sobrevivência pós-transplante de medula óssea	190
6.2	Gráfico de sobrevivência estratificado por índice de prognóstico para os quatro modelos da Tabela 6.1 . . .	205
7.1	Resíduos de Schoenfeld para o modelo $m4$	221
7.2	Resíduos de Schoenfeld para os modelos com o tempo particionado	226
7.3	Resíduos do modelo nulo contra covariável para investigação da forma funcional	229
7.4	Resíduos martingale e <i>deviance</i> identificando indivíduos mal ajustados pelo modelo $m4$	232
7.5	Idade contra resíduos martingale do modelo nulo . . .	234
7.6	Resíduos score para o modelo $m4$	236
8.1	Representação gráfica dos dados de transplante de medula óssea para os cinco primeiros pacientes	247
8.2	Resíduos de Schoenfeld para o modelo <code>tmo.cox</code>	253

8.3	Gráfico dos resíduos de Schoenfeld para as covariáveis <i>haart</i> , <i>idade</i> e <i>sexo</i> do modelo <i>muda.cox</i>	255
8.4	Gráfico dos resíduos de Schoenfeld para a covariável escolaridade (<i>escol</i>) do modelo <i>muda.cox</i>	256
8.5	Gráfico dos resíduos de martingale para o modelo <i>tmo.cox</i> e modelo nulo	258
8.6	Resíduos escore para o modelo <i>tmo.cox</i>	261
8.7	Dados prevalentes	263
9.1	Suavização <i>lowess</i> com diferentes larguras de banda	278
9.2	Polinômios segmentados de grau 3 (<i>spline</i> cúbico) ajustado com dois nós	279
9.3	Curvas ajustadas por <i>spline</i> com diferentes graus de suavização (valores de θ)	282
9.4	Resíduos martingale do modelo nulo contra a variável idade	285
9.5	Resíduos martingale do modelo nulo contra a covariável proporção de dias em atraso para obter o medicamento	289
9.6	Efeito da proporção de dias em atraso sobre falha terapêutica estimado no modelo <i>adesao.sp1</i>	291
10.1	Representação gráfica de modelos de sobrevivência por meio de modelos multiestados	304
10.2	Tempo até a ocorrência de algumas doenças oportunistas em quatro pacientes portadores do vírus HIV	306
10.3	Curva de sobrevivência estimadas pelo Kaplan-Meier segundo doenças oportunistas	310
10.4	Risco basal acumulado do modelo de eventos paralelos com estratificação	312
10.5	Tempos observados entre episódios recorrentes de diarreia	313

10.6	Risco basal acumulado para ocorrência de novo episódio de diarreia	319
11.1	Representação gráfica em multiestados para eventos competitivos	331
11.2	Exemplo de eventos competitivos para os dados da Tabela 11.1	334
11.3	Função de incidência acumulada para pacientes em hemodiálise segundo os três desfechos estudados	346
11.4	Função de incidência acumulada para pacientes em hemodiálise para os três desfechos segundo a presença de diabetes registrada como causa da insuficiência renal	347
11.5	Resíduos de Schoenfeld para modelo de risco específico e para subdistribuições da função de risco	355
11.6	Exemplo de cadeia causal para a TMO com diversos estados	357
12.1	Distribuição gama (à esquerda) e lognormal (à direita) com valor esperado 1 e diferentes variâncias ξ	369
12.2	Distribuição das fragilidades estimadas segundo diferentes modelos para os dados de diálise	383
12.3	Estimativa pontual da fragilidade e seu intervalo de confiança de 95% para cada centro de diálise utilizando diferentes modelos	384
12.4	Distribuição das fragilidades gama estimadas dos dados de diarreia infantil	387
12.5	Fragilidades segundo grupo de tratamento	388

Tabelas

1.1	Caracterização de modelos por meio de dicotomias . . .	29
2.1	Tempo de sobrevivência (em meses) de 10 pacientes em diálise	48
2.2	Tempo de observação (em meses) de 10 pacientes em diálise e a ocorrência de censura à direita	52
2.3	Tempo de observação de pacientes participantes da coorte aberta	59
3.1	Tempos de sobrevivência de 32 pacientes com Aids que morreram antes do fim do estudo	79
3.2	Função de densidade do tempo até o óbito após o diagnóstico de Aids dos primeiros pacientes da Tabela 3.1	80
3.3	Cálculo da função de sobrevivência dos 32 pacientes da coorte de Aids (Tabela 3.1)	83
3.4	Estimativa da função de risco para os dados de Aids (veja também Tabelas 3.2 e 3.3)	86
3.5	Estimativa da função de risco acumulado para os dados de Aids utilizando estimativas calculadas nas Tabelas 3.3 e 3.4	90
3.6	Relação entre as funções básicas de sobrevivência . . .	91
4.1	Tempo de sobrevivência (em dias) de alguns pacientes da coorte de Aids do Ipec	100
4.2	Função de sobrevivência estimada pelo método Kaplan-Meier para os 21 pacientes com Aids (Tabela 4.1) . . .	104
4.3	Função de risco acumulado por Kaplan-Meier e Nelson-Aalen	107
4.4	Estimativa do intervalo de confiança exponencial de Greenwood para $\hat{S}_{km}(t)$	113

4.5	Distribuição observada e esperada de eventos por estrato dos pacientes com tempo de sobrevivência menor ou igual a 10 meses	125
5.1	Informações a serem retiradas da saída do R dos modelos paramétricos	156
5.2	Estimativas do risco relativo dos modelos paramétricos (Weibull) para os dados da diálise	157
6.1	Funções de verossimilhança dos modelos de Cox para o exemplo de transplante de medula óssea	196
7.1	Estimativa da razão de riscos dos modelos com tempo de sobrevivência particionado e seus respectivos teste da correlação linear (resíduo de Schoenfeld)	225
8.1	Razões de risco estimadas pelo modelo de Cox para dados prevalentes utilizando três abordagens	266
9.1	Conjunto de dados para exemplificar funções de suavização	278
10.1	Efeitos de covariáveis sobre o risco de desenvolver algumas doenças oportunistas	309
11.1	Tempos de alta ou óbito para 20 pacientes	333
11.2	Efeito das variáveis idade e diabetes como causa da insuficiência renal para três desfechos possíveis em pacientes hemodialisados	343
11.3	Comparação das estimativas segundo diferentes abordagens de modelos para eventos competitivos	353
12.1	Comparação resultados do modelo de Cox clássico e modelo com fragilidade individual	366

12.2	Comparação dos efeitos fixos dos modelos de fragilidade para diálise	381
12.3	Comparação das medidas de ajuste dos modelos de fragilidade	382

Remissivo

- $F(t)$, 81
- $S(t)$, 81
- $\Lambda(t)$, 88
- $\lambda(t)$, 83
- $f(t)$, 78
- Aids, 77, 102, 305
- algoritmo EM, 370
- banco de dados, 65
- censura, 50
 - direita, 50
 - esquerda, 51
 - informativa, 53
 - intervalar, 51
 - não informativa, 53
- concordância, 201
- covariável mudando no tempo, 242
- Cox, 40, 186
 - deviance, 198
 - estendido, 242
 - estratificado, 192
 - qualidade de ajuste, 198
 - seleção de modelos, 195
- curva ROC, 201
- deviance, 162
- diálise, 47, 133, 339, 373
- diarreias, 386
- distribuição
 - exponencial, 136
 - lognormal, 141
 - valor extremo, 139, 141
 - Weibull, 140, 152
- distribuição acumulada, 81
- efeitos aleatórios, 32, 364
- estimador produto, 101
- eventos competitivos, 329
 - diálise, 339
 - risco específico por causa, 341
 - sobrevivência livre de eventos, 338
 - subdistribuições dos riscos, 344
- eventos múltiplos, 42, 298, 304
 - classificação, 298
 - eventos ordenados independentes, 312, 314
 - modelo AG, 314
 - modelo estruturado, 317
 - modelo PWP, 317
 - ordenados, 299
 - paralelos, 299, 305, 308
- formato gráfico, 219
- fragilidade, 32
- função de densidade, 78
- função de incidência acumulada, 334, 335, 358
- função de sobrevivência, 80
- função desvio, 162
- Greenwood, 110
- hazard, 83, 191

- Kaplan-Meier, 100
 - estratificado, 116
 - tempo mediano, 114
 - variância, 110
- kernel, 277
- leucemia mieloide crônica, 183
- lowess, 230, 276
- modelo multinível, 366
- modelo nulo, 199, 230
- modelo saturado, 163, 198
- não paramétrico
 - intervalo de confiança, 110
- não-paramétrico, 38
- Nelson-Aalen, 109
- paramétrico, 38
 - estratificado, 155
 - exponencial, 136, 150
 - lognormal, 141
 - Weibull, 140, 152
- processo de contagem, 44, 60
- R
 - fragilidade individual, 371
 - gráfico de fragilidade, 385
 - anova, 161
 - chamar biblioteca, 46
 - concordância, 202
 - Cox, 191
 - Cox estendido, 248
 - Cox estratificado, 193
 - distribuição qui-quadrado, 351
 - distribuições paramétricas, 165
 - eliminar linhas duplicadas, 259
 - escala do tempo, 218
 - escrevendo funções, 207
 - eventos múltiplos, 317
 - eventos ordenados, 321
 - fatores, 120
 - fim de linha, 345
 - fragilidade, 370, 373
 - gráfico função de incidência
 - acumulada, 346
 - gráficos, 119
 - gráficos Schoenfeld, 219
 - help, 45
 - identificação de pontos em gráficos, 167
 - janelas, 46
 - Kaplan-Meier, 106, 108
 - legenda em gráfico, 120
 - lendo funções, 206
 - ler arquivo csv, 74
 - log-rank, 127
 - múltiplos gráficos, 219
 - matriz das covariáveis, 191
 - modelo AG, 321
 - modelo nulo, 199
 - modelo PWP, 321
 - modelo saturado, 200
 - modelos competitivos, 348, 350
 - Cox, 352
 - Nelson-Aalen, 109
 - nome de variável, 74
 - Peto, 127
 - reordenar fator, 181
 - resíduo deviance, 233
 - resíduo escore, 235, 260
 - resíduo martingale, 230, 258
 - resíduo Schoenfeld, 217, 251

- retirar linhas com valores NA, 197, 258
- spline, 284
- spline gráfico, 291
- tempo de sobrevivência, 69
- teste da razão de verossimilhanças, 197
- transformar variável categórica em numérica, 345
- vetores lógicos em modelos, 344
- R comando
 - anova, 197, 286
 - biblioteca ipmeta, 371
 - biblioteca phmm, 371
 - cluster, 317
 - collapse, 258, 260
 - colors, 119
 - complete.cases, 197, 258
 - cox.zph, 217, 222, 251
 - coxph, 109, 191, 248
 - crprep, 350
 - dev.off, 219
 - duplicated, 259
 - factor, 189
 - for, 219
 - frailty, 373
 - function, 206, 207
 - head, 76, 409
 - I, 344
 - identify, 167
 - ifelse, 224, 264
 - jpeg, 219
 - legend, 120
 - levels, 120
 - library, 46
 - lowess, 230
 - mstate, 350
 - not, 259
 - par, 119, 219
 - pchisq, 351
 - phmm, 370
 - plot, 108
 - plot.pi, 204
 - ponto e vírgula (;), 345
 - postscript, 219
 - pspline, 284
 - qqline, 233
 - qqnorm, 233
 - Rcmdr, 46
 - read.csv, 74
 - read.table, 67, 74
 - relevel, 181, 340, 374
 - resid, 230, 233, 258, 260
 - RSiteSearch, 45
 - source, 206
 - sparse, 379
 - strata, 193, 317
 - Surv, 69
 - Surv(inicio,fim,...), 248
 - survConcordance, 202
 - survdiff, 127
 - survfit, 106
 - survfit(event=), 348
 - survreg, 153, 160
 - tail, 76
 - termplot, 291
 - razão de chances, 32
 - razão de riscos, 191
 - regressão segmentada, 287
 - resíduo
 - Cox-Snell, 225

- deviance, 230
- escore, 233, 259
- martingale, 225, 254
- Schoenfeld, 215, 251
- risco, 33, 78, 83
- risco acumulado, 88
- riscos proporcionais, 149
- semi-paramétrico, 38
- spline, 217, 229, 279, 284
- tábua de vida, 85
- taxa de incidência, 84
- tempo de vida acelerado, 135
- tempo descontínuo, 265
- tempo mediano, 78, 81, 82, 118
- teste
 - deviance, 162
 - log-rank, 121
 - Mantel-Haenszel, 121
 - modelos aninhados, 195
 - Peto, 123
 - razão de verossimilhanças, 161, 195
 - Wald, 162, 195
- transplante de medula óssea, 183
 - resíduo deviance, 231
 - resíduo martingale, 231
 - resíduo schoenfeld, 220
 - resíduos shoenfeld, 224
- truncamento, 50, 53, 260
 - dados prevalentes, 55
 - direita, 55
 - esquerda, 55
- UTI-Inca, 274, 284
- verossimilhança penalizada, 371
- verossimilhança parcial, 186